

8주차 과제

1. GPT

1. 어떤 문제를 해결하려 했는가? (Abstract)

자연어 이해는 텍스트 분류, 질문 응답, 문장 유사도, 자연어 추론 등 다양한 작업을 포함한다. 그러나 이러한 작업을 학습하기 위해서는 많은 양의 라벨링된 데이터가 필요하며, 실제로는 대부분의 분야에서 충분한 라벨 데이터를 확보하기 어렵다.

반면 인터넷에는 라벨이 없는 텍스트 데이터는 매우 풍부하게 존재한다.

본 논문은 이러한 문제를 해결하기 위해 대규모 비지도 텍스트 데이터로 언어 모델을 pre-training 한 뒤, 특정 작업에 맞게 지도 학습으로 fine-tuning하는 방법을 제안한다.

연구 결과, 제안된 방법은 다양한 자연어 이해 벤치마크에서 기존 모델보다 높은 성능을 보였으며, 12개 평가 과제 중 9개에서 기존 최고 성능을 갱신하였다.

2. 연구 동기와 문제점 (Introduction)

기존의 자연어 처리 모델들은 대부분 지도 학습 기반으로 학습되었다. 이러한 방식은 다음과 같은 한계를 가진다.

a. 많은 양의 라벨 데이터가 필요하다.

하지만 실제 자연어 처리 문제에서는 데이터 라벨링 비용이 매우 높기 때문에 충분한 데이터를 확보하기 어렵다.

b. 기존 연구는 대부분 단어 수준의 표현을 활용하였다. 예를 들어 word2vec이나 GloVe와 같은 사전학습 임베딩은 단어 표현을 개선하지만, 문장 수준의 의미나 문맥 구조를 충분히 반영하기 어렵다.

c. 사전 학습된 표현을 실제 작업에 적용하는 방식이 연구마다 다르며, 모델 구조를 작업별로 크게 변경해야 하는 경우가 많았다.

이 논문은 이러한 문제를 해결하기 위해

- 대규모 텍스트로 언어 모델을 사전 학습
- 다양한 자연어 이해 작업에 최소한의 구조 변경으로 전이 학습

이 가능한 일반적인 프레임워크를 제안한다.

3. 관련 연구 동향 (Related Works)

자연어 처리에서 비지도 데이터를 활용하려는 연구는 크게 세 가지 방향으로 진행되어 왔다.

(1) 단어 임베딩 기반 방법

대표적으로 Word2Vec, GloVe 와 같은 방법이 있다.

이 방법들은 대규모 텍스트로 단어 벡터를 학습한 뒤 이를 다른 모델의 입력 특징으로 사용한다. 하지만 이러한 방식은 주로 단어 수준 정보만 전달하며 문장 수준 의미를 충분히 반영하지 못한다.

(2) 문장 표현 학습

문장 단위 표현을 학습하는 연구도 진행되었다.

예를 들어, sentence embedding, paragraph vector 와 같은 방식은 문장을 하나의 벡터로 표현하지만, 특정 작업에 맞게 별도의 모델을 다시 학습해야 하는 경우가 많다.

(3) 언어 모델 기반 전이 학습

최근에는 LSTM 기반 language model pretraining, ULMFiT와 같이 언어 모델을 사전 학습한 뒤 다른 작업에 활용하는 연구가 등장했다. 그러나 이러한 연구는 대부분 LSTM 구조를 사용하기 때문에 긴 문맥 정보를 충분히 활용하기 어려운 문제가 있었다.

본 논문은 이러한 한계를 해결하기 위해 Transformer 구조 기반 언어 모델을 사용한다.

4. 연구 접근법과 모델 구조 (Method)

(1) Unsupervised Pre-training

첫 번째 단계에서는 대규모 비라벨 텍스트 데이터로 언어 모델을 학습한다.

목표는 다음 단어의 확률을 최대화하는 것이며, 언어 모델의 목적 함수는 다음과 같다.

$$L_1(\mathcal{U}) = \sum \log P(u_i | u_{i-k}, \dots, u_{i-1}; \Theta)$$

- u_i : 현재 토큰
- k : 문맥 길이
- P : 신경망이 추정하는 확률

즉, 이전 단어들을 기반으로 다음 단어를 예측하도록 학습한다.

(2) 모델 구조

논문에서는 Transformer decoder 구조를 사용한다.

<모델 구성>

- 12개의 Transformer layer

- hidden dimension 768
- attention head 12
- feed-forward layer 3072

<입력 처리 과정>

```
token embedding + positional embedding
    ↓
Transformer layers
    ↓
next token probability
```

Transformer는 self-attention을 이용하여 긴 문맥 의존성을 효과적으로 학습할 수 있다.

(3) Supervised Fine-tuning

사전 학습이 완료된 모델 위에 linear classifier를 추가하고 특정 작업에 맞게 학습한다.

예측 확률은 다음과 같이 계산되며, fine-tuning 과정에서 모델 구조는 거의 변경되지 않는다.

$$P(y|x^1, \dots, x^m) = \text{softmax}(h_l^m W_y).$$

- h_l^m : 마지막 Transformer layer의 hidden state
- W_y : 분류 layer 파라미터

(4) Task-specific Input Transformation

다양한 자연어 작업을 동일한 모델로 처리하기 위해 입력 형식을 변환하는 방식을 사용한다.

예

Natural Language Inference

```
premise $ hypothesis
```

Question Answering

```
document ; question ; answer
```

이러한 방식으로 구조화된 입력을 하나의 텍스트 시퀀스로 변환한다.

5. 실험 구성과 결과 (Experiments)

(1) Pre-training 데이터

사전 학습에는 BooksCorpus 데이터셋을 사용하였다. 이는 약 7000권의 책, 긴 문맥 구조 존재, 다양한 장르 포함한다.

(2) 평가 작업

다음과 같은 자연어 이해 작업에서 실험하였다.

Task	Dataset
Natural Language Inference	SNLI, MultiNLI
Question Answering	RACE
Sentence Similarity	STS-B
Text Classification	SST-2, CoLA

(3) 주요 결과

제안된 모델은 12개 데이터셋 중 9개에서 기존 최고 성능을 갱신하였다.

- Story Cloze Test: +8.9%
- RACE Question Answering: +5.7%
- MultiNLI: +1.5%

또한 GLUE benchmark에서도 이전 모델보다 높은 점수를 기록하였다.

6. 발견한 점과 한계 (Discussion)

a. 사전 학습이 모델 성능에 매우 큰 영향을 미친다.

사전 학습을 제거하면 평균 성능이 약 14.8% 감소하였다.

b. Transformer 구조는 LSTM보다 전이 학습 성능이 더 좋았다.

c. 사전 학습된 언어 모델은 일부 작업에서 fine-tuning 없이도 일정 수준의 성능을 보였다.

다만 몇 가지 한계도 존재한다.

- 작은 데이터셋에서는 성능 개선이 제한적이다.
 - 학습에 대규모 데이터와 계산 자원이 필요하다.
-

7. 결론 및 주요 요약 (Conclusion)

이 논문은 자연어 이해 작업을 위한 generative pre-training + discriminative fine-tuning 프레임워크를 제안하였다.

대규모 텍스트로 사전 학습된 Transformer 모델은 문맥 구조, 언어적 지식, 장거리 의존성을 효과적으로 학습하며, 이를 다양한 자연어 처리 작업에 전이할 수 있다.

실험 결과 제안된 방법은 여러 벤치마크에서 기존 최고 성능을 갱신하였다.

8. 기존 연구 대비 차별점

1. 대규모 언어 모델 사전 학습을 활용한 전이 학습 구조
2. Transformer 기반 모델 사용
3. 작업별 모델 구조 변경 최소화
4. 다양한 NLP 작업을 하나의 모델로 해결

9. 핵심 아이디어

대규모 텍스트로 언어 모델을 사전 학습하면, 이 모델을 다양한 자연어 이해 작업에 효과적으로 전이할 수 있다.

즉, 'Pre-training → Fine-tuning'이라는 패러다임을 제시하였다.

10. 주요 수식

언어 모델 목적 함수

$$L_1(\mathcal{U}) = \sum \log P(u_i | u_{i-k}, \dots, u_{i-1}; \Theta)$$

fine-tuning 분류 함수

$$P(y | x^1, \dots, x^m) = \text{softmax}(h_l^m W_y).$$

최종 학습 목적

$$L_3(\mathcal{C}) = L_2(\mathcal{C}) + \lambda * L_1(\mathcal{C})$$

즉, supervised loss와 language modeling loss를 함께 사용한다.

11. 공부할 때 중요한 포인트

이 논문은 이후 등장하는 GPT, BERT, ChatGPT 모델의 기본 구조가 되는 연구이다.

1. Pre-training + Fine-tuning 구조
2. Language model 기반 representation learning
3. Transformer의 long-range dependency 처리 능력
4. Task-specific input transformation

이 논문은 대규모 언어 모델 기반 자연어 처리 패러다임의 시작점이라고 볼 수 있다.

2. DEEPSEEK

1. 어떤 문제를 해결하려 했는가? (Abstract)

기존의 LLM은 추론 능력을 강화하기 위해 인간이 작성한 사고 경로 데이터에 의존해 왔다. 그러나 이러한 방식은 데이터 구축 비용이 높고 모델의 능력이 인간의 수준에 국한되는 한계가 있다. 본 연구는 인간의 가이드 없이 순수 강화학습만으로 LLM이 고도의 추론 능력을 스스로 깨우칠 수 있음을 증명하고, 이를 통해 수학, 코딩 등 복잡한 태스크에서 성능을 극대화한 DeepSeek-R1 모델을 제시한다.

2. 연구 동기와 문제점 (Introduction)

추론은 인간 지능의 핵심이며, 이를 AI로 구현하기 위해 그동안 SFT가 주로 활용되었다. 하지만 SFT는 데이터의 확장이 어렵고 인간의 사고 편향이 모델에 전이되는 문제가 발생한다. 또한, 모델이 인간의 사고방식을 단순히 복제하게 되면 비인간적인 최적의 추론 경로를 탐색할 기회를 박탈하게 된다. 이에 본 연구는 모델이 스스로 시행착오를 거치며 진화하는 자가 진화 시스템 구축을 목표로 한다.

3. 관련 연구 동향 (Related Works)

기존 연구들은 CoT 프롬프팅이나 다수결 투표 등을 통해 추론 성능을 보완해 왔다. 특히 OpenAI의 o1 모델은 추론 단계에서의 연산량을 늘려 성능을 비약적으로 상승시켰으나, 구체적인 학습 방법론은 공개되지 않았다. 강화학습 분야에서는 PPO가 표준으로 자리 잡았으나, 대규모 모델 적용 시 비평가 모델 운영에 따른 자원 소모가 극심하다는 단점이 제기되어 왔다.

4. 연구 접근법과 모델 구조 (Method)

DeepSeek-R1-Zero (순수 RL 버전)

- 구조: DeepSeek-V3-Base 모델에서 시작, SFT 단계 없음
- 알고리즘: GRPO (Group Relative Policy Optimization), Critic 모델 없이 그룹 내 상대적 보상을 계산해 효율성을 높임
- 보상(Reward):
 1. Accuracy: 정답이 맞았나? (수학, 코딩 등)
 2. Format: `<think>` 와 `<answer>` 태그를 잘 썼나?

DeepSeek-R1 (정제된 버전)

R1-Zero의 가독성 문제(언어 혼용 등)를 해결하기 위해 'Cold-start SFT → RL → 재차 SFT → 최종 RL'이라는 다단계 파이프라인을 구축했다.

Zero 모델에서 발생한 언어 혼용 및 가독성 문제를 해결하기 위해 소량의 'Cold-start' 데이터를 먼저 학습시킨 후, RL과 SFT를 반복하는 다단계 공정을 거쳐 완성도를 높였다.

5. 실험 구성과 결과 (Experiments)

- 수학 (AIME 2024): R1-Zero는 15.6%에서 77.9%까지 성능이 수직 상승했다. 최종 R1은 79.8%를 기록했다.
- 코딩 (Codeforces): 상위 96.3%의 인간 참여자 수준에 도달했다.
- 특이점: 모델이 더 어려운 문제를 풀 때 스스로 답변 길이를 늘려가며 깊게 생각하는 'Test-time compute scaling' 현상이 자연적으로 발생했다.

6. 발견 및 한계점 (Discussion)

- **발견:** 'Aha Moment'의 발견, 학습 도중 모델이 스스로 풀이를 재검토하는 능력을 갖추게 되었습니다.
- **한계점:**
 1. 언어 혼용 이슈(다국어 처리 시 영어가 섞임)
 2. 소프트웨어 엔지니어링 등 특정 복잡한 작업에서는 여전히 개선 여지가 있음
 3. 프롬프트에 민감함(Few-shot 보다 Zero-shot 성능이 더 좋음)

7. 결론 (Conclusion)

DeepSeek-R1은 순수 강화학습만으로도 복잡한 추론 능력이 발현될 수 있다는 것을 입증한 기념비적인 연구이다. 특히 거대 모델이 습득한 추론 로직을 소형 모델(1.5B, 7B 등)에 증류(Distillation)하여 배포함으로써, 고성능 추론 AI의 대중화에 기여했다. 이는 향후 정답 확인

이 가능한 모든 도메인에서 AI가 인간의 가이드 없이도 스스로 성능을 개선할 수 있음을 시사한다.

8. 기존 연구 대비 차별점 & 핵심 아이디어

- 순수 RL의 가능성: SFT 단계가 추론 최적화의 필수 요건이 아님을 증명함
- GRPO 알고리즘: 비평가 모델 없는 상대평가 방식을 통해 거대 모델 학습 효율 극대화
- 증류의 위력: 거대 모델의 추론 사고방식 자체를 데이터화하여 소형 모델에 이식, 경량화 모델의 한계를 돌파함

9. 주요 수식과 코드 분석

핵심 수식: GRPO Advantage

GRPO에서 가중치를 계산하는 수식으로, 별도의 Value 모델 없이 그룹 평균을 쓰는 게 핵심

$$A_i = \frac{r_i - \text{mean}(\{r_1, r_2, \dots, r_G\})}{\text{std}(\{r_1, r_2, \dots, r_G\})}.$$

- r_i : 각 답변의 보상 점수
- G : 한 질문에 대해 생성한 답변 그룹

코드 분석 (Inference 예시)

논문에서 제공한 실제 모델 사용 코드의 핵심 부분

Python

```
# DeepSeek-R1은 <think> 태그를 통해 사고 과정을 출력
# 추론 시 T(온도)는 0.6 정도를 권장함 (논문 상의 0.7 혹은 0.6)
# T가 0과 가까울 수록 안전하고 예측 가능한 단어 선택, 1이상일 경우
다양하고 창의적이지만 헛소리 가능
generate_args = {
    "ckpt_path": "/path/to/DeepSeek-R1-Demo",
    "config": "configs/config_671B.json",
    "interactive": True,
    "temperature": 0.7, # 창의성과 정교함의 균형
    "max_new_tokens": 8192 # 긴 추론 과정을 담기 위해 길게 설정
}
```


10. 공부할 때 중요한 포인트

▼ 핵심 단어

- **Distillation (지식 증류):** 거대 모델(Teacher)의 지식을 훨씬 작은 모델(Student)에게 전달하는 과정이다. 정답만 가르치는 것이 아니라, 거대 모델이 문제를 해결하는 '사고 과정'을 작은 모델이 따라 배우게 하여, 크기 대비 압도적인 성능을 내게 만든다.
- **SFT (Supervised Fine-Tuning, 지도 미세 조정):** '질문-정답' 쌍으로 구성된 데이터셋을 학습시켜 모델이 모범 답안을 모방하게 하는 단계이다. 모델의 기초적인 지식 습득과 말투 교정에 필수적이다.
- **GRPO (Group Relative Policy Optimization):** DeepSeek가 고안한 효율적인 강화학습 알고리즘이다. 별도의 비평가 모델 없이, 한 질문에 대해 여러 답변을 생성한 뒤 그들 사이의 **상대적 점수**를 계산한다. 이를 통해 GPU 메모리를 획기적으로 절약할 수 있다.

<DeepSeek-R1 지식 증류(Distillation) 핵심>

1. 증류의 정의와 목적

거대 모델(DeepSeek-R1, 671B)이 강화학습을 통해 습득한 고도의 추론 능력과 사고 방식(Long CoT)을 소형 모델(Qwen, Llama 기반 1.5B~70B)에게 그대로 이식하는 과정이다. 이를 통해 연산 자원이 부족한 환경에서도 고성능 추론 AI를 사용할 수 있게 하는 것이 주된 목적이다.

2. 데이터 구성의 특징

단순히 질문과 정답만 가르치는 것이 아니라, 거대 모델이 문제를 풀기 위해 거친 '사고의 전 과정(<think> 태그 내부 내용)'을 포함한 약 80만 개의 데이터를 학습시킨다. 이 데이터에는 수학, 코딩, STEM, 논리 등 정답 확인이 가능한 고난도 추론 문제가 포함된다.

3. 모델 크기의 한계를 돌파한 성능

증류를 거친 1.5B 크기의 초소형 모델이 수학 벤치마크(AIME 2024)에서 28.9%를 기록하며, 기존의 거대 모델인 GPT-4o나 Claude-3.5-Sonnet의 기본 성능을 상회하는 이례적인 결과를 보여준다. 이는 모델의 크기보다 '어떤 논리적 경로를 학습하느냐'가 추론 능력에 결정적임을 시사한다.

4. 순수 강화학습 대비 증류의 효율성

소형 모델을 처음부터 대규모 강화학습으로 가르치는 것보다, 이미 똑똑해진 거대 모델의 사고 방식을 지도 학습(SFT)으로 따라 하게 만드는 것이 훨씬 빠르고 성능이 좋다. 논문에 따르면, 32B 모델을 직접 강화학습 시킨 것보다 R1에서 증류한 결과가 모든 지표에서 압도적으로 우수하다.