



8주차 과제

⚙ Status	In progress
📁 Task type	

8주차 과제

1. GPT

1. 어떤 문제를 해결하려 했는가? (Abstract)

자연어 이해는 Textual Entailment, Question Answering, Semantic Similarity, Text Classification 등의 다양한 작업을 포함한다. 이러한 작업을 수행하기 위해서는 많은 양의 라벨 데이터가 필요하다. 하지만 실제로는 라벨이 없는 텍스트 데이터는 풍부하고, 라벨 데이터는 매우 부족한 문제가 존재한다. 그래서 기존의 딥러닝 기반 NLP 모델들은 대부분 지도학습에 의존하기 때문에 이러한 환경에서 성능이 제한되는 문제점이 있었다. 이 논문은 이러한 문제를 해결하기 위해 다음과 같은 방법을 제안한다.

핵심 접근 방식

1. 대규모 unlabeled text 데이터로 언어 모델을 먼저 학습한다.
2. 이후 각 NLP task에 맞게 fine-tuning을 제안한다.

이 방식은 다양한 자연어 이해 벤치마크에서 좋은 성능을 보였으며, 실험 결과 12개의 NLP task 중 9개에서 기존 최고 성능을 달성하였다.

2. 연구 동기와 문제점 (Introduction)

자연어 처리 분야에서 가장 큰 문제 중 하나는 대량의 라벨 데이터 부족이다. 기존 연구에서는 이 문제를 해결하기 위해 word embedding을 활용하였다. Word2Vec이나 GloVe 같은 방법

을 통해 라벨이 없는 텍스트로부터 단어 벡터를 학습하고 이를 다양한 NLP 작업에 활용하였다. 하지만 이러한 방식에는 몇 가지 한계점이 존재한다.

1. 단어 수준 정보만 학습 가능

문장이나 문맥 전체의 의미를 충분히 반영하지 못한다.

2. 전이 학습 방식이 복잡함

기존 모델들은 각 task마다 다른 구조를 사용하거나 별도의 학습 방식을 적용해야 한다.

이 논문은 이러한 문제를 해결하기 위해 Transformer 기반 언어 모델을 이용한 generative pre-training 방법을 제안하였다.

3. 관련 연구 동향 (Related Works)

논문에서는 기존 연구를 크게 세 가지 방향으로 분류한다.

1. Semi-supervised Learning

라벨이 없는 데이터를 활용하여 모델을 학습하는 방식이다. 초기 연구에서는 단어 통계 정보나 문장 패턴을 활용하여 feature를 생성하고 이를 지도학습 모델에 활용하였다. 최근에는 word embedding을 활용하여 다양한 NLP 작업의 성능을 개선하는 연구가 진행되었다. 그러나 이러한 방식은 대부분 단어 수준 정보 전달에 제한되어 있으며 문장 전체 의미를 충분히 학습하지 못한다.

2. Unsupervised Pre-training

신경망을 먼저 비지도 학습으로 pre-training한 후 특정 작업에 맞게 학습하는 방식이다. 이 방법은 이미지 분류, 음성 인식, 기계 번역 등 다양한 분야에서 사용되었으며 딥러닝 모델의 일반화 성능을 향상시키는 효과가 있는 것으로 알려져 있다.

3. 언어 모델 기반 전이 학습

최근 연구에서는 언어 모델을 사전 학습한 후 NLP task에 적용하는 방법이 제안되었다. 하지만 대부분의 연구는 LSTM 기반 모델을 사용하여 긴 문맥을 학습하는 데 한계가 있었다. 이 논문에서는 이러한 문제를 해결하기 위해 Transformer 구조를 사용한 언어 모델을 적용하였다.

4. 연구 접근법과 모델 구조 (Method)

논문에서 제안한 모델은 두 단계 학습 구조로 이루어진다.

4.1 Unsupervised Pre-training

첫 번째 단계에서는 대규모 비라벨 텍스트 데이터로 언어 모델을 학습한다. 언어 모델의 목적은 다음 단어의 확률을 예측하는 것이다.

$$L_1(\mathcal{U}) = \sum_i \log P(u_i | u_{i-k}, \dots, u_{i-1}; \Theta)$$

이 식은 이전 단어들이 주어졌을 때 다음 단어가 등장할 확률을 최대화하도록 학습한다는 의미

4.2 Transformer 기반 모델

논문에서는 **Transformer decoder** 구조를 사용하였다.

모델의 구조는 다음과 같다.

1. Token Embedding
2. Position Embedding
3. Transformer Block (Self-Attention)
4. Feed Forward Network
5. Softmax Layer

Transformer는 Self-Attention 메커니즘을 사용하여 문장 내의 단어 간 관계를 효과적으로 학습할 수 있으며 긴 문맥 정보도 처리할 수 있다.

4.3 Supervised Fine-tuning

Pre-training 이후에는 특정 NLP task에 맞게 모델을 fine-tuning 한다. 입력 문장을 Transformer에 넣어 얻은 표현을 이용해 다음과 같은 확률을 계산한다.

$$P(y | x^1, \dots, x^m) = \text{softmax}(h_l^m W_y).$$

여기서

- (h^m) : Transformer의 마지막 layer 출력

- (Wy) : task-specific classifier

즉 Transformer 출력 위에 간단한 linear classifier만 추가하여 다양한 NLP 작업을 수행할 수 있다.

4.4 Task-specific Input Transformations

논문에서는 다양한 NLP task를 하나의 Transformer 모델로 처리하기 위해 task-specific input transformations 방법을 사용하였다. 각 task의 입력 데이터를 하나의 연속된 토큰 시퀀스로 변환하여 Transformer에 입력한다.

예를 들어

- Text Classification : 문장을 그대로 입력
- Natural Language Inference : 두 문장을 하나의 시퀀스로 결합
- Question Answering : 문서와 질문을 하나의 시퀀스로 결합

이 방식은 모델 구조를 변경하지 않고도 다양한 NLP task에 적용할 수 있도록 해준다.

5. 실험 구성과 결과 (Experiments)

Dataset

- Pre-training에는 **BooksCorpus** 데이터셋을 사용
-

평가 작업

논문에서는 다음과 같은 NLP task를 평가하였다.

- Natural Language Inference
 - Question Answering
 - Semantic Similarity
 - Text Classification
-

주요 결과

모델은 12개 데이터셋 중 9개에서 최고 성능을 달성하였다.

예시 결과

Task	성능
Story Cloze	86.5
RACE QA	59.0
SST-2	91.3

6. 발견한 점과 한계 (Discussion)

주요 발견

1. Pre-training이 매우 중요

Pre-training 없이 학습할 경우 성능이 크게 감소하였다.

2. Transformer가 LSTM보다 성능이 우수

Self-attention 구조가 긴 문맥을 처리하는 데 더 효과적이다.

3. Pre-training을 통해 다양한 언어 지식을 학습

모델은 문법, 의미 관계 등 다양한 언어 정보를 자동으로 학습한다.

한계점

1. 사용한 데이터셋 규모가 제한적이다.
2. 모델 크기가 비교적 작다.
3. 완전한 zero-shot 능력은 제한적이다.

7. 결론 및 주요 요약 (Conclusion)

이 논문은 Generative Pre-training + Fine-tuning이라는 새로운 학습 프레임워크를 제안하였다.

핵심 과정은 다음과 같다.

1. 대규모 텍스트로 언어 모델을 학습한다.
2. 학습된 모델을 다양한 NLP task에 fine-tuning 한다.

이 방법은 하나의 모델을 이용해 다양한 자연어 이해 작업을 수행할 수 있으며 여러 benchmark에서 기존 방법보다 높은 성능을 보였다.

8. 기존 연구 대비 차별점

이 연구의 주요 차별점은 다음과 같다.

1. Transformer 기반 언어 모델 사용
2. Generative Pre-training 방식 제안
3. Task-agnostic 모델 구조

즉 하나의 모델을 다양한 NLP task에 적용할 수 있는 범용 언어 이해 모델을 제안했다는 점에서 의미가 크다.

9. 핵심 아이디어

이 논문의 핵심 아이디어는 다음과 같다.

대규모 텍스트로 언어 모델을 먼저 학습한 후 이를 다양한 NLP task에 전이 학습한다.

즉

```
Large unlabeled text
↓
Language model pretraining
↓
Fine-tuning
↓
Downstream task
```

이 패러다임은 이후 등장한 GPT, BERT, T5, LLaMA 등의 대형 언어 모델의 기본 구조가 되었다.

10. 추가 학습 포인트

이 논문은 **현대 LLM의 출발점이 된 연구**이다.

이후 발전 과정

```
GPT-1
↓
GPT-2
```

↓

GPT-3

↓

ChatGPT

즉 Generative Pretraining + Fine-tuning 패러다임을 최초로 체계적으로 제시한 논문이라는 점에서 중요한 의미를 가진다.

2. DeepSeek

1. 어떤 문제를 해결하려 했는가? (Abstract)

최근 LLM은 다음 방법을 통해 추론 능력을 향상시켰다.

- Chain-of-Thought (CoT) prompting
- human-annotated reasoning examples
- supervised fine-tuning

하지만 이러한 방법에는 한계가 있다.

1. 인간이 작성한 reasoning 데이터에 의존
2. 확장성 문제
3. 인간 사고 방식에 제한됨

따라서 이 논문은 다음 질문을 탐구한다.

인간이 만든 reasoning 데이터를 사용하지 않고

순수 reinforcement learning만으로 LLM의 추론 능력을 향상시킬 수 있는가?

논문에서는 DeepSeek-R1-Zero와 DeepSeek-R1 모델을 제안하며, reinforcement learning을 통해 모델이 self-reflection, verification, strategy exploration 같은 reasoning behavior를 스스로 학습할 수 있음을 보여준다.

2. 연구 동기와 문제점 (Introduction)

최근 대형 언어 모델은 규모가 커짐에 따라 이러한 능력을 일부 보이기 시작했으며, 특히 Chain-of-Thought(CoT) prompting을 통해 문제 해결 과정을 단계적으로 생성하면 성능이 크게 향상되는 것이 확인되었다. 그러나 이러한 접근 방식에는 몇 가지 중요한 한계가 존재한다.

- 대부분의 방법은 인간이 작성한 reasoning 예시 데이터에 의존한다. 이러한 데이터는 생성 비용이 높고 대규모로 확보하기 어렵다.
- 모델이 인간의 사고 방식을 그대로 모방하게 되기 때문에 모델이 인간보다 더 효율적인 reasoning 전략을 발견하기 어렵다.
- 대규모 reasoning 데이터 구축은 확장성이 낮고 비용이 매우 크다.

따라서 본 연구는 인간이 만든 reasoning 데이터 없이도 모델이 스스로 reasoning 능력을 발전시킬 수 있는지를 탐구한다. 이를 위해 reinforcement learning을 활용하여 모델이 정답 여부에 기반한 보상을 통해 스스로 reasoning 전략을 학습하도록 하는 방법을 제안하였다.

3. 관련 연구 동향 (Related Works)

기존 연구는 크게 세 가지 방향으로 발전해 왔다.

- 대형 언어 모델의 발전이다. GPT-3, GPT-4와 같은 대형 모델은 규모가 증가하면서 자연스럽게 일부 reasoning 능력을 보이기 시작하였다.
- Chain-of-Thought prompting이다. 이는 모델이 문제 해결 과정을 단계적으로 생성하도록 유도하는 방법으로, 수학 문제나 논리 문제에서 성능을 크게 향상시켰다.
- RLHF(Reinforcement Learning from Human Feedback) 기반 학습이다. 이 방법은 human preference 데이터를 활용하여 모델 출력을 개선하는 방식이다.

그러나 이러한 방법들은 대부분 human-annotated reasoning 데이터 또는 human feedback에 의존한다. 본 논문은 이러한 의존성을 줄이고 reinforcement learning만으로 reasoning 능력을 학습하는 방법을 제안한다는 점에서 기존 연구와 차별화된다.

4. 연구 접근법과 모델 구조 (Method)

본 연구에서는 **DeepSeek-R1-Zero**와 **DeepSeek-R1** 두 가지 모델을 제안

DeepSeek-R1-Zero

DeepSeek-R1-Zero는 supervised fine-tuning 없이 reinforcement learning만으로 학습된 모델이다. 모델은 DeepSeek-V3-Base를 기반으로 하며, RL을 통해 reasoning 능력을 발전시킨다. 모델은 문제를 해결할 때 다음과 같은 구조로 응답을 생성한다.

```
<think> reasoning process </think>
<answer> final answer </answer>
```

이 구조는 모델이 reasoning 과정과 최종 답을 명확히 구분하도록 한다.

GRPO (Group Relative Policy Optimization)

논문에서는 RL 학습 알고리즘으로 **GRPO**를 사용한다. 이는 기존 PPO 기반 RL을 단순화하고 계산 비용을 줄이기 위해 제안된 방법이다. GRPO의 핵심 아이디어는 하나의 질문에 대해 여러 개의 답을 생성한 후, **그룹 내에서 상대적인 reward를 기준으로 policy를 업데이트**하는 것이다.

Advantage 계산은 다음과 같이 정의된다.

$$A_i = \frac{r_i - \text{mean}(\{r_1, r_2, \dots, r_G\})}{\text{std}(\{r_1, r_2, \dots, r_G\})}.$$

이 방식은 별도의 value model 없이도 안정적인 policy 업데이트를 가능하게 한다.

Reward 설계

DeepSeek-R1-Zero의 reward는 두 가지 요소로 구성된다.

1. Accuracy Reward

문제의 정답 여부를 평가하는 보상

2. Format Reward

모델이 reasoning 구조(`<think>` 태그)를 올바르게 사용했는지 평가하는 보상

이 방식은 모델이 정확한 답을 생성하면서 동시에 reasoning 과정을 표현하도록 유도한다.

DeepSeek-R1 학습 파이프라인

DeepSeek-R1은 DeepSeek-R1-Zero의 문제점을 개선하기 위해 multi-stage training pipeline을 사용한다. 학습 과정은 다음과 같다.

1. DeepSeek-V3-Base 모델 준비
2. RL을 통한 reasoning 능력 학습
3. Rejection sampling 및 SFT 적용
4. 추가 RL을 통한 alignment 학습

이 과정은 reasoning 능력뿐 아니라 helpfulness와 safety도 함께 향상시키는 것을 목표로 한다.

5. 실험 구성과 결과 (Experiments)

주요 평가 benchmark

- MMLU
 - AIME (math)
 - GPQA
 - Codeforces
 - SWE-Bench
 - LiveCodeBench
-

실험 결과 DeepSeek-R1은 수학, 코딩, STEM 문제에서 매우 높은 성능을 보였다.

- **AIME**
 - DeepSeek-R1-Zero : 77.9
 - DeepSeek-R1 : 79.8
 - **Codeforces benchmark**에서는 **2029 rating**을 기록하며 높은 코드 생성 능력을 보여 주었다.
-

6. 발견한 점과 한계 (Discussion)

실험 결과 reinforcement learning을 통해 모델이 스스로 reasoning 전략을 발전시킬 수 있음이 확인되었다. 학습 과정에서 모델은 점차 더 긴 reasoning chain을 생성하고, 문제 해결 과정에서 다양한 전략을 시도하였다. 특히 학습 과정 중 모델이 스스로 오류를 발견하고 다시 계산하는 “aha moment”가 관찰되었다. 이는 모델이 인간의 도움 없이도 reasoning 전략을 개선할 수 있음을 보여준다.

그러나 몇 가지 한계도 존재한다.

- 모델이 여러 언어를 혼합하여 사용하는 language mixing 문제가 발생하였다.
- 모델이 간단한 문제에서도 지나치게 긴 reasoning을 생성하는 overthinking 문제가 나타났다.
- reinforcement learning에서 reward model을 속이는 reward hacking 문제가 발생할 가능성이 있다.

7. 결론 및 주요 요약 (Conclusion)

본 논문은 reinforcement learning을 활용하여 대형 언어 모델의 reasoning 능력을 향상시키는 새로운 학습 방법을 제안하였다. 실험 결과 모델은 human-annotated reasoning 데이터 없이도 스스로 reasoning 전략을 학습할 수 있음을 보여주었다. 특히 self-reflection, verification, alternative reasoning 전략과 같은 행동이 reinforcement learning 과정에서 자연스럽게 나타났다. 이 연구는 향후 reasoning 중심 LLM 연구에서 중요한 방향을 제시하며, 정답 검증이 가능한 문제 영역에서는 RL 기반 학습이 매우 효과적임을 보여준다

8. 기존 연구 대비 차별점

기존 LLM 학습 방식은 다음과 같다.

```
Pretraining
→ Supervised Fine Tuning
→ RLHF
```

반면 DeepSeek-R1은 다음과 같은 접근을 사용한다.

```
Pretraining
```

→ Reinforcement Learning 기반 reasoning discovery

즉 모델이 인간 reasoning을 모방하는 것이 아니라 스스로 reasoning 전략을 발견하도록 학습한다는 점이 가장 큰 차별점이다.

9. 핵심 아이디어

이 논문의 핵심 아이디어는 다음과 같다. **“적절한 reward만 제공하면 모델은 reinforcement learning을 통해 스스로 reasoning 전략을 발전시킬 수 있다.”** 즉 reasoning을 직접 가르치는 것이 아니라 문제 해결 결과에 기반한 보상만 제공하여 reasoning을 유도하는 방식이다.

11. 추가 공부 포인트

DeepSeek-R1은 최근 등장한 reasoning-centric LLM 연구 흐름을 대표한다. 현재 LLM 연구 흐름은 다음과 같이 발전하고 있다.

Pretrained LLM

→ Chain-of-Thought

→ RL reasoning training

→ reasoning-specialized models

이 연구는 향후 AI가 복잡한 문제를 해결하는 능력을 강화하는 중요한 방향을 제시한다.