



8주차: 자연어 생성형 모델 : GPT & DeepSeek

Improving Language Understanding by Generative Pre-Training

cdn.openai.com

https://cdn.openai.com/research-covers/language-unsupervised/language_understanding_paper.pdf

Introduction

배경

대부분의 딥러닝들은 상당한 양의 labeled data를 필요로 했고, 이는 labeled data의 부족으로 인해 해당 방법론이 많은 domain에 적용되지 못하는 이유가 되었다.

이러한 상황에서, unlabeled data로부터 언어적 정보를 활용할 수 있는 모델은 완전 좋은 수단이었고, labeled data로 충분히 훈련시키는 것이 가능하더라도 비지도 학습으로부터 좋은 representation을 학습하는 것은 성능 향상을 불러일으킬 수 있다.

그러나, 이렇게 unlabeled data로부터 언어적 정보를 활용하는 것은 2가지의 해결 과제들이 있다.

문제 제시

1. unlabeled data이다 보니 objective function, 즉 목표가 분명하지 않아서 모델을 어떤 방향으로 최적화해야 하는지 분명하지 않다.
→ 어떤 방식으로 학습해야 다른 모델에서도 잘 쓸 수 있는지 불분명하다.
2. 학습된 representation을 다른 task에 활용하는 방법이 정립되지 않았다.

해결방법

저자들은 이러한 문제를 해결하고자 unsupervised pre-training & supervised fine-tuning을 조합한 새로운 semi-supervised의 접근법을 제시한다.

이 연구의 목적은 **universal representaion**을 다양한 범위의 **task**에 **transfer** 시키는 것이다.

제시한 train 과정

1. Neural network model의 초기 파라미터를 학습하기 위해 unlabeled data에 language modeling을 적용한다.
2. 학습된 초기 파라미터들을 target task에 적용시켜 supervised learning을 진행한다.

Related Work

Semi-supervised learning for NLP

NLP에서의 Semi-supervised Learning

- sequence labeling
- text classification

같은 NLP task에서 semi-supervised learning이 많이 연구되었고 큰 관심을 받아왔다.

초기 연구들은 unlabeled data를 직접 모델에 쓰기보다는 통계 정보를 추출해서 feature로 사용했는데 word-level 통계, phrase-level 통계 사용했고 이렇게 계산한 통계를 supervised model의 feature로 사용했다.

그 다음 연구들은 unlabeled data로부터 word embedding을 학습하고 이를 다양한 NLP task에 적용하였는데 대표 예시로는 word2vec, GloVe이 있고 그 결과 여러 task에서 성능 향상이 확인되었다.

하지만 한계도 존재하였다. 기존 연구들의 특징은 대부분 word-level 정보만 transfer하기에 문맥, 문장 구조, 의미 관계 같은 higher-level 정보를 충분히 담지 못한다.

그래서 최근 연구들은 unlabeled corpus를 이용해

- **phrase-level representation**
- **sentence-level representation**

을 학습하는 방법을 연구하고 있다.

목표는 다양한 NLP task에 사용할 수 있는 더 풍부한 text representation을 만드는 것이다.

Unsupervised pre-training

Unsupervised pre-training은 semi-supervised learning의 한 형태로, supervised learning의 목적 함수를 변경하기보다는 모델이 학습을 시작하기에 좋은 초기 파라미터를 찾는 데 목적이 있다. 이러한 방식은 이미지 분류와 회귀 문제 등에서 연구되어 왔다. 또한

pre-training이 일종의 regularization 역할을 하여 deep neural network의 일반화 성능을 높이는 데 도움이 된다는 연구도 제안되었다. 최근에는 이 접근법이 이미지 분류를 넘어 음성 인식, 개체 의미 결정(entity disambiguation), 기계 번역 등 다양한 분야에서 딥러닝 모델 학습을 돕는 방법으로 활용되고 있다.

NLP 분야에서도 텍스트 분류에 unsupervised pre-training을 적용한 연구들이 진행되었다. 다만 이러한 연구에서는 pre-training이 언어적 정보를 학습하는 데에는 도움이 되었지만, LSTM 구조의 특성상 모델이 포착할 수 있는 문맥 범위가 짧아 예측 능력이 제한되는 문제가 있었다.

이에 본 연구에서는 더 넓은 범위의 언어 구조를 학습하기 위해 transformer 구조를 사용한다.

Auxiliary training objective

Auxiliary objective(보조 목적 함수)를 unsupervised learning에 함께 사용하는 방법은 semi-supervised learning의 또 다른 형태로 볼 수 있다. NLP 분야에서도 보조 목적 함수를 활용하여 모델의 성능을 향상시킨 연구들이 존재한다.

본 연구 역시 학습 과정에서 보조 목적 함수를 추가하여 모델을 학습했지만, 실험 결과 unsupervised pre-training만으로도 target task에 필요한 언어적 정보를 충분히 학습할 수 있음을 보여준다.

Framework

1. Unsupervised pre-training) Large corpus로 high-capacity language model을 학습한다.
2. Supervised fine-tuning) 각 task에 대해 model을 adapt 하는 fine-tuning을 한다.

Unsupervised pre-training

unsupervised corpus of token $U\{u_1, \dots, u_n\}$ 이 주어진다고 해보자. 이를 log-likelihood를 최대화 하는 standard language modeling objective에 적용하면 이러한 수식이 나온다.

$$L_1(U) = \sum_i \log P(u_i | u_{i-k}, \dots, u_{i-1}; \Theta)$$

이 수식에서 k 는 context window의 size이며, 조건부 확률 P 는 parameter Θ 를 가진 neural network에 의해 구성되며, parameter Θ 는 stochastic gradient

descent로 train 된다.

본 연구에서는 language modeling을 위해 transformer의 변형인 multi-layer transformer decoder를 사용하였고 이러한 transformer는 multi-headed self-attention을 input context vector에 적용하고, position-wise feed forward network에 통과시켜 target token의 분포를 output으로 내놓는다.

$$\begin{aligned}h_0 &= UW_e + W_p \\h_l &= \text{transformer_block}(h_{l-1}) \forall i \in [i, n] \\P(u) &= \text{softmax}(h_n W_e^T)\end{aligned}$$

Supervised fine-tuning

Unsupervised pre-training을 마친 이후, supervised target task로 parameter를 adapt 시키는 fine-tuning을 진행한다.

각각의 instance가 input token으로 이루어진 sequence, $x_1, \dots, x_m$ 과 label y 로 이루어져 있는 dataset C 가 있다고 가정해보자. 이 input dataset은 pre-trained model에 입력으로 들어가게 되고, 이를 통해 우리는 마지막 transformer block의 activation인 h 를 얻게 된다. 이 activation h 은 파라미터 W_y 를 가진 linear output layer에 입력되어 최종적으로 y 를 예측하게 된다.

$$P(y|x^1, \dots, x^m) = \text{softmax}(h_l^m W_y)$$

Task specific input transformations

text classification과 같은 task에서는 위에서 언급된 방법대로 곧바로 fine-tuning이 가능하다. 그러나, question answering과 textual entailment와 같이 input이 문장의 쌍으로 이루어져 있거나 triplets을 형성하고 있는, structured input을 가지는 task에서는 그렇지 못하다.

논문에서 제안하는 pre-trained model은 contiguous sequence of text(연속된 문장)에서 train 되었기 때문에, 우리는 이러한 task에 model을 적용하기 위해서는 약간의 수정이 필요하다.

기존의 연구들은 transferred representation 위에 특정 task에 맞는 architecture를 학습하는 방법을 제시했지만,

(ELMo의 경우이다. 실제로 논문에서도 이 방법론을 소개하면서 ELMo가 소개된 논문을 제시하였다.)

이러한 방법은 상당한 양의 task-specific customization을 다시 도입하며, 이러한 추가적인 task-specific architecture에는 transfer learning을 사용하지 않는다는 단점이 있다.

대신, 논문에서는 structured input을 pre-trained model이 처리할 수 있는 ordered sequence로 변환해주는 travelsal-style apporoach를 제안한다. 이러한 input transformation을 통해, task에 따라 architecture를 광범위하게 변경하지 않아도 된다는 장점이 있다.

논문에서는 각각의 task에 대해 어떻게 transformation 해야 하는지 제시하는데, 해당 내용은 다음과 같다.

- **Textual entailment** : premise p와 hypothesis h sequence를 concat 하고, 사이에는 delimiter token \$를 넣어준다.
- **Similarity** : 유사도를 구할 때에는 두 개의 sentence에 정해진 순서가 따로 없다. 이를 반영하여, input sequence를 가능한 두 경우 모두의 sentence ordering으로 수정해준다. 예를 들어 text1, text2가 있다고 가정해보자. text 1, text2의 순서도 가능할 것이고 text2, text1의 순서도 가능할 것이다. 이렇게 가능한 순서 모두 text1과 text2를 concat 해주고, 두 문장 사이에 delimiter token \$를 넣어준다. 이때, 생성된 두 input sequence에 대한 sequence representation hml 을 구하는 각각의 과정은 **독립적**으로 이루어진다.
- **Question answering and commonsense reasoning** : 해당 task는 context document z, question q, set of possible answer ak가 주어지는데, 이를 바탕으로 context document z와 question q, 그리고 가능한 모든 answer를 각각 concat 한다.(이 때도 마찬가지로 문장 사이에 delimiter token \$를 넣어준다.) 유사도를 구할 때와 마찬가지로, 가능한 모든 answer에 대한 각각의 input sequence를 통해 sequence representation hml 을 구하는 과정은 **독립적**으로 이루어진다.

Experiments

Setup

먼저, Unsupervised pre-training을 위해 7000권이 넘는 다양한 분야의 미출판 서적에 관련된 dataset인 BookCorpus dataset을 사용한다. 이 BookCorpus dataset은 긴 길이의 contiguous text(연속된 문장)을 가지고 있어서 model이 long-range information을 잘 학습하게끔 하는 이점이 있다.

논문에서 제시한 model은 transformer decoder로 이루어진 12개의 layer를 사용하였으며, 각 transformer는 768의 dimensional states와 12개의 attention heads를 가지며,

3072 dimension의 position-wise feed-forward-network를 가진다.

Pre-training 할 때 Adam optimizer를 사용하였으며, learning rate의 경우 0부터 $2.5e-4$ 까지 2000 step 동안 선형적으로 증가한 뒤 cosine 함수를 따라 0까지 감소하게끔 설정하였으며, sample당 512개의 token을 가졌으며, batch size는 64로 학습을 진행하였다.

또한, 40000번 merge 한 BPE(Byte-Pair Encoding)를 사용하였으며, activation function으로는 GELU(Gaussian Error Linear Unit)를 사용하였다.

눈에 띄는 점은 transformer 논문(Attention is all you need)에서 제안되었던 sinusoidal position embedding을 사용하지 않고 learned position embedding을 사용하였다고 한다.

Fine-tuning을 진행할 때에도 unsupervised pre-training의 hyperparameter와 대부분 동일하지만, $p=0.1$ 의 dropout을 추가하였고, learning rate : $6.25e-5$, batch size : 32, 0.2%의 learning rate decay와 앞서 살펴본 auxiliary objective의 weight λ 로 0.5를 주었다는 차이가 있다.

Supervised fine-tuning

NLP 분야의 다양한 task(natural language inference, question answering, semantic similarity, and text classification)에 대해 실험을 진행하였고, 해당 task에 적용한 dataset은 다음과 같다.

Table 1: A list of the different tasks and datasets used in our experiments.

Task	Datasets
Natural language inference	SNLI [5], MultiNLI [66], Question NLI [64], RTE [4], SciTail [25]
Question Answering	RACE [30], Story Cloze [40]
Sentence similarity	MSR Paraphrase Corpus [14], Quora Question Pairs [9], STS Benchmark [6]
Classification	Stanford Sentiment Treebank-2 [54], CoLA [65]

먼저, natural language inference를 살펴보자

Table 2: Experimental results on natural language inference tasks, comparing our model with current state-of-the-art methods. 5x indicates an ensemble of 5 models. All datasets use accuracy as the evaluation metric.

Method	MNLI-m	MNLI-mm	SNLI	SciTail	QNLI	RTE
ESIM + ELMo [44] (5x)	-	-	<u>89.3</u>	-	-	-
CAFE [58] (5x)	80.2	79.0	<u>89.3</u>	-	-	-
Stochastic Answer Network [35] (3x)	<u>80.6</u>	<u>80.1</u>	-	-	-	-
CAFE [58]	78.7	77.9	88.5	<u>83.3</u>		
GenSen [64]	71.4	71.3	-	-	<u>82.3</u>	59.2
Multi-task BiLSTM + Attn [64]	72.2	72.1	-	-	82.1	61.7
Finetuned Transformer LM (ours)	82.1	81.4	89.9	88.3	88.1	56.0

textual entailment라고 알려진 natural language inference(NLI) task는 pair of sentence를 읽고 두 sentence의 관계를 entailment(귀결), contradiction(모순), neutral(중립) 중 하나의 관계로 판단한다.

이 task를 위해 각각 Image caption(SNLI), 문서화된 음성, 소설과 정부 보고서(MNLI), 위키피디아 기사(QNLI), 과학시험(SciTail), 뉴스 기사(RTE) 도메인에서 추출한 데이터셋을 이용하였다.

그 결과, 데이터 크기가 가장 적은 RTE 데이터셋을 제외하고, 논문에서 제시하는 모델이 가장 좋은 성능을 보이는 것을 확인할 수 있다.

이번에는 Question answering and commonsense reasoning task에 대한 결과이다.

Table 3: Results on question answering and commonsense reasoning, comparing our model with current state-of-the-art methods.. 9x means an ensemble of 9 models.

Method	Story Cloze	RACE-m	RACE-h	RACE
val-LS-skip [55]	76.5	-	-	-
Hidden Coherence Model [7]	<u>77.6</u>	-	-	-
Dynamic Fusion Net [67] (9x)	-	55.6	49.4	51.2
BiAttention MRU [59] (9x)	-	<u>60.2</u>	<u>50.3</u>	<u>53.3</u>
Finetuned Transformer LM (ours)	86.5	62.9	57.4	59.0

중고등학교 시험지의 영어 지문 및 질문으로 구성된 RACE, 주어진 문장들에 이어질 적합한 엔딩을 고르는 Story Cloze를 사용하며, 모든 지문에서 SOTA를 달성하였다. 또한 여러 문장이 주어진 Story Cloze에서 비약적인 성능 향상을 보이는 점에서 미루어 논문에서 제시하는 model이 long-range context를 잘 포착하고 있음을 확인할 수 있다.

마지막으로, Semantic Similarity과 Classification task에 관해 살펴보겠다.

Table 4: Semantic similarity and classification results, comparing our model with current state-of-the-art methods. All task evaluations in this table were done using the GLUE benchmark. (*mc*= Mathews correlation, *acc*=Accuracy, *pc*=Pearson correlation)

Method	Classification		Semantic Similarity			GLUE
	CoLA (mc)	SST2 (acc)	MRPC (F1)	STSB (pc)	QQP (F1)	
Sparse byte mLSTM [16]	-	93.2	-	-	-	-
TF-KLD [23]	-	-	86.0	-	-	-
ECNU (mixed ensemble) [60]	-	-	-	<u>81.0</u>	-	-
Single-task BiLSTM + ELMo + Attn [64]	<u>35.0</u>	90.2	80.2	55.5	<u>66.1</u>	64.8
Multi-task BiLSTM + ELMo + Attn [64]	18.9	91.6	83.5	72.8	<u>63.3</u>	<u>68.9</u>
Finetuned Transformer LM (ours)	45.4	91.3	82.3	82.0	70.3	72.8

먼저, 두 sentence 간 유사도를 구하는 Semantic Similarity task이다.

뉴스로부터 수집한 dataset인 MRPC와 QQP, STS-B dataset을 사용하였는데, QQP와 STS-B dataset에서 SOTA를 달성하였다.


Classification task의 경우, 문장이 문법적으로 옳은지에 대한 전문가의 판단과 학습된 model의 linguistic bias에 대한 테스트를 포함하는 CoLA(The Corpus of Linguistic Acceptability) dataset과 표준 이진 분류 문제인 SST-2(The Stanford Sentiment Treebank) dataset을 사용하였으며, 두 dataset을 사용하였을 때 모두 SOTA를 달성하였다.

전반적으로, 논문에서 제시하는 모델은 12개의 dataset 중에서 9개에서 SOTA를 달성하였다. 또한 dataset의 size와 관계없이 좋은 성능을 내는 것을 확인할 수 있었다.

Analysis

Impact of number of layers transferred

저자들은 연구를 진행하면서 unsupervised pre-training에서 supervised target task로 transfer 하는 layer의 개수의 영향을 관찰하였다. 아래의 사진을 살펴보자.



위 그래프는 MNLI dataset과 RACE dataset에서, unsupervised pre-training에서 supervised target task로 transfer하는 layer의 개수 당 model 성능을 나타낸 그래프이다.

transfer하는 layer의 개수가 증가할수록 정확도가 향상하는 것을 볼 수 있는데, 이는 사전 학습 모델의 각 layer가 target task에 적합한 기능을 학습했음을 의미한다.


Zero-shot Behaviors

논문에서는 transformer를 이용한 pre-training이 효과적인 이유를 찾고자 하였다. 그래서 다음과 같은 가설을 세운다.

- Underlying generative model(unsupervised pre-trained model)이 language model의 성능을 향상하기 위해서 다양한 task를 수행하는 방법을 학습한다.
- LSTM에 비해 Transformer의 attentional memory 가 전이하기에 적합하다.

저자들은 이러한 가설들을 검증하기 위해 supervised fine-tuning 없이 underlying generative model(unsupervised pre-trained model)만으로 각 task를

수행하는 실험을 하여 zero-shot performance를 측정하였다. 결과는 아래와 같다.



우선, 실선의 경우 transformer로 수행된 결과이고, 점선은 LSTM으로 수행된 결과이다.

transformer로 수행된 결과인 실선부터 살펴보겠다. pre-training 횟수가 늘어날수록 성능이 향상하는 것을 볼 수 있으며, **generative pre-training(생성적 사전 학습)이 다양한 task와 관련된 다양한 기능을 학습하였음을 알 수 있다.**

또한, LSTM으로 수행된 결과인 점선을 살펴보면, transformer로 동일한 작업을 수행한 결과에 비해 낮은 zero-shot performance를 보임을 확인할 수 있다. 논문에서는 이러한 이유로 **transformer의 inductive bias가 transfer를 돕는 것**이라고 추측한다.

(Transformer의 경우 RNN, CNN에 비해 inductive bias가 부족하다. 이러한 inductive bias가 높을수록 작은 dataset에서도 학습 성능이 높아지긴 하지만, **generalization(variance)은 낮아진다.** transformer의 상대적으로 낮은 inductive bias로 인해 RNN 계열의 LSTM보다 **robust 하게 동작하기** 때문에 보다 다양한 task에 적용해야 하는 transfer에서 강세를 보인다고 생각한다.)

Ablation studies

논문에서는 제시한 방법론들의 효과를 알아보기 위해 ablation study를 진행하였다. 결과는 아래와 같다.

Table 5: Analysis of various model ablations on different tasks. Avg. score is a unweighted average of all the results. (*mc*= Mathews correlation, *acc*=Accuracy, *pc*=Pearson correlation)

Method	Avg. Score	CoLA (mc)	SST2 (acc)	MRPC (F1)	STSB (pc)	QQP (F1)	MNLI (acc)	QNLI (acc)	RTE (acc)
Transformer w/ aux LM (full)	74.7	45.4	91.3	82.3	82.0	70.3	81.8	88.1	56.0
Transformer w/o pre-training	59.9	18.9	84.0	79.4	30.9	65.5	75.7	71.2	53.8
Transformer w/o aux LM	75.0	47.9	92.0	84.9	83.2	69.8	81.1	86.9	54.4
LSTM w/ aux LM	69.1	30.3	90.5	83.2	71.8	68.1	73.7	81.1	54.6

먼저, 저자들은 fine-tuning의 objective function L2(C)에 auxiliary objective(보조 목적함수)로 language modeling을 추가하는 것에 대한 측정을 시도하였다. 그 결과, **fine-tuning시 auxiliary objective(보조 목적함수)**를 추가하는 것은 큰 데이터셋에는 효과적이지만, 작은 데이터셋에는 그렇지 않음을 확인할 수 있다.

이어서, LSTM과 비교하여 Transformer의 효과를 분석하였다. 단일 layer의 2048 unit **LSTM과 비교하였을 때 transformer가 더 좋은 성능을 보이는 것을 확인할 수 있다.**

마지막으로, pre-training 없이 target task에 바로 학습한 결과도 도출하였다. 그 결과, **pre-training 없이는 모든 task에서 성능이 저하하였음을 확인할 수 있다.**

DeepSeek-R1: Incentivizing Reasoning Capability in LLMs via Reinforcement Learning

arxiv.org

<https://arxiv.org/pdf/2501.12948>

Introduction

배경

최근 몇 년간 대규모 언어 모델(LLM)은 빠르게 발전하고 있으며, 점차 범용 인공지능(Artificial General Intelligence, AGI)에 가까워지고 있다. 특히 최근에는 **사후 훈련(Post-training)**이 전체 학습 파이프라인에서 중요한 구성 요소로 떠올랐는데, 이는 모델의 추론 정확도를 향상시키고, 사회적 가치와 정렬하며, 사용자 선호에 맞게 모델을 적응시키면서도 사전학습에 비해 상대적으로 적은 연산 자원을 필요로 한다.

추론 능력 측면에서 OpenAI의 o1 시리즈 모델은 최초로 추론 과정의 **Chain-of-Thought 길이를 늘림**으로서 추론 성능을 향상시키는 **Inference-time scaling**을 도입하였다. 이를 통해 수학, 코딩, 과학적 추론 등의 다양한 분야에서 큰 성능 향상을 이루었으나, 테스트 시간의 확장 문제는 한계로 남아있다.

목표

강화 학습(RL)만을 이용하여 언어 모델의 추론 능력을 향상

즉, 지도 학습 데이터를 사용하지 않고, 모델이 순수한 강화학습 프로세스를 통해 스스로 진화할 수 있는 가능성을 탐구하는 것을 목표로 한다. 구체적으로는 **DeepSeek-V3-Base**를 기본 모델로 사용하며, **GRPO 프레임워크를 활용한 강화 학습을 적용**하여 추론 성능을 개선한다.

DeepSeek-R1-Zero

강화학습 알고리즘 - GRPO

그룹 상대 정책 최적화 (Group Relative Policy Optimization, GRPO)

- RL 학습 비용을 절감하기 위해 GRPO 방식을 채택
- GRPO는 일반적인 강화학습에서 Policy 모델과 동일한 크기를 가지는 Critic 모델을 생략하고, 그룹 점수에서 베이스라인을 추정하는 방법을 사용함
- 각각의 질문 q에 대해 GRPO는 아웃풋의 그룹 $\{o_1, \dots, o_G\}$ 를 기존 정책에서 샘플링한 후, 다음의 목적 함수에 대해 policy model을 최적화함

$$\mathcal{J}_{GRPO}(\theta) = \mathbb{E}[q \sim P(Q), \{o_i\}_{i=1}^G \sim \pi_{\theta_{old}}(O|q)]$$

$$\frac{1}{G} \sum_{i=1}^G \left(\min \left(\frac{\pi_{\theta}(o_i|q)}{\pi_{\theta_{old}}(o_i|q)} A_i, \text{clip} \left(\frac{\pi_{\theta}(o_i|q)}{\pi_{\theta_{old}}(o_i|q)}, 1 - \epsilon, 1 + \epsilon \right) A_i \right) - \beta \mathbb{D}_{KL}(\pi_{\theta} || \pi_{ref}) \right), \quad (1)$$

$$\mathbb{D}_{KL}(\pi_{\theta} || \pi_{ref}) = \frac{\pi_{ref}(o_i|q)}{\pi_{\theta}(o_i|q)} - \log \frac{\pi_{ref}(o_i|q)}{\pi_{\theta}(o_i|q)} - 1, \quad (2)$$

- ϵ, β : 하이퍼파라미터
- A_i : advantage, 그룹 내 아웃풋에 해당하는 reward 그룹 $\{r_1, \dots, r_G\}$ 로부터 계산함

$$A_i = \frac{r_i - \text{mean}(\{r_1, r_2, \dots, r_G\})}{\text{std}(\{r_1, r_2, \dots, r_G\})}.$$

Reward Modeling

Reward Modeling - 룰 기반의 보상 시스템 채택

DeepSeek-R1-Zero 학습 시에는 신경망 기반의 reward model을 적용하지 않았는데, 대규모 강화학습과정에서 이러한 신경망 보상모델은 보상 해킹(Reward Hacking)에 취약하기 때문이다. 뿐만 아니라 신경망 기반의 모델을 학습하는 데에 추가적인 학습 리소스가 필요하며, 전체 훈련 파이프라인이 복잡해지기 때문에 두 가지 규칙 기반의 보상 시스템을 채택함으로써 학습 효율성을 극대화했다.

(1) 정확도 보상 (Accuracy Rewards)

- 모델의 응답이 올바른지 평가함
- 결과를 명확하게 판별 가능한 문제에 대해 신뢰할 수 있는 정답 검증 시스템을 적용함
- 수학 문제: 결과가 명확하게 결정되는 문제에 대해 모델은 지정된 형식(ex. 박스 안에 최종 정답을 기입함)으로 응답하도록 하고, 이를 통해 신뢰성 있는 룰 기반 채점이 가능해짐
- LeetCode 문제: 컴파일러를 사용하여 사전에 정의된 테스트케이스를 기반으로 모델 응답을 평가함

(2) 형식 보상 (Format Rewards)

- 응답 형식을 강제하는 추가적인 보상 모델을 도입
- 모델이 사고과정을 특정 태그(예. <think>와 </think>) 사이에 포함하도록 강제함
- 체계적인 사고과정을 명시하도록 유도하여 보다 논리적인 추론 구조를 형성함

Training Template


학습 템플릿

DeepSeek-R1-Zero 학습을 위해 기본 모델이 주어진 지침을 따를 수 있도록 단순한 템플릿을 설계하는 것부터 시작하였다. 아래 기본 템플릿을 기반으로 DeepSeek-R1-Zero는 먼저 추론 과정을 생성한 후, 최종 답변을 출력하도록 한다.

해당 템플릿은 출력 형식에 대한 제약만 설정하고, 내용과 관련된 편향은 최소화하도록 설계되었기 때문에 특정 사고 방식이나 문제 해결 전략을 강제하지 않는다. 따라서 모델이 강화 학습 과정에서 자연스럽게 발전하는 모습을 관찰할 수 있다.

성능, 진화 과정, Aha-moment

성능



학습과정 중 AIME 정확도. 각각의 질문에 대해 16개의 답변을 샘플링하여 평균 정확도를 계산함

→ 강화학습 과정 전반에 걸쳐 AIME 2024 벤치마크에서 DeepSeek-R1-Zero의 성능 변화 추이를 나타낸다.

그래프에서 볼 수 있듯이, DeepSeek-R1-Zero는 RL 훈련이 진행됨에 따라 성능이 지속적이고 안정적으로 향상되는 모습을 보인다. 특히, AIME 2024에서의 평균 pass@1 점수는 **초기 15.6%에서 71.0%로 크게 상승**하며, OpenAI-o1-0912와 유사한 수준의 성능을 달성하였다. 이러한 향상은 모델의 성능을 최적화하는 데 있어 우리의 RL 알고리즘이 효과적임을 보여준다.


Model	AIME 2024		MATH-500	GPQA Diamond	LiveCode Bench	CodeForces
	pass@1	cons@64	pass@1	pass@1	pass@1	rating
OpenAI-o1-mini	63.6	80.0	90.0	60.0	53.8	1820
OpenAI-o1-0912	74.4	83.3	94.8	77.3	63.4	1843
DeepSeek-R1-Zero	71.0	86.7	95.9	73.3	50.0	1444

→ 다양한 추론 관련 벤치마크에서 DeepSeek-R1-Zero와 OpenAI의 o1-0912 모델을 비교 분석한 결과

이를 통해 DeepSeek-R1-Zero가 어떠한 지도 학습 기반의 미세 조정 데이터 없이 강화학습 만으로도 강력한 추론 능력을 갖게 된 것을 볼 수 있다. 이는 RL만으로도 모델이 효과적으

로 학습하고 일반화할 수 있음을 보여주는 성과이다. 다수결 투표 방식을 적용함으로써 해당 성능을 더 끌어올릴 수 있는데, AIME 벤치마크에서 다수결 투표를 활용할 경우, DeepSeek-R1-Zero의 성능은 71.0%에서 86.7%로 상승하며, OpenAI-o1-0912의 성능을 능가한다.

DeepSeek-R1-Zero의 자기 진화 과정 (Self-evolution)



학습 과정 중 DeepSeek-R1-Zero의 평균 답변 길이의 변화

DeepSeek-R1-Zero 학습 과정에서 SFT 없이도 강화학습을 통해 모델의 추론 능력을 자율적으로 향상시키는 자기 진화 과정을 관찰할 수 있다.

그래프에서 볼 수 있듯이, DeepSeek-R1-Zero이 '생각'에 할당하는 시간은 훈련 과정 전반에 걸쳐 지속적으로 증가한다.

이러한 개선은 외부적인 조정의 결과가 아니라, 모델 내부에서 자연스럽게 이루어진 발전의 결과이다. DeepSeek-R1-Zero는 테스트 시간 동안 연장된 연산을 활용하여 점점 더 복잡한 추론 작업을 해결하는 능력을 자연스럽게 습득한다. 이 과정에서 수백 개에서 수천 개에 이르는 추론 토큰을 생성하며, 모델은 보다 깊이 있는 사고 과정을 탐색하고 정제할 수 있게 된다.

이 자기 진화 과정에서 가장 주목할 만한 점 중 하나는 테스트 시간 연산이 증가함에 따라 정교한 사고 행동들이 자발적으로 나타난다는 것이다.

예를 들어, 모델이 자신의 이전 단계를 되돌아보고 재평가하거나 문제 해결을 위한 대체 접근 방식을 탐색하는 행동 등이 자연스럽게 발생하였다. 이러한 행동들은 명시적으로 프로그래밍된 것이 아니라, 강화 학습 환경과의 상호 작용을 통해 자발적으로 형성된 것이다. 이러한

자기 진화는 DeepSeek-R1-Zero의 추론 능력을 크게 향상시키며, 어려운 문제들도 더욱 효율적이고 정확하게 해결할 수 있도록 만든다.

DeepSeek-R1-Zero의 '아하' 순간

Question: If $a > 1$, then the sum of the real solutions of $\sqrt{a - \sqrt{a+x}} = x$ is equal to

Response: <think>

To solve the equation $\sqrt{a - \sqrt{a+x}} = x$, let's start by squaring both ...

$$(\sqrt{a - \sqrt{a+x}})^2 = x^2 \implies a - \sqrt{a+x} = x^2.$$

Rearrange to isolate the inner square root term:

$$(a - x^2)^2 = a + x \implies a^2 - 2ax^2 + (x^2)^2 = a + x \implies x^4 - 2ax^2 - x + (a^2 - a) = 0$$

...

Wait, wait. Wait. That's an aha moment I can flag here.

Let's reevaluate this step-by-step to identify if the correct sum can be ...

We started with the equation:

$$\sqrt{a - \sqrt{a+x}} = x$$

First, let's square both sides:

$$a - \sqrt{a+x} = x^2 \implies \sqrt{a+x} = a - x^2$$

Next, I could square both sides again, treating the equation: ...

...

DeepSeek R1-Zero 학습 중 모델이 사람처럼 '다시 생각'하는 모습

DeepSeek-R1-Zero의 훈련 과정에서 특히 흥미로운 현상 중 하나는 **아하 순간(aha moment)**의 발생이다. 표에서 볼 수 있듯, 이 순간은 모델의 중간 버전에서 나타난다.

이 단계에서 DeepSeek-R1-Zero는 초기 접근 방식을 재평가하면서 문제 해결을 위해 더 많은 사고 시간을 할애하는 법을 학습한다. 이러한 행동 양상은 모델의 추론 능력이 점점 성장하고 있음을 보여줄 뿐만 아니라, 강화 학습이 예측하지 못한 정교한 결과를 이끌어낼 수 있다는 점에서 흥미로운 사례이다.

한계점

DeepSeek-R1-Zero의 성능 향상에도 불구하고, 출력물이 가독성이 낮거나 여러 언어가 혼합되는 등의 문제가 있었다.


추론 과정을 보다 가독성 높게 만들기 위해 **DeepSeek-R1** 모델을 도입하였다. 해당 모델에서는 사람 친화적인 cold start 데이터를 활용한 강화 학습(RL)을 적용하여 기존 모델이 가지고 있는 문제를 개선하는 것을 목표로 한다.

DeepSeek-R1

DeepSeek-R1-Zero의 결과에 대한 질문들

1. 소량의 **고품질 데이터를 cold start**로 활용하면 추론 성능을 더욱 향상시키거나 수렴 속도를 가속할 수 있을까?
2. 어떻게 하면 명확하고 **일관된 사고 과정**(Chain of Thought, CoT)을 생성하는 동시에 강력한 일반화 능력을 갖춘 사용자 친화적인 모델을 학습할 수 있을까?

이러한 질문에 답하기 위해 우리는 **DeepSeek-R1** 학습을 위한 파이프라인을 설계하였다. 이 파이프라인은 아래와 같이 네 개의 단계로 구성된다.



Cold Start

DeepSeek-R1에서는 기본 모델에서 강화 학습을 시작할 때 발생하는 초기의 불안정한 콜드 스타트 단계를 방지하기 위해, 소량의 양질의 CoT 데이터를 구축하여 초기 RL actor로서 모델을 fine-tuning한다.

양질의 Cold Start 데이터를 수집하기 위해서는 다양한 방식을 사용하였다:

- 긴 CoT를 예시로 활용한 few-shot prompting 기법
- 모델이 반성(reflection) 및 검증(verification)을 포함한 상세한 답변을 생성하도록 직접 프롬프트를 제공
- DeepSeek-R1-Zero의 출력을 가독성 있는 형식으로 변환하여 수집
- 사람이 직접 후처리를 통해 결과를 정제함

이번 연구에서는 **수천 개의 콜드 스타트 데이터**를 수집하여 DeepSeek-V3-Base에 대해 강화 학습(RL)의 출발점으로 fine-tuning하였다. DeepSeek-R1-Zero와 비교했을 때, 이 방법은 다음과 같은 장점을 가지고 있다:

- **가독성 증가:** DeepSeek-R1-Zero는 생성된 콘텐츠의 가독성이 떨어지는 경우가 많다는 한계가 있었다. 모델 답변이 여러 언어를 혼합해 사용하거나, 마크다운 형식이 적용되지 않는 경우가 있다. DeepSeek-R1 학습을 위한 콜드 스타트 데이터를 생성할 때는,

각 응답의 끝에 요약물을 포함하는 하고, 읽기에 적합하지 않은 응답은 필터링하였다. 이때 출력 형식은 |special_token|<reasoning_process>|special_token|<summary>로 정의하였고, reasoning_process에는 질의에 대한 CoT를, summary는 추론 결과에 대한 요약물을 작성하였다.

가독성 높은 패턴을 설계

- **잠재적 성능 향상:** 사람의 사전 지식을 반영하여 콜드 스타트 데이터를 신중하게 설계한 결과, DeepSeek-R1-Zero보다 더 나은 성능을 보였다. 이러한 반복적인 학습은 추론 모델을 발전시키는 더 효과적인 방법일 수 있다.

추론 기반의 강화학습

콜드 스타트 데이터에 대해 DeepSeek-V3-Base를 Fine-tuning한 후, DeepSeek-R1-Zero에서와 마찬가지로 대규모 강화 학습 훈련 프로세스를 진행하였다. 이 단계는 코드 작성, 수학, 과학 및 논리적 추론과 같은 잘 정의된 문제와 명확한 솔루션을 포함하는 추론 집약적인 태스크에서 모델의 추론 능력 향상에 중점을 둔다.

이때 학습 중 모델의 CoT 과정에 여러 개의 언어가 혼합되는 현상이 자주 나타났다. 이러한 언어 혼합 문제를 완화하기 위해, RL 학습 중에 CoT에서 목표 언어의 단어가 사용된 비율을 언어 일관성에 대한 보상로 도입하였다. Ablation Study 결과, 이러한 언어 일관성에 대한 설계가 모델의 성능을 약간 저해하나, 인간의 선호와 일치하며 모델 출력의 가독성을 높였다.

따라서 추론에 대한 정확도에 언어 일관성 점수를 보상으로 합산하여 최종 reward를 정의하고, fine-tuning된 모델에 대해 수렴할 때까지 강화학습을 진행하였다.

Rejection Sampling과 Supervised Fine-tuning

추론 성능 향상을 위한 강화학습 과정이 수렴한 후, 결과 체크포인트를 활용하여 이후 학습 파이프라인을 위한 SFT 데이터를 수집한다. 초기 콜드 스타트 데이터는 주로 추론에 중점을 두었지만, 이 단계에서는 모델의 작문, 역할 수행, 그리고 기타 범용 작업 능력을 향상시키기 위해 다른 도메인의 데이터를 포함하였다. SFT 수집 과정은 다음과 같다:

- **추론 데이터:** 프롬프트를 큐레이팅하고, RL 학습이 완료된 체크포인트를 사용하여 이를 통해 SFT 데이터를 정제한다. 각 프롬프트에 대해 모델로부터 여러 응답을 샘플링하고, 올바른 응답만을 보존하여 총 했다. 정제에 활용한 방법은 다음과 같다.

Rejection sampling

약 60만 개의 추론 관련 훈련 샘플을 수집

- **생성형 보상 모델 활용:** RL 단계에서는 규칙 기반 보상을 사용하여 평가할 수 있는 데이터만을 포함했지만, 이번 단계에서는 데이터 중 일부에 대해 생성형 보상 모델

을 활용하여 ground truth와 모델 출력을 DeepSeek-V3에 입력하여 판단한 결과물을 활용한다

- **응답 필터링:** 모델 출력의 가독성이 떨어지는 경우가 있어 언어가 혼합된 경우, 긴 문단, 코드 블록이 포함된 사고 과정은 필터링하였다.
- **비추론 데이터:** 작문, 사실 QA, 자기 인식, 번역 등의 비추론 데이터에는 DeepSeek-V3에서 사용한 파이프라인을 사용하고 DeepSeek-V3의 SFT 데이터셋 일부를 재사용하였다. 특정 비추론 작업에 대해서는 질문에 대답하기 전에 프롬프트를 주어 잠재적으로 사고 과정을 생성하도록 하였다. 단, "hello"와 같은 간단한 질문에 대해서는 CoT를 제공하지 않는다. 이 과정을 통해 약 20만 개의 비추론 관련 훈련 샘플을 수집했다.

20만 개의 비추론 관련 훈련 샘플

이와 같이 정제한 약 80만 개 샘플의 데이터셋을 사용하여 DeepSeek-V3-Base를 2 epoch fine-tuning하였다.

모든 시나리오에 대한 Reinforcement Learning

사람 선호와의 alignment를 위해 모델의 유용성과 무해성을 개선하면서 추론 능력을 다듬기 위한 2차 강화 학습 단계를 도입한다. 이 단계에서는 다양한 보상 신호를 혼합하여 사용하고, 다양한 프롬프트 분포를 사용하였다.

- 추론 데이터 - DeepSeek-R1-Zero에서와 같이 수학, 코드, 논리적 추론 분야의 학습을 위해 을 활용

규칙 기반 보상

- 일반 데이터 - 복잡하고 미묘한 상황에서 인간의 선호를 포착하기 위해 . DeepSeek-V3 파이프라인을 기반으로 비슷한 분포의 선호 쌍과 학습 프롬프트를 사용함.

보상 모델을 사용

- 유용성 - 최종 요약에만 집중해 평가함으로써, 사용자에게 유용성과 관련성을 강조하면서 모델의 추론 과정이 간접하는 것을 최소화함.
- 무해성 - 모델의 전체 응답을 평가. 추론 과정 및 요약을 포함하여 위험, 편견 또는 해로운 내용이 생성 과정 중에 발생할 수 있는 가능성을 식별하고 완화함.

이와 같이 다양한 보상 신호와 다양한 데이터 분포를 통합함으로써 추론에서 우수함을 다듬으면서도 유용성과 무해성을 우선시하는 모델을 학습하였다.

Experiment

본 연구에서는 DeepSeek-R1 모델을 다양한 벤치마크를 통해 평가하였다.

(벤치마크 종류 : MMLU, MMLU-Redux, MMLU-Pro, C-Eval, CMMLU, IFEval,

FRAMES, GPQA Diamond, SimpleQA, C-SimpleQA, SWE-Bench Verified, Aider, LiveCodeBench, Codeforces, CNMO 2024, AIME 2024 등)

DeepSeek-R1의 성능은 여러 개발 단계에 따라 비교되었다.

먼저 DeepSeek-R1-Zero와 DeepSeek-R1 Dev1을 비교했을 때, Dev1은 instruction-following 능력에서 뚜렷한 향상을 보였으며 이는 IF-Eval과 ArenaHard 벤치마크에서의 점수 상승으로 확인되었다.

그러나 cold-start 데이터셋의 규모가 제한적이었기 때문에 Dev1은 일부 추론 성능에서 DeepSeek-R1-Zero보다 낮은 결과를 보였으며, 특히 AIME 벤치마크에서 이러한 성능 저하가 두드러졌다.

다음 단계인 DeepSeek-R1 Dev2에서는 추론 중심의 강화학습이 적용되었으며, 그 결과 코드 생성, 수학 문제 해결, STEM 관련 문제와 같이 높은 수준의 추론 능력이 요구되는 벤치마크에서 성능이 크게 향상되었다.

반면 AlpacaEval 2.0과 같은 일반 목적의 벤치마크에서는 성능 향상이 비교적 제한적으로 나타났다. → 추론 중심의 강화학습이 모델의 추론 능력 향상에는 효과적이지만 사용자 선호 기반의 평가에는 상대적으로 적은 영향을 미친다는 점을 보여준다.

DeepSeek-R1 Dev3 단계에서는 추론 데이터와 비추론 데이터를 모두 SFT 파이프라인에 포함시켜 학습을 진행하였다.

이를 통해 모델은 추론 능력뿐만 아니라 일반적인 언어 생성 능력도 함께 향상시킬 수 있었다. Dev2와 비교했을 때 Dev3는 AlpacaEval 2.0과 Aider-Polyglot 벤치마크에서 의미 있는 성능 향상을 보였으며, 이는 대규모 비추론 코퍼스와 코드 엔지니어링 데이터가 학습에 포함된 결과로 볼 수 있다.

마지막으로 Dev3 모델을 기반으로 추론 중심 데이터와 일반 데이터를 혼합하여 강화학습을 수행함으로써 최종 DeepSeek-R1 모델이 완성되었다. 이전 단계에서 이미 충분한 추론 중심 학습이 이루어졌기 때문에 코드와 수학 관련 벤치마크에서는 비교적 작은 성능 향상이 나타났지만, instruction-following과 사용자 선호 기반 평가에서는 큰 개선이 확인되었다. 특히 AlpacaEval 2.0에서는 약 25%, ArenaHard에서는 약 17%의 성능 향상이 나타났다.

추가적으로 논문의 부록에서는 DeepSeek-R1과 다른 모델 간의 성능 비교, 모델 안전성 평가, DeepSeek-V3와의 비교 분석, 새로운 테스트셋에서의 성능 평가, 수학 능력에 대한 세부 분석, 테스트 시간 스케일링 분석 등이 제시되어 있다. 또한 강력한 추론 능력이 더 작은 모델로도 전이될 수 있음을 확인하였다.