



10주차 과제

⚙ Status	In progress
📁 Task type	

1. GAN

1. Abstract — 해결하려는 문제

- 기존 생성 모델 문제:
 - likelihood 계산 어려움
 - MCMC 등 복잡한 샘플링 필요
- 해결:
 - 👉 **Generator vs Discriminator 경쟁 구조 도입**
- 목표:
 - 👉 생성 모델이 데이터 분포(pdata)를 그대로 학습하도록 함

2. Introduction — 연구 동기

- Deep learning은 분류에서는 성공
- 생성 모델은:
 - 계산 복잡
 - 학습 어려움
- 👉 핵심 아이디어:
 - 생성 문제 → **판별 문제로 변환**

- 두 모델이 경쟁하며 학습

3. Related Works — 기존 한계

방법	문제
RBM, DBM	MCMC 필요, 계산 어려움
DBN	구조 복잡
NCE	noise 고정 문제
Autoencoder/GSN	Markov chain 필요

👉 GAN 차별점:

- Markov chain ❌
- explicit likelihood ❌
- backprop만 사용

4. Method — 모델 구조

구조

- 입력: $z \sim p(z)$ (noise)
- Generator: $x = G(z)$
- Discriminator: $D(x) \in [0, 1]$

핵심 Objective

$$\min_G \max_D V(D, G) = \mathbb{E}_{\mathbf{x} \sim p_{\text{data}}(\mathbf{x})} [\log D(\mathbf{x})] + \mathbb{E}_{\mathbf{z} \sim p_z(\mathbf{z})} [\log(1 - D(G(\mathbf{z})))]$$

학습 방식

- D: 진짜 vs 가짜 구분
 - G: D를 속이도록 학습
 - 번갈아 업데이트 (k번 D, 1번 G)
-

5. 핵심 이론

Optimal Discriminator

$$D_G^*(\mathbf{x}) = \frac{p_{data}(\mathbf{x})}{p_{data}(\mathbf{x}) + p_g(\mathbf{x})}$$

최종 목표

$$C(G) = -\log(4) + 2 \cdot JSD(p_{data} \| p_g)$$

👉 의미:

- JSD 최소화 →

👉 $p_g = p_{data}$ (완벽한 생성)

6. Experiments — 실험

데이터셋

- MNIST
- TFD
- CIFAR-10

결과

- 기존 모델과 비슷하거나 더 좋은 성능
- 실제 이미지 생성 가능

👉 특징:

- Markov chain 없이 샘플 생성
 - 데이터 복사 아님
-

7. Discussion — 장단점

장점

- MCMC 없음
- inference 없음
- backprop만 사용
- sharp distribution 가능

단점

- 학습 불안정
 - mode collapse
 - 확률밀도 직접 계산 불가
-

8. Conclusion

- 생성 모델 학습을:
 - 👉 게임 문제(minimax) 로 변환
 - 간단하지만 강력한 프레임워크 제시
-

9. 기존 대비 차별점

항목	기존	GAN
학습	likelihood	adversarial
샘플링	MCMC 필요	없음
확률모델	explicit	implicit

👉 핵심:

👉 확률 모델링을 직접 하지 않음

10. 핵심 아이디어

👉 “생성 문제를 판별 문제로 바꿨다”

11. 코드 구조 (핵심)

```
# Discriminator
loss_D = log(D(real)) + log(1 - D(fake))

# Generator
loss_G = log(D(fake))
```

🔥 최종 한 줄 요약

👉 GAN = 두 신경망의 경쟁으로 데이터 분포를 학습하는 생성 모델

2. Diffusion

1. Abstract — 해결하려는 문제

- 목표:

👉 고품질 이미지 생성 모델 설계

- 기존 문제:

- GAN: 학습 불안정
- likelihood 모델: 복잡
- 해결:
 - 👉 **diffusion** 과정 기반 생성 모델 제안
- 핵심 아이디어:
 - 데이터에 **노이즈**를 점진적으로 추가
 - 그 과정을 **역으로** 학습해서 복원

📌 결과:

- CIFAR-10에서 **SOTA** 수준 **FID 3.17** 달성

2. Introduction — 연구 동기

- 다양한 생성 모델 존재:
 - GAN, VAE, Flow, Autoregressive

👉 하지만:

- 안정성 / likelihood / 샘플 품질 trade-off 존재

핵심 질문

👉 “안정적이면서도 고품질 생성 가능한 모델은?”

해결 방향

👉 물리 개념 활용:

- **diffusion** (확산 과정)

3. Related Works — 흐름

- Score matching + Langevin dynamics
- Energy-based model

- VAE / Flow

👉 DDPM의 핵심 연결:

- **score matching**
- **variational inference**
- **Langevin dynamics**

📌 즉:

👉 여러 이론을 하나로 통합한 모델

4. Method — 핵심 구조

4.1 전체 구조

Forward process (노이즈 추가)

$$q(\mathbf{x}_t | \mathbf{x}_{t-1}) := \mathcal{N}(\mathbf{x}_t; \sqrt{1 - \beta_t} \mathbf{x}_{t-1}, \beta_t \mathbf{I})$$

👉 데이터 → 점점 노이즈 → 결국 완전 랜덤

Closed-form

$$q(\mathbf{x}_t | \mathbf{x}_0) = \mathcal{N}(\mathbf{x}_t; \sqrt{\bar{\alpha}_t} \mathbf{x}_0, (1 - \bar{\alpha}_t) \mathbf{I})$$

👉 한 번에 t-step 이동 가능

4.2 Reverse process (핵심!)

- 목표:

👉 ($\mathbf{x}_t \rightarrow \mathbf{x}_{t-1}$)

$$p_{\theta}(\mathbf{x}_{t-1} | \mathbf{x}_t)$$

👉 이걸 neural network가 학습

4.3 핵심 아이디어

👉 노이즈(ϵ)를 예측하는 방식

$$\epsilon_{\theta}(x_t, t)$$

4.4 최종 학습 objective

$$L_{\text{simple}}(\theta) := \mathbb{E}_{t, \mathbf{x}_0, \epsilon} \left[\left\| \epsilon - \epsilon_{\theta}(\sqrt{\bar{\alpha}_t} \mathbf{x}_0 + \sqrt{1 - \bar{\alpha}_t} \epsilon, t) \right\|^2 \right]$$

👉 그냥 MSE

📌 핵심:

👉 “노이즈 맞추기 문제”로 바뀜

4.5 Sampling 과정

(논문 Algorithm 2, page 4)

1. $\mathbf{x}_T \sim N(0, I)$
2. 반복:
 - 노이즈 제거

3. X0 생성

👉 점진적 복원

5. 핵심 이론 (중요)

Variational bound

$$L = \sum KL + reconstruction$$

👉 diffusion = VAE 구조

중요한 insight

👉 DDPM =

- Variational inference
- Score matching
- Langevin dynamics

👉 3개가 동일한 형태로 연결됨

6. Experiments — 실험

설정

- T = 1000 step
 - β : 0.0001 $\rightarrow$ 0.02
-

결과

모델	FID
GAN (기준)	~2~10
DDPM	3.17

👉 GAN급 성능 달성

특징

- 학습 안정적
 - 고품질 이미지 생성
 - 다양한 데이터셋에서 성공
-

7. 중요한 분석 (논문 핵심)

(1) Progressive generation

👉 특징:

- 먼저 큰 구조 생성
- 나중에 디테일 생성

📌 즉:

👉 coarse → fine 생성 구조

(2) Compression 관점

- diffusion = **lossy compression**

👉 중요한 발견:

- 대부분 정보는 큰 구조에 있음
 - 디테일은 나중 단계
-

(3) Autoregressive와 연결

👉 diffusion =

- 일반화된 autoregressive 모델
-

8. Discussion — 장단점

장점

- ✓ 매우 안정적인 학습
- ✓ 높은 샘플 품질
- ✓ 이론적 기반 탄탄
- ✓ mode collapse 없음

단점

- ✗ sampling 느림 (T step 필요)
- ✗ 계산 비용 큼
- ✗ likelihood 성능은 최고는 아님

9. Conclusion

- diffusion model이:
 - 👉 강력한 생성 모델임을 증명
- 다양한 분야와 연결:
 - score matching
 - energy-based model
 - autoregressive

10. 기존 연구 대비 차별점

항목	GAN	DDPM
학습 안정성	낮음	높음
샘플 품질	높음	높음
속도	빠름	느림
이론 기반	약함	강함

11. 핵심 아이디어

🔥 한 줄 요약:

👉 "노이즈를 추가하고, 그 노이즈를 제거하는 법을 배우면 생성이 된다"

12. 공부 핵심 포인트

👉 꼭 이해해야 하는 것

1. forward vs reverse process
 2. 왜 ϵ 예측이 중요한가
 3. 왜 MSE로 되는가
 4. DDPM = score matching 연결
-

🔥 최종 한 줄 요약

👉 DDPM = 노이즈 제거 과정을 학습해서 데이터를 생성하는 모델
