

10주차 과제

GAN

1. 어떤 문제를 해결하려 했는가? (Abstract)

- 기존 생성 모델은 확률 분포를 직접 추정하는 과정에서 계산이 매우 어렵고 비효율적
- 특히 Markov Chain, approximate inference 등이 필요하여 학습이 복잡함
- 이를 해결하기 위해 생성 모델(G)과 판별 모델(D)을 경쟁시키는 새로운 프레임워크 제안
- 목표:
 - 생성 모델이 데이터 분포를 그대로 모방
 - 판별 모델은 진짜/가짜 구분
- 결과:
 - 이 구조는 minimax 게임으로 표현 가능하며,
 - 이론적으로 G가 실제 데이터 분포를 완벽히 복원 가능

2. 연구 동기와 문제점 (Introduction)

- 딥러닝은 분류 모델에서는 성공적이지만, 생성 모델은 여전히 어려움
- 문제:
 1. likelihood 계산이 어렵다
 2. inference 과정이 복잡하다
 3. MCMC 기반 방법은 느리고 불안정
- 핵심 아이디어:
 - 확률 분포를 직접 계산하지 말고 "속이기 게임"으로 학습하자

3. 관련 연구 동향 (Related Works)

기존 생성 모델의 한계:

1. **RBM, DBM**: partition function 계산 불가능 → MCMC 필요
2. **DBN**: hybrid 구조 → 학습 복잡

3. **NCE (Noise Contrastive Estimation)**: 고정된 noise → 학습 느림

4. **Autoencoder 계열**: 확률 분포 명확히 표현 못함

5. **GSN**: Markov chain 필요

→ 공통 문제:

- 계산 복잡
- sampling 비효율
- inference 필요

4. 연구 접근법과 모델 구조 (Method)

- 핵심 구조
 - Generator: $G(z)$
 - Discriminator: $D(x)$
- 목적 함수 (핵심 수식)

$$\min_G \max_D V(D, G) = \mathbb{E}_{x \sim p_{data}} [\log D(x)] + \mathbb{E}_{z \sim p_z} [\log(1 - D(G(z)))]$$

- D: 진짜 데이터는 1로, 가짜는 0으로 맞추기
 - G: D를 속이도록 학습
-
- 학습 방식: 번갈아 학습
 - k번 D 업데이트
 - 1번 G 업데이트
 - gradient saturation 문제 해결:
 - 기존: $\log(1 - D(G(z)))$
 - 개선: $\log D(G(z))$

5. 실험 구성과 결과 (Experiments)

데이터셋

- MNIST
- TFD (얼굴 데이터)
- CIFAR-10

평가 방식: Parzen window 기반 likelihood 추정

결과

- 기존 모델(DBN, GSN 등) 대비 경쟁력 있는 성능
- 생성된 이미지:
 - 실제 데이터와 유사
 - 단순 memorization 아님

6. 발견한 점과 한계 (Discussion)

- 발견
 - adversarial 학습만으로 분포 학습 가능
 - Markov chain 없이 샘플링 가능
 - sharp distribution 표현 가능
- 한계
 1. $p_G(x)$ 명시적 표현 없음
 2. G와 D의 균형 중요
 - 불균형 → 학습 붕괴 (mode collapse)
 3. 학습 안정성 문제

7. 결론 및 요약 (Conclusion)

- GAN은 새로운 생성 모델 학습 방식 제안
- 장점:
 - inference 불필요
 - sampling 간단
 - backprop만 사용
- 향후 연구 방향:

- conditional GAN
- semi-supervised learning
- inference network 추가

8. 기존 연구 대비 차별점

- 확률 분포 직접 추정 X
- MCMC / inference 제거
- 생성 모델 학습을 게임 문제로 변환
- 두 모델(G vs D) 동시 학습 구조

9. 핵심 아이디어

- 생성 vs 판별 경쟁 구조
- G는 fake 생성
- D는 fake 탐지
- 반복 → G가 진짜 같은 데이터 생성

10. 주요 수식 및 코드 분석

(1) 최적 Discriminator

$$D^*(x) = \frac{p_{data}(x)}{p_{data}(x) + p_g(x)}$$

(2) 목적 함수 변형

$$C(G) = \log 4 + 2 \cdot JSD(p_{data} || p_g)$$

→ 의미: GAN은 결국 Jensen-Shannon Divergence 최소화

(3) 알고리즘 구조

- Step:

1. noise z 샘플링
 2. $G(z)$ 생성
 3. D 업데이트
 4. G 업데이트
-

11. 추가 학습 포인트

1. 왜 중요한 논문인가
 - 현대 생성 모델 (Diffusion 이전 시대 핵심)
 - GAN → StyleGAN, CycleGAN 등 확장
2. 핵심 이해 포인트
 - likelihood 없이 학습 가능
 - divergence 최소화 구조
 - equilibrium 개념 ($G = p_{data}$)
3. 실전에서 중요한 문제
 - mode collapse
 - unstable training
 - hyperparameter tuning

Diffusion

1. Abstract

- 문제 정의: 기존 생성 모델(GAN, VAE, Autoregressive 등)은 고품질 이미지 생성에는 성공했으나, 학습 안정성·해석 가능성·likelihood 평가 측면에서 한계 존재
 - **해결 목표: Diffusion Probabilistic Model**을 통해 고품질 이미지 생성, 안정적인 학습 구조, 확률적 해석 가능 모델 구축
 - **핵심 결과: CIFAR-10에서 FID 3.17 (SOTA 수준) 달성, diffusion 모델이 실제로 고품질 생성 가능함을 입증**
-

2. Introduction

- **연구 동기**
 - 기존 생성 모델:
 - GAN → 불안정한 학습, mode collapse
 - VAE → blur 발생
 - Autoregressive → 느린 샘플링
 - **문제점**
 - 생성 품질 vs likelihood 간 trade-off
 - sampling 과정의 비효율성
 - **아이디어**
 - 데이터에 점진적으로 노이즈를 추가하고
 - 이를 역으로 복원하는 학습 방식 도입
-

3. Related Works

- **GAN (Generative Adversarial Network)**
 - 고품질 이미지 생성 가능
 - 단점: 학습 불안정
 - **Autoregressive Models (PixelCNN 등)**
 - 정확한 likelihood 계산 가능
 - 단점: 샘플링 느림
 - **VAE (Variational Autoencoder)**
 - 확률적 해석 가능
 - 단점: 이미지 품질 낮음
 - **Score Matching / Energy-based Model**
 - 확률 밀도 gradient 학습
 - **Diffusion Model의 위치**
 - 위 모든 모델의 장점을 일부 통합
 - 특히 score matching + variational inference 연결이 핵심
-

4. Method

- 전체 구조

1. Forward process (노이즈 추가)

- 데이터에 점진적으로 Gaussian noise 추가
- Markov chain 형태

$$q(x_t|x_{t-1}) = \mathcal{N}(x_t; \sqrt{1 - \beta_t}x_{t-1}, \beta_t I)$$

- 결과:

- $x_0 \rightarrow x_T$
- 최종적으로 완전한 노이즈 상태

2. Reverse process (노이즈 제거)

- 노이즈에서 원 데이터 복원

$$p_\theta(x_{t-1}|x_t) = \mathcal{N}(x_{t-1}; \mu_\theta(x_t, t), \sigma_t^2 I)$$

- 신경망이 μ_θ 예측

3. 핵심 파라미터화 (ϵ -prediction)

모델은 직접 x_0 가 아니라 노이즈 ϵ 를 예측

$$x_t = \sqrt{\alpha_t}x_0 + \sqrt{1 - \alpha_t}\epsilon$$

- 목적:

- 학습 안정성 증가
- score matching과 연결

4. Loss Function (핵심)

$$L_{simple} = \mathbb{E}_{t, x_0, \epsilon} [\|\epsilon - \epsilon_{\theta}(x_t, t)\|^2]$$

- 의미: "노이즈를 얼마나 잘 맞추는가"
-

5. Experiments

- **Dataset**
 - CIFAR-10
 - LSUN (256×256)
 - **모델 구조**
 - U-Net backbone
 - self-attention 포함
 - **결과**
 - CIFAR-10:
 - FID: 3.17
 - IS: 9.46
 - GAN 수준 이상의 품질 달성
 - **분석**
 - Variational bound보다
→ 단순 MSE loss가 더 좋은 샘플 생성
-

6. Discussion

- **주요 발견**
 - 고품질 생성 가능
 - 안정적 학습 구조
 - noise 제거 과정이 이미지 생성에 매우 효과적
- **한계**
 - sampling 속도 느림 (T step 필요)
 - likelihood는 최고 수준 아님

- 계산 비용 큼

7. Conclusion

- diffusion model은 새로운 생성 모델 패러다임 제시
- 주요 기여:
 - score matching과의 연결
 - variational inference 기반 학습
 - progressive generation 구조
- 향후: 다양한 데이터 (음성, 텍스트 등) 확장 가능

8. 기존 연구 대비 차별점

- GAN vs Diffusion
 - GAN: adversarial training
 - Diffusion: probabilistic + iterative denoising
- Autoregressive vs Diffusion
 - Diffusion은 **bit ordering**을 일반화
- Score matching과 직접 연결

9. 핵심 아이디어

- “노이즈를 점점 추가 → 다시 제거하면 데이터 생성 가능”
- 생성 문제를 denoising 문제로 변환

10. 주요 수식과 코드 핵심 요약

- **Forward sampling**

```
x_t=sqrt(alpha_t)*x_0+sqrt(1-alpha_t)*noise
```

- **Training**

```
loss= (noise-model(x_t,t))**2
```

- **Sampling**

```
for t in reversed(range(T)):  
    x_t-1 = denoise(x_t)
```

10. 공부 포인트

- 이 논문이 중요한 이유: Stable Diffusion, DALL·E 등 기반 기술
- 핵심 연결 개념
 - Score Matching
 - Langevin Dynamics
 - Variational Inference
- 확장 방향
 - Latent Diffusion (속도 개선)
 - Conditional generation (text-to-image)