



11주차 과제

⚙ Status	In progress
📁 Task type	

1. CLIP

1. Abstract — 해결하려는 문제

- 기존 컴퓨터 비전 문제:
 - 고정된 클래스(label set)만 예측
 - 새로운 개념 → 추가 데이터 필요
- 해결:
 - 👉 이미지 + 자연어 쌍으로 학습
- 목표:
 - 👉 자연어를 통해 새로운 task를 바로 수행 (zero-shot)

2. Introduction — 연구 동기

- NLP:
 - 대규모 텍스트 → 범용 모델 성공
- CV:
 - 여전히 라벨 기반 학습 (ImageNet 등)
- 👉 핵심 아이디어:
 - 이미지 학습을

👉 자연어 supervision으로 확장

- 이유:
 - 자연어는 훨씬 다양한 개념 표현 가능

3. Related Works — 기존 한계

방법	문제
ImageNet supervised	클래스 제한
Weak supervision (hashtags 등)	표현 제한
Caption prediction	학습 비효율

👉 CLIP 차별점:

- 자연어를 그대로 사용
- 특정 label set에 묶이지 않음
- 더 넓은 generalization 가능

4. Method — 모델 구조

구조

- Image Encoder (ResNet / ViT)
- Text Encoder (Transformer)

👉 두 encoder를 동시에 학습

핵심 Objective

👉 **contrastive learning**

- 같은 (image, text) → similarity ↑
- 다른 쌍 → similarity ↓

👉 batch에서 $N \times N$ pair 비교

학습 방식

- cosine similarity 계산
 - temperature scaling 적용
 - symmetric cross entropy loss 사용
-

5. 핵심 이론

Contrastive 학습 의미

- 모델이 배우는 것:
👉 "이 이미지와 이 문장은 같은 의미인가?"
-

Zero-shot 분류 방식

- 클래스 이름을 문장으로 변환:
👉 "a photo of a dog"
 - 이미지와 가장 유사한 문장 선택
-

핵심 포인트

- 👉 classifier를 따로 학습하지 않음
 - 👉 텍스트 encoder가 classifier를 생성
-

6. Experiments — 실험

데이터

- 약 4억 개 image-text pair 사용
-

결과

- ImageNet zero-shot:
👉 기존 supervised ResNet-50 수준 달성
- 30개 이상의 dataset에서:

👉 좋은 일반화 성능

특징

- task-specific 학습 없이도:
👉 다양한 비전 task 수행 가능
-

7. Discussion — 장단점

장점

- zero-shot 가능
 - 라벨링 비용 감소
 - 다양한 task에 적용 가능
 - 높은 generalization
-

단점

- 대규모 데이터 필요
 - 자연어 bias 영향
 - 학습 비용 큼
-

8. Conclusion

- 기존 CV paradigm:
👉 "라벨 → 분류"
 - CLIP:
👉 "자연어 → 의미 이해"
-

9. 기존 대비 차별점

항목	기존 CV	CLIP
supervision	label	자연어
task	고정	유연
classifier	별도 학습	텍스트로 생성
generalization	낮음	높음

10. 핵심 아이디어

👉 “이미지와 텍스트를 같은 공간에서 이해한다”

11. 코드 구조 (핵심)

```
# embedding
image_emb = image_encoder(image)
text_emb = text_encoder(text)

# similarity
logits = image_emb @ text_emb.T

# loss
loss = cross_entropy(logits)
```

🔥 최종 한 줄 요약

👉 CLIP = 이미지와 텍스트를 함께 학습하여, 자연어만으로 다양한 비전 작업을 수행하는 모델

2. SAM

📌 1. Abstract — 해결하려는 문제

- 기존 segmentation 문제:
 - task마다 **별도 모델 필요 (semantic / instance / panoptic 등)**
 - 데이터 부족 (mask 데이터는 웹에 거의 없음)
 - generalization (새 데이터/새 task)에 약함

👉 해결 목표:

- 모든 **segmentation**을 하나의 모델로 처리
- **prompt 기반**으로 다양한 task 해결 (**zero-shot**)

👉 핵심:

- “**Segment Anything**” = 범용 segmentation foundation model 구축
 - **1B masks + 11M images** 데이터셋 구축 (SA-1B)
-

2. Introduction — 연구 동기 & 문제점

문제

- NLP는 GPT 같은 **foundation model** 등장
- CV는:
 - CLIP처럼 일부만 generalization 가능
 - segmentation은 여전히 **task-specific**

👉 핵심 문제:

1. 어떤 task가 generalization을 가능하게 하는가?
 2. 어떤 모델 구조가 필요?
 3. segmentation 데이터 부족 문제
-

아이디어

👉 segmentation도 NLP처럼:

- **prompt 기반 문제로 재정의**
-

3. Related Works — 기존 연구 한계

기존 segmentation 방법들

- semantic segmentation
- instance segmentation
- panoptic segmentation
- interactive segmentation

👉 문제:

- 각각 따로 학습 필요
 - **task generalization 없음**
-

foundation model 관련

- CLIP:
 - text prompt로 zero-shot 가능
 - BUT segmentation은 못함

👉 결론:

- segmentation에서는 아직 **foundation model 없음**
-

4. Method — 핵심 접근 & 모델 구조

(1) 핵심 아이디어

👉 segmentation을 이렇게 바꿈:

| **!** “무엇을 분할할지 prompt로 지정 → mask 출력”

👉 즉:

- segmentation = **prompt** → **mask 함수**
-

🔥 (2) Task 정의

Promptable Segmentation Task

입력:

- point / box / mask / text

출력:

- 해당 객체의 segmentation mask

👉 특징:

- ambiguous prompt도 처리 (여러 mask 출력 가능)
-

🔥 (3) 모델 구조 (SAM)

구조는 3개:

1 Image Encoder

- ViT 기반 (MAE pretrained)
 - 이미지 → embedding
-

2 Prompt Encoder

- point / box → positional encoding
 - text → CLIP encoder
 - mask → CNN
-

3 Mask Decoder

- transformer 기반
- image + prompt → mask 생성

👉 특징:

- **50ms inference (real-time)**
-

핵심 구조 요약

Image → embedding
Prompt → embedding
→ 결합 → mask 출력

(4) Ambiguity 해결

- 하나의 prompt → 여러 mask 출력
- confidence score (IoU 예측)

(5) Loss

- focal loss + dice loss

(6) Data Engine (핵심 혁신)

 가장 중요한 부분

3단계:

1. manual + model assist
2. semi-automatic
3. fully automatic

 결과:

- 1.1B masks 생성

5. Experiments — 실험 & 결과

실험 구성

- 23개 segmentation dataset 평가
- zero-shot 테스트



결과

- 단일 point만으로도 높은 성능
- 기존 supervised 모델과 거의 동일 수준

👉 핵심:

- **zero-shot**인데도 SOTA급 성능
-



다양한 task 적용

- edge detection
- object proposal
- instance segmentation
- text → mask

👉 결론:

- 하나의 모델로 다양한 task 해결 가능
-



6. Discussion — 발견 & 한계



발견

- segmentation도 foundation model 가능
 - prompt 기반 generalization 가능
-



한계

- 완전한 understanding은 아님
 - 텍스트 prompt 성능 제한적
 - 작은 객체 / 어려운 경우 성능 저하
-

7. Conclusion — 결론 요약

- segmentation을 위한 첫 foundation model
- 대규모 dataset + promptable 구조
- zero-shot generalization 가능

👉 핵심 결론:

“segmentation을 범용 문제로 바꿨다”

8. 기존 연구 대비 차별점

기존	SAM
task-specific	범용
dataset 작음	1B masks
fine-tuning 필요	zero-shot 가능
고정 task	prompt 기반

9. 핵심 아이디어 (진짜 중요)

👉 한 줄 요약:

segmentation = prompt → mask 함수로 재정의

👉 더 본질적으로:

1. task 통합
2. prompt 기반 generalization
3. data engine으로 데이터 해결

10. 주요 수식 & 학습 방식

논문은 복잡한 확률식보다 구조 중심이라 핵심만:

학습 방식

- 입력: (image, prompt)
- 출력: mask

loss:

$$L = \lambda_1 * \text{Focal Loss} + \lambda_2 * \text{Dice Loss}$$

Mask prediction

```
Mask = Decoder(Image embedding, Prompt embedding)
```

Multi-mask

```
min loss over multiple masks
```

11. 코드/구현 관점 핵심

구조

```
image_emb = image_encoder(image)
prompt_emb = prompt_encoder(prompt)

mask = mask_decoder(image_emb, prompt_emb)
```

특징

- image embedding 재사용 (효율)
- prompt만 바뀌 여러 결과 생성

12. 공부 포인트 (중요)

이 논문 핵심 이해 포인트:

1 왜 prompt가 중요한가

- task를 하나로 통합 가능
-

2 왜 데이터 엔진이 중요한가

- segmentation 데이터 부족 해결
-

3 왜 foundation model인가

- fine-tuning 없이 일반화 가능
-

최종 한 줄 정리



“SAM은 segmentation을 ‘prompt 기반 함수’로 바꿔서, 하나의 모델로 모든 segmentation을 가능하게 만든 논문”
