

1

11주차: 멀티모달과 파운데이션 모델 CLIP & SAM

Learning Transferable Visual Models From Natural Language Supervision

Introduction

배경

NLP에서는 대규모 텍스트로 사전학습 → 다양한 작업에 바로 적용 성공함
그렇다면 이미지에서도 텍스트 기반 supervision으로 학습 가능할까?

⇒ 기존 연구 있긴 했지만 성능이 낮거나 데이터 규모가 작았음

해결방안

4억 개 이미지-텍스트 쌍으로 학습한 **CLIP** 제안

⇒ 다양한 작업에서 zero-shot 성능이 뛰어남을 보여주었다.

Approach




Figure 1. Summary of our approach. While standard image models jointly train an image feature extractor and a linear classifier to predict some label, CLIP jointly trains an image encoder and a text encoder to predict the correct pairings of a batch of (image, text) training examples. At test time the learned text encoder synthesizes a zero-shot linear classifier by embedding the names or descriptions of the target dataset's classes.

- CLIP은 Image Encoder와 Text Encoder를 공동으로 훈련시켜 (image, text) 훈련 예제의 정확한 쌍을 예측한다.
- 테스트 시간에 학습된 text encoder는 target data의 class name 또는 description을 포함함으로써 zero shot linear classifier를 합성한다.

Natural Language Supervision

핵심 접근 방식 : text의 supervision으로부터 image의 perception을 학습하는 방식

⇒ natural language를 training signal로서 이해하는 것이 핵심이기 때문에 **CLIP**에서는 이를 "natural language supervision"으로 부른다.

선행 연구들은 topic modeling과 n-gram 표현을 사용할 때 natural language의 복잡성 때문에 어려움이 있었지만, deep contextual representation learning은 이 풍부한 supervision source를 효과적으로 활용할 수 있는 도구가 있음을 제시한다.

자연어로부터의 학습의 장점

1. 일반적으로 image classification을 위한 crowd-sourced labeling보다 natural language supervision을 scaling하는것이 훨씬 쉽다.
⇒ "gold label" N개 중 하나를 투표하는 것과 같은 기존의 "machine learning compatible format"으로 특별한 annotation을 필요로 하지 않기 때문이다.
대신, 자연어에 작용하는 방법은 인터넷상의 방대한 양의 텍스트에 포함된 supervision으로 부터 수동적으로 배울 수 있다.
2. representation을 "단순히 학습"하는 것이 아니라 representation을 다른 language와 연결한다는 점(word2vec)에서 zero-shot transfer 역시 가능하게 한다.

Creating a Sufficiently Large Dataset

기존의 연구들은 주로 세 가지의 데이터셋을 사용하였다.

- MS-COCO : 높은 품질의 crowd-labeled dataset이지만 10만개 정도의 이미지
- Visual Genome : 높은 품질의 crowd-labeled dataset이지만 10만개 정도의 이미지
- YFCC100M : 다양한 품질의 1억장의 이미지 → (쓸만 한 것을) 필터링하면 600 ~ 1500만개 정도 (ImageNet과 비슷)

⇒ 다른 컴퓨터 비전에서 사용하는 데이터셋의 크기에 비해 데이터셋 너무 작음. 그래서 35억개의 인스타그램 사진을 이용해 학습하기도 함.

⇒ 본 연구에서는 새로운 데이터셋을 새로 만들었다. = **WebImageText, WIT**

약 4억개의 (image, text) 페어로 구성되어 있고 모든 데이터는 인터넷에서 수집한 데이터

- 데이터의 다양성을 얻기 위해, 5만 개의 텍스트 쿼리를 이용했으며, 하나의 쿼리에서 2만 개가 넘는 (image, text) 페어를 갖지 않도록 했다.

(즉, 쿼리를 이용해 텍스트-이미지 매칭을 한 뒤, 페어를 만들어주는데, 한 쿼리당 페어 이미지가 2만개를 넘지 않도록 함)

- 사용된 데이터셋의 총 단어 수는 GPT-2에서 사용된 WebText에서의 양과 유사하다.


Selecting an Efficient Pre-Training Method

기존의 연구에서는 ImageNet 데이터에서 단지 1000개 class 분류를 위해 매우 많은 GPU 메모리를 사용하였다. 따라서 본 연구에서는 효율적으로 학습하는 것이 중요한 조건이라 생각하고 이를 항상 고려하도록 하였다.

본 연구의 초기 접근 방법은, VirTex와 유사하게 이미지는 CNN으로, 텍스트는 transformer를 이용해 학습시키고 각각 이미지에 대해 이미지의 설명 텍스트(caption)를 예측하는 태스크를 수행했다. 그러나, 이 방법으로는 효과적으로 모델의 크기(scale)을 증가시키기 어려웠다.

⇒ 본 논문에서는 **이미지에 해당하는 텍스트를 예측하는 태스크를 수행할 때의 과정을 수정해 효율적인 학습이 가능하도록 했다.**


⇒ 기존의 방식에서는 텍스트 문장을 예측할 때 그 문장 그대로, 즉 단어의 순서까지 정확 맞추는 태스크로 학습했는데, 본 연구에서는 순서는 고려하지 않고 예측할 수 있도록 bag-of-words encoding을 사용해 contrastive learning을 했다.




⇒ 이를 통해 효율적인 학습 가능했음

학습 방식


(1) Contrastive pre-training



(2) Create dataset classifier from label text



(3) Use for zero-shot prediction



1. 기본적으로 배치 단위로 학습이 이뤄지는데, 예를 들어 배치 사이즈가 N 이라고 하면 N 개의 (image, text) 페어가 있는 것이다.
2. 텍스트는 Text Encoder를 이용해 벡터 값으로 표현되게 되고, 이미지는 Image Encoder를 이용해 벡터 값으로 표현되게 된다.
3. N 개의 텍스트 벡터와 N 개의 이미지 벡터 사이의 코사인 유사도를 구한다.
4. $N * N = N^2$ 개의 값이 나오는데 N 개는 실제 (image, text) 페어에서 나온 값이고 $N^2 - N$ 개는 다른 (image, text) 페어에서 나온 값이다.
5. 이 유사도 값을 이용해 Cross Entropy loss 값을 계산해 최적화 한다.

pseudocode


```

# image_encoder - ResNet or Vision Transformer
# text_encoder  - CBOW or Text Transformer
# I[n, h, w, c] - minibatch of aligned images
# T[n, l]       - minibatch of aligned texts
# W_i[d_i, d_e] - learned proj of image to embed
# W_t[d_t, d_e] - learned proj of text to embed
# t             - learned temperature parameter

# extract feature representations of each modality
I_f = image_encoder(I) #[n, d_i]
T_f = text_encoder(T)  #[n, d_t]

# joint multimodal embedding [n, d_e]
I_e = l2_normalize(np.dot(I_f, W_i), axis=1)
T_e = l2_normalize(np.dot(T_f, W_t), axis=1)

# scaled pairwise cosine similarities [n, n]
logits = np.dot(I_e, T_e.T) * np.exp(t)

# symmetric loss function
labels = np.arange(n)
loss_i = cross_entropy_loss(logits, labels, axis=0)
loss_t = cross_entropy_loss(logits, labels, axis=1)
loss   = (loss_i + loss_t)/2

```

Figure 3. Numpy-like pseudocode for the core of an implementation of CLIP.

- 본 연구에서 사용된 데이터셋의 개수가 많기 때문에 over-fitting 문제는 고려하지 않았다.
⇒ CLIP의 Text Encoder와 Image Encoder에서 다른 pre-trained weight나 ImageNet weight를 사용하지 않고 처음부터 학습시켰다.
- 이전의 연구들과 다르게 image와 text representation을 multi-modal embedding으로 보낼 때 non-linear projection을 하지 않고 linear하게 projection을 하였다.

Choosing and Scaling a Model

- Image Encoder로서는 ResNet-50과 ViT를 사용한다.
 - 둘 다 아주 약간의 수정 외에는 기존 모델을 거의 그대로 사용하였다.
- Text Encoder로는 transformer를 사용했는데, 8개의 Head와 12개의 layer를 사용하였고 max sequence length는 76으로 제한하였다.
 - CLIP는 text encoder의 용량에 덜 민감하기 때문에, ResNet의 계산된 너비 증가에 비례하도록 모델의 너비를 스케일링할 뿐 모델의 깊이는 스케일링하지 않는다.

Training

- CLIP에서는 5종류의 ResNets와 3 종류의 ViT 를 훈련시킨다.
- 모델 훈련 방식
 - 32epochs
 - 초기 하이퍼파라미터는 1epoch마다의 grid search와 random search의 조합을 사용하도록 설정
 - Adam Optimizer
 - Cosine schedule을 사용하여 학습률을 감소
 - mini batch의 크기: 32,768
 - 훈련을 가속화하고, 메모리를 절약하기 위해 Mixed-precision을 사용


Experiments

Zero-Shot Transfer

	aYahoo	ImageNet	SUN
Visual N-Grams	72.4	11.5	23.0
CLIP	98.4	76.2	58.5


Visual N-Grams vs CLIP

- 모든 데이터셋에 대해 CLIP 모델을 통해 성능이 향상된 것을 확인할 수 있다.



prompt engineering


- 여러가지 데이터셋에서 "A photo of a {label}"과 같은 형식의 prompt를 default로 사용
- ImageNet에서는 80개의 다른 prompt를 사용하는 것이 하나의 default prompt를 사용하는 것보다 3.5%의 성능향상
- 종합하면 prompt engineering을 사용함으로써 5% 정도의 성능 향상



Linear Probe 방식을 통해 fine tuning을 시킨 ResNet-50 모델과 여러가지 데이터셋에 대해 성능을 비교

- 총 27개의 데이터셋 중, 16개의 데이터셋에서 CLIP이 더 좋은 성능 보여줌
- CLIP이 더 약한 성능을 보인 데이터셋을 살펴보면 더 복잡하거나 추상적인 태스크를 가진 데이터셋이었음 (제일 성능 차이가 심한 EuroSAT은 인공위성 이미지를 분류하는 태스크임)




⇒ Supervised learning을 한 모델(ResNet-50)과 그렇지 않은 모델(CLIP)을 비교한 것이기에 CLIP에서 성능이 좋지 않다고 나온 태스크를 CLIP이 정말 못 한다고 단정지을 수는 없다.



추가로 zero-shot CLIP 모델을 few-shot 모델들과 비교

- SimCLR와 비교하면 16-shot SimCLR가 Zero-shot CLIP과 성능이 비슷한 것을 확인할 수 있음


Representation Learning



CLIP을 포함한 모든 모델에 Linear probe를 이용한 성능 비교

- 모든 크기에서 CLIP모델이 다른 모델보다 좋은 성능을 냈음

Robustness to Natural Distribution Shift



ImageNet 점수와 다른 태스크에서의 점수(Transfer Score)와의 비교 관계

- CLIP 모델은 다른 분포의 데이터에 대해서도 훨씬 견고함을 가진다고 볼 수 있음

Comparison to Human Performance

	Accuracy	Majority Vote on Full Dataset	Accuracy on Guesses	Majority Vote Accuracy on Guesses
Zero-shot human	53.7	57.0	69.7	63.9
Zero-shot CLIP	93.5	93.5	93.5	93.5
One-shot human	75.7	80.3	78.5	81.2
Two-shot human	75.7	85.0	79.2	86.1

5명을 대상으로 Oxford IIT Pets dataset에서 3669개의 이미지를 보고 37개의 class로 classification한 것

- Zero-shot에서 One-shot으로 갈 때는 유의미한 성능 향상이 있지만 One-shot에서 Two-shot으로 갈 때는 성능 변화가 미미하다.

⇒ 이것이 의미하는 것은 인간은 자기가 무엇을 알고 무엇을 모르는지 알고 있다는 것

Zero shot에서 몰랐던 내용 중 예시 하나만 주어져도(One-shot) 알게 되는 내용이 생기지만, 예시를 추가한다고 해서 더 알게 되지는 않은 것으로 보아 이렇게 추측한 것으로 이해했음

- CLIP은 이와 다르게 shot을 늘려갈수록 성능이 계속 증가한 것으로 보아, 알고리즘적으로 개선할 여지가 있다고 판단할 수 있음.

Limitations

- 특정 태스크에서는 CLIP이 여전히 좋지 않은 성능을 보인다.
특히 차의 모델 분류, 꽃의 종 분류 등 태스크가 복잡한(*fine-grained classification*) 경우 조금 더 성능 저하가 심했음.
- CLIP은 인터넷 상에서 가져온 (image, text) 페어를 통해 학습되었는데, 필터링이 되지 않았다는 문제가 있다. ⇒ social biases를 그대로 학습할 수 있는 문제가 있음
- CLIP 에서 zero-shot 성능을 더욱 상승시킬 수 있는 few-shot 방법에 대해 후속 연구가 필요.

Segment Anything

arxiv.org

<https://arxiv.org/pdf/2304.02643>

Introduction

배경

기존 방식) 작업마다 모델 따로 학습

Foundation Model) **Prompt Engineering**을 통해 현재 task에 대한 유효한 텍스트 응답을 생성하도록 구현 ⇒ 추가 학습 없이 바로 수행(Zero-shot)

← 데이터가 많아질수록, 모델이 커질수록, 연산량 많아질수록 일반화 능력이 계속 좋아짐



Foundation Model이란?

- 아주 큰 데이터로 미리 학습되어, 다양한 작업에 재사용할 수 있는 범용 AI 모델
- 여러 작업에 "기반(foundation)"이 되는 모델
- 먼저 대규모 데이터로 학습하고 이후에는 추가 학습 없이 (zero-shot) 또는 조금만 조정해서 (few-shot/fine-tuning) 다양한 문제를 해결할 수 있다.

그럼 이것 컴퓨터 비전에 적용한다면?

CLIP/ALIGN

- 웹의 텍스트와 이미지를 연결(align)하여 둘을 같은 의미 공간에 매핑한다.
- 학습방법) contrastive learning(대조학습)

텍스트와 이미지를 연결한 쌍을 비교하여 맞으면 가깝게, 틀리면 멀게 진행

⇒ 텍스트만으로 이미지를 이해할 수 있고, zero-shot도 가능해졌다. 다른 task에도 사용 가능해져서 인코더 활용하여 이미지를 생성할 수 있도록 하였다.

문제 제기


- 컴퓨터 비전에는 훨씬 더 많은 문제가 있었지만 그 중 하나는 데이터가 부족하다는 점이다.

텍스트-이미지 데이터는 많지만 segmentation 데이터는 거의 없다.



segmentation이란?

이미지에서 물체의 '정확한 영역'을 픽셀 단위로 나누는 작업



목표




"image segmentation을 위한 foundation model을 구축하자"

즉, 강력한 일반화를 가능하게 하는 task를 사용하여 광범위한 데이터셋에서 promptable model을 개발하고 사전학습하는 것을 추구한다. 이 모델을 통해 프롬프트 엔지니어링을 사용하여 새로운 데이터 분포에 대한 다양한 하위 segmentation 문제를 해결하는 것을 목표로 한다.

이를 개발하기 위해 image segmentation에 대한 해결할 다음 질문

1. Zero-shot 일반화를 가능하게 하는 task는 무엇인가?
2. 해당 모델 아키텍처는 무엇인가?
3. 어떤 데이터가 이 task와 모델에 힘을 실어줄 수 있는가?

아이디어



- (1) Task : 프롬프트 기반 segmentation 작업
- (2) Model : 데이터 주석(annotation)을 지원하고 프롬프트 엔지니어링을 통해 다양한 작업에 zero-shot transfer를 가능하게 하는 segmentation 모델 SAM
- (3) Data: 10억 개 이상의 mask로 이루어진 데이터셋 SA-1B를 수집하기 위한 데이터 엔진

Segment Anything Task

목표) “다음 토큰 예측” task가 foundation model 사전 학습에 사용되고 프롬프트 엔지니어링을 통해 다양한 하위 task를 해결하는 NLP에서 영감을 얻음 → Segmentation을 위한 foundation model을 구축하기 위해 유사한 능력을 가진 task를 정의하는 것

Task (프롬프트 기반 분할)

기존의 이미지 분할 AI는 "고양이를 찾아라", "자동차를 찾아라"처럼 미리 정해진 객체만 찾을 수 있었다. ⇒ 이 모델은 NLP 모델처럼 '**사용자의 프롬프트**'에 따라 작동

- **프롬프트의 형태:** 이미지 위의 점(Point), 대략적인 네모 상자(Box), 대충 칠한 마스크, 혹은 "강아지"라는 텍스트 등 무엇이든 될 수 있다.
- **모호성 해결 (유효한 마스크):** 만약 사용자가 사람의 '셔츠'에 점을 찍었다면, 이것이 셔츠를 의미하는지, 사람 전체를 의미하는지 모호할 수 있다. 모델은 이럴 때 에러를 내는 것이 아니라, 셔츠나 사람 중 **적어도 하나의 그럴듯한 결과물**을 출력해 내야 한다.



Pre-training (자동화와 모호성 대응)

대규모 데이터로 학습시키는 과정

- **시뮬레이션 학습:** 정답이 있는 이미지에 무작위로 점을 찍거나 박스를 치는 등 프롬프트를 가상으로 생성하여, 모델이 정답 마스크를 잘 맞히도록 학습시킨다.
- **인터랙티브 분할과의 차이점:** 기존의 인터랙티브 모델은 사용자가 점을 여러 번 찍으며 수정해 나가는 '인간' 위주의 방식이었다면, 이 모델은 단 하나의 모호한 프롬프트가 주어져도 **항상 그럴듯한 결과를 한 번에** 내도록 학습된다.
⇒ 사람이 직접 개입하지 않는 '자동화된 AI 시스템(데이터 엔진)'에서도 활용할 수 있음.

Zero-shot transfer (프롬프트를 통한 확장)

새롭게 학습(Fine-tuning)을 하지 않고도, 프롬프트만 잘 주면 처음 보는 작업도 해낼 수 있다.


- **예시 (고양이 분할):** 기존에 고양이의 '위치 상자(Box)'만 찾아주는 탐지기(Detector)가 있다고 가정해 보자면, 이 탐지기가 찾은 상자 좌표를 **이 분할 모델의 프롬프트로 입력**하면, 분할 모델은 그 상자 안의 고양이 '윤곽선(Mask)'을 완벽하게 따낸다.
⇒ 즉, 모델 하나로 프롬프트만 바뀌가며 수많은 실용적인 컴퓨터 비전 문제를 해결 가능

Discussion (AI 시스템의 조립과 확장성)

“프롬프트 방식”이 왜 좋은거냐?

- **결합성(Composition):** 프롬프트를 사용할 수 있다는 것은, 이 모델을 다른 AI 시스템의 '부품'처럼 연결해서 쓸 수 있다는 뜻이다.
(예: 텍스트 AI → 상자 탐지 AI → 분할 AI로 이어지는 파이프라인)
⇒ 이는 개발 당시에는 상상하지 못했던 전혀 새로운 목적(Unknown task)으로도 모델을 활용 가능
⇒ 사람만 쓸 수 있었던 기존 모델의 한계를 넘어, 알고리즘 시스템끼리 서로 프롬프트를 주고받으며 작동하는 거대한 AI 생태계를 만들 수 있음.

Segment Anything Model



핵심 구성요소


- **이미지 인코더 = 이미지를 압축된 특징으로 바꾸는 단계**
 - 역할: 이미지를 컴퓨터가 이해할 수 있는 벡터로 변환
 - 특징: 고해상도 이미지를 처리하기 위해 강력한 성능의 ViT(Vision Transformer) 구조를 사용, 이 작업은 연산량이 많지만, 이미지당 딱 한 번만 실행하면 됨.
- **프롬프트 인코더 = 모든 프롬프트를 같은 "벡터 공간"으로 변환하는 단계**
 - 역할: 사용자가 입력한 다양한 단서(점, 박스, 텍스트, 마스크)를 컴퓨터가 이해할 수 있는 벡터로 변환
 - 특징: 점이나 박스는 위치 정보로, 텍스트는 언어 모델(CLIP)을 이용해 변환, 기존 마스크 입력은 합성곱(Conv) 처리를 거쳐 이미지 특징과 합쳐짐.
- **마스크 디코더 = 프롬프트를 반영해서 이미지에서 해당 영역을 찾아내는 단계**
 - 역할: 이미지 + 프롬프트 → segmentation mask 생성
 - 과정
 1. Self-attention : 프롬프트끼리 관계 이해
 2. Cross-Attention : Prompt ↔ Image 관계 이해
 3. 이미지 임베딩 업샘플링 → 각 픽셀마다 객체일 확률 계산 → mask 출력

Resolving ambiguity(모호성 해결)

사용자가 강아지의 '목줄'에 점을 찍었을 때, 모델은 목줄을 원하는 건지, 강아지 전체를 원하는 건지 헷갈릴 수 있음.

⇒ SAM은 이를 해결하기 위해 **하나의 프롬프트에 대해 3개의 서로 다른 스케일의 마스크(예: 목줄, 강아지 머리, 강아지 전체)를 동시에 출력**

⇒ 각 마스크가 얼마나 정확할지 신뢰도 점수(IoU)도 같이 예측하여 순위를 매긴다.



IoU (Intersection over Union)이란?

예측 결과와 정답이 얼마나 겹치는지를 측정하는 값

$$\text{IoU} = \frac{\text{겹치는 영역}}{\text{전체 영역}}$$

Efficiency

무거운 '이미지 인코딩'은 서버에서 미리 계산

사용자가 클릭하거나 박스를 칠 때마다 작동하는 것은 가벼운 '프롬프트 인코더 + 디코더' 사용

⇒ 이 설계 덕분에 일반적인 노트북(CPU 환경의 웹 브라우저)에서도 **0.05초(50ms) 이내**에 마스크를 생성해 내며, 사용자가 버벅임 없이 실시간으로 상호작용할 수 있다.

Losses and training

Loss 함수 = focal loss + dice loss

- Focal Loss : 어려운 픽셀이 틀렸을 때 벌점을 아주 크게 줘서 어려운 부분에 집중하게 만듦.
- Dice Loss : 픽셀 하나하나를 따지는 것을 넘어, AI가 그린 마스크의 전체적인 덩어리가 정답 마스크와 얼마나 잘 포개어지는 평가하는 방식

▼ IoU와 Dice Loss의 차이점

IoU는 평가지표

⇒ 모델 성능 평가 (클수록 좋아)

Dice Loss는 학습에 더 적합한 지표

⇒ 겹치는 부분에 더 큰 가중치를 주는거

$$IoU = \frac{|A \cap B|}{|A \cup B|}$$

$$Dice = \frac{2|A \cap B|}{|A| + |B|}$$

⇒ 더욱 정교하게 mask를 생성할 수 있도록

학습

1. 기하학적 프롬프트의 혼합

화면에 점 하나만 찍거나, 박스를 치거나, 둘다 하거나 여러가지 프롬프트 생성
학습할 때부터 무작위로 점과 박스를 섞어서 입력 → 정답을 맞히도록 훈련

2. 11-round interactive 상황 시뮬레이션

- a. 1라운드 : 알고리즘이 무작위로 점 하나 찍어주면 SAM은 그 점을 보고 첫 번째 가
상마스크 생성
- b. 오차 확인: SAM이 그린 마스크 진짜 정답 마스크 비교
- c. 2~11 라운드 : SAM이 틀린 영역에 새로운 점을 꼭 찍어주면 기존 점들에 이 새로운
피드백 점까지 합쳐서 마스크 새로 생성 ⇒ 최대 11번씩 반복해서 마스크 깎기

⇒ 실제 사람들이 데이터 엔진에서 사용할 때 마우스 클릭 몇 번만으로도 사용자의 의도를
찰떡같이 알아채고 깔끔하게 이미지 분할 가능

Segment Anything Data Engine



왜 데이터 엔진이 필요한가?

segmentation 데이터는 거의 없으니깐 모델을 이용해서 데이터를 스스로 만들
어내자!

(1) Assisted-manual stage = 사람이 주도하고 초기 AI가 보조하는 단계

- **작업 방식:** 전문 작업자가 웹 브라우저에서 직접 점을 찍거나 지우개를 써서 객체를 분할
한다. 이때 SAM이 실시간으로 마스크(영역)를 그려주며 작업을 도와준다.
- **진행 과정:** 작업자는 눈에 띄는 객체부터 자유롭게 분할하고 데이터가 쌓일수록 SAM을
더 똑똑한 구조(ViT-H)로 6번이나 재학습시킨다.
- **결과**
 - 34초 → 14초로 확 줄었음.

- 한 이미지당 찾아내는 객체 수는 20개에서 44개로 늘었음.
이 단계에서 **430만 개의 마스크**를 수집했음.

(2) Semi-automatic stage = 쉬운건 AI가, 어려운 건 사람이 찾는 단계

- **작업 방식:** 1단계에서 학습된 AI가 이제 눈에 잘 띄는 확실한 객체들은 '자동'으로 먼저 마스크를 씌워놓는다.
- **사람의 역할:** 작업자는 AI가 찾아낸 것 외에, 구석에 있거나 눈에 잘 띄지 않는 자잘하고 어려운 객체들만 집중적으로 찾아 추가로 분할한다.
- **결과**
 - 남은 객체들이 찾기 어려운 것들이라 작업 시간은 다시 마스크당 34초로 늘어났음.
 - 마스크의 '다양성'이 크게 늘어났음.
총 5번 재학습하며 **추가로 590만 개(누적 1,020만 개)의 마스크**를 수집했음.


(3) Fully automatic stage = 사람 개입 없이 AI가 스스로 짚어내는 단계

- **작업 방식:** 1~2단계를 거치며 완벽에 가깝게 학습된 SAM이 이제 사람 없이 스스로 이미지를 분석한다.
- **어떻게? (그리드 기법):** 이미지 전체에 촘촘한 바둑판 모양(32×32 그리드)으로 수많은 점을 뿌리고 모델은 각 점이 가리키는 객체(부분, 하위 부분, 전체 등)를 모호성 없이 다 각도로 유추하여 마스크를 그린다.
- **필터링:** 생성된 수많은 마스크 중 신뢰도가 높고 안정적인 것만 골라내고, 중복되는 영역은 NMS(Non-Maximal Suppression)라는 기술로 깔끔하게 걸러낸다.
작은 객체는 이미지를 확대해서 한 번 더 꼼꼼히 찾는다.

? NMS란?

- 객체 감지 모델에서 겹치는 Bounding Box를 제거하여 최종 결과를 정리하는 기술
- 여러 후보 중에서 겹치는 상자들을 필터링하는 것인데 겹치는 상자들 중에서 가장 확률이 높은 상자를 선택 / 나머지는 제거

⇒ 모델의 출력을 간결하게 하고 중복된 결과를 제거함으로써 정확한 객체 감지 가능




• 결과

- 데이터셋에 있는 1,100만 장의 모든 이미지에 이 자동화 과정을 돌려, 마침내 **11억 개의 고품질 마스크 데이터(SA-1B)**를 완성

Segment Anything Dataset

▼ SA-1B 데이터셋



데이터 엔진으로 수집된 1,100만개의 다양한 고해상도 라이선스 및 개인 정보 보호 이미지와 11억 개의 고품질 segmentation mask로 구성된다.

⇒ 마스크의 99.1%는 자동으로 생성되었음

⇒ 저자들은 마스크 품질을 측정하기 위해 랜덤하게 선택된 500개의 이미지와 약 5만 개의 마스크를 주식 전문가들에게 개선해달라고 요청 → 주식 전문가들은 편집 도구를 이용하여 정교하게 품질을 개선 → 원래의 마스크와 개선된 마스크 사이의 IoU를 계산

⇒ 그 결과 94%의 마스크가 90% 이상의 IoU를, 97%의 마스크가 75% 이상의 IoU를 보임.

Mask properties





Figure 5: Image-size normalized mask center distributions.

SA-1B의 물체 중심의 공간적 분포를 다른 segmentation 데이터셋과 비교

⇒ SA-1B는 가장 유사하게 분산된 두 개의 데이터셋인 LVIS v1과 ADE20K에 비해 이미지 모서리의 범위가 더 넓은 반면 COCO와 Open Images V5는 중심 편향이 더 두드러진다.

⇒ SA-1B는 중심 편향도 해결하고 대충 넘겼을만한 사진의 구석이나 테두리에 잘려있는 물체들까지 기계가 살살이 뒤져서 마스크를 생성했다는 뜻.

⇒ 중앙에만 정답이 몰려있지 않고 화면의 좌우상하 모서리 끝까지 마스크 데이터가 아주 고르게 분포하는 완벽에 가까운 데이터셋이 탄생 ⇒ 다양한 위치에서도 잘 작동



데이터셋들을 크기로 비교

⇒ SA-1B는 이미지 당 마스크의 개수가 높음.

배경에 있는 아주 작은 사물들까지 모조리 다 분할해 두었다고 볼 수 있음

⇒ 중소형 크기의 마스크 더 많이 포함

미세한 디테일을 잡아낼 수 있는 데이터


⇒ 마스크의 오목함 분포 유사

단순한 타원형이 아닌 사람이 직접 정성 들여 딴 기존 데이터셋처럼 세세하게 만든 마스크

Segment Anything RAI Analysis

SA-1B 데이터셋과 SAM 모델을 사용할 때 발생할 수 있는 공정성과 편향 문제 분석

- SA-1B의 지리적/소득 수준 분포



	# countries	SA-1B		% images		
		#imgs	#masks	SA-1B	COCO	O.I.
Africa	54	300k	28M	2.8%	3.0%	1.7%
Asia & Oceania	70	3.9M	423M	36.2%	11.4%	14.3%
Europe	47	5.4M	540M	49.8%	34.2%	36.2%
Latin America & Carib.	42	380k	36M	3.5%	3.1%	5.0%
North America	4	830k	80M	7.7%	48.3%	42.8%
high income countries	81	5.8M	598M	54.0%	89.1%	87.5%
middle income countries	108	4.9M	499M	45.0%	10.5%	12.0%
low income countries	28	100k	9.4M	0.9%	0.4%	0.5%

유럽, 아시아/오세아니아, 중간 소득 국가 비율 높음 ⇒ 특정 지역 쏠림 방지

아프리카와 저소득 국가는 적음

⇒ SA-1B의 경우, 아프리카를 포함한 모든 지역이 최소 2,800만 개 이상의 마스크를 포함

⇒ 기존 어떤 데이터셋의 총 마스크 수보다도 10배 이상 많은 수준

- 사람과 관련된 민감 속성 (성별, 나이, 피부톤) 에 대한 공정성

mIoU at			mIoU at		
	1 point	3 points		1 point	3 points
<i>perceived gender presentation</i>			<i>perceived skin tone</i>		
feminine	54.4 ± 1.7	90.4 ± 0.6	1	52.9 ± 2.2	91.0 ± 0.9
masculine	55.7 ± 1.7	90.1 ± 0.6	2	51.5 ± 1.4	91.1 ± 0.5
<i>perceived age group</i>			3	52.2 ± 1.9	91.4 ± 0.7
older	62.9 ± 6.7	92.6 ± 1.3	4	51.5 ± 2.7	91.7 ± 1.0
middle	54.5 ± 1.3	90.2 ± 0.5	5	52.4 ± 4.2	92.5 ± 1.4
young	54.2 ± 2.2	91.2 ± 0.7	6	56.7 ± 6.3	91.2 ± 2.4

랜덤하게 1개 또는 3개의 포인트를 샘플링한 interactive segmentation 방식

⇒ 성별 간 성능 차이 거의 없음

⇒ 어린 연령대와 노년층이 대규모 데이터셋에서 과소 대표되는 경향이 있는데 노년층에서 성능이 가장 좋았음 (But, 신뢰구간이 커서 확실하진 않음)

⇒ (숫자가 클수록 어두운거) 피부톤 차이로 인해 큰 성능 차이 많이 없음.

⇒ 이러한 결과가 segmentation task의 특성에서 기인한 것으로 보고 있고 SAM이 더 큰 시스템의 구성 요소로 사용될 경우 편향이 발생할 가능성은 여전히 존재함을 인정.

⇒ 마지막으로 의류 segmentation에 대한 분석도 수행) 성별 표현에 따른 편향의 징후 일부 관찰

Zero-Shot Transfer Experiments





Figure 8: Samples from the 23 diverse segmentation datasets used to evaluate SAM's zero-shot transfer capabilities.


SAM의 zero-shot transfer 능력을 평가하기 위해 사용된 23개의 다양한 데이터셋의 샘플들

Zero-Shot Single Point Valid Mask Evaluation



23개의 데이터셋에 대하여 mIoU를 측정하고 RITM과 그 결과를 비교한 그래프

Zero-Shot Edge Detection



BSDS500 에서 zero-shot으로 edge를 예측한 예시

method	year	ODS	OIS	AP	R50
HED [108]	2015	.788	.808	.840	.923
EDETR [79]	2022	.840	.858	.896	.930
zero-shot transfer methods:					
Sobel filter	1968	.539	-	-	-
Canny [13]	1986	.600	.640	.580	-
Felz-Hutt [35]	2004	.610	.640	.560	-
SAM	2023	.768	.786	.794	.928

BSDS500에서 edge detection에 대한 zero-shot transfer 성능을 비교

Zero-Shot Object Proposals


method	all	mask AR@1000					
		small	med.	large	freq.	com.	rare
ViTDet-H [62]	63.0	51.7	80.8	87.0	63.1	63.3	58.3
<i>zero-shot transfer methods:</i>							
SAM – single out.	54.9	42.8	76.7	74.4	54.7	59.8	62.0
SAM	59.3	45.5	81.6	86.9	59.1	63.9	65.8

LVIS v1에서 object proposal 생성 성능을 비교한 표

Zero-Shot Instance Segmentation


method	COCO [66]				LVIS v1 [44]			
	AP	AP ^S	AP ^M	AP ^L	AP	AP ^S	AP ^M	AP ^L
ViTDet-H [62]	51.0	32.0	54.3	68.9	46.6	35.0	58.0	66.3
<i>zero-shot transfer methods (segmentation module only):</i>								
SAM	46.5	30.8	51.0	61.7	44.7	32.5	57.6	65.5

instance segmentation 결과를 나타낸 표



사람이 평가한 마스크 품질 rating을 나타낸 그래프


Zero-Shot Text-to-Mask



zero-Shot text-to-mask에 대한 정량적 결과

⇒ SAM은 간단하고 미묘한 텍스트 프롬프트에 대하여 동작할 수 있으며, 정확한 예측에 실패한 경우 추가 점 프롬프트로 예측을 도울 수 있다.

Ablations



데이터 엔진 단계, 학습 데이터 스케일링, 이미지 인코더 스케일링에 대한 ablation study 결과를 나타낸 그래프

Discussion

Foundation models

- **의의:** 최근 ChatGPT처럼 거대한 데이터로 학습해 다양한 목적에 쓸 수 있는 범용 AI를 '파운데이션 모델'이라고 부릅니다. 저자들은 SAM이 '**이미지 분할(Segmentation) 분야의 파운데이션 모델**' 역할을 할 것이라고 정의합니다.
- **차별점:** 기존의 파운데이션 모델들은 정답지 없이 스스로 학습하는 '자기 지도 학습(Self-supervised)'을 강조했습니다. 하지만 SAM은 데이터 엔진을 통해 얻어낸 11억 개의 정답지(SA-1B)를 이용한 **대규모 지도 학습(Supervised)**이 핵심 동력임을 강조합니다. 즉, 압도적인 양의 데이터가 있다면 지도 학습이 여전히 가장 강력한 무기라는 것을 증명했습니다.

Compositionality

- **의의:** SAM이 진정으로 빛을 발하는 부분입니다. SAM은 단독으로 쓰이기보다, **다른 AI 시스템의 '부품(레고 블록)'처럼 결합**되어 쓰이도록 설계되었습니다. 프롬프트만 주면 결과를 내놓기 때문에 연결하기가 아주 쉽습니다.
- **활용 예시:**
 - **3D 재구성:** 어떤 물체를 3D로 만들고 싶을 때, 먼저 SAM에게 물체를 올려내라고 지시한 뒤 3D 변환 AI로 넘길 수 있습니다.
 - **AR/VR 웨어러블:** 스마트 안경이 사용자의 시선(Gaze point) 위치를 인식하면, 그 좌표를 SAM에 프롬프트로 전달합니다. 그러면 SAM은 사용자가 쳐다보는 물체를 실시간으로 분할해 냅니다. 추가 학습(Fine-tuning) 없이도 이런 새로운 응용이 즉각적으로 가능합니다.

Limitations

SAM이 훌륭하긴 하지만, 완벽한 마법은 아니라고 솔직하게 한계를 밝힙니다.

- **디테일 부족:** 아주 미세한 구조물(거미줄, 머리카락 등)을 놓치거나, 엉뚱한 조각을 마스크로 잘못 인식(환각, Hallucination)할 때가 있습니다.
- **전문 모델과의 비교:** 사용자가 점을 수십 개씩 찍어가며 극도로 정밀하게 작업할 때는, 오히려 기존의 '인터랙티브 전용 모델'이 더 나을 수 있습니다. SAM은 정밀도보다는 '범용성'에 초점을 맞췄기 때문입니다.
- **실시간의 한계:** 프롬프트를 입력하고 마스크가 나오는 과정은 눈 깜짝할 새(실시간)지만, 처음에 이미지를 분석하는 '이미지 인코더'가 무거워서 전체 과정을 완벽한 실시간이라고 부르기엔 제약이 있습니다.
- **텍스트 프롬프트의 한계:** "강아지"라고 텍스트를 입력해서 분할하는 기능은 아직 실험적인 단계라 완벽하게 안정적이지 않습니다.
- **특화 도구의 벽:** 의료 영상 등 아주 좁고 전문적인 영역에서는 해당 데이터로만 깊게 학습한 전용 도구들이 당장은 SAM보다 성능이 좋을 수 있습니다.

Conclusion

- 저자들은 *****"이미지 분할 분야를 파운데이션 모델의 시대로 끌어올리기 위한 원대한 시도"*****였다고 이 프로젝트를 요약합니다.
- 완전히 새로운 개념인 **'프롬프트 기반 분할 태스크'**, 이를 구현한 **'SAM 모델'**, 그리고 세계 최대 규모의 *****SA-1B 데이터셋*****이 앞으로 컴퓨터 비전 연구의 탄탄한 포장도로 (pave the path)가 될 것이라는 자부심으로 논문을 마무리합니다.