

260205-4주차: CV 심화 - Transformer, BERT

Attention → Transformer → BERT

Transformer

Sequential ~ GRU

순차적인 데이터의 중요성 : 언어의 순서 중요성 - 단어의 순서에 따라 의미가 달라짐

이전 단계 단어를 토대로 다음 단어의 예측

(초기모델) n-gram : 순서와 빈도에 기반하여 확률 추정

↳ extremely == really를 다르게 이해(빈도의 차이 : 희소 문제)

NNLM

embedding의 표현 : 각 단어를 신경망에 넣고 유사한 의미끼리 엮음

고정된 길이만 받아들임

RNN

과거 정보를 hidden state로 계속 누적하여 전달

입력 길이의 제한이 없음 — 히든층 축적으로 인해 장기 의존성 학습의 어려움

LSTM&GRU

hidden state 외에 input/output/ update/ 등으로 발전

여전히 순차적이기에 데이터 처리가 어려움

필요한 정보!만 가져올 수는 없을까?

Seq2Seq :

구조

Encoder - Decoder 개념으로 도입

Decoder : 가장 그럴듯한 데이터 뽑기 + <SOS>

교사강요(Teacher's ~~ ,)

GT를 부여함으로써 안정적으로 학습이 되도록 수행
context로 도입하기 때문에, 입력길이와 출력길이가 달라도괜찮
하지만, 정보의 병목 발생

Attention

hidden state를 넘겨주어 (각 단어에 대한 hiddenstate를 Decoder로 전달)

연산과정

이전에 입력한 토큰을 넘겨줌


Attention Score로 정량화 및 softmax로 표준화

가중합을 토대로 context vector를 생성

↳ seq2seq는 컨텍스트 하나에 대해서만, attention은 하나의 단어마다 생성

Transformer

TRANSFORMER



encoder-decoder 구조 유지하고, 여러개가 쌓여있는 과정

각 단어를 순차적으로 받지 않음 - 모두 병렬적으로, 일괄적으로 연산

What is Attention

문장을 입력하면 embedding vector로 변환

Attention Value : Query + KEy + Value를 모두 포함해서 연산

Multi-head Attention

언어의 유사도만으로도 추정할 수 없기에

head마다 각각 다른 값을 만들어서,

문법/의미로 나누어서 언어를 여러 관점으로 파악하게 함

Decoder MASK

제약을 일부로 걸어서 치팅을 방지

Feed-Forward Networks

각 토큰별로 비선형적인 함수를 포함한 변환을 함으로서 표현력 있게 변환

Residual Connection + Layer Normalization

집중!

정규화 진행

BERT

Bi-directional Encoder Representations from Transformaers

언어모델 위에 1개의 classification layer만 부착해서 수행

문장을 양방향에서 이해할 수 있도록 수행

BERT transforemer의 encoder만 사용

1 Input Sequence

1 orignal Text

2 토큰형식으로 쪼개서 더 이해

3 스페셜 토큰 2개를 넣어서 더 많은 이해

2 embedding

3 encoder

4 Pre-Training

MLM : Masked Language Model

- 양방향 이해를 예측할 수 있도록 함

일부로 마스크를 넣어서

실제 단어 분포에 따라 학습할 수 있도록 함

NSP : Next Sentence Prediction

- 두 문장이 연속된 문장이진 아닌지 이진 분류

5 Fine-Tuning for NLP Tasks