

boaz 1주차 과제

Improving Language Understanding by Generative Pre-Training

1. Abstract

자연어 이해는 문장 관계 추론, 질의응답, 의미 유사도 분석, 문서 분류 등 다양한 작업을 포함한다. 그러나 이러한 작업을 수행하기 위해서는 대량의 라벨링된 데이터가 필요하며, 실제로는 라벨 데이터가 부족한 경우가 많다.

이 논문은 unlabeled text를 활용하여 언어 모델을 사전 학습한 후, 특정 작업에 대해 지도 학습 기반의 **fine-tuning**을 수행하는 방법을 제안한다. 이를 통해 하나의 일반적인 모델을 다양한 자연어 이해 작업에 효과적으로 적용할 수 있음을 보였다.

2. Introduction

자연어 처리 분야에서 대부분의 딥러닝 모델은 지도학습에 의존하며, 이를 위해 많은 양의 라벨링된 데이터가 필요하다. 그러나 다음과 같은 문제가 존재한다.

1) 라벨 데이터 부족 문제

대규모 텍스트 데이터는 풍부하게 존재하지만, 특정 작업에 맞게 라벨링된 데이터는 매우 제한적이다. 라벨링 작업은 시간과 비용이 많이 소요되기 때문에 데이터 확보가 어렵다.

2) 비지도 학습 표현의 활용 어려움

기존 연구에서는 단어 임베딩을 활용하여 비지도 데이터를 사용하려는 시도가 있었지만, 대부분 단어 수준의 정보만을 전달할 뿐 문장 수준이나 문맥 수준의 의미를 충분히 반영하지 못했다.

3) 전이 학습 방식의 불명확성

기존 접근 방법에서는

- 각 task마다 다른 모델 구조를 설계하거나
- 복잡한 학습 방법을 적용하거나
- 추가적인 auxiliary objective를 사용해야 하는 문제가 있었다.

이 논문은 이러한 문제를 해결하기 위해 대규모 비지도 텍스트로 언어 표현을 학습한 뒤 이를 다양한 자연어 이해 작업에 전이하는 방법을 제안한다.

3. Related Works

논문에서는 자연어 처리에서의 semi-supervised learning과 pre-training에 대한 기존 연구를 다음과 같이 정리하였다.

1) 단어 임베딩 기반 연구

Word2Vec, GloVe 등의 모델은 대규모 비지도 텍스트 데이터를 이용하여 단어 벡터를 학습하고 이를 다양한 NLP 작업에 활용하였다. 그러나 이러한 방법은 주로 단어 수준의 의미 정보만 전달한다는 한계가 있었다.

2) 문장 표현 학습 연구

Skip-thought, sentence embeddings 등 문장 단위 표현을 학습하는 방법이 연구되었다. 이러한 방법은 문장 의미를 벡터로 표현할 수 있었지만 다양한 NLP 작업에 대한 전이 성능은 제한적이었다.

3) 언어 모델 기반 사전 학습 연구

일부 연구에서는 언어 모델을 사전 학습한 후 특정 작업에 맞게 fine-tuning하는 방식을 사용하였다. 그러나 대부분 LSTM 기반 모델을 사용했기 때문에 긴 문맥을 처리하는 데 한계가 있었다.

이 논문에서는 이러한 문제를 해결하기 위해 Transformer 기반 언어 모델을 사용하여 더 긴 문맥 정보를 효과적으로 학습하도록 설계하였다.

4. Method

논문에서 제안한 방법은 두 단계 학습 구조로 이루어진다.

4.1 Unsupervised Pre-training

첫 번째 단계에서는 대규모 비지도 텍스트 데이터를 이용하여 language model을 학습한다.

목표는 이전 단어들을 기반으로 다음 단어를 예측하는 것이다.

$$L_1(U) = \sum \log P(u_i | u_{i-k}, \dots, u_{i-1})$$

이 과정에서 모델은 텍스트의 문법, 문맥, 의미 관계 등을 학습하게 된다.

사용된 모델 구조

논문에서는 Transformer decoder 구조를 사용하였다.

구성 요소

- Token embedding
- Positional embedding
- Multi-head self-attention
- Feed-forward layer
- Softmax output layer

Transformer 구조는 긴 문맥 정보를 효과적으로 처리할 수 있어 언어 모델 학습에 적합하다.

4.2 Supervised Fine-tuning

두 번째 단계에서는 사전 학습된 모델을 특정 자연어 이해 작업에 맞게 fine-tuning한다.

입력 문장은 Transformer를 통과하여 마지막 hidden representation을 생성하고, 이를 이용하여 분류 결과를 예측한다.

$$P(y | x_1, \dots, x_m) = \text{softmax}(h_m W_y)$$

또한 fine-tuning 과정에서 언어 모델 objective를 보조 목적으로 함께 사용하여 학습 안정성과 일반화 성능을 향상시켰다.

4.3 Task-specific Input Transformation

자연어 이해 작업마다 입력 구조가 다르기 때문에 이를 하나의 토큰 시퀀스로 변환하는 방법을 사용하였다.

예시

- **Textual entailment**
premise + delimiter + hypothesis
- **Sentence similarity**
두 문장의 순서를 모두 고려하여 입력
- **Question answering**
document + question + candidate answer

이 방식은 모델 구조를 크게 변경하지 않고 다양한 작업에 적용할 수 있도록 한다.

5. Experiments

5.1 Pre-training Dataset

사전 학습에는 **BooksCorpus dataset**을 사용하였다.

- 약 7,000권의 책으로 구성
- 다양한 장르 포함
- 긴 문맥 정보를 포함한 텍스트 데이터

이러한 데이터는 모델이 긴 문맥 정보를 학습하는 데 도움이 된다.

5.2 모델 설정

모델 구조

- 12-layer Transformer
- Hidden dimension: 768
- Attention heads: 12
- BPE vocabulary 사용

5.3 평가 데이터셋

논문에서는 다음과 같은 자연어 이해 작업을 평가하였다.

Task	Dataset
Natural Language Inference	SNLI, MultiNLI

Task	Dataset
Question Answering	RACE
Semantic Similarity	STS-B, QQP
Text Classification	SST-2, CoLA

5.4 실험 결과

제안된 방법은 총 12개의 데이터셋 중 9개에서 최고 성능을 달성하였다.

- Story Cloze Test: 약 8.9% 향상
- RACE Question Answering: 약 5.7% 향상
- GLUE benchmark: 기존 대비 약 4점 향상

이 결과는 사전 학습된 언어 모델이 다양한 자연어 이해 작업에 효과적으로 전이될 수 있음을 보여준다.

6. Discussion

주요 발견

1) 사전 학습의 중요성

사전 학습 없이 모델을 학습할 경우 성능이 크게 감소하였다. 이는 언어 모델 pre-training 이 자연어 이해 성능 향상에 중요한 역할을 한다는 것을 의미한다.

2) Transformer 구조의 효과

Transformer 기반 모델은 LSTM 기반 모델보다 긴 문맥 정보를 효과적으로 처리할 수 있으며, 실제 실험에서도 더 높은 성능을 보였다.

3) Zero-shot 능력

언어 모델은 일부 작업에 대해 별도의 학습 없이도 일정 수준의 성능을 보였다. 이는 사전 학습 과정에서 다양한 언어적 지식을 학습했기 때문이다.

한계점

- 사전 학습 데이터가 BooksCorpus에 제한되어 있다.
- 모델 규모가 비교적 작은 편이다.

- 멀티태스크 학습을 적용하지 않았다.

7. Conclusion

이 논문은 generative pre-training과 discriminative fine-tuning을 결합한 자연어 이해 프레임워크를 제안하였다.

대규모 비지도 텍스트 데이터를 이용하여 언어 모델을 사전 학습하고 이를 다양한 자연어 이해 작업에 전이함으로써 높은 성능을 달성하였다.

실험 결과 제안된 방법은 여러 자연어 이해 데이터셋에서 기존 모델보다 우수한 성능을 보였으며, 비지도 학습을 활용한 전이 학습의 가능성을 보여주었다.

8. 기존 연구 대비 차별점.

1. 하나의 모델을 다양한 NLP 작업에 적용할 수 있는 task-agnostic 구조를 제안하였다.
2. Transformer 기반 언어 모델을 사용하여 긴 문맥 정보를 학습하였다.
3. 비지도 학습과 지도 학습을 결합한 pre-training + fine-tuning 구조를 통해 성능을 향상시켰다.

DeepSeek-R1: Incentivizing Reasoning Capability in Large Language Models via Reinforcement Learning

1. Abstract

최근 LLM은 다양한 작업에서 높은 성능을 보이지만 복잡한 추론 능력에서는 여전히 한계가 존재한다. 특히 수학 문제, 논리 문제, 장문의 추론 문제와 같은 영역에서는 모델이 안정적으로 올바른 reasoning chain을 생성하지 못하는 문제가 있다.

이 논문은 이러한 문제를 해결하기 위해 강화학습을 활용하여 모델의 추론 능력을 강화하는 방법을 제안한다.

특히 다음과 같은 목표를 가진다.

- 모델이 복잡한 reasoning 과정을 스스로 탐색하도록 학습
- Chain-of-Thought와 같은 장기 추론 패턴을 자연스럽게 생성

- 인간이 작성한 reasoning 데이터에 크게 의존하지 않고 RL 기반으로 reasoning 능력을 향상

이를 위해 DeepSeek-R1-Zero와 DeepSeek-R1 모델을 제안하고, 대규모 강화학습을 통해 모델의 reasoning 능력을 개선하였다.

2. Introduction

현재 대형 언어 모델은 다음과 같은 문제를 가진다.

1) 복잡한 추론 능력 부족

LLM은 일반적인 텍스트 생성이나 질문 응답에서는 높은 성능을 보이지만, 다음과 같은 문제에서는 성능이 제한적이다.

- 수학 문제
- 논리적 추론
- 다단계 reasoning

이는 모델이 긴 reasoning chain을 안정적으로 생성하기 어렵기 때문이다.

2) 인간 데이터 의존 문제

기존 방법에서는 모델의 reasoning 능력을 향상시키기 위해 다음과 같은 접근을 사용하였다.

- Chain-of-Thought 데이터 수집
- 인간이 작성한 reasoning 과정 학습

하지만 이러한 방법은

- 데이터 수집 비용이 높고
- 확장성이 제한적이라는 문제가 있다.

3) 강화학습 활용의 어려움

강화학습을 LLM에 적용할 경우 다음과 같은 문제가 발생한다.

- reward 정의가 어렵다
- reward hacking 발생 가능
- 학습 안정성이 낮다

따라서 효율적인 RL 기반 reasoning 학습 방법이 필요하다.

3. Related Work

1) Chain-of-Thought Prompting

Chain-of-Thought는 문제 해결 과정을 단계적으로 설명하도록 모델을 유도하는 방법이다.

장점

- reasoning 성능 향상

단점

- 사람이 작성한 reasoning 데이터 필요
- generalization 제한

2) Reinforcement Learning 기반 방법

최근 연구에서는 RL을 활용하여 모델의 reasoning 능력을 향상시키려는 시도가 있었다.

예

- RLHF
- process reward model
- search-based reasoning

하지만 이러한 방법들은

- reward 설계 어려움
- 학습 비용 증가
- reward hacking

등의 문제가 있었다.

4. Method

논문은 reasoning 능력을 향상시키기 위한 다단계 학습 파이프라인을 제안한다.

4.1 DeepSeek-R1-Zero

DeepSeek-R1-Zero는 순수 RL 기반 reasoning 모델이다.

특징

- supervised fine-tuning 없이 RL로 학습

- 모델이 reasoning 전략을 스스로 탐색

이 과정에서 모델은 다음과 같은 행동을 학습한다.

- self-verification
- reflection
- reasoning chain 생성

이러한 행동은 강화학습 과정에서 자연스럽게 나타난다.

4.2 Multi-Stage Training Pipeline

논문에서는 RL과 SFT를 결합한 다단계 학습 구조를 제안한다.

학습 단계

1. Cold start data 수집
2. RL 기반 reasoning 학습
3. Rejection sampling
4. Supervised fine-tuning
5. 추가 RL alignment

이 과정에서

- RL → reasoning 능력 탐색
- SFT → 안정적인 출력 학습

을 수행한다.

4.3 Reward Model

강화학습을 위해 모델의 답변을 평가하는 reward mechanism이 필요하다.

논문에서는 다음 두 가지 방법을 사용한다.

1) Rule-based reward model

정답이 명확한 문제에서는

- 수학
- 논리 문제

규칙 기반 reward를 사용한다.

2) LLM-based evaluation

정답 비교를 위해 다른 LLM을 활용하여

- reasoning 과정
- 최종 답

을 평가한다.

5. Experiments

논문에서는 다양한 reasoning benchmark에서 성능을 평가하였다.

대표적인 벤치마크

- 수학 문제
- 논리 문제
- 코드 문제
- instruction following

주요 결과

DeepSeek-R1은 다음과 같은 성능 향상을 보였다.

- AlpacaEval 2.0: 25% 성능 향상
- ArenaHard benchmark: 17% 향상

6. Discussion

주요 발견

1) reasoning 능력은 RL 과정에서 자연스럽게 발생

강화학습을 통해 모델은 다음과 같은 행동을 학습하였다.

- self-verification
- reflection
- chain-of-thought reasoning

이러한 행동은 별도의 지도 데이터 없이 RL 과정에서 자연스럽게 등장하였다.

2) 어려운 reasoning 문제와 충분한 compute가 중요

논문은 다음 요소가 reasoning 모델 학습에 중요하다고 강조한다.

- 어려운 reasoning 문제
- reliable verifier
- 충분한 compute

한계점

1) 구조화된 출력 능력 부족

DeepSeek-R1은

- tool 사용
- structured output

측면에서 기존 모델보다 제한적이다.

2) Token 효율성 문제

모델은 문제 난이도에 따라 reasoning 길이를 조절하지만

- 간단한 문제에서도 과도한 reasoning이 발생하는 경우가 있다.

3) 언어 혼합 문제

모델은

- 영어
- 중국어

에 최적화되어 있어 다른 언어 처리에서 language mixing 문제가 발생할 수 있다.

4) Reward hacking 가능성

강화학습에서는 reward 모델의 취약점을 이용하는 reward hacking 문제가 발생할 수 있다.

7. Conclusion

논문은 DeepSeek-R1과 DeepSeek-R1-Zero라는 reasoning 중심 LLM을 제안하였다.

핵심 결론은 다음과 같다.

- 대형 언어 모델은 이미 reasoning 잠재력을 가지고 있다.
- 강화학습을 통해 이러한 능력을 효과적으로 끌어낼 수 있다.
- 복잡한 reasoning 행동은 RL 과정에서 자연스럽게 등장할 수 있다.

즉, reasoning 모델 개발에서 대규모 인간 데이터보다 RL 기반 탐색이 중요한 역할을 할 수 있다는 것을 보여준다.

8. 핵심 아이디어

이 논문의 핵심 아이디어는 다음과 같다.

1. LLM은 이미 reasoning 잠재력을 가지고 있다.
2. 강화학습을 통해 이러한 능력을 탐색하고 강화할 수 있다.
3. RL과 SFT를 결합한 학습 파이프라인을 통해 안정적인 reasoning 모델을 만들 수 있다.