

260305-8주차 : Deepseek

DeepSeek

사전지식

PPO : 강화학습 알고리즘

Policy Model - 학습대상 : Reference/Reward/Value 을 통해 Advantage 부여

GRPO : DeepSeek의 강화학습 알고리즘

Value 모델의 제거 : 여러개의 답변을 생성해서 상대적으로 좋은 답변을 생성

배경

Reasoning

: CoT -

: Few-shot Examples -

확장성 : 인간이 직접 데이터를 만든다? 너무 많은 비용이 든다

인간이 직접 가르쳐야만 할까?

Introduction

모델의 스스로 Reasoning 수행

가독성+언어 Mixing

GRPO : Group Relative Policy Optimization

학습 비용을 절감하기 위한 방법

일반적인 강화학습에서 Policy 모델과 동일한 크기를 가지는 Value 모델을 생략하고, 그룹 점수

생성된 답변중 좋은거는 +, 나쁜거는 -

Prompt 템플릿 - Reasoning 먼저 수행하도록

Reward Design

Rule-Based 2가지 규칙 시스템 적용


정확도 보상

형식 보상 : 응답 형식의 강제 - /think 토큰 사용

훈련할수록 Reasoning 길이가 길어진다

버전

3. DeepSeek-R1



SFT : 지도학습 기반 파인튜닝

실험

Cold-start 데이터 규모가 적음

AlpacaEval2.0

Aider-Polyglot