

260305-8주차 : GPT

GPT-1

등장배경

RNN / LSTM : 텍스트(순차 데이터)의 기울기 소실 문제의 발생 + 게이트 구조 도입

Seq2Sep : Encoder-Decoder 구조로

Transformer : RNN 없이 Self-Attention

Encoder

: Multi-Head Self-Attention - 단어 간 연관성

: FFN

: Residual Connection

Introduction

지도학습의 한계

라벨 없는 텍스트 : " 뭘 목표로 학습해야 좋은 표현이 생기는가"

학습한 표현을 다른 태스크로 표현

제안

2-stage 학습 : 조금만 바뀌어도 많은 태스크로 옮겨지는 표현

Pre-trained(태스크 분류) 후에 Fine-tuning(태스크별로 수행)

배경

지도/비지도/준지도 학습 : 라벨의 유무

준지도학습 - 라벨없는 데이터로 특징 만들기 - Word Embedding(단어 벡터) - 단어 수준 정보로만 옮김

사전학습을 통한 일반화 → NLP를 넘어 이미지/음성 부문 등으로 확장

모델의 한계

LSTM 기반의 한계 를 잡는 Transformer : 더 긴 언어 구조를 잘 이해

보조 학습

비지도 학습을 넘어, NLP Task를 한 모델에서 함께 학습
즉, 메인 테스크를 학습하며 다른 목표를 학습하는 것

“앞 문맥을 보고 다음 단어 확률의 최대값을 구하기”

Unsupervised Pre-training : 비지도 사전학습과 지도 미세 조정

03 Framework		
Textual Entailment (자연어 추론) 문제 구조 - 추론(premise) p - 가설(hypothesis) h 중간에 구분자 토큰 $\$$ 추가 $[p \\$ h]$ 두 문장을 이어붙여 하나의 시퀀스로 만든다.	Similarity (문장 유사도) 문제 구조 - 두 문장 A, B의 유사도를 판단. - 하지만 A, B는 순서가 없음. 두 가지 순서를 모두 처리 $[s_1 \\$ s_2]$ $[s_2 \\$ s_1]$ 각각 모델에 통과시켜 벡터를 얻고 더한 뒤 선형층(linear layer)에 입력한다.	Question Answering (질의 응답) & Commonsense Reasoning(상식 추론) 문제 구조 문서 z, 질문 q, 후보 답들 $\{a_k\}$ 각 후보마다 하나의 시퀀스 생성 $[z \\$ q \\$ a_k]$ 후보가 4개면 → 모델을 4번 실행. 각 시퀀스에서 점수 계산 → 후보들 사이에서 softmax → 가장 확률 높은 답 선택.

실험

책데이터 : BooksCorpus

Transformer의 Decoder 부분을 떼옴

fine-tuning

특정 태스크를 위해 따로 한개 아니라 하나의 LLM으로 설정

실험 Task 4가지

NLP : 자연어추론

QA :

Sentence Similarity :

Classification :

분석

Q1 : 레이어를 많이 가져올 수록 좋은가?

Q2 : LM이 오래 학습할수록 zero-shot 능력이 좋은가?

Future Work

task-specific model → General Language Model

GPT-1

GPT-2

: LM 자체가 multitask learner 가 될 수 있는가?

: Scaling : 태스크별 fine-tuning 없이도 zero-shot setting을 수행 가능하다

GPT-3

: 모델을 엄청 크게 만들면 task learning 없이도 가능한가 → Decoders:96 X Input

Token : 2056으로 늘려

: In-Context Learning : 의미를 스스로 이해해서 fine-tuning이나 구조 변화 없이