

LoRA : 발표 대본

1 Prefix-Tuning 설명 (대본 추가 요청)

여기서 사용하는 special token은 일반적인 단어 토큰과는 조금 다릅니다.

이 토큰들은 모델이 원래 가지고 있던 vocabulary에 포함된 단어가 아니라, **새롭게 추가된 토큰**입니다.

그리고 이 토큰들은 **학습 가능한 embedding vector**를 가지고 있습니다.

즉 실제 단어 의미를 표현하는 토큰이 아니라 **모델을 특정 task에 맞게 조정하기 위한 파라미터 역할**을 합니다.

다시 말해 입력 문장 앞이나 중간에 이러한 토큰을 추가하고 **이 토큰들의 embedding만 학습함으로써 모델을 task에 적응시키는 방식**이 Prefix-Tuning입니다.

2 Prefix Tuning의 한계 (GPT-3 실험)

Prefix tuning에서는 special token을 너무 많이 사용할 경우 오히려 성능이 크게 감소하는 현상이 관찰됩니다.

실제 실험에서는 prefix-embedding tuning에서 **256개 이상의 token**, prefix-layer tuning에서는 **32개 이상의 token**을 사용할 때 성능이 크게 떨어졌습니다.

이는 너무 많은 special token이 입력 분포를 pre-training 데이터 분포에서 멀어지게 만들기 때문으로 추정됩니다.

3 Prefix-Tuning 실험 설정 설명

GPT-2 실험에서는 Prefix-Tuning 논문의 실험 설정을 그대로 사용하여 비교가 공정하게 이루어지도록 했습니다.

실험은 RoBERTa, DeBERTa, GPT-2와 같은 언어모델에서 시작하여, 최종적으로는 **175B 규모의 GPT-3 모델**까지 확장됩니다.

또한 자연어 이해(NLU)와 자연어 생성(NLG) 모두를 포함하는 다양한 task에서 성능을 평가합니다.

즉 dataset, hyperparameter, training setup을 동일하게 맞춘 상태에서 LoRA의 성능을 비교합니다.

4 RoBERTa 실험 조건 설명

RoBERTa 실험에서는 기존 연구들과 공정하게 비교하기 위해 실험 조건을 동일하게 맞추었습니다.

구체적으로 모든 task에서 동일한 batch size를 사용하고 입력 sequence length를 128로 고정하여 Adapter baseline과 같은 환경에서 실험을 진행했습니다.

또한 Houlsby 논문의 설정을 그대로 따른 실험은 결과 표에서 **+ 기호로 표시**하여 구분했습니다.

5 Figure 2 설명 (GPT-3 실험 맥락)

Figure 2의 핵심 질문은 **LoRA가 초대형 모델에서도 full fine-tuning 수준의 성능을 유지할 수 있는가**입니다.

실험 결과 LoRA는 GPT-3 규모의 모델에서도 full fine-tuning과 거의 동일한 성능을 유지할 수 있음을 보여줍니다.

6 Transformer Fine-tuning 패러다임 설명

BERT와 GPT-2의 등장 이후 NLP에서는 새로운 학습 패러다임이 등장했습니다.

먼저 대규모 텍스트 데이터로 **pre-training**을 수행한 뒤, 특정 task 데이터로 **fine-tuning**을 수행하는 방식입니다.

이러한 방식은 task 데이터만으로 모델을 학습하는 것보다 훨씬 높은 성능을 보여주며, 현재 대부분의 NLP 모델 학습 방식의 표준이 되었습니다.

9. 논문에서 제시하는 연구 질문

논문에서는 LoRA의 특성을 이해하기 위해

세 가지 중요한 질문을 제시합니다.

첫 번째는

파라미터 수가 제한되어 있을 때 Transformer의 어떤 weight matrix를 업데이트하는 것이 가장 효과적인가입니다.

두 번째는

LoRA의 업데이트 행렬 ΔW 가 실제로 low-rank 구조를 가지는가입니다.

그리고 그렇다면 실제로 어떤 rank 값이 적절한지도 분석합니다.

세 번째는

LoRA가 학습한 업데이트 ΔW 와 기존 weight W 사이에는 어떤 관계가 있는가입니다.

7 Figure 3 설명 (Subspace similarity)

Figure 3에서는 rank 8과 rank 64 LoRA가 학습한 업데이트 방향을 비교합니다.

여기서 세로축 i 와 가로축 j 는 각각 몇 개의 주요 singular vector를 고려하는지를 의미합니다.

예를 들어 $i=10$ 이면 $r=8$ 모델에서 가장 중요한 방향 하나만을 의미하고, $j=30$ 이면 $r=64$ 모델에서 상위 세 개 방향이 만드는 공간을 의미합니다.

ϕ 값이 크다는 것은 $r=8$ 모델의 중요한 방향이 $r=64$ 모델의 상위 방향들이 만드는 공간 안에 잘 포함되어 있다는 뜻입니다.

이 실험의 목적은 두 모델이 완전히 같은 공간을 가진다는 것을 증명하는 것이 아니라, 작은 rank 모델도 큰 rank 모델이 학습한 핵심 방향을 이미 포함하고 있는지 확인하는 것입니다.

8 논문에서 제시하는 연구 질문 (Section 7)

논문에서는 LoRA의 특성을 이해하기 위해 세 가지 질문을 제시합니다.

첫 번째는 파라미터 수가 제한되어 있을 때 Transformer의 어떤 weight matrix를 업데이트하는 것이 가장 효과적인가입니다.

두 번째는 LoRA의 업데이트 행렬 ΔW 가 실제로 low-rank 구조를 가지는가이며, 그렇다면 어떤 rank가 적절한지에 대한 질문입니다.

세 번째는 LoRA가 학습한 업데이트 ΔW 와 기존 weight W 사이에는 어떤 관계가 있는가입니다.

9 Conclusion 핵심 메시지

LoRA는 기존 대형 언어모델의 대부분의 파라미터를 유지하면서 low-rank 업데이트만 학습하여 효율적으로 모델을 적응시키는 방법을 제안합니다.

이 방법은 inference latency를 증가시키지 않으면서도 높은 성능을 유지할 수 있으며, 대부분의 파라미터를 공유하기 때문에 여러 task 간 빠른 전환이 가능합니다.
