

RAG : 발표대본

1 Document 설명 (대본 추가 요청)

RAG에서는 Wikipedia 문서를 그대로 사용하는 것이 아니라 **chunk** 단위로 분할하여 입력합니다.

여기서 하나의 chunk는 **100개의 단어**로 구성됩니다.

이렇게 Wikipedia 문서를 분할하면 **총 약 2100만 개의 문서**가 생성되며,
이 문서들이 이후 **retrieval**의 대상이 되는 **knowledge base** 역할을 합니다.

2 Vector Search 설명

RAG는 질문과 관련된 문서를 찾기 위해 **Vector Search** 기반 **retrieval**을 사용합니다.

이때 ****MIPS(Maximum Inner Product Search)****를 사용하여 질문 벡터와 문서 벡터 간 유사도를 계산합니다.

그리고 가장 유사한 **Top-k** 문서를 선택하여 **generator**가 답을 생성하도록 합니다.

논문에서는 훈련 시 **k = 5 또는 10**개의 문서를 retrieval하여 사용합니다.

3 Open-domain QA 결과 설명

기존 QA 시스템인 DPR은 **retriever, re-ranker, extractive reader**로 구성된 **3단계 pipeline** 구조를 사용합니다.

반면 RAG는 **retriever**와 **generator**만으로 구성된 단순한 구조로도 높은 성능을 달성합니다.

또한 REALM이나 T5+SSM과 달리 **비용이 많이 드는 salient span masking pretraining** 없이도 강력한 성능을 보입니다.

특히 중요한 결과는 **정답이 retrieval된 문서에 존재하지 않더라도 모델의 parametric knowledge**를 활용하여 답을 생성할 수 있다는 점입니다.

4 Abstractive QA 설명

Abstractive QA는 문서에서 정답을 그대로 추출하는 방식이 아니라 새로운 문장을 생성하여 답변하는 방식입니다.

이 실험에서는 MSMARCO NLG dataset을 사용하며,

dataset에서 제공되는 **gold passage**는 사용하지 않고 RAG가 직접 **retrieval**을 수행하도록 설정했습니다.

또한 Wikipedia에 없는 질문의 경우 모델의 **parametric knowledge**를 활용하여 합리적인 답을 생성할 수 있습니다.

예를 들어 *****"What is the weather in Volcano, CA?"*****와 같은 질문이 이에 해당합니다.

5 Jeopardy Task 설명

Jeopardy는 어떤 엔티티에 대한 사실을 기반으로 그 엔티티를 맞추는 질문을 생성하는 형식의 **task**입니다.

예를 들어 **"The Sun Also Rises"**와 **"A Farewell to Arms"**라는 소설을 쓴 작가는 누구인가와 같은 질문이 생성될 수 있습니다.

이러한 질문은 **정확한 사실 기반 문장**으로 구성되기 때문에 외부 지식 **retrieval**이 중요한 **knowledge-intensive generation task**입니다.

6 Human Evaluation 방식 설명

생성된 질문의 품질을 평가하기 위해 **human evaluation**을 수행합니다.

평가자는 **정답과 두 개의 생성된 질문**을 보게 됩니다.

하나는 **BART**, 다른 하나는 **RAG 모델**이 생성한 질문입니다.

이후 평가자는 **Question A가 더 좋다, Question B가 더 좋다, 둘 다 좋다, 둘 다 좋지 않다** 중 하나를 선택합니다.

7 Figure 2 설명 (RAG-Token 동작)

Figure 2는 **RAG-Token**이 여러 문서를 활용하여 질문을 생성하는 과정을 보여줍니다.

예를 들어 "Sun"이라는 토큰을 생성할 때는 **The Sun Also Rises**를 포함한 문서가 선택되고,

이후 **"A Farewell to Arms"**를 생성할 때는 다른 문서가 선택됩니다.

하지만 책 제목의 첫 토큰 이후에는 retrieval의 영향이 줄어드는데,

이는 모델의 **parametric knowledge**만으로도 제목을 완성할 수 있기 때문입니다.

이 예시는 **retrieval memory**와 **parametric memory**가 함께 작동한다는 것을 보여줍니다.

8 Fact Verification

[Fact Verification]

Fact Verification은 주어진 주장이 Wikipedia에 의해 참인지, 거짓인지, 아니면 정보가 부족한지를 판단하는 태스크입니다. FEVER 데이터셋을 사용했습니다.

중요한 점은 어떤 문서가 근거인지 알려주지 않는다는 것입니다. 현실과 비슷하게 supervision 없이 RAG가 스스로 관련 문서를 찾아야 합니다.

결과를 보면 SotA보다는 성능이 약간 낮지만, SotA는 복잡한 파이프라인에 supervision이 필요한 반면 RAG는 스스로 evidence를 탐색합니다. Top1 retrieval 정확도가 71%, Top10은 90%로 높은 검색 성능을 보였습니다.

8 Conclusion 핵심 메시지

RAG는 ****모델 파라미터에 저장된 지식(parametric memory)****과 ****외부 문서 retrieval(non-parametric memory)****을 결합한 hybrid generation 모델입니다.

이러한 구조를 통해 기존 generation 모델보다 더 **factual**하고 구체적인 답변을 생성할 수 있습니다.

또한 **retrieval index**를 교체하는 것만으로도 모델의 지식을 업데이트할 수 있어 재학습 없이 최신 정보를 반영할 수 있습니다.