

260326-11주차 : CILP

arxiv.org

<https://arxiv.org/pdf/2103.00020>

Leraning Transferable VM From NL supervision : Contrasive Language Image Pretraining

1. OPAI 2021년

Image → Text : CLIP

DALL-E : Text → Image

2. ConVIRT : 근간

이미지 간 유사도 학습

ImageNET의 도메인 특화성을 줄이고, 대용량 데이터에 맞추었다

3. VirTex : 근간2

캡션을 생성하는

문장을 트랜스포머를 통해 직접 생성

주관식 → 객관식 : 이미지와 텍스트의 짝꿍

4. Dataset

기존의 데이터셋은 부정확성과 범주의 다양성이 적어서

웹에서 직접 끌어오는 WIT Dataset 자체 학습

5. 구조 이해

Encoder 두개 : Text와 Image

가운데(행과 열) 일치하는 것만 확대되게, 나머지는 최소화

6. Method

Efficient Pre-Traing Method

데이터의 특성 상 성능이 감소됨

그래서 prompt 처리를 해서 성능 약간 향상

동음이의어 처리

Ensemble of different context prompts

label 별로 prompt를 형성해서, 임베딩 공간에서의 처리

7. Zero - shot 성능의 극대화

ResNet VS. 테스트가 확실한 거에 대해 너무 큼

↳ 거리-추론이나 위성 사진 등 대분류가 뚜렷하지 않은 건에 대해서 분류율이 낮음

8. CLIP의 강건성

학습데이터와 외부데이터가 달라도 성능이 비슷함

분포에 특화된 학습은 강건성을 저하시킨다

9. VS 인간

인간은 few-shot 성능이 극대화되지만, CLIP이 그정도는 아님

10. CLIP이 오류패턴이 인간과 비슷하다

사전학습 데이터와 평가 데이터 간 겹치는 경우는 많이 없다

11. 한계

연산량이 많이 필요하다

세밀한 분류나 추상적 추론에 약하다

사람도 이런 실수 많이 함 🙌

- 늑대 vs 허스키 🐕🐕
- 표범 vs 치타
- 머핀 vs 치와와 (진짜 유명함ㅋㅋ)

🙌 CLIP도 똑같이

겉모양 + 의미가 비슷하면 헛갈림

✓ 핵심

- 픽셀 기반이 아니라
- **semantic(의미)** 기반 판단이라 생기는 오류

12. 사회적 팩터

인터넷 데이터다 보니 사회적편향이 그대로 학습됨