

260402-12주차 : TabPFN

<https://www.nature.com/articles/s41586-024-08328-6>

Q1. Attention 메커니즘으로 어떤걸 이해해?

TabNet → feature 선택을 위한 attention

TabPFN → 데이터 간의 관계를 이해하기 위한 attention

"이 test sample이 train data 중 어떤 패턴이랑 비슷하지?"

TabPFN은 attention을 사용하지만 feature가 아니라

"데이터 간 관계"를 보기 위해 사용한다

Q2. TabNet VS TabPFN

구분	TabNet	TabPFN
대상	feature	data sample
목적	feature 선택	데이터 간 관계
방식	sequential	global attention

Q3. 학습이 없는 TabPFN

이미 사전

(1) synthetic dataset 생성

- 랜덤 함수 생성

linear, nonlinear, noisy, categorical, interaction 등

▼ 어떤 데이터 학습하는가?

① Linear 관계

$$y = w_1x_1 + w_2x_2 + \dots$$

- 가장 기본적인 관계
- noise 포함

👉 선형 회귀 문제 대응

② Nonlinear 관계

$y = \sin(x), x^2, \exp(x), \text{piecewise}$ 등

👉 실제 데이터는 대부분 nonlinear

③ Feature Interaction

$y = x_1 * x_2$
 $y = x_1 + x_2^2$
 $y = f(x_1, x_2, x_3)$

👉 이게 진짜 중요

- 단일 feature ✖
- 조합 관계 ○

④ Noise / Uncertainty

$y = f(x) + \text{noise}$

- Gaussian noise
- heteroscedastic noise

👉 현실 데이터 반영

- 다양한 distribution 생성
- 이게 GT가 됨

(2) 반복 학습

dataset만 보고 prediction 맞추기

(3) TabPFN이 학습 알고리즘으로서 이해 가능

tabular foundation 모델 :

AI 역사 수동으로 설계된 구조들이 이제 end-to-end 학습으로 대체되어 가고 있따
정형데이터에도 가져와볼까?

데이터별로 특성이 다르다

domain specialiation 때문에

표 형식 데이터는 이상치와 다양한 척도의 데이터에서 해석하기 불가능 얘기가 있다

딥러닝 측면에서는 이질성으로 데이터 처리가 어려움

TabPFN에서는 최대 10000 샘플 X 500 특징에서 해석가능

ICL : 컨텍스트 학습

트랜스포머가 간단한 알고리즘을 해석할 수 있다

복잡한 알고리즘까지 가능~

Attention

양방향 어텐션 메커니즘 : sample간의 sample끼리의 학습

알고리즘을 데이터로부터 학습한다

데이터 생성(노이즈 생성)

-사전학습(컨텍스트로 PFN 학습 베이지안 알고리즘으로 완성)

-실제 예측(임의의 미지의 데이터셋에대해서 적용)

synthetic data 생성 : 노이즈 있는 데이터를 생성

1. 함수 f 샘플링
2. 입력 x 생성
3. $y = f(x)$ 계산
4. noise 추가 $\rightarrow \tilde{y}$

보조적 인과모델 : SCM

모델 내부에 학습

"하이퍼파라미터까지 포함해서 미리 학습해둔다"