


2026.03.12

논문1: Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks



1) RAG를 만들게 된 이유

기존 대형 언어모델(LLM)의 문제점이 있었음

-지식을 파라미터(가중치) 안에만 저장해서 업데이트가 어렵다

-왜 그런 답을 했는지 설명이 안 된다

-사실과 다른 내용을 그럴듯하게 생성하는 할루시네이션 문제

->외부 문서 데이터베이스에서 관련 정보를 검색한 뒤

LLM과 결합하여 답변을 생성하는 "RAG"를 제안함

Ex) "파라메트릭 메모리(모델 내부 지식) + 비파라메트릭 메모리(외부 위키피디아 검색)"

2) Methods

① 검색기 (Retriever) — DPR

- 질문을 BERT로 인코딩 → 위키피디아 2,100만 개 문서 중 관련 문서 K개 검색
- Maximum Inner Product Search(MIPS)로 빠르게 유사 문서 찾기


② 생성기 (Generator) — BART

- 검색된 문서 + 원래 질문을 합쳐서 최종 답변 생성
- 파라미터 4억 개짜리 seq2seq 트랜스포머


RAG-Sequence: 답변 전체를 생성할 때 같은 문서 하나를 계속 참조

RAG-Token: 각 토큰을 생성할 때마다 서로 다른 문서를 참조 가능 → 여러 문서에서 정보를 조합할 수 있음

Index hot-swapping : 재학습 필요없이 2016년 위키피디아 인덱스 → 2018년 인덱스로



논문 2: LORA: LOW-RANK ADAPTATION OF LARGE LANGUAGE MODELS



1) LoRA를 만들게 된 이유

대형 언어 모델(LLM)을 특정 태스크에 맞게 파인튜닝하려면 수백억 개의 파라미터를 전부 업데이트해야 함. -> 이는 시간과 비용, 메모리 면에서 현실적으로 매우 비효율적

2) 핵심 idea

모델이 새로운 태스크에 적응할 때, 실제로 필요한 가중치 변화는 낮은 랭크 구조를 가짐. 즉, 수천만 개짜리 행렬을 통째로 바꾸지 않아도 됨.

3) 수식

기존 파인튜닝은 사전학습된 가중치 W_0 를 직접 수정한다. LoRA는 대신 이렇게 분해한다:

$$W = W_0 + \Delta W = W_0 + BA$$

- W_0 : 사전학습 가중치 (고정, 학습 안 함)
- $B : d \times r$ 행렬
- $A : r \times k$ 행렬
- r : 랭크 (보통 4~64), $r \ll d, k$

예를 들어 4096×4096 행렬(약 1,600만 파라미터)에서 $r=8$ 이면 학습 파라미터가 약 65,000개로 줄어든다 — 250배 감소.

4) 장점 요약

항목	내용
파라미터 절감	수백억 → 수만~수십만 개만 학습
추론 오버헤드 없음	BA를 W_0 에 병합 → 레이턴시 변화 없음
어댑터 교체 가능	기본 모델 1개 + 태스크별 어댑터로 운용
안정적 학습	$B=0$ 초기화로 사전학습 성능 보존

+) 이후 발전

LoRA를 기반으로 다양한 변형

- QLoRA — 4비트 양자화 기반 모델에 LoRA 적용, VRAM 대폭 절감

- DoRA — 가중치를 크기와 방향으로 분해 후 적용
- AdaLoRA — 레이어별로 랭크를 동적으로 할당
- LoRA+ — A, B에 다른 학습률을 적용해 효율 향상