



카테고리 없음

[DeepSeek] 논문 리뷰

yuha933 2026. 3. 11. 21:43

1. Introduction

연구 배경

- 추론 능력의 중요성 : 추론 능력은 인간 지능의 핵심 요소이며, 수학 문제 해결, 논리적 추론, 프로그래밍과 같은 복잡한 인지 작업 수행이 필수적이다.
- 추론 능력 향상을 위한 방법론 등장 :
 - Chain-of-Thought(CoT) 프롬프팅을 사용하면, 모델이 중간 추론 과정을 생성하면서 복잡한 문제 해결 성능이 향상된다.
 - post-training 단계에서 multi-stop reasoning trajectory를 학습하면, 추가적인 성능 향상이 관찰된다.

기존 연구의 한계

- 인간 주석에 의존하기 때문에, 확장성이 제한되고, 동시에 인지적 편향이 도입될 수 있다.

- 모델이 인간의 사고 과정을 그대로 모방하도록 제한되기 때문에, 성능이 인간이 제공한 예시의 수준에 의해 제한된다.
- 인간 추론 패턴을 모방하도록 제한되어, 비인간적이고 더 효율적인 추론 전략을 발견하기 어렵다.

기존 연구의 수정 방향 및 한계

- 수정 방향 아이디어 : 인간 추론을 모방하는 것이 아니라 정답 기반 reward만 제공하여 자율적인 추론 학습을 유도하자 !!
- DeepSeek-R1-Zero
 - SFT 없이 RL만으로 추론 능력을 학습한다.
 - 최종 답의 정확도만 reward로 사용한다.
 - 추론 과정에는 제약을 두지 않는다.
- 한계
 - 가독성이 낮다.
 - 한 응답의 CoT 내부에서 영어와 중국어가 혼합되는 현상이 발생하기도 한다.
 - reasoning task에만 특화되어 있어.writing 및 general QA 성능이 제한된다.

DeepSeek-R1 제안

- DeepSeek-R1의 multi-stage training pipeline :
 - rejection sampling : RL 과정에서 생성된 다양한 reasoning trajectory 중 품질이 높은 reasoning 데이터만 선택해, 고품질 reasoning 데이터셋을 구축한다.
 - reinforcement learning (RL) : Group Relative Policy Optimization 기반 RL을 적용한다.
 - supervised fine-tuning (SFT) : rejection sampling으로 선별된 데이터를 활용하여 지도학습을 수행해, 모델의 출력 품질을 향상시키고 가독성, 언어 일관성, 일반적인 QA 및 writing 능력을 개선한다.

2. DeepSeek-R1-Zero

- DeepSeek-R1-Zero의 학습 방식 : SFT를 사용하지 않고, 오직 강화학습에만 의존하여 학습된다.

2.1 Group Relative Policy Optimization

GRPO

- DeepSeek-R1-Zero와 DeepSeek-R1을 학습하기 위해 사용하는 강화학습 알고리즘으로, PPO의 학습 과정을 단순화하고 자원 사용량을 줄이기 위해 제안되었다.
- 학습 방식 :
 1. 이전 정책으로부터 여러 개의 출력을 샘플링한다
 2. 이후 정책 모델을 다음 목적함수를 최대화하도록 최적화한다.
(목적함수의 의미 : 좋은 답변의 확률은 높이고, 나쁜 답변의 확률은 낮추면서, 모델이 갑자기 크게 변하지는 않도록 한다.)

$$\mathcal{J}_{GRPO}(\theta) = \mathbb{E}[q \sim P(Q), \{o_i\}_{i=1}^G \sim \pi_{\theta_{old}}(O|q)]$$
$$\frac{1}{G} \sum_{i=1}^G \left(\min \left(\frac{\pi_{\theta}(o_i|q)}{\pi_{\theta_{old}}(o_i|q)} A_i, \text{clip} \left(\frac{\pi_{\theta}(o_i|q)}{\pi_{\theta_{old}}(o_i|q)}, 1 - \epsilon, 1 + \epsilon \right) A_i \right) - \beta \mathbb{D}_{KL}(\pi_{\theta} || \pi_{ref}) \right),$$

목적 함수

※ KL divergence

- policy가 reference model에서 너무 멀어지는 것을 방지하는 수식이다.

$$\mathbb{D}_{KL}(\pi_{\theta} || \pi_{ref}) = \frac{\pi_{ref}(o_i|q)}{\pi_{\theta}(o_i|q)} - \log \frac{\pi_{ref}(o_i|q)}{\pi_{\theta}(o_i|q)} - 1,$$

※ Advantage :

- 답변들 사이의 상대적 품질을 학습시키는 수식이다.

$$A_i = \frac{r_i - \text{mean}(\{r_1, r_2, \dots, r_G\})}{\text{std}(\{r_1, r_2, \dots, r_G\})}.$$

학습 설정

- learning rate : 3e-6
- KL coefficient : 0.001
- sampling temperature : 1
- 토큰 길이 제한 : 32,768 tokens → 65,536 tokens
- 각 질문마다 16개의 출력을 샘플링한다.

학습 과정

- 총 10,400 training steps (약 1.6 training epochs)
- 각 step마다 32개의 질문, batch size = 512
- 400 step마다 reference model을 최신 policy로 업데이트한다.
- 훈련을 가속하기 위해 각 rollout에서 8,192 outputs 생성하고, 이를 16 mini-batch로 나누어 학습한다.

Prompt Template

- [추론 과정] - [최종 답] 을 생성하도록 요구한다.

```
<think> reasoning process </think>
<answer> final answer </answer>
```

2.2 Reward Design

rule-based reward

- Accuracy reward : 모델의 최종 답이 정답인지 여부를 평가한다.
- Format reward : 모델이 정해진 출력 형식을 따르도록 유도한다.

최종 Reward

```
Reward_rule = Reward_acc + Reward_format
```

Neural reward model을 사용하지 않는 이유

- reward hacking
- 추가 계산 비용
- 훈련 파이프라인 복잡도 증가

2.3. Incentivize Reasoning Capability in LLMs

학습 방식

- DeepSeek-R1-Zero는 DeepSeek-V3 base 모델 위에서 강화학습(RL)을 적용하여 학습된다.

- 모델의 추론 능력을 자연스럽게 관찰하기 위해 제약을 최소화한다. (reasoning 구조는 요구하되, 특정 reasoning 전략은 강제하지 않고, 내용에 대한 추가적인 규칙도 두지 않는다.)

성능 결과




Figure 1

- RL 학습을 통해 AIME 2024 benchmark 성능이 15.6%에서 77.9%까지 크게 향상되었다.
- self-consistency decoding을 적용하면 성능은 86.7%까지 향상되며, 이는 AIME insan 평균 성능을 크게 초과하는 결과이다.

학습 진행에 따른 특징적인 변화

- Thinking Time의 증가 : 훈련이 진행될수록 모델의 응답 길이가 점차 증가되며, 이는 모델이 더 많은 추론 과정을 탐색하고 있음을 의미한다.
- 고급 reasoning 전략 : 학습 과정에서 아래와 같은 고급 reasoning 전략을 자연스럽게 학습한다.
 - Reflective reasoning : 이전 reasoning을 다시 검토한다.
 - Alternative solution exploration : 여러 해결 방법을 탐색한다.
- Aha Moment : 모델이 자신의 reasoning을 다시 평가하고 수정하는 행동을 보이며, 연구에서는 이를 RL 기반 self-evolution 과정의 증거로 본다.

Question: If $a > 1$, then the sum of the real solutions of $\sqrt{a - \sqrt{a + x}} = x$ is equal to

Response: <think>

To solve the equation $\sqrt{a - \sqrt{a + x}} = x$, let's start by squaring both ...

$$(\sqrt{a - \sqrt{a + x}})^2 = x^2 \implies a - \sqrt{a + x} = x^2.$$

Rearrange to isolate the inner square root term:

$$(a - x^2)^2 = x^2 \implies a^2 - 2ax^2 + (x^2)^2 = a + x \implies x^4 - 2ax^2 - x + (a^2 - a) = 0$$

...

Wait, wait. Wait. That's an aha moment I can flag here.

Let's reevaluate this step-by-step to identify if the correct sum can be ...

We started with the equation:

$$\sqrt{a - \sqrt{a + x}} = x$$

First, let's square both sides:

$$a - \sqrt{a + x} = x^2 \implies \sqrt{a + x} = a - x^2$$

Next, I could square both sides again, treating the equation: ...

...

Table 2 : Aha moment를 확인해볼 수 있다.

DeepSeek-R1-Zero의 의의


- RL은 명시적인 reasoning instruction 없이도, 모델이 자율적으로 문제 해결 전략을 발전시킬 수 있도록 한다.

3. DeepSeek-R1

DeepSeek-R1-Zero의 한계

- 가독성이 낮다.
- 언어 혼합 문제가 발생한다.

DeepSeek-R1의 파이프라인



1. Cold-Start Data 수집 :

- conversational thinking process이면서 human-like reasoning을 가진 데이터를 수집한다.
- ► 모델이 초기 reasoning 스타일을 안정적으로 시작하도록 한다.

2. 첫 번째 RL :

- 알고리즘 : GRPO
- 추가 reward : Language consistency reward
→ target language 비율이 높을수록 reward 증가하는 구조이다.
- ► RL을 통해 reasoning 능력과 언어 일관성을 개선하고, language mixing 문제를 해결한다.

3. Rejection Sampling + SFT :

- rejection sampling을 거친 후, SFT를 수행한다. (reasoning data와 non-reasoning 데이터 모두 사용)
- ► reasoning 성능을 유지하면서, writing 능력을 향상시킨다.

4. 두 번째 RL :

- human preference alignment를 수행한다.
- ► helpfulness, harmlessness, reasoning refinement의 안정적인 성능을 기대한다.

3.1 Model-based Rewards

Helpful Reward Model

- 답변이 얼마나 유용한가 (66,000 pair)
 1. 각 response에 대해 score를 계산한다.
 2. 모델이 더 좋은 응답에 더 높은 score를 주도록 학습한다.
 3. 최종적으로 어느 응답이 더 좋은지 판단한다.

Safety Reward Model

- 답변이 안전한가 (106,000 prompt)

1. 모델이 응답 하나에 대해 안전 점수를 계산한다.
2. 각 응답에 대해 label을 붙여 binary classification를 진행한다.
3. 최종적으로 응답이 얼마나 안전한지 score로 평가한다.

3.2. Training Details

3.2.1. Training Details of the First RL Stage

목적

- 추론 능력 강화
- 언어 일관성 개선
- 모델의 reasoning 품질 향상

학습 설정

- 알고리즘 : GRPO
- 주요 하이퍼파라미터
 - learning rate: 3e-6
 - KL coefficient: 0.001
 - GRPO clip ratio ϵ : 10
 - sampling temperature: 1
- 각 step마다 32개의 질문, batch size = 512
- 400 step마다 reference model을 최신 policy로 업데이트한다.
- 훈련을 가속하기 위해 각 rollout에서 8,192 outputs 생성하고, 이를 16 mini-batch로 나누어 학습한다.

Language Consistency Reward

- language mixing 문제를 줄이기 위해 language consistency reward를 추가한다.
(reasoning data와 non-reasoning 데이터 모두 사용)

$$Reward_{language} = \frac{Num(Words_{target})}{Num(Words)}$$

3.2.2. Training Details of the Second RL Stage

목적

- 추론 능력 유지
- helpfulness 향상
- safety 향상
- human preference alignment

학습 데이터

- Reasoning Data
 - reward : rule-based reward
 - 대상 : math, coding, logical reasoning
- General Data
 - reeward : reward model 기반 reward

최종 reward

$$\text{Reward} = \text{Reward_reasoning} + \text{Reward_general} + \text{Reward_language}$$

학습 설정

- temperature = 0.7 제외하고는 first RL stage와 동일하다.
- 총 1700 training steps, 마지막 400 stps에는 instruction data, preference reward 적용한다.
 - reward model 기반 학습을 오해 하면, reward hacking이 발생하기 때문에 preference reward는 마지막 단계에서만 적용한다.

4. Experiment

Benchmark (Metric)		R1-Zero	R1-Dev1	R1-Dev2	R1-Dev3	R1
English	MMLU (EM)	88.8	89.1	91.2	91.0	90.8
	MMLU-Redux (EM)	85.6	90.0	93.0	93.1	92.9
	MMLU-Pro (EM)	68.9	74.1	83.8	83.1	84.0
	DROP (3-shot F1)	89.1	89.8	91.1	88.7	92.2
	IF-Eval (Prompt Strict)	46.6	71.7	72.0	78.1	83.3
	GPQA Diamond (Pass@1)	75.8	66.1	70.7	71.2	71.5
	SimpleQA (Correct)	30.3	17.8	28.2	24.9	30.1
	FRAMES (Acc.)	82.3	78.5	81.8	81.9	82.5
	AlpacaEval2.0 (LC-winrate)	24.7	50.1	55.8	62.1	87.6
	ArenaHard (GPT-4-1106)	53.6	77.0	73.2	75.6	92.3
Code	LiveCodeBench (Pass@1-COT)	50.0	57.5	63.5	64.6	65.9
	Codeforces (Percentile)	80.4	84.5	90.5	92.1	96.3
	Codeforces (Rating)	1444	1534	1687	1746	2029
	SWE Verified (Resolved)	43.2	39.6	44.6	45.6	49.2
	Aider-Polyglot (Acc.)	12.2	6.7	25.6	44.8	53.3
Math	AIME 2024 (Pass@1)	77.9	59.0	74.0	78.1	79.8
	MATH-500 (Pass@1)	95.9	94.2	95.9	95.4	97.3
	CNMO 2024 (Pass@1)	88.1	58.0	73.9	77.3	78.8
Chinese	CLUEWSC (EM)	93.1	92.8	92.6	91.6	92.8
	C-Eval (EM)	92.8	85.7	91.9	86.4	91.8
	C-SimpleQA (Correct)	66.4	58.8	64.2	66.9	63.7

Table 3

실험 결과

- RL은 reasoning 능력을 크게 향상시킨다.
- RL만으로는 general task가 부족하다.
- 일반 데이터 SFT가 필요하다.

5. Ethics and Safety Statement

6. Conclusion, Limitation, and Future Work

의의

- 인간 CoT 데이터 없이도 reasoning을 학습할 수 있다.
- reasoning 능력은 RL로 크게 향상된다.
- reasoning을 위한 핵심은 human data가 아니다.

한계

- 모델의 한계

- Structured Output 및 Tool 사용 부족
- Token Efficiency 문제
- Language Mixing
- Prompt 민감성
- Software Engineering Task 성능
- RL 방법론 자체의 한계
 - Reward Hacking

향후 연구 방향

- 더 강력한 Reward Model
- Tool-augmented Reasoning
- Verifiable Task 중심 RL 확장