



카테고리 없음

[GAN] 논문 리뷰

yuha933 2025. 5. 26. 00:37

Abstract

- 적대적 과정(adversarial process)을 통해 생성 모델을 추정하는 새로운 프레임워크 제안
→ 2개의 모델 동시에 훈련

- G : 데이터 분포를 학습하는 생성 모델
- D : 샘플이 훈련 데이터에서 온 것인지 G에 의해 생성된 것인지를 추정하는 판별 모델

⇒ 최소-최대 이인 게임

1. Introduction

- 지금까지 딥러닝의 가장 두드러진 성공 사례는 주로 판별 모델에서 !

↔ 생성 모델은 상대적으로 덜 주목받아 왔음 ...

- 이유

- 이유 1) 최대 우도 추정 및 관련 전략에서 발생하는 난해한 확률 계산을 근사화하는 것이 어렵기 때문
 - 최대 우도 추정 : 데이터가 주어졌을 때, 그 데이터를 가장 잘 설명할 수 있는 모델의 파라미터를 찾는 방법
 - 생성 모델의 경우 데이터의 잠재적인 변동성이나 모델의 복잡성 때문에 정확한 확률 계산이 힘들기 때문에 이 확률 계산이 복잡함 따라서 근사화해야 한다는 문제가 있음
- 이유 2) 선형 변환을 신경망 층에 적용하는 것이 생성 모델에서 효율적으로 사용되기 어렵기 때문
 - 왜냐하면 신경망에서는 일반적으로 비선형 활성화 함수를 적용하여 더 복잡하고 다양한 표현을 학습할 수 있는데 선형 유닛만 사용하면 표현 능력이 제한될 수 있음

⇒ 새로운 생성 모델 추정 방법을 제안함

- 적대적 신경망 프레임워크

- 생성 모델 VS. 판별 모델 구조
 - 두 모델이 점점 더 정교한 전략을 발전시키도록 유도
 - 결국 훈련 데이터와 생성된 데이터를 **구별할 수 없을 정도로 발전**하게 됨
- 다양한 모델과 최적화 알고리즘에 적용될 수 있는 특정 훈련 알고리즘 제공
 - 생성 모델이 **무작위 노이즈를 다층 퍼셉트론에 통과시켜 샘플 생성**
 - 판별 모델은 생성된 샘플과 실제 데이터를 비교하여 판별함
 - 이 과정을 반복하며 생성된 샘플은 점점 실제 데이터와 유사해짐
 - 판별 모델이 **MLP로 구성**되는 특수한 경우 탐구
 - 판별 모델 : 두 개의 분포를 구분하는 역할
 - MLP : 비선형적인 차이를 잘 구분할 수 있음
 - 효과적임
 - 두 모델 모두 **역전파 및 드롭아웃 알고리즘**을 사용하여 훈련할 수 있음
 - 생성 모델에서 **샘플을 생성할 때 순전파만** 사용하면 됨
 - 즉, 근사 추론이나 마르코프 연쇄를 사용할 필요가 없음
 - ∴ 생성 모델에서는 느리지만 정확한 샘플 생성보다 빠르고 유사한 즉 효율적인 샘플 생성에 더 중점을 두기 때문

2. Related work

- 비방향성 그래픽 모델
- 단일 비방향성 계층과 여러 방향성 계층을 포함하는 하이브리드 모델
- 로그 가능도를 근사하거나 경계하지 않는 대체 기준
- 노이즈 대비 추정
- 생성 기계를 훈련하는 방법
- 생성 확률적 네트워크

3. Adversarial nets

- 생성 모델과 판별 모델이 모두 다층 퍼셉트론일 때 가장 간단하게 적용될 수 있음

- 데이터 x 에 대한 생성 모델의 분포 p_g 를 학습하기 위해,

1. 입력 노이즈 변수 z 에 대한 사전 분포 $p_z(z)$ 를 정의

- z : 무작위로 샘플링되는 잠재 변수

2. 이를 데이터 공간으로 매핑하는 함수 $G(z; \theta_g)$ 를 설정

- G : 매개변수 θ_g 를 갖는 다층 퍼셉트론으로 표현되는 미분 가능한 함수
- 매핑: 잠재 변수 z 를 실제 데이터처럼 보이는 샘플로 변환하는 과정을 의미
- 샘플 생성
 - z : 노이즈 벡터로, 데이터의 특성은 담고 있지 않지만 실제 데이터 샘플을 생성할 수 있도록 하는 벡터
 - θ_g : 학습 가능한 파라미터로, 생성 모델이 데이터와 유사한 샘플을 생성하기 위해 조정해야 하는 값이며, 이 값이 최적화되면서 정교화해짐

3. 하나의 스칼라 값을 출력하는 두 번째 다층 퍼셉트론 $D(x; \theta_d)$ 를 정의

- $D(x)$: 입력 x 가 실제 데이터 분포에서 온 것인지, 생성 모델의 분포 p_g 에서 생성된 것인지를 나타내는 확률
- θ_d : 판별 모델을 학습시키기 위한 가중치와 편향으로, 판별 모델이 훈련 과정에서 점차적으로 데이터를 더 잘 구분할 수 있도록 최적화 됨

- 판별 모델 D 의 학습 목표

: 훈련 데이터와 생성 모델 G로부터 생성된 샘플 각각에 대해 **올바른 레이블을 부여할 확률**을 최대화하는 것

↔ 생성 모델 G의 학습 목표 : 최소화하는 것

- $\log(1-D(G(z)))$

: 생성된 샘플이 판별 모델에 의해 실제 데이터처럼 분류되도록 하는 손실 함수

- $D(G(z))$: 생성된 샘플 $G(z)$ 가 판별 모델에 의해 실제 데이터일 확률
- $1-D(G(z))$: 생성된 샘플이 실제 데이터가 아닐 확률

- 즉, D와 G는 다음과 같은 **미니맥스 이인 게임**을 수행함

- $\mathbb{E}_{x \sim p_{data}(x)} [\log D(x)]$: 실제 데이터가 들어왔을 때 그 데이터가 실제 데이터일 확률
- $\mathbb{E}_{z \sim p_z(z)} [\log (1 - D(G(z)))]$: 샘플이 실제 데이터인지 아닌지를 판별하는 값 (D는 최대화, G는 최소화 하려고 함)

$$\min_G \max_D (D, G) = \mathbb{E}_{x \sim p_{data}(x)} [\log D(x)] + \mathbb{E}_{z \sim p_z(z)} [\log(1 - D(G(z)))]$$

- 이론적으로 충분한 용량을 가진 G와 D를 사용할 경우 훈련 기준이 데이터 생성 분포를 복원할 수 있음

↔ 유한한 데이터셋에서는 오버피팅이 발생할 수 있음

⇒ ∴ **D를 k번 최적화한 후, G를 한 번 최적화하는 방식**으로 교대로 학습을 진행함

- 이렇게 하는 이유

: D가 G의 샘플을 제대로 구별할 수 있어야 G가 더 나은 샘플을 생성할 수 있음

→ 판별 모델 D가 먼저 충분히 학습되어야 함

→ G가 훈련 초기에는 샘플 생성이 잘 되지 않기 때문에 D가 먼저 잘 학습되어야 G가 실수 없이 피드백을 받을 수 있음

→ 그런 이유로 판별 모델의 학습은 k번 반복이 이루어짐

- 실제 훈련 과정에서, 다음 식은 G가 충분히 학습되도록 하기에는 기울기를 충분히 제공하지 못할 수 있음

- 문제

: 학습 초기에 G가 잘못된 분포 생성

→ D는 이 샘플들을 높은 확률로 거부함 (다시 말해서, 샘플과 훈련 데이터를 구분하기 쉬워짐)

→ 그런데, G의 훈련 목표는 D가 얼마나 잘 구별할 수 있는 지에 따라 업데이트 됨


- $D(G(z))$ 값이 1에 가까운 값을 가질 수 있음
- $\log(1-D(G(z)))$ 값이 포화 되어 기울기가 거의 0이 됨

⇒ 이를 해결하기 위해, G의 훈련 목표를 다음과 같이 변경할 수 있음

$$\max_G \log D(G(z))$$

- 기존 식 : D가 생성된 샘플을 가짜로 판별할 때 G가 그 샘플을 진짜처럼 보이게 만들려는 목표
- 수정한 식 : G가 D가 샘플을 진짜로 판단할 확률을 최대화하려고 하는 목표
 - G와 D의 동적 균형에서 동일한 고정점에 도달하지만, 학습 초기에 더 강한 기울기를 제공하여 보다 빠른 학습이 가능하게 함
 - 그니까 쉽게 말해서 기본적으로 처음에는 잘 안 맞는 게 당연하니까 처음에 안 맞을 때의 기울기를 더 높게 보려는 거 ~

- 그래프 설명



- (a) : 생성 모델의 분포가 실제 데이터 분포와 유사해지고, 판별 모델 D가 부분적으로 정확한 분류기를 형성함
- (b) : 판별 모델 D가 훈련 데이터와 생성된 데이터를 구별하도록 학습됨
 - 이 과정에서 D는 최적의 판별 기준인 $D^*(x)$ 로 수렴함
 - $D^*(x) = \frac{p_{\text{data}}(x)}{p_{\text{data}}(x) + p_g(x)}$
 - : p_{data} 와 p_g 는 상대적인 비율을 의미함 (확률 분포)
 - 다음 식을 통해 결과적으로 확률이 됨
- (c) : D의 기울기에 따라 $G(z)$ 가 실제 데이터로 분류될 가능성이 높은 영역으로 이동하도록 학습됨
- (d) : G와 D가 충분한 용량을 가지고 있다면, 학습이 진행될수록 생성 모델의 분포는 실제 데이터 분포에 수렴함

→ 이 경우, 판별 모델 D는 생성된 데이터와 실제 데이터를 구별할 수 없으며, $D(x) = \frac{p_g(x)}{p_g(x) + p_{\text{data}}(x)}$ 이 되어 더 이상 학습이 진행되지 않음

4. Theoretical Results

- 본 절에서는 비모수적 설정에서 이를 분석하며, 즉 무한한 용량을 가진 모델을 가정하여 확률 밀도 함수 공간에서 수렴성을 연구함

Algorithm 1 Minibatch stochastic gradient descent training of generative adversarial nets. The number of steps to apply to the discriminator, k , is a hyperparameter. We used $k = 1$, the least expensive option, in our experiments.

for number of training iterations **do**

for k steps **do**

- Sample minibatch of m noise samples $\{z^{(1)}, \dots, z^{(m)}\}$ from noise prior $p_g(z)$.
- Sample minibatch of m examples $\{x^{(1)}, \dots, x^{(m)}\}$ from data generating distribution $p_{\text{data}}(x)$.
- Update the discriminator by ascending its stochastic gradient:

$$\nabla_{\theta_d} \frac{1}{m} \sum_{i=1}^m \left[\log D(x^{(i)}) + \log (1 - D(G(z^{(i)}))) \right].$$

end for

- Sample minibatch of m noise samples $\{z^{(1)}, \dots, z^{(m)}\}$ from noise prior $p_g(z)$.
- Update the generator by descending its stochastic gradient:

$$\nabla_{\theta_g} \frac{1}{m} \sum_{i=1}^m \log (1 - D(G(z^{(i)}))).$$

end for

The gradient-based updates can use any standard gradient-based learning rule. We used momentum in our experiments.

4.1 Global Optimality of $p_g = p_{\text{data}}$

- 주어진 생성 모델 G에 대한 최적의 판별 모델 D를 고려함

Proposition 1

- 생성 모델 G가 고정되었을 때, 최적의 판별 모델 D는 다음과 같음

$$D^*(x) = \frac{p_{\text{data}}(x)}{p_{\text{data}}(x) + p_g(x)}$$

- 증명

: 주어진 생성 모델 G에 대해 판별 모델 D의 학습 기준은 다음을 최대화하는 것

$$V(G, D) = \int_x p_{data}(x) \log D(x) dx + \int_z p_z(z) \log(1 - D(G(z))) dz$$

- 판별 모델이 최적화해야 하는 목적 함수
 - 첫 번째 항 : 실제 데이터에서 샘플 x 를 뽑았을 때 판별 모델이 진짜라고 판단할 확률
 - 두 번째 항 : 생성 모델 G 가 만든 가짜 샘플 $G(z)$ 를 판별 모델이 가짜라고 판단할 확률

⇒ ∴ 생성 모델의 입장에서 전체 값을 최소화하도록 해야 함

$$V(G, D) = \int_x p_{data}(x) \log D(x) + p_g(x) \log(1 - D(x)) dx$$

- 위 식을 데이터 공간의 표현으로 변환하면, (↑)
 - 입력 데이터
 - 첫 번째 항의 x : 훈련 데이터에서 나온 샘플
 - 두 번째 항의 x : 생성 모델에서 생성된 샘플 ($x = G(z)$)
 - 함수 $y \rightarrow a \log(y) + b \log(1-y)$ 는 $[0,1]$ 범위에서 $a/(a+b)$ 에서 최댓값을 가짐
 → ∴ $f(y) = a \log(y) + b \log(1-y)$ 를 미분해서 함수의 기울기를 구하고 기울기가 0이 되는 지점을 찾아서 최댓값을 찾을 수 있는데 그게 $a/(a+b)$ 임
 ⇒ 따라서 위 식의 최적 해는 다음과 같으므로, 증명이 완료됨
 $D^*(x) = \frac{p_{data}(x)}{p_{data}(x) + p_g(x)}$

- 미니맥스 게임의 재구성

→ 판별 모델 D 의 학습 목표는 조건부 확률 $P(Y=y|x)$ 를 최대우도 추정하는 것과 같이 해석할 수 있음

($Y=1$ 은 x 가 p_{data} 에서 온 경우, $Y=0$ 은 x 가 p_g 에서 온 경우를 의미)

$$\begin{aligned} C(G) &= \max_D V(G, D) \\ &= \mathbb{E}_{x \sim p_{data}} [\log D_G^*(x)] + \mathbb{E}_{z \sim p_z} [\log(1 - D_G^*(G(z)))] \end{aligned}$$

⇒ 따라서 미니맥스 게임은 다음과 같이 표현할 수 있음

- 첫 번째 항
: 훈련 데이터에서 샘플을 뽑아 $D(x)$ 를 계산하고, 그 값을 로그 함수에 넣은 값
→ $D(x)$ 가 훈련 데이터 샘플을 진짜로 잘 판별하도록 만드는 항
- 두 번째 항
: 생성된 샘플을 D 가 어떻게 판별하는 지를 나타냄
→ D 가 생성된 샘플을 가짜로 잘 판별하도록 만드는 항

⇒ ∴ D 는 첫 번째 항을 최대화하고, 두 번째 항을 최소화하도록 학습

↔ G 는 두 번째 항을 최대화하도록 학습함

$$= \mathbb{E}_{x \sim p_{data}} \left[\log \frac{p_{data}(x)}{p_{data}(x) + p_g(x)} \right] + \mathbb{E}_{x \sim p_g} \left[\log \frac{p_g(x)}{p_{data}(x) + p_g(x)} \right]$$

⇒ 이를 데이터 공간에서 표현하면,

- 최대우도 추정 : 데이터의 분포를 추정할 때 사용되는 방법으로, 주어진 데이터에 대한 모델의 파라미터를 조정하여 데이터가 주어졌을 때 해당 모델이 가장 잘 맞는 확률 분포를 찾는 방식
- $D(x)$ 의 목표
: 훈련 데이터가 실제 데이터에서 온 것인지, 아니면 생성 모델 G 로부터 생성된 데이터 인지를 구별하는 것
 - $P(Y=1|x)$: x 가 실제 데이터에서 나올 확률
→ 훈련 데이터가 주어졌을 때 이 값을 최대화 하려고함
 - $P(Y=0|x)$: x 가 생성 모델로부터 나온 가짜 데이터일 확률
→ 생성된 데이터가 주어졌을 때 이 값을 최대화 하려고함

→ 비율을 최대화 하는 방식이 최대우도 추정의 접근법과 일치함

- 비율을 사용하는 이유 : 분포화 확률의 차이

Theorem 1

가상의 학습 기준 $C(G)$ 의 전역 최소값은 $p_g = p_{data}$ 일 때 유일하게 달성됨
이때, $C(G)$ 의 값은 $-\log 4$ 임

- 증명

$p_g = p_{data}$ 인 경우,

$$D_G^*(x) = \frac{p_{data}(x)}{p_{data}(x) + p_g(x)} \text{에서}$$

$$D_G^*(x) = \frac{1}{2} \text{가 성립함}$$

이를

$$C(G) = \mathbb{E}_{x \sim p_{data}} [\log \frac{p_{data}(x)}{p_{data}(x) + p_g(x)}] + \mathbb{E}_{x \sim p_g} [\log \frac{p_g(x)}{p_{data}(x) + p_g(x)}]$$

에 대입하면,

$$C(G) = \log \frac{1}{2} + \log \frac{1}{2} = -\log 4 \text{이 됨}$$

또한, $C(G)$ 가 이 값보다 작아질 수 없음을 보이기 위해,

$$C(G) = -\log 4 + KL(p_{data} || \frac{p_{data} + p_g}{2}) + KL(p_g || \frac{p_{data} + p_g}{2})$$

를 이용함

- 두 번째 항

: 실제 데이터 분포 p_{data} 가 평균 분포와 얼마나 차이가 나는지 계산하는 항

- 세 번째 항

: 생성된 데이터 분포 p_g 가 평균 분포와 얼마나 차이가 나는지 계산하는 항

→ 생성된 데이터가 실제 데이터를 더 잘 모방하도록 유도

- KL: 쿨백-라이블러 발산

(식은 젠센-샤넬 발산을 의미)

$$C(G) = -\log 4 + 2 * JSD(p_{data} || p_g)$$

- KL: 두 확률 분포 간의 차이를 측정하는 방법

→ 두 분포 간의 차이가 클수록 커지며, $p_g = p_{data}$ 일 때만 0이 됨

- 젠센-샤넬 발산: KL발산의 변형

(마찬가지로 두 분포 간의 차이를 측정하는데, KL 발산보다 대칭적이고 일반적인 방법)

→ 젠센-샤넬 발산은 KL발산을 두 번 사용해서 두 분포의 평균을 기준으로 분포 간의 차이를 계산함

⇒ 따라서 $C^* = -\log 4$ 는 전역 최소값이며, 유일한 해는 $p_g = p_{data}$ 임

4.2 Convergence of Algorithm 1

proposition 2

- G와 D가 충분한 용량을 갖고, 알고리즘 1의 각 단계에서 판별 모델 D가 주어진 G에 대해 최적값을 달성하며 p_g 가 아래의 기준을 따라 업데이트될 경우, p_g 는 p_{data} 로 수렴함

$$\mathbb{E}_{x \sim p_{data}} [\log D_G^*(x)] + \mathbb{E}_{x \sim p_g} [\log(1 - D_G^*(x))]$$

- 증명

위 식을 이용하여 $V(G, D) = U(p_g, D)$ 를 p_g 의 함수로 보면, $U(p_g, D)$ 는 p_g 에 대해 볼록하다

- V 는 목적 함수, U 는 판별 모델의 성능 함수
(동일한 함수는 아니지만, 같은 구조로 해석될 수 있음)
→ V 의 최적화가 U 의 최적화로 나타날 수 있음
- 볼록하다: p_g 가 변할 때 $U(p_g, D)$ 가 볼록한 형태로 변화한다는 뜻
- 볼록한 이유
: jensen-Shannon 발산과 연관되어 있기 때문에 항상 p_g 에 대해 볼록함을 보장함
- 특정 점에서 볼록 함수의 상한을 취한 경우, 해당 점에서의 도함수가 그 상한의 부분 도함수 내에 포함됨
→ p_g 를 최적의 D 에 대해 기울기 하강 방식으로 업데이트하는 것과 동일함
∴ 도함수라는 게 원래 함수의 변화율을 근사하는 값이기 때문
⇒ 따라서, 충분히 작은 업데이트를 사용하면 결과적으로 p_g 가 p_{data} 로 수렴함
(너무 큰 변화가 일어나지 않도록 천천히 매개변수 업데이트 크기를 작게 유지해서 진행)

- 결론

- 이론적으로, GAN의 최적화 과정은 적절한 조건하에서 생성 모델 p_g 가 실제 데이터 분포 p_{data} 를 정확히 복제하도록 학습될 수 있음을 보임
- 다만, 실제로는 G 를 다층 퍼셉트론으로 정의하는 경우 다중 극소점 문제가 발생할 수 있으며, 이는 이론적 보장이 없는 영역임
- 그러나, 실험적으로 다층 퍼셉트론은 효과적인 모델로 작동함이 관찰됨

5. Experiments

- 실험에 사용한 데이터셋

- MNIST
- Toronto Face Database (TFD)
- CIFAR-10

- 활성화 함수

- 생성 모델 : 부분적으로 선형 활성화 함수와 시그모이드 활성화 함수를 혼합하여 사용함
- 판별 모델 : Maxout 활성화 함수를 사용함

- 판별 모델의 훈련에서 드롭아웃을 적용함

- 이론적 프레임워크에서는 생성 모델의 중간 계층에 드롭아웃 및 기타 노이즈를 사용할 수 있지만,

↔ 실험에서는 입력 노이즈를 생성 네트워크의 가장 아래 계층에만 적용함

- 테스트 세트 데이터의 확률 추정 방법

: 생성 모델 G로부터 샘플을 생성한 후, 가우시안 파르젠 윈도우를 적용하여 p_g 하에서의 테스트 세트 데이터의 확률을 추정함

→ 정확한 가능성이나 확률을 계산할 수 없는 생성 모델을 평가하는 데 사용되었음

- 이 방법은 높은 분산을 가지며, 고차원 공간에서는 성능이 떨어지는 단점이 있지만, 현재까지 사용할 수 있는 최선의 방법이라고 판단됨
- 샘플링은 가능하지만 가능도를 직접 추정할 수 없는 생성 모델의 발전으로 인해, 이러한 모델을 평가하는 새로운 방법에 대한 연구가 필요함

- 결과

Model	MNIST	TFD
DBN [3]	138 ± 2	1909 ± 66
Stacked CAE [3]	121 ± 1.6	2110 ± 50
Deep GSN [6]	214 ± 1.1	1890 ± 29
Adversarial nets	225 ± 2	2057 ± 26

- 모델로부터 생성된 샘플



a)



b)



c)



d)

- 오른쪽 가장자리 칼럼 : 가장 가까운 훈련 샘플을 표시한 것
→ 모델이 훈련 데이터를 단순히 암기한 것이 아님을 입증함
 - 샘플들은 공정한 무작위 추출의 결과이며, 임의로 선택된 것이 아님
 - 기존의 많은 심층 생성 모델이 숨겨진 유닛으로부터 조건부 평균을 시각화하는 방식과 달리,
→ 여기에서는 실제 모델 분포에서 직접 생성된 샘플을 제공함
- 그림 의미
 - a : MNIST
 - b : TFD
 - c : CIFAR-10 (fully connected model)
 - d : CIFAR-10 (convolutional discriminator & “deconvolutional” generator)



- 모델의 잠재 공간에서 좌표를 선형 보간하여 얻은 숫자 샘플들을 보여줌
- 기존 방법보다 우수한 샘플을 생성했다고 주장하지는 않지만, 최신 생성 모델들과 경쟁력 있는 성능을 보이며, 적대적 신경망의 가능성을 보여줌

- 생성 모델링의 주요 도전 과제

	Deep directed graphical models	Deep undirected graphical models	Generative autoencoders	Adversarial models
Training	Inference needed during training.	Inference needed during training. MCMC needed to approximate partition function gradient.	Enforced tradeoff between mixing and power of reconstruction generation	Synchronizing the discriminator with the generator. Helvetica.
Inference	Learned approximate inference	Variational inference	MCMC-based inference	Learned approximate inference
Sampling	No difficulties	Requires Markov chain	Requires Markov chain	No difficulties
Evaluating $p(x)$	Intractable, may be approximated with AIS	Intractable, may be approximated with AIS	Not explicitly represented, may be approximated with Parzen density estimation	Not explicitly represented, may be approximated with Parzen density estimation
Model design	Nearly all models incur extreme difficulty	Careful design needed to ensure multiple properties	Any differentiable function is theoretically permitted	Any differentiable function is theoretically permitted

- Deep 생성 모델이 각각의 주요 연산에서 겪는 어려움을 요약한 것
→ 모델마다 특정 연산 (ex. 샘플링, 가능도 추정, 학습 등) 에서 다양한 난제들이 존재함

6. Advantages and disadvantages

- 단점

- **$p_g(x)$ 의 명시적인 표현이 없음**
: 기존의 생성 모델들은 $p_g(x)$ 를 명시적으로 표현할 수 있는 경우가 많지만
↔ 적대적 신경망에서는 $p_g(x)$ 를 직접 계산할 방법이 존재하지 않음
쉽게 말하자면,
기존의 생성 모델들은 명시적으로 확률 분포를 정의하고 그에 맞는 샘플을 생성할 수 있기 때문에 $p_g(x)$ 를 직접적으로 계산할 수 있었지만, GAN에서는 그런 명시적인 확률 분포 없이 경쟁을 통해 정교한 샘플을 만들어냄
- **판별 모델 D와 생성 모델 G 간의 동기화 필요**
 - 훈련 중 D와 G가 적절하게 동기화되어야 함
 - 문제) G를 너무 많이 학습시키고 D를 충분히 업데이트하지 않으면 “Helvetica 시나리오”가 발생할 수 있음
 - Helvetica 시나리오 : 생성 모델 G가 너무 많은 z 값을 하나의 x 값으로 수렴시켜, 데이터의 다양성이 부족해지는 현상

- 장점

• 마르코프 체인이 필요하지 않음

기존의 생성 모델에서는 마르코프 체인을 사용하여 데이터를 생성해야 했음

↔ 적대적 신경망은 마르코프 체인이 전혀 필요하지 않음

- 마르코프 체인 : 특정한 상태에서 다음 샘플을 생성할 때, 이전 샘플과의 관계를 기반으로 생성하는 방식

• 역전파만으로 기울기 계산 가능

: 기울기를 계산하는 데 오직 역전파만을 사용하므로 복잡한 샘플링 기법 없이 효율적인 학습이 가능함

- 역전파만으로 기울기 계산이 가능한 이유
 - GAN의 손실 함수는 정규화 상수가 없음
 - 신경망의 출력에 대해 직접 미분이 가능함

• 학습 중 추론이 필요하지 않음

기존 생성 모델에서는 학습 과정에서 잠재 변수를 추론하는 과정이 필요했음

↔ 적대적 신경망에서는 학습 과정 중 별도의 추론 과정이 필요하지 않음

- 추론하는 과정이 필요하지 않은 이유
: 기존 생성 모델들은 학습 중에 데이터가 어떤 잠재변수에서 나왔을지 고민하는 과정이 필요하지만, GAN은 랜덤한 z 로 직접 데이터를 만들기 때문에 그 과정이 필요하지 않음

• 다양한 함수 형태를 모델에 포함 가능함

: 선형 및 비선형 변환을 자유롭게 사용할 수 있어 매우 다양한 함수 형태를 모델에 포함할 수 있음

- 통계적 장점

• 적대적 신경망의 생성 모델은 데이터 샘플을 직접 사용하여 업데이트 되지 않고 판별 모델을 통한 기울기를 통해서만 학습됨

- 기존의 생성 모델은 입력 데이터 x 를 직접 활용하여 모델을 업데이트하며, 실제 데이터 분포와 모델이 생성한 분포를 비교하여 직접적인 손실 함수를 최적화함
↔ GAN의 생성 모델은 샘플을 생성해 판별 모델의 기울기를 통해 업데이트함
- 오버피팅을 방지하는 효과를 가질 수 있음
∵ 애초에 데이터 자체를 기억하는 것이 불가능하기 때문

- 날카로운 분포를 학습할 수 있음

- 마르코프 체인 기반의 방법은 모드 간 혼합 가능성을 높이기 위해, 분포를 다소 흐릿하게 만드는 경향이 있음
 - ↔ 적대적 신경망은 매우 날카로운 분포, 심지어 퇴화된 분포도 모델링할 수 있음

7. Conclusions and future work

- 이 프레임워크는 여러 가지 직관적인 확장 가능성을 제공함

1. 조건부 생성 모델 $p(x|c)$

- 조건부 생성 모델을 만들기 위해 조건 변수 c 를 생성 모델 G 와 판별 모델 D 의 입력으로 추가할 수 있음

2. 근사 추론의 학습

- 보조 네트워크를 훈련하여 주어진 x 에 대해 z 를 예측하는 방식으로 근사추론을 수행할 수 있음

3. 모든 조건부 분포 $p(x_s|x_{\text{portions}})$ 를 근사적으로 모델링

- x 의 일부 인덱스 집합 S 를 기준으로 하는 모든 조건부 분포를 학습할 수 있음
 - 이를 위해 파라미터를 공유하는 조건부 모델의 집합을 훈련할 수 있음
- 본질적으로, 적대적 신경망을 이용해 결정론적 MP-DBM의 확률적 확장을 구현할 수 있음

4. 반지도 학습

- 판별 모델 또는 추론 네트워크에서 추출한 특징을 제한된 개수의 라벨 데이터로 학습하는 분류기의 성능을 향상시키는 데 활용할 수 있음

5. 효율성 향상

- G 와 D 의 조정 방식 개선
- 훈련 중 z 를 샘플링하는 더 나은 분포를 탐색
- 이러한 개선을 통해 학습 속도를 크게 향상시킬 수 있음