



카테고리 없음

[GPT-1] 논문 리뷰

yuha933 2025. 4. 6. 08:17

1. Introduction

- 문제 : 대부분의 딥러닝 방법은 상당한 양의 수작업으로 라벨링된 데이터가 필요하며, 이는 주석 자원이 부족한 많은 도메인에서 적용 가능성을 제한함
- 대안 : 비지도 학습
- 비지도 텍스트에서 단어 수준 이상의 정보를 활용하기 어려운 이유
 - 전이 학습에 유용한 텍스트 표현을 학습하기 위해 어떤 종류의 최적한 목표가 가장 효과적인지가 명확하지 않음
 - > 원래 지도학습에서는, 보통 라벨을 통해 먼저 텍스트 표현을 학습해두고, 그걸 다른 작업에 다시 사용하는 방식으로 되는데, 비지도 학습의 문제는 학습된 게 뭐가 없고, 어떻게 무엇을 학습을 해야하는 지도 명확하지 않고, 심지어 그 학습된 표현이 실제로 잘 되는 지도 모르는 상황이라 활용하기가 어려움

- 학습된 표현을 목표 작업에 어떻게 전이시키는 것이 가장 효과적인지에 대한 합의가 없음
 - > 좋은 텍스트 표현을 만들었다고 하더라도, 그걸 실제 작업에 적용할 때 "피쳐 추출(feature extraction) 방식이 좋을지", "파인튜닝(fine-tuning) 방식이 좋을지" 등 어떻게 활용하는 게 가장 효과적인지에 대한 명확한 합의가 없음
- 이러한 이유들 때문에, semi-supervised learning 방식이 NLP에 효과적으로 적용되기 어려움
- 이 논문의 제안 방법 : semi-supervised learning (비지도 사전 학습 + 지도 학습의 미세 조정)
 - 목표 : 최소한의 조정만으로 다양한 작업에 전이 가능한 범용 표현 학습
 - > 목표 작업들이 동일한 도메인일 필요가 없어도 되도록 !
 - 학습 절차
 - 비지도 데이터에 대한 언어 모델링 목표를 사용하여 신경망 모델의 초기 파라미터 학습
 - > 큰 텍스트 데이터로 언어에 대한 감을 익히도록 함 (도메인에 상관없이 기본기 다지기 단계)
 - 파라미터를 해당 지도 학습 목표를 사용해 목표 작업에 맞게 조정
 - > 실제 작업이 주어졌을 때, 그 작업에 맞게 모델을 조금 더 훈련시켜서 조정하도록 함 (더 나아가 특정 문제에 대한 맞춤 설계 단계)
- 이 논문에서 사용하는 모델 아키텍처 : Transformer
 - 텍스트 내 장기 의존성을 처리하는 데 더 구조화된 메모리를 제공함
 - > 모든 단어가 서로 직접 연결되어 있어 멀리 떨어진 단어들 간의 관계를 명확하게 구조화해서 더 잘 기억할 수 있음
 - 다양한 작업에 걸쳐 견고한 전이 성능을 가능하게 함
 - > 위와 같이 학습된 표현은 다양한 작업에 그대로 써도 잘 작동한다는 말임 ~
- 전이 학습 : task-specific input adaptation (from. traversal 방식)
 - traversal : 입력 문장을 특정 방식으로 재구성해서, 그 작업이 잘 맞게 모델이 이해할 수 있도록 만드는 방법
 - > [CLS] 문장 A [SEP] 문장 B [SEP] ([CLS]는 시작 표시, [SEP]는 문장 구분자)
 - BERT 스타일의 입력 형식

이런식으로 표시해서, 여러 정보를 한 줄로 이어 붙여서 Transformer가 이해할 수 있게 입력을 재구성하는 방식을 말함

- 구조화된 텍스트 입력을 하나의 연속적인 토큰 시퀀스로 처리함
-> ex. 문장1: A man is playing guitar. 문장2: A person is making music. 정답:
- 사전 학습된 모델의 아키텍처를 거의 변경하지 않고도 효과적인 미세 조정을 가능하게 함
-> 입력만 작업에 맞게 잘 구성해서 주면, 모델 구조는 손 안 대고 그대로 써도 성능이 잘 나옴
(비교 : 원래는 작업이 달라질 때마다 모델 구조를 손보거나 새로운 학습을 처음부터 다시 해야 했음)

- 실험 결과

- 평가 과제 : 자연어 추론, 질문 응답, 의미 유사도, 텍스트 분류
- 기존 기술보다 12개 중 9개 작업에서 state-of-the-art 성능을 초과하거나 개선함

2. Related Work

- Semi-supervised learning for NLP

- 초기 : 라벨이 없는 데이터를 이용해 단어 수준 혹은 구 수준의 통계 정보를 계산하고, 이를 지도 학습의 모델의 특징으로 사용하는 방식
-> 라벨이 없는 텍스트에서 자주 등장하는 단어들이나 함께 등장하는 단어 쌍들 등 이러한 텍스트 내의 패턴을 인식하고, 후에 라벨이 있는 문제에 쓸 수 있는 입력 값으로 넣는 방식
- 최근 : 라벨 없는 말뭉치에서 학습된 단어 임베딩이 다양한 작업에서 성능 향상에 도움이 됨
-> 비지도 학습을 통해 단어들을 벡터 공간에 의미 기반으로 배치한 방식 (단어 수준)
- 문제 : 단어 수준 정보의 전이에 한정되어 있음
-> 단어 수준 정보 전이의 문제점 : 문맥 반영이 어려움
- 해결 : 최근에 구나 문장 수준의 의미 정보를 비지도 방식으로 학습하려는 시도가 활발하게 이루어지고 있음
-> 이러한 라벨 없는 텍스트에서 학습한 구나 문장 임베딩은 다양한 NLP 작업에서 텍스트를 벡터로 효과적으로 인코딩하는 데 활용되고 있음

- Unsupervised pre-training

- 비지도 사전 학습 : 지도 학습의 목적 함수를 수정하는 대신, 좋은 초기화 지점을 제공해 지도 학습 성능을 높이는 지도 학습 방식
- 언어 모델링 목표를 통해 신경망을 사전 학습하고, 이후 해당 모델을 지도 학습을 통해 목표 작업에 맞게 미세 조정 하는 방식 사용

- 기존 연구의 문제 : LSTM 모델을 기반으로 하였기 때문에 예측 범위가 짧음
- 이 논문 : Transformer를 사용해, 보다 장기적인 언어 구조를 효과적으로 포착할 수 있음

- 학습 표현

- 기존 연구의 문제 : 은닉 벡터를 추출해서 다른 모델의 입력으로 넣거나 추가적인 분류기나 네트워크를 따로 붙여서 학습함
-> 많은 수의 추가 파라미터가 필요함
- 이 논문 : 사전 학습된 모델을 그대로 사용하며, 입력만 바꿔 전체 모델을 한꺼번에 미세 조정함
-> 모델 구조의 변경이 최소화됨

- Auxiliary training objectives

- 보조 학습 목표 : 본 목적이 정답을 맞추는 거라면, 보조 학습 목표는 모델이 언어를 더 잘 이해하도록 돕기 위해 추가로 시키는 과제
ex. 주요 학습 목표 : 감정이 긍정인지 부정인지 맞추기 / 보조 학습 목표 : 문장 안에서 가려진 단어 맞추기, 다음 단어가 뭘지 예측하기, 문장이 문법적으로 맞는지 판단하기, 문장에 등장한 단어의 품사 태깅 하기
- Rei가 학습 목표에 보조적인 언어 모델링 목표를 추가하여, 시퀀스 라벨링 과제에서 성능 향상을 입증했음
- 본 논문에서도 보조 과제를 같이 써보긴 했지만, 사실 비지도 사전 학습만으로도 이미 모델이 언어에 대한 중요한 특성들을 충분히 잘 배웠기 때문에, 꼭 보조 목표가 없어도 잘 됨을 입증함

3. Framework

3.1 Unsupervised pre-training

- 학습 목표

- 비지도 학습용 토큰 코퍼스 $U = \{u_1, \dots, u_n\}$ 가 주어졌을 때, 다음 단어가 이전 단어들에 조건부로 등장할 확률을 최대화하는 우도함수를 학습함

$$L_1(u) = \sum_t \log P(u_t | u_{t-k}, \dots, u_{t-1}; \Theta)$$

- 학습 방법

- 우도 함수의 파라미터들은 SGD을 통해 최적화됨

- 모델 구조

- 언어 모델로 다층 Transformer 디코더 사용 (Transformer의 변형)
 - 입력 문맥 토큰에 대해 Multi Self-Attention 수행
 - 이어서 위치별 Feed Forward 층 적용
 - 출력 토큰에 대한 확률 분포 생성

- 수식 정리

$$h_0 = UW_e + W_p$$

입력 임베딩 + 위치 임베딩

$$h_l = \text{TransformerBlock}(h_{l-1}), \quad l = 1, 2, \dots, n$$

Transformer 계층 적용

$$P(u_t) = \text{softmax}(h_n W_e^T)$$

다음 토큰 예측 확률

3.2 Supervised fine-tuning

- 사전 학습만으로는 문장 분류, 감정 분석, 개체명 인식 등의 task는 할 수 없음
-> 사전 학습된 모델을 바탕으로 라벨이 있는 데이터로 다시 학습을 시킴

$$L_2(C) = \sum \log P(y|x)$$

- 언어 모델링을 미세 조정 과정의 보조 학습 목표로 포함시키는 것이 학습에 도움이 됨
 - 목적 함수
 - L1(C) : 원래 모델이 하던 일 (언어 모델링, 문장 구조 이해)
 - L2(C) : 실제 적용하고 싶은 일 (분류, 정답 맞추기)
 - 둘 다 같이 학습할 때의 효과
 - 모델의 일반화 능력이 좋아짐
 - 빠르게 학습됨
 - 작은 데이터로 좋은 성능을 낼 수 있음
- 추가로 필요한 파라미터
 - W_y : 정답 분류를 위한 가중치
 - 특수 토큰의 임베딩 (ex. [CLS], [SEP])

3.3 Task-specific input transformations

- 문제 : 단순 텍스트 시퀀스 작업이 아닌 입력이 문장쌍 또는 복잡한 구조로 구성된 경우, 일부 수정이 필요함
(ex. 질문 응답, 텍스트 추론)
- 해결 방법 : Traversal 방식
-> 구조화된 입력을 사전 학습 모델이 이해할 수 있는 단일 텍스트 시퀀스로 변환하는 방식으로, 다양한 작업에 같은 모델 구조를 그대로 유지하면서 적용 가능함
 - 변환 방식 : 입력에 특수 토큰을 추가하여 문장 연결
 - Textual entailment
 - 전제 p와 가설 h 사이에 구분자 토큰(\$)\$을 넣어 연결한 연속 시퀀스로 입력 구성
 - Similarity
 - 문장 간 순서에 의미가 없기 때문에, 두 가지 순서(p-h, h-p)를 모두 생성하여, 각각을 독립적으로 모델에 입력 → 출력 벡터를 평균하여 최종 표현 사용

- Question Answering and Commonsense Reasoning
 - 문서, 질문, 각 가능한 답변 후보 a_k 를 [질문; 문서; 답변 후보] 형태로 이어붙인 시퀀스로 구성
 - > softmax를 통해 가장 적절한 답변 선택

4. Experiments

4.1 Setup

- Unsupervised pre-training
 - 데이터셋 : BooksCorpus
 - 7,000권 이상의 미출판 책
 - 긴 연속 텍스트 포함
 - 장기적인 문맥 정보에 기반해 학습하는 데 유리함
 - perplexity : 18.4
- Model specifications
 - 모델
 - Decoder 전용 12층 Transformer 구조
 - masked self-attention
 - dimensional states : 768
 - attention head : 12
 - feed-forward network : 3072 dimensional inner states
 - 학습
 - 최적화 알고리즘 : Adam
 - 최대 학습률 : $2.5e-4$ (2000번의 update 후 cosine schedule)
 - 미니배치 : 64개 (512개의 토큰)
 - epoch 수 : 100

- 정규화
 - layer normalization (가중치 초기화 : $N(0,0,0.2)$)
 - 드롭아웃 : 0.1
 - L2 정규화의 수정된 버전 적용 ($w=0.01$)
- 활성화 함수
 - GELU
- 위치 임베딩
 - 사인 함수 기반 위치 임베딩 대신 학습된 위치 임베딩 채택
- 입력 전처리
 - 원시 텍스트 전처리에는 ftfy 라이브러리 사용
-> 문자부호 및 공백 정규화
 - spaCy 토크나이저 활용
- Fine-tuning details
 - 별도의 언급이 없으면, 비지도 사전 학습에서 사용한 하이퍼파라미터 사용
 - 분류기 드롭아웃 비율 : 0.1
 - 대부분의 작업에서:
 - 학습률 : $6.25e-5$
 - batch size: 32
 - 학습 epoch : 3
 - 학습률 schedule : 전체 학습의 0.2% 동안 워밍업 후, 선형 감소
 - λ 값 : 0.5

4.2 Supervised fine-tuning

- Natural Language Inference

- NLI : 두 문장 간의 관계를 함의, 모순, 중립 중 하나로 분류하는 과제
-> 어휘적 함의, 지시어 해석, 어휘 및 구문적 중의성 등의 다양한 언어 현상들로 인해 어려운 문제로 남아 있음
- 데이터셋 : SNLI (이미지 캡션), MNLI (정부 보고서), QNLI (위키피디아 문서), SciTail (과학 시험), RTE (뉴스 기사)
- 실험 결과
 - MNLI : 1.5%
 - SciTail : 5%
 - QNLI : 5.8%
 - SNLI : 0.6 % 의 절대 향상 기록
 - RTE의 경우, 비교적 작은 규모의 데이터셋으로, biLSTM 모델의 성능보다 낮은 수치를 기록함
- 본 모델은 대규모 NLI 데이터셋에서 강력한 성능을 보였다는 점을 고려했을 때, 멀티태스킹 학습을 통해 더 향상된 결과를 얻을 수 있을 가능성을 보임

- Question answering and commonsense reasoning

- Question answering : 단일 문장과 다중 문장 추론
 - 데이터셋 : RACE 데이터셋
 - ,장기 문맥 처리 능력 평가에 적합함 (:추론 중심의 질문이 많음)
- Story Cloze Test : 다중 문장으로 구성된 이야기의 올바른 결말을 고르는 작업
- 실험 결과
 - RACE : 5.7% 향상
 - Story Cloze Test : 8.9% 향상
- 본 모델은 장기 문맥을 효과적으로 처리할 수 있는 능력을 갖추고 있음을 보임


- Semantic Similarity

- Semantic Similarity : 두 문장이 의미적으로 동등한지 예측하는 작업
-> 개념 재구성의 인식, 부정 표현 이해, 구문적 모호성 처리 하는 데 어려움이 있음

- 데이터셋 : MRPC (뉴스 출처), QQP, STS-B
- 실험 결과
 - 세 가지 중 두 가지에서 최신 성능을 기록함
 - QQP : 4.2%의 절대 성능 향상 (vs. Single-task BiLSTM + ELMo + Attention)
 - STS-B : 1점의 절대 향상
- Classification
 - CoLA : 문장이 문법적으로 타당하지를 전문가가 판단한 데이터
-> 모델이 언어적 직관을 얼마나 잘 반영하는지를 측정하는 데이터
 - SST-2 : 일반적인 이진 감정 분류 과제
 - 실험 결과
 - CoLA : 45.4점 (기존 최고 성능 : 35.0)
 - SST-2 : 91.3%의 정확도
 - GLUE 벤치마크 전체 점수 : 72.8 (기존 최고 점수 : 68.9)
- 본 모델은 12개의 데이터셋 중 9개에서 새로운 최고 성능을 보임 (앙상블 모델보다도 우수한 성과)
- 다양한 크기의 데이터셋에서 잘 작동함을 보임

5. Analysis

- Impact of number of layers transferred
 - 비지도 사전 학습에서 지도 학습으로 전이되는 레이어 수에 따라 성능이 어떻게 달라지는 지 관찰함
 - 실험 결과
 - 레이어 수가 늘어날수록 성능이 향상됨
 - 전체 레이어를 전이했을 때 MultiNLI에서 최대 9%까지 성능 향상됨



• Zero-shot Behaviors

- Supervised fine-tuning 없이도 생성 모델 자체를 이용해 작업을 수행할 수 있는 heuristic solutions을 설계함

• 실험 결과

- 성능이 안정적이며 학습이 진행될수록 점진적으로 향상됨을 보임
-> 생성 기반 사전 학습이 다양한 과제에 관련된 기능을 학습하는 데 도움이 된다는 것을 시사함
- LSTM이 zero-shot 성능에서 더 높은 분산을 보임
-> Transformer 아키텍처의 귀납적 편향(inductive bias)이 전이 학습을 돕는 데 기여하고 있음을 나타냄

• CoLA

- 각 예시에 대해 생성 모델이 할당한 토큰의 로그 확률 평균을 점수로 사용하고, 임계값 기준으로 예측을 수행

• SST-2

- 각 예제 뒤에 very라는 토큰을 추가하고, 언어 모델의 출력 분포를 positive와 negative라는 단어로만 제한한 뒤, 더 높은 확률을 할당한 단어를 예측값으로 사용

• RACE

- 문서와 질문을 조건으로 주었을 때, 생성 모델이 가장 높은 평균 토큰 로그 확률을 할당한 답변 선택

• DPRD

- 문장에서 지시 대명사를 두 가지 가능한 지시 대상 중 하나로 바꾼 후, 해당 대체 이후의 나머지 시퀀스에 대해 생성 모델이 더 높은 평균 토큰 로그 확률을 부여한 해석을 예측값으로 선택
- Ablation studies
 - fine-tuning 과정에서 보조 언어 모델링 목표를 제거한 경우
 - 보조 목표가 NLI와 QQP에서 성능 향상에 도움을 주는 것으로 나타남
 - 전반적으로 큰 규모의 데이터셋에서는 효과적인 반면, 작은 데이터셋에서는 그렇지 않은 경향을 보임
 - 동일한 실험 프레임워크에서 단일 레이어 2048 유닛 LSTM과 성능 비교 (Transformer)
 - Transformer 대신 LSTM을 사용했을 때 평균 점수가 5.6점 하락
 - LSTM이 Transformer보다 더 나은 성능을 보인 데이터셋은 MRPC 하나 뿐임
 - 사전 학습 없이 Transformer architecture를 지도 학습 대상 과제에 직접 학습시킨 경우
 - 사전 학습이 없는 경우 모든 과제에서 성능이 전반적으로 하락함
 - 전체 모델과 비교해 평균 14.8% 성능 감소가 발생함

6. Conclusion

- 다른 분야에서의 비지도 학습 연구를 촉진하고, 비지도 학습이 어떻게, 언제 효과적으로 작동하는지에 대한 이해를 더욱 발전시키는 데 기여하길 바램