



카테고리 없음

[논문 리뷰] Learning Transferable Visual Models From Natural...

yuha933 2026. 4. 1. 02:38

1. Introduction and Motivating Work

기존 Computer Vision의 한계

- 기존의 Computer Vision은 정해진 클래스 맞추기 문제로 설계되기 때문에, 새로운 개념을 적용하려면 해당 개념에 대한 데이터 수집과 학습이 다시 필요하다.
- 다른 task로 확장을 하지 못한다.

본 연구의 아이디어

- 기존의 방식이 이미지에 대해 클래스를 맞추는 거였다면, CLIP은 이미지와 텍스트 연결을 맞춘다.
- 이렇게 되면, 모델이 자연스럽게 개념을 배우고 별도 라벨 없이 학습이 가능하다.

기존 연구와 CLIP의 차이점

- 기존 연구들은 데이터가 부족하고, 여전히 classifier 구조로 출력이 고정된다는 한계가 있었으며, zero-shot accuracy가 매우 낮다.
- 반면, CLIP은 4억 image-text pair를 사용하였으며, contrastive 방식으로 단순하게 학습한다. 또한, zero-shot임에도 불구하고 성능이 높으며, supervised 모델과도 경쟁이 가능한 수준이다.

2. Approach

2.1 Natural Language Supervision

- 기존의 이미지 - 라벨 학습의 한계 : 사람이 직접 라벨링해야 하고, 표현할 수 있는 개념이 제한적이며, 새로운 문제마다 다시 학습해야 한다.
- 본 연구의 아이디어 : 이미지에 붙어 있는 자연어 설명 자체를 학습 신호로 사용한다.
- 장점 : 자연어는 표현력이 훨씬 풍부해서 단순 클래스보다 상황, 속성까지 담을 수 있으며, 인터넷이 이미 이런 데이터가 많기 때문에 별도의 라벨링이 필요 없다. 또한 새로운 task 적용 시에도 텍스트로 질문만 하면 해결이 가능하다.

2.2 Creating a Sufficiently Large Dataset

- 기존 데이터셋들은, 예를 들어 MS-COCO, Visual Genome 의 경우에는 품질은 좋지만 너무 작고, YFCC100M의 경우에는 크기 하지만 텍스트 품질이 떨어지는 등의 문제가 있었다.
- 본 연구의 아이디어 : 직접 4억 개의 (image, text) pair를 만든다. 이는 수십만 개의 검색 query를 만들고 각 query마다 이미지-텍스트 쌍을 수집해서 최대한 다양한 상황, 객체, 표현을 포함하도록 한다. 이로써 다양한 개념을 최대한 많이 포함하는 데이터를 목표로 구성된다.

2.3 Selecting an Efficient Pre-Training Method

- 처음에는 CLIP도 기존 방식처럼 이미지를 보고 문장을 생성하는 모델을 시도했다. 그러나 문장 생성은 너무 어려운 task라서, 학습이 느리고 compute가 엄청 많이 드는데 성능은 생각보다 안 좋은 문제가 생겼다.
- 본 논문의 아이디어 : 문장을 정확히 맞추기 보다는 해당 이미지와 해당 텍스트가 맞는 지 아닌지만 판단하는 contrastive learning을 하자.
- 과정 : 한 배치 안에 이미지와 텍스트 쌍이 여러 개 있으면, 진짜로 맞는 쌍은 서로 가깝게 만들고 틀린 조합은 멀어지게 만든다.

- 장점 : 이렇게 하면, 문제 난이도가 낮아지고 학습이 훨씬 빨라지고 representation은 그대로 잘 배우게 된다.

2.4 Choosing and Scaling a Model

- 모델 구조는 이미지 쪽은 ResNet이나 Vision Transformer, 텍스트 쪽은 Transformer (GPT 계열), 즉 이미 있는 모델들을 그대로 사용한다.
- 다만, 모델을 키울 때 width, depth, resolution을 균형 있게 같이 키운다.
- 이때, 이미지 encoder가 성능에 훨씬 중요하기 때문에 텍스트 쪽은 상대적으로 덜 키워도 되고, projection layer도 단순하게 가져가도 된다.

2.5 Training

- 매우 큰 batch(3만 이상)를 사용한다.
- mixed precision을 사용한다.
- cosine learning rate를 사용한다.
- temperature parameter를 학습하면서 조정한다.
- scale 면에서는, 수백 개의 GPU로 수 주간 학습을 진행한다.

3. Experiments

3.1 Zero-shot Transfer

실험 내용

- CLIP을 추가 학습 없이 다양한 데이터셋에 바로 적용하였다.
- 각 데이터셋의 클래스 이름을 텍스트로 만들어서 이미지와 텍스트 similarity로 분류 수행하였다.

성능 결과

- ImageNet에서 zero-shot인데도 ResNet-50 수준의 성능을 보인다.
- 30개 이상의 데이터셋에서 대부분의 task에서 유의미한 성능 확보하였다.
- 기존 zero-shot 방법 대비 훨씬 높은 정확도를 보인다.

3.2 Representation Learning

실험 내용

- CLIP으로 feature만 뽑고, 위에 linear classifier만 붙여서 학습하였다.

성능 결과

- CLIP feature가 매우 강력해서 최고 수준 ImageNet 성능 달성한다.
- 기존 supervised representation보다 더 좋은 성능을 더 효율으로 달성한다.

3.3 Robustness to Natural Distribution Shift

실험 내용

- distribution shift 상황을 평가하였다.

성능 결과

- 동일 accuracy 기준에서 CLIP이 더 안정적이다.
- 다양한 데이터셋 변화에도 일반화 성능이 우수함을 보인다.

4. Comparison to Human Performance

- 인간의 판단 방식 : 상황이나 맥락, 상식 기반으로 판단한다.
- 본 연구 : 텍스트 패턴 기반으로 판단하기 때문에, 헛갈리는 경우에 이상한 실수를 많이 한다. 특히 배경 때문에 오판단을 하거나 비슷한 단어나 개념을 혼동하거나, 문맥 이해가 부족할 수 있다.
- 결과적으로, CLIP은 인간 수준에 근접한 성능을 보이지만 여전히 이해가 아니라 패턴 매칭에 가깝다.

5. Data Overlap Analysis

- 문제 의식 : 성능이 좋았던 이유가 진짜 일반화가 아니라 단순한 암기 때문일 수도 있다는 의심에서 시작한다.
- 분석 방법 : CLIP 학습 데이터 4억 pair와 benchmark dataset 사이의 중복을 측정했다.
- 결과 : 일부 데이터셋이 overlap 있긴 했으나, overlap을 제거해도 성능이 크게 떨어지지 않는 것으로 보아 CLIP의 성능은 단순 암기 때문에 아니라 실제 일반화 능력에 나온다고 볼 수 있다.

6. Limitations

- 텍스트 의존 : 이미지 자체를 이해한다기보다 텍스트와 연결된 패턴을 학습한 모델로, 텍스트에 잘 안 나오는 개념이거나 설명하기 어려운 시각 정보에 대해서는 약하다.
- 문맥 이해 부족 : 객체는 잘 맞추지만 상황이나 관계 이해에는 약하다.
- 데이터 편향 문제 : CLIP은 인터넷 데이터로 학습되기 때문에 특정 그룹에 대한 편향된 예측을 한다거나 윤리적 문제가 발생할 가능성이 있다.
- Out-of-distribution : 일반화가 강하긴 하지만, 완전히 새로운 분포에서는 여전히 약하다.
- 추론 부족 : 논리적 추론이나 인과관계 이해는 부족하다.
- 계산 비용 문제 : 학습에 수백 GPU와 수주가 필요하기 때문에 현실적으로 재현하기 어렵다.

7. Broader Impacts

7.1 Bias

- CLIP은 인터넷 데이터로 학습되기 때문에 데이터에 포함된 사회적 편향을 그대로 학습할 수 있다. 또한 단순 데이터뿐 아니라 텍스트로 클래스를 정의하는 구조 자체도 편향을 만들 수 있다.
- 실험 결과 : zero-shot CLIP은 집단별 성능 편차가 크게 나타난다. 일부 경우, 부정적 개념과 특정 집단이 더 자주 연결되기도 한다.

7.2 Surveillance

- CLIP은 텍스트만으로 분류기를 만들 수 있어서 감시 / 행동 분석 task에도 쉽게 적용 가능하다.
- 실험 결과 : zero-shot으로도 얼굴 / 정체 인식이 일정 수준 가능하다. 하지만 전문 face recognition 모델보다 성능은 낮다.
- 또한, detection이나 segmentation에는 최적화되지 않는다.

7.3 Future Work

- 현재 분석은 초기적 수준에 불과하며, 앞으로 어떤 task에 적합한지 구분하고, bias 및 failure 사례를 체계적으로 분석하며, 다양한 환경에서 평가 기준을 마련하는 등의 연구가 필요하다.

8. Related Work

9. Conclusion

- CLIP은 이미지와 텍스트를 함께 사용하는 간단한 pre-training task로 강력한 visual representation을 학습할 수 있음을 보여준다.
- 이 방식은 기존처럼 task마다 따로 학습하지 않아도 zero-shot으로 다양한 작업을 수행할 수 있다는 점이 핵심이다.
- 실제로 30개 이상의 데이터셋에서 평가했을 때 추가 학습 없이도 기존 supervised 모델과 경쟁 가능한 성능을 보였다.
- 또한 모델 성능이 데이터 규모와 compute에 따라 안정적으로 증가(scaling)하는 것도 확인된다.
- 이 결과는 자연어 기반 supervision이 컴퓨터 비전에서도 매우 효과적이며, 기존의 라벨 기반 학습 방식을 대체할 가능성이 있음을 시사한다.