



카테고리 없음

[논문 리뷰] Segment Anything (SAM)

yuha933 2026. 3. 31. 22:19

1. Introduction

등장 배경

- NLP 분야에서는 LLM(Large Language Models)과 같은 foundation 모델이 등장하면서, 하나의 모델이 다양한 Task를 zero-shot / few-shot 방식으로 수행하는 것이 가능해졌다.
- Computer Vision 분야에서도 유사한 시도가 있었으며, CLIP과 같은 모델은 텍스트와 이미지를 연결하여 zero-shot generalization을 일부 가능하게 했다.

기존 모델의 한계

- task별로 모델이 분리되어 있다.
- segmentation과 같은 작업은 범용적으로 해결할 수 없다.
- 대규모 segmentation 데이터셋이 부족하다.

본 연구의 목표

- 이미지 segmentation을 위한 foundation 모델을 구축하고자 한다.
- 즉, 하나의 모델이 다양한 segmentation task를 prompt만으로 해결하고, 새로운 데이터에서도 일반화 가능하도록 만들고자 한다.

본 연구의 아이디어




Figure 1: We aim to build a foundation model for segmentation by introducing three interconnected components: a promptable segmentation task, a segmentation model (SAM) that powers data annotation and enables zero-shot transfer to a range of tasks via prompt engineering, and a data engine for collecting SA-1B, our dataset of over 1 billion masks.

- Task, Model, Data를 동시에 새롭게 정의한다.
- Task : 기존의 segmentation은 고정된 입출력 구조로 인해 유연성이 부족했으며, 이를 prompt 기반 segmentation 수행으로 새롭게 정의한다.
- Model : Task가 바뀌면 모델 요구사항도 바뀌어야 하기 때문에, 이미지 이해를 위한 Image Encoder, prompt 이해를 위한 Prompt Encoder, 그리고 둘을 연결해서 결과를 생성할 Mask Decoder로 구성한다.
- Data : segmentation 데이터는 만들기가 너무 힘들기 때문에, 모델을 이용해서 데이터를 만든다. 데이터 생성은 처음에 사람이 Mask를 그리면 Model이 도와주는 형태에서, 모델이 일부 자동 생성하면 사람이 부족한 부분을 수정하는 반자동 상태로 발전한 후, 최종적으로 모델이 스스로 Mask를 생성하도록 발전한다. 이러한 발전을 통해 모델이 좋아질수록 데이터를 더 잘 만들고, 데이터가 좋아질수록 모델이 더 좋아지는 루프를 겪는다.

본 논문의 핵심 질문

- 어떤 task가 zero-shot 일반화를 가능하게 하는가?
- 이를 위한 적절한 모델 구조는 무엇인가?
- 이를 학습시킬 데이터는 어떻게 구축할 것인가?

2. Segment Anything Task

Task

- 기존 Segmentation : 해당 이미지에서 특정 클래스를 분할하는 문제가 고정되어 있는 형태였다.
- 본 논문 : 프롬프트가 주어지면 그걸 기준으로 segmentation을 수행하는 모델을 만들 고자 한다.
- 본 논문은 프롬프트가 애매해도 괜찮다고 정의하면서, 어떤 프롬프트가 들어와도 최소 한 하나의 합리적인 segmentation 결과를 내는 것을 핵심으로 본다.

Pre-training

- 기본 구조 : 이미지와 프롬프트를 입력으로 주면 모델이 Mask를 예측하고 정답과 비교 하면서 학습하는 구조이다.
- 차이점
 - 기존 interactive segmentation : 사용자가 계속 입력을 추가하면서 점점 정확한 결과를 얻는 방식이다.
 - 본 논문 : 입력이 부족하거나 애매해도, 한 번에 valid한 결과를 내야 한다.
- 다만, 이는 정보가 부족한 상태에서도 판단해야 하고, 여러 가능성 중 하나를 선택해야 하기 때문에 어렵다.

Zero-shot transfer

- 본 논문과 같이 pre-training을 하게 되면, 모델을 다시 학습할 필요 없이 프롬프트만 바 꾸면 새로운 task에도 대응할 수 있게 된다.

Related tasks

- 기존 segmentation에는 서로 다른 문제들이 따로 존재했으며, 이 모든 걸 하나의 task 로 통합하고자 한다.
 - semantic segmentation
 - instance segmentation
 - edge detection
 - object proposal
- 기존 multi-task 모델은 여러 task를 한 모델에서 처리하기는 하지만, task가 미리 정해 져 있으며 학습할 때 본 것만 가능하다는 한계가 존재했다.

Discussion

- 프롬프트만 바꾸면 모델을 새로 만들 필요 없이 다양한 문제 해결이 가능하다.

- 이 모델은 단독으로 쓰는 것도 가능하지만, 다른 모델과 결합해서 쓰면 더 강력해진다.

3. Segment Anything Model

Image Encoder

- 처음에 이미지를 한 번 쓱 보고 해당 이미지의 특징을 요약한 벡터로 만들어 둔다.
- prompt 처리를 할 때마다 이미지를 다시 분석하면 너무 느리기 때문이다.

Prompt Encoder

- prompt를 모델이 이해할 수 있도록 전부 같은 형태의 벡터로 변환한다.
- 점과 같은 위치 정보, 박스와 같은 영역 정보, 텍스트와 같은 의미 정보를 모두 같은 공간으로 맞춰준다.

Mask Decoder

- 이미지 정보와 prompt 정보를 계속 서로 참고하면서 해당 픽셀이 포함인지를 판단한다.
- 각 픽셀마다의 확률 계산을 통해 최종적으로 segmentation mask를 생성한다.

Resolving ambiguity

- 문제 : 프롬프트가 애매할 수 있다. (ex. 점 하나를 찍었는데, 이 점이 나타내는 게 사람일 수도 있고 가방일 수도 있다.)
- 기존 모델이면 이 중 하나만 골라야 해서 어렵지만, SAM은 mask를 여러 개 동시에 출력한다. 그리고 그 중 가장 좋은 하나만 학습에 사용하기 때문에, 모델은 부담을 덜 느끼고 ambiguity는 자연스럽게 처리된다.

Efficiency

- 이미지 처리를 한 번으로 줄이고, 이후는 가벼운 연산만 수행하도록 설계해서 실시간 사용이 가능하게 만들었다.

Losses and Training

- SAM은 segmentation이므로 픽셀 단위 정확도가 중요하다. 그래서 아래 두 가지 loss를 같이 사용한다.
 - Focal loss : 어려운 픽셀에 더 집중하도록 한다.
 - Dice loss : 전체 mask 형태가 얼마나 잘 맞는지 본다.

- 학습 방식은 interactive 상황을 흉내 내면서 학습한다. 그러다 보니 학습할 때도 프롬프트를 한 번만 주는 게 아니라 여러 번 나눠서 주면서 한 mask당 11번 정도 반복한다.
- Data 측면에서, 실제 annotation도 interactive하게 이루어지기 때문에 모델이 점점 더 나은 mask를 생성하게 된다.

4. Segment Anything Data Engine

Assisted-manual stage

- 처음에는 모델이 충분히 좋지 않기 때문에, 사람이 직접 segmentation을 해야 한다. 다만, 완전히 수작업은 아니고 SAM이 실시간으로 도와주는 인터랙티브 방식이다.
- 사람이 foreground / background 점을 클릭하면, 모델이 segmentation 결과를 보여주고, 사람이 brush / eraser로 수정하는 방식이다.
- 이렇게 하면, 기존과 다르게 아무 객체나 자유롭게 라벨링할 수 있어 데이터 다양성이 엄청 커진다.
- 모델이 데이터 생성 속도를 올려준다. (annotation 시간 : 34s → 14s)

Semi-automatic stage

- 초기 단계에서는 사람이 눈에 잘 보이는 객체를 위주로 라벨링을 하게 되어서 중요한 객체는 많고, 덜 중요한 객체는 부족하다. 이에 해당 단계에서는 Mask의 다양성을 증가시키는 것을 목표로 한다.
- 모델이 먼저 Mask를 생성하면 사람은 빠진 객체만 추가하거나 덜 눈에 띄는 객체 중심으로 라벨링하는 방식이다.
- 이 단계에서는 어려운 객체만 남아서 annotation 시간은 늘어나지만, 그만큼 Mask의 개수도 많이 증가한다.

Fully automatic stage

- 이제 완전히 자동화된 데이터 생성을 가능하게 한다. 이를 가능하게 하는 데에는 데이터가 충분히 쌓여서 모델 성능이 충분히 좋아졌고, 여러 Mask 출력이 가능해서 ambiguity 처리가 가능해졌기 때문이다.
- 이 단계에서는 이미지에 grid를 생성하고 각 포인트마다 segmentation을 수행해 엄청 많은 후보 Mask를 생성한 후, 좋은 Mask만 선택하고 중복을 제거(NMS 적용)한 후 작은 객체를 보완(zoom-in-crop)하는 과정을 거치며 자동화한다.

5. Segment Anything Dataset

Images

- 사진작가와 협력하여 라이선스가 확보된 이미지를 사용한다.
- 해상도 : 평균 약 3300*4950 (해상도가 굉장히 커서 짧은 변 기준 1500px로 다운샘플링해서 공개하였으며, 그림에도 여전히 높은 해상도를 유지하여 더 디테일한 segmentation을 가능하게 한다.)
- 개인정보 처리 : 얼굴과 번호판은 blur 처리하였다.

Mask

- 총 1.18 masks가 존재하며, 그 중 99.1%가 자동 생성된 것이다.
- 자동 생성 mask도 충분히 품질이 좋다.
- SA-1B는 자동 생성 Mask만 포함한다.

Mask quality

- 자동 생성 Mask가 진짜로 품질이 괜찮은지를 검증했다. 검증은 500개의 이미지(약 50 k mask)를 샘플링하고, 사람이 다시 수정하여 자동 Mask와 수정 Mask를 비교하였다.
- 결과는 94%의 이미지가 IoU 90%이상, 97%의 이미지가 IoU 75% 이상임을 보였다.
- 이는 SAM 자동 Mask가 사람 수준이며, 사람 annotation 없이도 충분함을 보여준다.

Mask properties

- 위치 분포 : 기존 데이터는 중심에 객체 많았던 반면, SA-1B는 이미지 전체에 객체가 고르게 분포해 있으며 특히 모서리까지 잘 포함한다.
- 데이터 규모 : 이미지는 수는 기존보다 11배, mask 수는 기존 대비 400배이다.
- 이미지당 Mask 수 : 36배 정도 SA-1B가 훨씬 많다.
- Mask 크기 다양성 : SA-1B는 작은 객체와 중간 크기의 객체가 많아 기존보다 더 현실적인 분포를 보인다.
- shape 복잡도 : 기존 데이터셋과 유사하다.

6. Segment Anything RAI Analysis

Geographic and income representation

- 이미지가 특정 국가나 소득 수준에 몰려 있는지를 본다.
- 데이터는 완전 한쪽으로 쏠리지 않고 여러 지역에서 수집되었다. 유럽과 아시아의 비중이 상대적으로 크며, 중간 소득 국가도 포함된다.
- 다만, 아프리카나 저소득 국가는 여전히 부족하다.

Fairness in segmenting people

- 사람 segmentation에서 특정 그룹이 분리한지를 본다.
- 결과적으로, gender bias는 거의 없고, Age에서는 약간의 차이는 있지만 큰 bias는 아니다. 또한, 피부색 기반 편향도 크지 않다.

7. Zero-Shot Transfer Experiments

7.1 Single point segmentation

실험 내용

- 입력 : foundation point 1개
- 다양한 segmentation dataset (23개)에서 평가한다.

결과

- 단일 point만으로도 높은 품질 mask 생성한다.
- 성능이 수동 annotation과 거의 근접하다.
- 일부 dataset에서는 기존 fully supervised 모델과 경쟁 가능하다.

7.2 Edge detection

실험 내용

- edge detection을 segmentation prompt 문제로 변환한다.
- prompt 기반으로 edge 추출한다.

결과

- 별도 학습 없이도 경쟁력 있는 성능을 보인다.
- 기존 edge detection 모델과 비슷한 수준이다.

7.3 Object proposal generation

실험 내용

- 다양한 point/grid prompt를 사용해 object 후보 영역 생성한다.

결과

- 높은 recall을 달성했다.
- object proposal task에서도 효과적으로 동작한다.

7.4 Instance segmentation

실험 내용

- detector(box) + SAM 결합하고, box를 prompt로 사용한다.

결과

- 별도 segmentation 학습 없이 instance segmentation이 가능하다.
- 기존 방법과 경쟁력 있는 성능을 보인다.

7.5 Text-to-mask

실험 내용

- 텍스트 prompt를 받아 segmentation 수행한다.

결과

- 기본적인 동작은 가능하지만 아직 불완전하며, 성능이 제한적이다.

7.6 Automatic mask generation

실험 내용

- grid prompt 방식으로 자동 mask 생성하여 human annotation과 비교한다.

결과

- 자동 생성 mask 품질이 높다.
- 사람 평가에서도 좋은 성능이 나옴을 확인하였다.

7.7 Generalization (zero-shot)

실험 내용

- 학습 데이터와 다른 dataset에서 평가한다.
- prompt만 사용한다. (fine-tuning 없음)

결과

- 다양한 dataset에서 일관된 성능을 보인다.

- 새로운 task에서도 zero-shot으로 잘 작동한다.

8. Discussion

Foundation models

- SAM은 foundation model이지만, 그 기반은 대규모 supervised 데이터에 있다.

Compositionality

- SAM은 다양한 시스템과 결합되어 새로운 기능을 만들어내는 인터페이스 역할을 한다.

Limitations

- 디테일 부족 : Efficiency 중심이라서 작은 구조를 잘 못 잡거나 경계가 덜 정확한 경우가 있다.
- hallucination : 없는 작은 객체를 만들어낼 수 있다.
- 고급 segmentation보다 낮은 성능 : SAM은 범용성을 선택했다.
- real-time : prompt는 빠르지만, 큰 image encoder를 쓰면 느리다.
- text-to-mask의 부족 : 텍스트 기반 segmentation은 아직 완벽하지 않다.
- prompt 설계 : semantic segmentation 같은 경우, 어떻게 prompt를 줘야 할지 애매한 경우가 많다.
- domain-specific 모델보다 약함 : 특정 분야에서는 전문 모델이 더 좋다.

Conclusion

- 본 연구는 segmentation을 foundation model 시대로 가져왔다.