

보아즈 과제

Learning Transferable Visual Models From Natural Language Supervision (CLIP) 정리

1. Abstract (문제 정의)

기존 컴퓨터 비전 모델은 고정된 클래스를 기반으로 학습되기 때문에, 새로운 개념을 다루기 위해서는 추가적인 라벨링과 재학습이 필요하다.

이 논문은 이러한 한계를 해결하기 위해,

이미지와 자연어 텍스트를 함께 사용하는 학습 방식을 제안한다.

핵심은 다음과 같다:

- 인터넷에서 수집한 대규모 (image, text) 데이터
- 이미지와 텍스트의 대응 관계를 학습
- 자연어를 활용한 zero-shot 일반화

그 결과, 별도의 task-specific 학습 없이도 다양한 비전 태스크에서 경쟁력 있는 성능을 달성한다

2. Introduction (연구 동기 및 문제점)

기존 비전 모델의 가장 큰 한계는 **일반화 범위의 제한**이다.

- 특정 데이터셋 (예: ImageNet)에 맞춰 학습
- 새로운 task → 새로운 데이터 필요
- 라벨링 비용이 매우 큼

반면 NLP 분야에서는

- 대규모 텍스트 기반 사전학습을 통해
- 다양한 task를 추가 학습 없이 수행 가능

이 논문은 이러한 흐름을 컴퓨터 비전에도 확장하려는 시도이다.

기존 접근의 한계

기존 연구들은 이미지와 텍스트를 함께 활용하려 했지만 다음과 같은 문제가 있었다:

- caption 생성 방식 → 학습 난이도 높음
- n-gram 기반 접근 → 표현력 부족
- 데이터 규모 부족 → 성능 한계

즉, 방법과 데이터 규모 모두 부족했다는 점이 핵심 문제이다.

3. Related Works (관련 연구)

기존 연구는 크게 세 가지 흐름으로 정리된다.

1) 이미지 → 텍스트 생성 방식

- 이미지로부터 문장을 생성
- 문제: 학습이 어렵고 효율이 낮음

2) Weak Supervision

- 해시태그, noisy label 활용
- 문제: 여전히 제한된 클래스 기반

3) Multimodal Representation Learning

- 이미지 + 텍스트 결합
- 문제: 데이터 규모가 작고 일반화 부족

이 논문은

대규모 데이터 + **contrastive learning**을 결합하여

기존 접근의 한계를 해결한다.

4. Method (접근 방법 및 모델 구조)

핵심 아이디어

이미지와 텍스트를 같은 공간에 매핑한 뒤,

서로 대응되는 쌍은 가깝게, 아닌 쌍은 멀어지도록 학습한다.

전체 구조

- Image Encoder: ResNet 또는 Vision Transformer
- Text Encoder: Transformer

각 입력은 embedding으로 변환된 뒤

공통 공간에서 비교된다.

학습 방식 (Contrastive Learning)

하나의 배치에 N개의 (image, text) 쌍이 있을 때:

- 정답: (i, i)
- 오답: (i, j)

모든 조합($N \times N$)을 고려하여:

- 정답 pair similarity 최대화
 - 오답 pair similarity 최소화
-

수식 구조 (핵심 흐름)

1. 이미지/텍스트 embedding 생성
2. cosine similarity 계산
3. similarity matrix 구성 ($N \times N$)
4. cross-entropy loss 적용

논문에서는 이미지 기준 loss와 텍스트 기준 loss를 모두 사용하여
대칭적인 학습을 수행한다

왜 Contrastive Learning인가

기존 방식은 "정확한 문장 생성"을 요구했지만,
이 방식은 "짜이 맞는지 여부"만 판단하면 된다.

- 학습 난이도 감소
- 학습 효율 증가

실제로 기존 방법 대비

zero-shot 학습 효율이 크게 개선됨

데이터셋

- 4억 개 (image, text) 쌍
- 웹에서 수집 (WIT dataset)

기존 데이터셋 대비 압도적인 규모

5. Experiments (실험 구성 및 결과)

평가 방식: Zero-shot

모델을 특정 데이터셋에 맞춰 학습하지 않고
바로 적용하여 성능을 측정한다.

Zero-shot 분류 방식

예: ImageNet

1. 클래스 이름을 텍스트로 변환
 - "a photo of a dog"
 2. 텍스트 embedding 생성
 3. 이미지 embedding과 similarity 계산
 4. 가장 높은 값을 선택
-

결과

- ImageNet zero-shot accuracy:
 - 기존: 11.5%
 - CLIP: 76.2%

→ 지도학습 모델과 유사한 수준

추가 특징

- OCR, 행동 인식, 지리 위치 추정 등 다양한 task 수행 가능
 - task-specific 학습 없이도 generalization 가능
-

6. Discussion (발견 및 한계)

주요 발견

1. 자연어 기반 supervision은 매우 강력한 신호이다
 2. 데이터 규모(scale)가 성능을 크게 좌우한다
 3. zero-shot 성능이 실제 모델 능력을 잘 반영한다
-

한계

- 데이터 품질이 일정하지 않음 (웹 데이터)
 - 편향(bias) 문제 가능성
 - 매우 큰 계산 자원 필요
-

7. Conclusion (결론)

- 자연어 기반 학습을 통해
범용적인 visual representation 학습 가능
 - contrastive learning이 핵심 역할 수행
 - zero-shot generalization 성능 크게 향상
-

8. 기존 연구 대비 차별점

- 고정된 label → 자연어 기반 표현
 - supervised learning → contrastive multimodal learning
 - task-specific 모델 → 범용 모델
 - 소규모 데이터 → 대규모 웹 데이터 활용
-

9. 핵심 아이디어 정리

- 이미지와 텍스트를 같은 embedding space에 매핑
 - pair matching 문제로 단순화
 - 자연어를 통해 새로운 개념 정의 가능
 - zero-shot 방식으로 다양한 task 해결
-

Segment Anything (SAM) 정리

1. Abstract (무슨 문제 풀려고 했냐)

이 논문은 이미지 segmentation을 위한 foundation model을 만드는 것을 목표로 한다.

핵심 구성:

- 새로운 task: **promptable segmentation**
- 새로운 모델: **SAM**
- 새로운 데이터셋: **SA-1B (11M images, 1B masks)**

이 모델은

→ 다양한 입력(prompt)을 받아 segmentation 수행

→ zero-shot으로 다양한 segmentation task에 적용 가능

결과적으로, 기존 supervised 모델과 비교해도

zero-shot 성능이 경쟁력 있음

2. Introduction (연구 동기 + 문제점)

기존 segmentation의 문제

- task별로 모델 따로 필요
 - 데이터셋마다 학습 다시 해야 함
 - segmentation 데이터는 특히 부족함
-

기존 흐름

- NLP → GPT 같은 foundation model 등장
- CV → CLIP 등 일부 foundation model 존재

하지만:

→ segmentation은 아직 foundation model 없음

핵심 질문

이 논문이 던지는 3가지 질문:

1. 어떤 task를 정의해야 generalization이 될까?
 2. 어떤 모델 구조가 필요한가?
 3. 어떤 데이터로 학습할 것인가?
-

3. Related Works (관련 연구)

- CLIP: 이미지-텍스트 alignment
 - detection / segmentation 모델들:
 - 특정 task에 특화됨
 - 범용성 부족
-

기존:

- task-specific model

SAM:

- task 자체를 general하게 정의
-

4. Method (접근 방법 + 모델 구조)

4-1. 핵심 아이디어

segmentation을 “prompt 기반 문제”로 바꾼다

4-2. Promptable Segmentation Task

입력:

- 점(point)
- 박스(box)
- 마스크(mask)
- 텍스트

출력:

- 해당 prompt에 맞는 segmentation mask
-

중요 포인트:

- prompt가 애매해도
→ “유효한 mask 하나”는 반드시 출력해야 함
-

4-3. 모델 구조 (SAM)

구성은 3개:

1) Image Encoder

- ViT 기반
 - 이미지 전체를 embedding으로 변환
-

2) Prompt Encoder

- point / box → positional encoding
 - text → CLIP encoder 사용
 - mask → convolution
-

3) Mask Decoder

- image embedding + prompt embedding 결합
 - Transformer 기반
 - segmentation mask 생성
-

구조 핵심

- image embedding은 **한 번만 계산**
 - prompt만 바뀌어서 빠르게 반복 사용
-

4-4. Ambiguity 처리

문제:

- 하나의 prompt가 여러 객체를 가리킬 수 있음

해결:

- **여러 개의 mask 출력**
 - 각 mask에 confidence score 부여
-

4-5. 속도 설계

- image encoder: 한 번만 수행
 - prompt encoder + decoder: 약 50ms
-

5. Data (데이터셋 + 데이터 엔진)

5-1. 핵심 문제

- segmentation 데이터는 웹에 거의 없음
-

5-2. 해결 방법: Data Engine

모델을 이용해서 데이터를 만드는 구조

3단계:

1) Assisted Manual

- 사람이 모델 도움 받아 라벨링

2) Semi-Automatic

- 일부는 모델이 자동 생성
- 나머지만 사람이 보완

3) Fully Automatic

- grid point로 prompt 생성
 - 모델이 자동으로 mask 생성
-

5-3. 최종 데이터셋

- 11M 이미지
- 1.1B masks

기존 대비:

- 이미지: 11배

- mask: 400배
-

6. Experiments (실험 구성 + 결과)

평가 방식

- 다양한 segmentation task (23개 dataset)
 - zero-shot 방식
-

결과 특징

1. 단일 point prompt만으로도 높은 정확도
 2. 다양한 task에서 성능 유지
 - edge detection
 - object proposal
 - instance segmentation
-

핵심 해석

- 특정 task 학습 안 했는데도 잘됨
→ “task generalization 성공”
-

7. Discussion (발견 + 한계)

주요 발견

1. segmentation도 foundation model 가능
 2. prompt 기반 접근이 매우 강력함
 3. 데이터 규모가 핵심 역할
-

한계

1. 완벽한 segmentation은 아님
 2. 복잡한 semantic understanding은 제한적
 3. 작은 객체나 세밀한 경계에서 성능 저하 가능
-

8. Conclusion (결론)

- segmentation을 prompt 기반 문제로 재정의
 - 대규모 데이터 + 효율적인 구조로 foundation model 구축
 - zero-shot segmentation 가능성 입증
-

9. 기존 연구 대비 차별점

- task-specific segmentation → 범용 segmentation
 - 고정 task → prompt 기반 task
 - 수동 라벨링 → 모델 기반 데이터 생성
 - 소규모 데이터 → 초대규모 데이터
-

10. 핵심 아이디어 정리

- segmentation을 "입력(prompt) → 출력(mask)" 구조로 통일
 - 다양한 task를 하나의 모델로 처리
 - prompt engineering으로 task 정의
-

핵심 포인트

- image embedding 재사용
 - prompt만 바꿔 다양한 결과 생성
 - multi-mask + confidence 구조
-