

BASE 세션 4주차 내용 정리 과제

Sequential 모델의 흐름

1. 기존 n-gram : 단어의 순서와 빈도 기반 (문제 : 희소 문제)
 2. NNLM : 단어를 embedding으로 표현 (문제 : 고정 길이)
 3. RNN : 과거 정보를 hidden state에 계속 누적 (문제 : 장기 의존성의 어려움)
 4. LSTM&GRU : 장기 의존성 문제 해결을 위한 게이트 구조 도입
-

Seq2Seq

- 구조 : 입력 문장 → Encoder → 하나의 Context 벡터 → Decoder → 출력 문장
 - 이전 정답 단어를 다음 입력으로 넣어줌
-

Attention

- 기존 모델(Seq2Seq) vs. Attention
 - Seq2Seq : 하나의 Context 벡터에 모든 정보를 압축하기 때문에 문장이 길어지면 정보 손실이 발생할 수 있음
 - Attention : hidden state 정보들을 들고 와 문장이 길어져도 정보 손실 발생이 적어짐
 - 흐름
 1. 인코더의 hidden state들과 현재 디코더 상태를 내적하여 유사도를 계산함
 2. 계산된 score들을 softmax에 통과시켜 가중치로 변환함
 3. 각 hidden state에 가중치를 곱하여 attention vector를 생성함
 4. 해당 벡터들을 디코더 상태와 concat하여 최종 출력 예측에 사용함
-

Transformer

- 구조
 - Encoder N개 + Decoder N개 (본 논문에서 N값은 6)
- 흐름

- Positional Encoding : self-attention은 순서 정보를 가지고 있지 않기 때문에 positional encoding을 사용해 단어 임베딩에 위치 벡터를 넣어줌
- Multi-Head Attention : Attention을 head수(본 논문에서는 8) 만큼 병렬 수행함

$$\left| \text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V \right.$$

- Masked Multi-Head Attention(Decoder) : Decoder는 치팅을 방지하기 위해 Mask를 적용하여, t번째 단어는 t 이전까지만 참조할 수 있도록 함
- Feed Forward : 비선형 변환을 하여 표현력을 증가하게 함

$$\left| \text{FFNN}(x) = \max(0, xW_1 + b_1)W_2 + b_2 \right.$$

- Add&Norm : 학습 안정화를 위함

$$\left| H(x) = x + F(x) \right.$$

$$\left| \text{LN} = \text{LayerNorm}(x + \text{Sublayer}(x)) \right.$$

BERT

- Transformer의 Encoder만 사용함
- 흐름

1. Input Sequence

- subword 기반 (ex. playing → play + ##ing)
- special 토큰 ([CLS] : 분류용/[SEP] : 문장 구분)
- 최종 입력 벡터 = (Token Embedding) + (Segment Embedding) + (Position Embedding)

2. Pre-training

- a. Masked Language Model : 일부 토큰을 가리고, 좌우 문맥을 이용해 예측

$$\left| P(w_i | w_1, \dots, w_{i-1}, w_{i+1}, \dots, w_n) \right.$$

- 전체 토큰 15% 선택하여 진행 (80%는 [MASK], 10%는 random, 10%는 그대로 유지)

- b. Next Sentence Prediction : 두 문장이 연속된 문장인지 아닌지 이진분류

- [CLS] 토큰의 최종 hidden state로 이진 분류 (50%는 실제 다음 문장, 50%는 랜덤 문장으로 데이터 구성)

3. Fine-Tuning

- a. Sentence A+B : 문장 쌍 분류
- b. Single sentence : 감정 분석
- c. Question + paragraph : QA
- d. single sentence : NER

BERT vs. GPT vs. BART

BERT

GPT

BART

: 양방향 Encoder : 단방향 Decoder : Encoder는 양방향 + Decoder는 단방향

문맥 이해 특화

생성 특화

이해 + 생성 결합