

[Improving Language Understanding by Generative Pre-Training]

GPT-1 은 대규모 라벨 없는 텍스트에서 언어 모델을 Generative Pre-Training 을 시킨 후, 각 타겟 작업에 맞춰 Discriminative Fine-tuning 을 수행하는 Semi-supervised learning 프레임워크를 제안. 특히 트랜스포머(Transformer) 디코더를 채택하고, Task-aware input transformations 을 도입하여 모델 아키텍처의 수정 없이 효과적인 전이 학습을 달성한다.

자연어 처리 모델을 학습시킬 때 라벨링이 된 데이터 많지 않기에 구축하는 데 막대한 시간과 비용이 많이 든다. 반면 라벨이 없는 텍스트는 많다. GPT-1 은 원래의 텍스트에서 언어적 표현을 효과적으로 학습하여 지도 학습 데이터 부족 현상을 완화하는 대안을 제시했다.

기존에는 크게 3 가지의 한계가 있었다.

1. 최적화 및 전이 방식의 부재 : 라벨이 없는 텍스트에서 단어 수준 이상의 의미를 학습하기 위해 어떤 최적화 목적 함수가 효과적인지 명확하지 않았으며, 학습된 표현을 타겟 작업에 전이하는 최적의 방법이 없었다.
2. 아키텍처의 비효율성 : 기존에는 대상 작업(분류, 합의, 질의응답 등)이 바뀔 때마다 모델 아키텍처를 그에 맞게 계속해서 변경해야 했다.
3. 모델 구조의 한계 : 텍스트 분류 등에서 사전 학습을 시도한 기존 연구들은 주로 LSTM 기반 모델을 사용하여 장기 의존성을 포착하는 데 근본적인 한계가 있었다.

한계를 극복하기 위한 2 가지 방법.

첫 번째: 비지도 사전 학습과 지도 미세 조정의 2 단계 훈련 <Two-stage Training Framework>

1 단계 Unsupervised Pre-training : 라벨이 없는 텍스트를 $U = \{u_1, \dots, u_n\}$ 를 활용하여 표준 언어 모델링 목적 함수를 최적화한다. 주어진 컨텍스트 윈도우 내에서 이전 토큰들을 기반으로 다음 토큰을 예측할 우도를 $L_1(U) = \sum_i \log P(u_i | u_{i-k}, \dots, u_{i-1}; \theta)$ 최대화하도록 파라미터를 학습시킨다.

2 단계 Supervised Fine-tuning : 타겟 작업의 레이블 데이터를 사용하여 목적 함수

$L_2(C) = \sum_{(x,y)} \log P(y | x^1, \dots, x^m)$ 를 최대화하도록 모델을 미세 조정한다. 학습 과정에서 기존 언어 모델링 목적 함수를 보조 목적 함수로 결합한 $L_3(C) = L_2(C) + \lambda L_1(C)$ 최적화함으로써 지도 모델의 일반화 성능을 높이고 수렴 속도를 가속화했다.

두 번째 : 트랜스포머 디코더 및 작업 맞춤형 입력 변환 <Transformer & Task-aware Input Transformations>

트랜스포머 아키텍처 : 텍스트의 장거리 의존성을 모델링하기 위해 LSTM 대신 12 개 레이어와 Multi-headed Self-attention 메커니즘을 갖춘 트랜스포머 디코더를 사용했다.

입력 구조 변환 : 타겟 작업별로 복잡한 아키텍처를 새로 구축하는 대신, 구조화된 입력을 단일 연속 토큰 시퀀스로 변환했다. 예를 들어, 질의응답(QA) 작업의 경우 [문서;질문;\$답변] 형태로 시작(Start), 추출(Extract), 구분자(Delim) 토큰을 삽입해 1 차원 시퀀스로 병합한다. 이 방법을 통해

사전 학습된 트랜스포머 구조를 그대로 유지하면서 마지막에 선형 레이어(Linear layer) 하나만 추가하여 효과적으로 태스크를 수행할 수 있게 되었다.

GPT-1 의 모델은 특정 작업 전용으로 설계된 기존 최신 모델보다 평가된 12 개 작업 중 9 개에서 최고 성능을 냈다. Story Cloze Test 에서 8.9%, 질의응답(RACE)에서 5.7%, 텍스트 함의에서 1.5%의 성능 향상을 보였다. 생성적 사전 학습만으로도 하위 작업에 필요한 다양한 언어적 기능과 유용한 제로샷 추론 능력을 획득한다는 것을 보였다.

GPT-1 에서 사용한 데이터는 2 가지의 종류가 있다.

사전 학습 : 모험, 판타지, 로맨스 등 다양한 장르의 미출판 도서 7,000 권 이상으로 구성된 'BooksCorpus' 데이터셋을 활용했다. 문장 단위로 섞여 있지 않고 긴 문맥이 유지된 데이터이므로 장기 의존성(long-range information)을 학습하기에 좋다.

미세 조정 : GLUE 벤치마크를 포함하여 SNLI, MultiNLI, RACE, Story Cloze, SST-2, CoLA 등 다양한 크기의 NLI, QA, 문장 유사도, 분류 데이터셋이 평가에 사용되었다.

GPT-1 의 한계점은 크게 2 가지가 있다.

1. 소규모 데이터셋에서의 한계 : 데이터 크기가 2,490 개에 불과한 RTE(텍스트 함의)

데이터셋에서는 56%의 정확도를 기록하여, 다중 작업(Multi-task) 학습을 적용한 기존 biLSTM 모델(61.7%)에 미치지 못했음을 확인했다. 이는 향후에 작은 데이터셋을 위한 다중 작업 학습 결합이 필요하다는 것을 보여준다.

2. 보조 목적 함수의 의존성 : 미세 조정 단계에서 언어 모델링 보조 목적 함수를 추가하는 것은 NLI 와 같이 상대적으로 큰 데이터셋에서는 성능 향상을 보였지만, 작은 데이터셋에서는 큰 이점을 제공하지 못했음을 확인했다.

[DeepSeek-R1: Incentivizing Reasoning Capability in LLMs via Reinforcement Learning]

최근 대형 언어 모델은 Chain-of-Thought, CoT 프롬프팅 등을 통해 수학적, 논리적 추론 작업에서 많은 성장을 이뤘다. 그러나 기존의 추론 능력 향상 기법들은 사람이 직접 세밀하게 작성한 고품질의 추론 데이터에 크게 의존한다는 치명적인 한계가 있었다.

이러한 지도 학습(Supervised Learning) 기반의 접근은 엄청난 데이터 구축 비용을 발생시키고, 모델의 인지적 한계를 '인간이 생각하는 방식' 안에 가두는 문제를 발생시킨다. 인간이 제공한 모범 답안만을 모방하게 되면, 모델 스스로 인간의 사고방식을 뛰어넘는 또다른 추론 경로를 탐색하는 것이 불가능해진다. 이 문제를 해결하기 위해 Deepseek R1 은 지도 미세 조정없이 순수 강화학습만을 활용하여 모델 스스로 진화하며 추론 능력을 발현할 수 있는지 탐구를 하고자했다.

먼저 사전 학습된 기본 모델인 'DeepSeek-V3-Base'에 지도 학습 없이 바로 강화학습을 적용한 DeepSeek-R1-Zero 를 개발했다.

1. GRPO (Group Relative Policy Optimization) 알고리즘 도입

일반적으로 LLM 의 강화학습에는 PPO(Proximal Policy Optimization) 알고리즘이 널리 사용되지만, PPO 는 정책 모델과 동일한 크기의 가치 모델을 메모리에 올려야하는데, 이는 엄청난 연산과 메모리 자원이 소모된다. 이를 해결하기 위해서 GRPO 알고리즘을 도입했고, GRPO 는 별도의 가치 모델을 두지 않고, 이전 정책에서 샘플링된 동일한 질문에 대한 여러 개의 응답 내에서 상대적인 점수(평균과 표준편차)를 비교하여 이점을 계산하게 된다.

2. 규칙 기반 보상 모델 (Rule-based Reward)

추론 작업에서 신경망 기반의 보상 모델을 사용할 경우, 강화학습이 진행됨에 따라 모델이 보상 시스템의 허점을 파고드는 보상 해킹 문제가 발생하기 쉽다. 따라서 DeepSeek-R1-Zero 는 엄격한 규칙 기반 보상만을 활용하여 진행한다.

- 정확도 보상 : 수학 문제의 최종 도출 값이나 코딩 테스트의 컴파일러 통과 여부 등 결정론적이고 객관적인 결과를 평가한다.

- 형식 보상 : 모델이 추론 과정을 명확히 분리하도록 유도한다.

3. 자발적 추론 능력의 발현 (Emergent Behaviors)과 "Aha Moment"

모델에게 '어떤 방식으로 추론하라'고 직접 가르치지 않았음에도 보상을 얻기 위해 자체적으로 추론 행동을 터득했다는 것을 확인할 수 있다.

- 학습이 진행될수록 모델이 응답을 생성하기 전 스스로 사고하는 토큰의 길이가 수백에서 수천 개로 자연스럽게 증가했다.

- Aha Moment : 모델은 문제를 풀다가 막히면 스스로 Wait 이나 Let me. Reevaluate 등의 단어를 생성하며 이전 단계를 검증하고, 오류를 반성한 뒤 새로운 접근법을 탐색하는 능력을 보여주었다.

DeepSeek-R1-Zero 는 AIME 2024 기준 77.9% 달성은 했으나 답변이 직관적이지 않고 가독성이 떨어지며, 동일한 답변 내에 영어와 중국어가 섞이는 언어 혼합(Language Mixing) 문제가 빈번하게 발생했다. 이러한 한계를 극복하고 인간의 선호도와 일반적인 언어 능력을 맞추기 위해, 4 단계의 학습 프레임워크(다단계 훈련 파이프라인)를 적용한 DeepSeek-R1 이 완성된다.

1. 콜드 스타트 SFT (Cold Start SFT) : R1-Zero 의 초기 불안정성을 잡기 위해, 좋은 품질의 Long CoT 데이터 수천 개를 수집하여 기본 모델을 미세 조정한다. 이 단계에서는 가독성을 높이고, 1 인칭 시점의 자연스러운 사고 흐름을 모델에게 부여하게 된다.
2. 추론 집중 강화학습 (Reasoning RL) : 콜드 스타트 이후, 코딩 및 수학 등 검증 가능한 데이터를 바탕으로 강화학습을 진행한다. R1-Zero 에서 발생했던 '언어 혼합' 문제를 해결하기 위해, 사고 과정 내에 질문과 동일한 타겟 언어가 얼마나 포함되었는지를 측정하는 Language Consistency Reward 을 추가로 도입했다.
3. 거절 샘플링 및 SFT (Rejection Sampling and SFT) : 추론 능력이 강화된 단계 2 의 모델을 이용해 방대한 양의 데이터를 생성한다. 생성된 데이터 중 정답을 맞히고 가독성이 좋은 데이터만 걸러내는 Rejection Sampling 을 통해 약 60 만 건의 추론 데이터를 확보한다. 여기에 글쓰기, 일반 상식, 역할극 등 추론과 무관한 일반 데이터 20 만 건을 더해 총 80 만 건의 거대한 SFT 데이터셋을 구성하여 모델을 다시 훈련한다. 이 과정에서 모델은 발전된 추론 능력과 범용적인 대화 및 작문 능력을 갖추게 된다.
4. 모든 시나리오를 위한 범용 강화학습 (General RL) : 최종적으로 모델을 인간의 윤리적 선호도에 정렬하기 위해 신경망 기반의 보상 모델활용하여 전반적인 강화학습을 수행한다. 일반적인 프롬프트에 대해서는 유용성과 무해성을 평가하여 보상을 제공하고, 추론 문제에 대해서는 규칙 기반 보상을 유지한다.

대형 언어 모델의 엄청난 에너지 소비와 배포의 어려움을 해결하기 위해, DeepSeek-R1 의 강력한 추론 능력을 더 작은 오픈소스 모델에 전달하는 지식 증류(Distillation)를 수행했다. 위의 3 단계에서 구축된 80 만 개의 정제된 SFT 데이터를 사용하여 Qwen(1.5B ~ 32B) 및 LLaMA(8B, 70B) 아키텍처 기반의 모델들을 미세 조정을 시행했다.

증류(Distillation) vs. 순수 RL 의 효과 비교도 진행했다. 소형 모델(Qwen-32B)에 대규모 강화학습을 직접 수행하는 것보다, R1 과 같은 강력한 모델에서 생성된 데이터를 증류하여 학습시키는 것이 더 높은 성능을 발휘한다. 이 결과는 소형 모델 생태계 발전에 있어, 거대 모델의 추론 패턴(Reasoning pattern)을 증류하는 방식이 연산 자원 측면에서 가장 효율적임을 보여준다.

DeepSeek-R1 핵심 성능에서 좋은 결과를 냈다.

수학 및 논리 추론에서는 미국 수학 올림피아드 예선(AIME 2024)에서 79.8%의 정답률을 기록했으며 , MATH-500 벤치마크에서는 97.3%라는 수치가 나왔다.

코딩 알고리즘에서는 Codeforces 플랫폼의 알고리즘 문제 풀이에서 상위 96.3%에 해당하는 성적을 거두어 사람의 평균을 뛰어넘었다.

테스트 타임 컴퓨팅 확장에서 DeepSeek-R1 은 문제의 난이도에 따라 스스로 컴퓨팅 자원을 동적으로 조절한다. 쉬운 문제에는 100 개 미만의 토큰을 쓰지만, 복잡한 문제에는 18,000 개 이상의 토큰을 생성하며 더 집중적으로 고민하여 결과를 출력하는 능력을 가지고 있다.

DeepSeek-R1 은 좋은 모델이지만 크게 3 가지의 한계점을 가진다.

1. 도구 사용 및 구조화된 출력의 한계 : 검색 엔진 브라우징이나 계산기 등 외부 도구(Tools)를 아직 사용할 수 없고, JSON 등 구조화된 포맷을 출력하는 성능이 부족하다.
2. 다국어 환경의 언어 혼합: 주로 영어와 중국어에 최적화 되어있기 때문에 그 외의 언어로 질문할 경우 CoT 단계에서 영어로 사고한 뒤 대답하는 현상이 발생하기도 한다.
3. 프롬프트 민감성 : 소수 샷 프롬프팅을 제공할 경우 오히려 성능이 하락하는 경향이 있어, 제로 샷 환경에서 문제만 간결하게 제시하는 것이 모델의 자발적 추론 능력을 이끌어내는 데 가장 유리하다.