

1. Generative Adversarial Nets

GAN은 adversarial process을 통해 생성 모델을 추정하는 프레임워크를 설명했다. 데이터 분포를 포착하는 생성 모델(G)과 샘플이 훈련 데이터인지 생성된 것인지 확률을 추정하는 판별 모델(D)을 동시에 훈련하는 minimax two-player game의 구조를 가진다.

GAN은 maximum likelihood estimation 등에서 발생하는 다루기 힘든 intractable probabilistic computations를 회피할 수 있기에 이 연구는 중요하다고 한다.

훈련이나 샘플 생성 과정에서 Markov chains이나 복잡한 근사 추론 네트워크가 필요하지 않고 오직 역전파(backpropagation)만으로 훈련이 가능하다.

딥러닝의 발전과 성공적인 결과는 대부분 고차원 입력을 클래스 레이블로 매핑하는 discriminative models에 집중되어 있었다. 하지만 심층 생성 모델(deep generative models)은 방향성 / 무방향성 그래픽 모델의 partition function를 계산하거나 Markov chain Monte Carlo의 mixing 문제로 인해 실질적인 효과를 거두는 데 어려움이 있었다.

GAN을 활용하여 위조지폐범(생성기)과 경찰(판별기)의 경쟁 구도를 모델링하여 한계를 극복하고, 더 나은 결과를 만들었다. 판별 모델 D는 실제 훈련 데이터와 G가 생성한 샘플에 올바른 레이블을 할당할 확률을 최대화하도록 훈련되고, 생성 모델 G는 D가 실수하도록 $\log(1 - D(G(z)))$ 를 최소화하는 방향으로 동시에 훈련시키면 된다.

이러한 **GAN**은 임의의 함수 공간에서 minimax two-player game는 생성 모델 G가 훈련 데이터 분포를 완벽하게 복원($p_g = p_{\text{data}}$)하고, 판별 모델 D는 모든 곳에서 구별 확률이 $\frac{1}{2}$ 이 되는 유일한 unique solution을 가진다는 것을 수학적으로 증명하게 된다. 마르코프 체인 혼합에 의존하지 않아 샘플 간 상관관계가 없다는 경쟁력 있고 선명한 샘플을 생성할 수 있다.

GAN은 모델을 훈련하고 평가하기 위해 MNIST, Toronto Face Database (TFD), 그리고 CIFAR-10 데이터셋을 사용했다.

하지만 이러한 GAN에도 단점이 있다.

가장 큰 단점은 생성된 분포 $p_g(x)$ 에 대한 명시적인 표현(explicit representation)이 없다는 것이었다. 또한, 훈련 중 D와 G가 제대로 동기화(synchronized)되어야 하며, D를 업데이트하지 않고 G를 너무 많이 훈련시킬 경우 모델이 다양한 데이터를 생성하지 못하고 소수의 특정 이미지만 반복 생성하는 the Helvetica scenario에 빠질 수 있다.

2. Denoising Diffusion Probabilistic Models

Diffusion은 nonequilibrium thermodynamics에서 영감을 받은 확산 확률 모델(diffusion probabilistic models)을 사용하여 고품질의 이미지 합성을 시연했다. 특히 확산 모델과 Langevin dynamics을 사용하는 denoising score matching 간의 새로운 수학적 연결 고리를 발견하고 이를 최적화에 적용하게 되었다.

이전까지 이론적으로만 존재하던 확산 모델이 실제로 다른 생성 모델들과 경쟁할 수 있는 매우 높은 품질의 샘플을 생성할 수 있음을 최초로 보여주었기 때문에 Diffusion은 매우 중요한 모델이라고 할 수 있다. 더불어 확산 모델의 샘플링 절차가 자기회귀 디코딩(autoregressive decoding)의 일반화로 해석될 수 있는 점진적인 손실 압축 풀기(progressive lossy decompression) 방식이라는 것을 이론적으로도 증명해냈다.

Diffusion 이전의 확산 모델 자체는 정의하기 쉽고 훈련이 효율적이었으나, 모델이 고품질 샘플을 생성할 수 있다는 어떠한 demonstration도 없었다. 또한, 기존 점수 매칭이나 에너지 기반 모델(EBM)은 샘플 품질은 좋으나 Likelihood 평가가 복잡하고, GAN은 훈련이 불안정하다는 한계가 있었다.

이러한 문제를 해결하기 위해 Diffusion은 reverse process의 신경망이 다음 상태의 평균을 직접 예측하는 대신, 현재 상태 x_t 에 더해진 노이즈 ϵ 를 예측하도록 parameterization를 변경했다. 또한, 네트워크가 너무 미세한 노이즈를 제거하는 데 에너지를 낭비하지 않고 더 어려운 denoising 구간에 집중할 수 있도록, 손실 가중치를 제거한 간소화된 simplified training objective를 훈련 목표로 채택하게 되었다.

Diffusion은 unconditional CIFAR10 데이터셋에서 Inception score 9.46, 당시에 가장 좋은(State-of-the-art)의 FID score 3.17을 달성했다. 또한 256x256 해상도의 LSUN 데이터셋에서도 ProgressiveGAN과 유사한 높은 수준의 샘플 품질을 얻으며 성공적인 결과를 보인다.

무조건부 모델 평가를 위해 CIFAR10, CelebA-HQ 256x256 데이터셋을 사용했으며, 추가적으로 LSUN 256x256 해상도의 Bedroom, Church, Cat 카테고리 이미지를 Diffusion에 활용했다.

생성된 샘플의 품질은 매우 뛰어나지만, 모델의 log likelihoods 수치가 다른 likelihood-based 생성 모델들과 비교했을 때 경쟁력이 떨어진다. GAN은 모델의 무손실 코드 길이(lossless codelengths)의 절반 이상이 사람이 인지조차 할 수 없는 미세한 imperceptible distortions을 설명하는 데 불필요하게 소비된다는 평가를 받기도 한다.