

CLIP | Learning Transferable Visual Models From Natural Language Supervision

1. Pre-knowledges & Abstract

1. 기본 컴퓨터 모델은 미리 정해진 class 예측만 가능
2. NLP에서는 대규모 텍스트 모델, 라벨없이 인터넷 텍스트로 예측
3. conVIRT
 - 엑스레이는 일반 사람은 어렵고, 의사가 텍스트 리포트를 같은 공간에서 매핑
 - 이미지는 이미지 인코더, 텍스트는 텍스트 인코더 → 벡터 → 유사도 확인
 - 의료 도메인에 특화
 - 데이터 규모도 작아서 일반화가 어려움
4. VirTex
 - 이미지는 CNN, 이걸 Transformer에 넣음
 - 사진을 하나를 봤을 때 주관적인 판단이 들어가서 제대로 진행하기 어려움

2. Apporach

1. 데이터셋이 중요함
2. MS-coco : high quality / small (100,000)
3. YFCC100M : Varying quality / large (100M)
4. WIT (Web Image Text) : Collected a new dataset of 400M (image/test) pairs
5. Efficient Pre-Training Method
6. Common Issues
 - Polysemy
 - Usually text is a full sentence in the training set

3. Experiments

- Customizing prompt text to each text - worked well on Oxford pets dataset
- Ensemble of different context prompts - Ensemble over the embedding space, instead of probability space On ImageNet, ensemble improved performance by 3.5%
- Zero shot performance
- Robustness to Natural Distribution Shift
- ImageNet으로 학습한 ResNet : 특정 데이터에 과적합 → 데이터셋이 바뀌면 성능 하락
- CLIP : 다양한 데이터로 학습 → 데이터셋이 바뀌면 성능 비슷
- Adapt to ImageNet:
 - ImageNet 정확도 +9.2% 향상
 - 단, 타 분포 데이터셋 성능 저하 (ImageNet-R -4.7%, ObjectNet -3.8%)
 - 분포 특화 학습이 강건성을 저하시킴
- Adapt to class shift:
 - 클래스 재설계만으로 Youtube-BB +26.9% 성능 향상
 - Zero-Shot의 유연성이 강건성 유지의 핵심 요인임을 시사

4. Conclusions & Future Works

1. Comparison to Human Performance

- Zero-shot 기준 93.5% vs 53.7%
- 인간 예시 1 개 학습 53.7% → 75.7%
- 사전 지식을 활용하는 방식이 인간과 CLIP 이 다름
- 오류 패턴은 인간과 유사

2. Data Overlap Analysis

3. 대규모 인터넷 데이터 사전학습 시 평가 데이터셋과의 비의도적 중복 가능성

4. 데이터 중복이 모델 성능에 미치는 영향은 통계적으로 유의미하지 않음 ($p > 0.05$) → 성능 향상은 학습 방법론에 기인

5. Limitations

- performance Gap : SOTA 대비 약 1000 배 연산 필요
- Task Weakness : 세밀한 분류 및 추상적 추론 취약
- OOD sensitivity : 학습 외 데이터 일반화 부족
- Data Inefficiency : 128 억 장 학습 필요 (405 년치)
- Broader Impacts

5. Future Work & Research Directions

1. Characterization : 모델 능력 및 한계 체계적 파악 필요
2. Bias Testing : 더 광범위한 편향 검사 필요
3. Policy Surfacing : 사회적 민감 task 식별 및 정책 개입
4. Failure Analysis : 실패 사례 분석 및 개선 방향 도출

CLIP: Learning Transferable Visual Models From Natural Language Supervision

CLIP 은 이미지 분류를 위해 고정된 정답 레이블(N-way classification)을 예측하는 기존의 학습 방식이 아닌 인터넷에서 수집한 4 억 개의 (이미지, 텍스트) 쌍을 바탕으로 '어떤 이미지가 어떤 텍스트와 짝을 이루는지'를 예측하는 대규모 대조 학습(Contrastive Learning) 프레임워크이다.. 추론 시에는 타겟 데이터셋의 클래스 이름을 텍스트 인코더에 넣어 제로샷 선형 분류기의 가중치를 동적으로 생성한다.

컴퓨터 비전 모델이 수동으로 레이블링된 한정된 데이터셋의 범주의 한계를 극복했다. 자연어라는 무한하고 풍부한 지도 신호(Supervision)를 활용함으로써 모델은 시각적 개념과 언어를 맵핑하게 되고, 결과적으로 어떤 특화된 미세 조정(Fine-tuning) 없이도 텍스트 프롬프트를 통해 대부분의 시각 분류 태스크를 제로샷으로 수행할 수 있는 범용적(General-purpose) 비전 모델의 시대를 열게 되었다.

기존의 모델은 한계를 가지게 된다. ImageNet 과 같은 Crowd-labeled 데이터는 확장 비용이 천문학적이며 정해진 클래스 외의 시각 개념은 학습할 수 없다. 이미지의 캡션을 토큰 단위로 정확히 예측하도록 학습하는 기존 방식들은, 광범위한 텍스트의 다양성 때문에 최적화가 어렵고 비효율적이다. 또한, 기존 ImageNet SOTA 모델들은 훈련 데이터 분포에서는 뛰어난 성능을 보이지만, 스케치, 적대적 예제, 비디오 프레임 등 자연스러운 분포 이동이 발생하면 성능이 급락하는 '견고성 갭(Robustness gap)' 문제가 있다.

CLIP 은 이러한 한계를 다음과 같이 극복한다. 대조적 목적 함수를 사용한다. 정확한 캡션 단어를 예측하는 대신, 배치(Batch) 내에 있는 N 개의 (이미지, 텍스트) 쌍에서 진짜 짝 N 개의 코사인 유사도는 최대화하고, 나머지 가짜 짝 $N^2 - N$ 개의 유사도는 최소화하는 대조 학습을 도입하여 언어 모델 예측 대비 학습 효율을 4 배 이상 키웠다. 프롬프트 엔지니어링을 활용한다. 제로샷 추론 시 단순히 단어(예: "dog")만 입력하면 다의어 문제나 문맥 부족이 발생한다. 이를 극복하기 위해 "A photo of a {label}"과 같은 텍스트 템플릿을 씌우고 여러 프롬프트를 앙상블(Ensemble)하여 제로샷 성능을 5% 이상 향상시켰다.

CLIP 은 ImageNet 의 128 만 장 훈련 데이터를 단 한 장도 보지 않고도 제로샷만으로 기존 ResNet-50 의 지도 학습 성능(76.2%)과 동일한 정확도를 달성했다. 그리고 ImageNetV2, ImageNet Sketch 등 자연적인 분포 이동이 일어난 7 개의 데이터셋에서 기존 지도 학습 모델들보다 높은 성능을 유지하며 Robustness gap 을 최대 75%까지 줄였다. 또한, OCR, 지리적 위치 추정(Geo-localization), 비디오 행동 인식 등 30 개 이상의 매우 다양한 컴퓨터 비전 태스크에 대한 전이 학습 성능을 보였다.

사전 학습에 CLIP 은 인터넷에서 수집한 4 억 개의 (이미지, 텍스트) 쌍으로 구성된 자체 구축 데이터셋인 WIT (WebImageText)를 사용했다. CLIP 은 평가 단계에서 ImageNet, CIFAR, OxfordPets, Food101 등 범용 객체 분류뿐만 아니라, SST2, Hateful Memes,, UCF101 을 포괄하는 30 개 이상의 공개 벤치마크 데이터셋을 사용했다.

현재의 지도 학습 SOTA 모델들의 성능을 '전반적으로' 제로샷으로 뛰어넘으려면 약 1,000 배의 연산량이 더 필요할 것으로 추산되어 여전히 계산 효율성에 한계가 있다. 또한 PatchCamelyon 이나 이미지 내 객체 개수 CLEVRCounts 와 같이 추상적이거나 복잡한 특수 태스크에서는 제로샷 성능이 무작위에 가까울 정도로 취약하다. 특히 렌더링된 텍스트(OCR)는 잘 읽지만, MNIST 등의 OOD(Out-of-Distribution) 수기 숫자 데이터에서는 매우 저조한 성능(88%)을 보여 근본적인 딥러닝의 일반화 취약성을 완전히 해결하지는 못한다. 인터넷 데이터를 필터링 없이 학습하여 사회적 편향(Social bias)을 그대로 내포하고 있다는 점도 큰 한계로 지적되고 있다.

SAM: Segment Anything

SAM은 Image Segmentation 분야를 위한 최초의 대규모 파운데이션 모델(Foundation Model)이다. Points, Boxes, Text, Masks 등 다양한 형태의 프롬프트를 입력받아 유효한 분할 마스크를 생성하는 '프롬프트 기반 분할' 태스크이다. 또한 모델과 데이터 수집을 반복하는 Data Engine을 구축하여, 1,100만 장의 이미지에 11억 개의 마스크가 포함된 역대 최대 규모의 분할 데이터셋인 SA-1B가 공개되었다.

기존의 분할 모델들은 특정 데이터셋과 고정된 범주에 대해서만 작동하도록 지도 학습되어, 새로운 데이터 분포나 새로운 태스크에 적용하려면 막대한 비용이 드는 수동 Annotation 작업과 재학습이 필수적이었지만 SAM은 LLM처럼 프롬프트 엔지니어링만으로 처음 보는 이미지와 객체에 대해 Zero-shot transfer가 가능하므로, 다운스트림 태스크의 데이터 수집 및 Fine-tuning 비용이 감소된다.

자연어 처리(NLP)나 텍스트-이미지 정렬(CLIP 등) 분야에서는 웹 규모의 데이터를 학습한 파운데이션 모델이 강력한 제로샷 성능을 보여주었으나, 픽셀 단위의 예측이 필요한 Segmentation 분야는 웹에서 마스크 데이터를 자연적으로 얻을 수 없다는 근본적인 데이터 부족 문제가 있다. 기존 분할 모델(Semantic, Instance, Panoptic)들은 단일 태스크에 국한되어 유연한 프롬프팅이나 모호성(Ambiguity)을 처리할 수 있는 아키텍처가 없었다.

이러한 한계를 해결하기 위해 MAE로 사전 학습된 ViT가 이미지 임베딩을 한 번 계산하면, 가벼운 프롬프트 인코더와 마스크 디코더가 브라우저 환경에서도 50ms 내에 실시간으로 마스크를 생성하도록 연산을 분리했다. 이 뿐만 아니라 점 하나가 주어졌을 때 그것이 '셔츠'인지 '셔츠를 입은 사람'인지 모호할 수 있는데, SAM은 단일 프롬프트에 대해 여러 개(주로 3개 - 전체, 부분, 하위 부분)의 마스크와 신뢰도 점수를 동시에 예측하도록 하여 모호성 문제를 해결했다. 또한 데이터 엔진을 활용해 모델 보조 수동 주석 Wri~~ght~~arrow 반자동 Wri~~ght~~arrow 전자동의 3 단계를 거쳐 11억 개의 마스크를 자체를 생산하게 된다.

수동 주석 없이 자동 생성된 SA-1B 데이터셋은 기존 Open Images 데이터셋보다 마스크 수가 400배 많다. 이 데이터로 학습된 SAM은 23개의 다양한 분할 벤치마크에서 단일 점 프롬프트만으로 기존 SOTA 대화형 분할 모델(RITM 등)의 성능을 넘어섰다. 엣지 감지(Edge detection), 객체 제안(Object proposal), 인스턴스 분할 등 완전히 새로운 태스크에서도 제로샷으로 SOTA에 근접한 성능을 보였다.

SAM에서 사용된 학습 데이터는 자체 구축한 SA-1B 데이터셋이다. 즉, 라이선스가 확보되고 프라이버시가 보호된 1,100만 장의 고해상도 이미지와 11억 개의 분할 마스크를 뜻한다. 평가 데이터는 제로샷 전이 능력을 평가하기 위해 LVIS, ADE20K, Cityscapes, EgoHOS (1인칭 시점), NDD20 (수중 이미지) 등 학습에 사용되지 않은 23개의 다양한 도메인 데이터셋이 사용되었다.

SAM은 아주 미세한 구조를 놓치거나, 작고 분리된 컴포넌트를 Hallucination으로 생성할 때가 있다. 또한, 복잡한 연산을 동반하는 전용 '줌인(zoom-in)' 모델들에 비해서는 마스크 경계의 선명도가 안 좋다. 시맨틱(Semantic)이나 파노픽(Panoptic) 분할과 같이 전체 범주를 한 번에 예측하는 태스크를 처리하려면 프롬프트를 어떻게 조합해야 할지 추가적인 엔지니어링이 필요하며, 텍스트-마스크(Text-to-mask) 기능은 아직 초기 단계로 완벽하지 않다.