

1. TabNet: Attentive Interpretable Tabular Learning

TabNet은 트랜스포머의 어텐션 메커니즘을 기반으로 표형 데이터에 최적화된 고성능의 해석이 가능한 딥러닝 아키텍처이다. TabNet의 가장 큰 특징은 각 Decision step마다 예측에 사용할 Features를 순차적인 어텐션을 통해 선택하는 '인스턴스 단위의 특성 선택(Instance-wise feature selection)'을 수행한다는 점이다. 또한, 표형 데이터에 대해 마스킹된 특성을 복원하는 Self-supervised pre-training 프레임워크를 최초로 도입했다.

표형 데이터는 현재 인공지능 응용 분야에서 가장 흔하게 쓰이는 데이터 유형이라고 한다. TabNet을 통한 표형 데이터의 인공지능 분야의 적용은 경사 하강법 기반의 종단간(End-to-end) 학습을 가능하게 한다. 이를 통해 이미지나 텍스트 등 다른 데이터 타입과의 효율적인 융합, 복잡한 Feature engineering의 최소화, 스트리밍 데이터의 지속적인 학습, 그리고 도메인 적응이나 Semi-supervised learning과 같은 표현 학습의 특징을 모두 지니고 있다.

표형 데이터에서는 XGBoost나 LightGBM과 같은 앙상블 결정 트리(DT) 기반 모델이 우위를 차지해왔다. 기존의 CNN이나 MLP 등은 표형 데이터의 결정 매니폴드에 적합한 Inductive bias이 부족하고 지나치게 매개변수가 되어 최적화에 실패하는 한계가 있었다. 반대로, 딥러닝에 트리를 결합하려 했던 미분 가능한 Soft DTs 방식은 결정적인 자동 특성 선택 능력을 잃어 성능이 저하되며, 기존의 인스턴스 단위 특성 선택 방식은 Explainer 네트워크나 액터-크리틱 구조를 추가로 두어야 하는 비효율성이 있었다.

TabNet은 단일 딥러닝 아키텍처 안에서 특성 선택과 추론을 동시에 수행하도록 설계되었다. 각 결정 단계에서 이전 단계의 정보를 바탕으로 Attentive transformer가 학습 가능한 곱셈 마스크($M[i]$)를 생성한다. Sparsemax 정규화를 통해 불필요한 특성을 Sparsity하여 모델의 학습 용량이 핵심 정보에만 집중되도록 유도하게 된다. 선택된 특성들은 결정 단계 간에 공유되는 레이어와 독립적인 레이어로 구성된 Feature transformer를 거쳐 처리되고 안정적인 학습을 위해 배치 정규화(Ghost BN)와 GLU 비선형 함수가 적용된다.

다양한 회귀 및 분류 벤치마크에서 강력한 트리 모델(XGBoost, LightGBM, CatBoost)과 AutoML과 유사하거나 더 좋은 성능을 가졌다고 한다. 특히 자기 지도 사전 학습은 레이블이 부족한 환경에서도 성능이 좋았고, 학습 수렴 속도가 빨라졌다. 각 결정 단계의 어텐션 마스크를 결합하여 개별 예측에 대한 Local 해석 가능성과 데이터셋 전체에 대한 Global 특성 중요도를 직관적으로 제공하게 되었으며, 앙상블 트리보다 훨씬 적은 파라미터 수로도 동일한 성능을 낼 수 있게 되었다

TabNet은 선택의 정확성을 수학적으로 증명하기 위해 구조가 통제된 합성 데이터셋을 활용했다. 실제 성능 평가는 Forest Cover Type, Poker Hand, Sarcos, Income 등 크기와 도메인이 다양한 여러 공개 데이터셋에서 이루어졌다.

TabNet은 모델의 성능이 희소성 정규화 계수나 특성 재사용 이완 변수(γ) 같은 새로운 하이퍼파라미터의 정밀한 튜닝 여부에 매우 의존한다는 단점이 있다. 또한 깊이를 과도하게 늘릴 경우 오히려 훈련 역학을 악화시켜 과적합이 발생할 수 있다. 범주형 변수를 입력할 때 단일 차원의 학습 가능한 스칼라로 단순 임베딩하기 때문에, 극도로 복잡한 범주형 데이터는 전처리가 필요할 수 있고, 고속 학습을 위해 큰 Batch size를 요구하여 메모리 제약을 받을 수 있다고 한다.

2. TabPFN: Accurate predictions on small data with a tabular foundation model

TabPFN은 ICL (In-Context Learning)을 활용하여 표형 데이터를 처리하는 파운데이션 모델이다. TabPFN은 사람이 수동적으로 수집한 데이터가 아닌, 구조적 인과 모델(SCM)을 통해 생성된 1억 개 이상의 합성 데이터셋을 사용하여 완전한 사전 학습되었다. 추론 시에는 신경망의 파라미터 업데이트 과정 없이, 훈련 데이터를 문맥 프롬프트로 받아들여 단일 순방향 패스(Single forward pass)만으로 테스트 데이터를 예측한다.

최근 표형 데이터 모델링은 그래디언트 부스팅 트리 모델 등 수동적으로 설계한 튜닝에서 End-to-end learned 신경망 알고리즘으로 교체되었다. 사용자는 오랜시간동안 하이퍼파라미터 튜닝을 할 필요 없이 약 2.8초 만에 예측 정확도를 확보할 수 있게 되었고, 수천 배 이상의 속도 향상과 작업 효율 극대화를 달성하게 되었다. TabPFN은 단순 분류/회귀뿐 아니라 데이터 생성, 밀도 추정, 임베딩 추출까지 가능하다.

표형 데이터는 데이터셋마다 속성(결측치 유무, 데이터 스케일, 카테고리/수치형의 혼재)이 너무 달라 머신러닝과 딥러닝에서 활용하기 어려웠다. 기존에 트랜스포머를 표형에 적용하려던 시도들 역시 2차원적인 표의 구조를 단순 1차원 시퀀스로 평탄화했고, ICL 방식은 테스트 샘플이 들어올 때마다 훈련 세트의 연산을 처음부터 다시 수행해야 하는 컴퓨팅 낭비의 문제가 있었다.

TabPFN은 결측치, 무의미한 특성, 비선형 관계, 잡음 등의 문제를 해결하기 위해 SCM을 활용한 복잡한 합성 데이터 생성 파이프라인을 구축하여 모델을 훈련시켰다. 또한 트랜스포머 구조를 개조하여 표의 개별 셀을 토큰으로 삼고, 행(Sample) 방향과 열(Feature) 방향으로 각각 교차 어텐션을 수행하는 2차원 양방향 아키텍처를 도입해 순서 불변성(Permutation invariance)을 유지했다. 마지막으로 훈련 데이터 세트를 한 번 연산한 후 그 표현(Key, Value)을 캐싱하여 새로운 테스트 샘플 추론 시 이를 그대로 재사용하게 함으로써 추론 속도를 개선했다.

1만 개 샘플, 500개 특성 규모의 데이터셋 환경에서 튜닝 없이 Default 설정만으로도, 4시간 동안 튜닝을 거친 CatBoost, XGBoost, AutoGluon 등 기존의 앙상블 기법보다 좋은 정확도를 보였다. 회귀 작업을 할 때에는 단일 값을 도출하는 것이 아니라 데이터의 불확실성과 다중 모달(Multi-modal)을 포착할 수 있는 전체 타겟 확률 Distribution를 모델링하는 차별성까지 지녔다. 데이터 밀도 추정을 통한 이상치 탐지, 합성 데이터 시뮬레이션 생성, 관련 태스크에 대한 Fine-tuning 역량까지 보였다.

사전 훈련에는 오직 무작위 매개변수를 기반으로 생성된 1억 개 이상의 SCM 합성 데이터만 활용되어 데이터 유출이나 프라이버시 문제를 방지했다. 성능 검증에는 AutoML Benchmark, OpenML-CTR23, Kaggle Tabular Playground Series 등 총 수십여 개의 다양한 실제 벤치마크 데이터셋이 활용되었으며, 파운데이션 모델의 정밀 역량 증명을 위해 German Credit Dataset 등이 개별적으로 분석에 사용되었다.

TabPFN은 아키텍처 특성상 최대 샘플 10,000개, 특성 500개, 분류 클래스 10개 규모 이하의 데이터셋에만 네이티브하게 작동한다는 한계가 있다. 트랜스포머의 어텐션 메커니즘으로 인해 메모리 사용량이 데이터셋 크기에 비례하여 $O(n \cdot m)$ 로 스케일링되며, 연산 요구량은 $O(n^2 + m^2)$ 로 급격히 증가하여 초대규모 데이터셋 적용에 제약이 따르기도 한다. 또한, 최적화된 트리 알고리즘이 예측당 0.0002초가 소요되는 반면, TabPFN은 약 0.2초가 소요되어 빠른 속도의 Real-time inference 인프라에는 최적의 모델은 아니다.