

10주차 - GAN, Diffusion

GAN (Generative Adversarial Networks)

1. Abstract — 핵심 아이디어
 - 2.1 기존 딥러닝 모델의 한계
 - 2.2 Adversarial Nets 제안
 - 2.3 GAN의 장점
3. Methods
 - 3.1 목적함수 (Adversarial Nets)
 - 3.2 Theoretical Results — 수렴 증명
4. Experiments
5. Conclusion — GAN의 강점과 한계

Diffusion Model (DDPM)

1. Abstract — 핵심 아이디어
 - 2.1 Diffusion Model 정의 — 마르코프 체인
 - 2.2 가우시안 노이즈 설정
 - 2.3 이전 모델과 비교
3. Background - 수식 깊이 이해
 - 3.1 Reverse process (p_θ)
 - 3.2 Forward process (q) - 학습 없음
 - 3.3 Negative Log Likelihood $\rightarrow$ ELBO
 - 3.4 Closed Form
 - 3.5 Loss Function
 - 3.6 원본으로 복원
4. Method
 - 4.1 Forward Process (L_t)
 - 4.2 Reverse Process ($L_{1:t-1}$)
 - 4.3 핵심 변환 — μ 예측 $\rightarrow$ ϵ 예측
 - 4.4 Data Scaling
 - 4.5 Simplified Training Objective (L_{simple})
 - 4.6 결과 비교

GAN vs Diffusion 비교 정리

핵심 요약

GAN (Generative Adversarial Networks)

1. Abstract — 핵심 아이디어

GAN은 두 네트워크 G(Generator)와 D(Discriminator)를 서로 경쟁시키는 **Adversarial Process** 기반 생성 모델이다. G는 실제 데이터 분포를 학습해 가짜 데이터를 만들고, D는 그 가짜와 진짜를 구별한다. 서로의 목표가 충돌하는 **Minmax Game** 속에서 두 네트워크는 성능을 발전시켜간다.

학습이 수렴하면 G는 실제와 구분 불가능한 샘플을 생성하고, D는 판별 확률 1/2에 도달한다. 기존 생성 모델과 달리 복잡한 수학적 기법 없이 MLP + Backpropagation만으로 학습이 가능하다는 것이 핵심 혁신이다.## 2. Introduction

2.1 기존 딥러닝 모델의 한계

기존 딥러닝 모델은 복잡한 입력을 레이블별로 분류하는 **discriminative** 역할에는 뛰어났지만, 새로운 데이터를 생성하는 **generative** 역할은 부족했다. 연산이 너무 복잡하고 역전파 적용도 어려웠다.

2.2 Adversarial Nets 제안

- **G (Generator)**: MLP 기반, 가짜 샘플 생성
- **D (Discriminator)**: MLP 기반, G가 만든 샘플과 실제 데이터를 판별

2.3 GAN의 장점

- 역전파 + 드롭아웃을 활용한 훈련 가능
- 순전파만으로 샘플링 가능
- 마르코프 체인 같은 복잡한 연산 불필요

3. Methods

3.1 목적함수 (Adversarial Nets)

GAN의 핵심은 다음 Minmax 목적함수이다:

$$\min_G \max_D V(D, G) = \underbrace{\mathbb{E}_{x \sim p_{\text{data}}(x)} [\log D(x)]}_{\text{실제 데이터가 들어왔을 때 그 데이터가 실제 데이터일 확률}} + \underbrace{\mathbb{E}_{z \sim p_z(z)} [\log(1 - D(G(z)))]}_{\text{샘플이 실제 데이터인지 아닌지를 판별하는 값 (D는 최대화, G는 최소화 하려고 함)}}$$

: 실제 데이터가 들어왔을 때 그 데이터가 실제 데이터일 확률

: 샘플이 실제 데이터인지 아닌지를 판별하는 값 (D는 최대화, G는 최소화 하려고 함)

- **D의 목표**: 위 식을 최대화 → 진짜는 1, 가짜는 0으로 판별
- **G의 목표**: 위 식을 최소화 → D가 가짜를 1로 판별하도록 유도

두 가지 주요 문제가 발생한다.

Problem 1 — Training imbalance: D를 완전히 최적화하면 계산 비용이 크고 overfitting 발생. G는 약한 gradient만 받아 학습이 불안정해진다. 해결책: **D를 k번, G를 1번** 업데이트.

Problem 2 — Gradient Saturation: $\log(1 - D(G(z)))$ 항이 쉽게 saturation 상태가 되어 vanishing gradient 발생. 해결책: $\log(1 - D(G(z)))$ 최소화 대신 $\log D(G(z))$ **최대화**로 목적함수 변경.

3.2 Theoretical Results — 수렴 증명

Proposition 1:

$$D_G^*(x) = \frac{p_{data}(x)}{p_{data}(x) + p_g(x)}$$

Theorem 1: $p_g = p_{data}$ 일 때 $D(x) = 1/2$ 이며, 이때 전체 비용함수 $C(G) = -\log(4)$ 이다. 이는 수학적으로 Jensen-Shannon Divergence (JSD) 최소화와 동치이며, JSD는 KL Divergence의 비대칭성 문제를 해결한 대칭적 거리 지표이다.

4. Experiments

데이터셋: MNIST, TFD (얼굴 이미지), CIFAR-10

네트워크 구조:

- G: ReLU + Sigmoid 활성화 함수, 노이즈는 입력층에만
- D: Maxout 활성화 함수 + Dropout
- 성능 평가에 Gaussian Parzen Window (로그 우도 추정) 사용

5. Conclusion — GAN의 강점과 한계

강점 (Strengths):

- 마르코프 체인 불필요 — 한 번의 연산으로 결과 생성
- 역전파만으로 학습 가능
- 매우 선명하고 뚜렷한 이미지 표현 가능

한계 (Challenges):

- **Mode collapse**: 다양한 이미지 대신 가장 자신 있는 하나의 이미지만 반복 생성
- **Blackbox**: 특정 데이터가 나올 확률이 얼마인지 계산 불가

Advanced GANs:

- **WGAN**: Wasserstein Distance로 vanishing gradient, mode collapse 해결
- **DCGAN**: Convolution layer로 불안정한 학습 극복
- **cGAN**: 입력에 조건(c)을 추가해 원하는 종류의 데이터 생성

Diffusion Model (DDPM)

1. Abstract — 핵심 아이디어

Diffusion 모델은 비평형 열역학(nonequilibrium thermodynamics) 관점에서 비롯된 확산 확률 모델이다. 두 단계로 동작한다:

- **Training (Forward process)**: 이미지에 노이즈를 단계적으로 섞어 형태를 알아볼 수 없는 상태로 만드는 과정을 학습
- **Generating (Reverse process)**: 노이즈 상태에서 노이즈를 단계별로 제거하며 선명한 이미지 생성

Denoising score matching + Langevin 역학이라는 수학적 방법론을 활용하며, CIFAR-10에서 SOTA FID score를 달성했다.## 2. Introduction

2.1 Diffusion Model 정의 — 마르코프 체인

Diffusion 모델은 **마르코프 체인** 기반이다: 특정 상태의 조건부 확률 분포는 오직 현재 상태에만 의존한다.

- **Forward process**: 선명한 사진 x_0 에 노이즈를 섞어 x_1 생성 $\rightarrow x_1$ 에 노이즈를 섞어 x_2 생성 ... (다음 단계 생성에 현재 단계만 필요)
- **Reverse process**: 노이즈 상태 x_T 를 보고 직전 단계 x_{T-1} 을 추측 (chain)

2.2 가우시안 노이즈 설정

복잡한 이미지를 한 번에 생성하기는 수학적으로 매우 어렵지만, **적은 양의 노이즈를 제거하는 것은 가우시안 분포 문제로 단순화 가능하다.**

가우시안을 선택하는 이유:

1. **계산 편의**: 선형 결합이 가능해 평균과 분산만으로 계산

2. **대칭적 구조**: 노이즈 제거 = 노이즈 추가의 역과정

3. **효율적 신경망 학습** 가능

2.3 이전 모델과 비교

GAN, VAE와 비교했을 때 Diffusion은 노이즈를 단계별로 추가/제거하면서 학습이 매우 안정적이고 고품질 이미지를 생성한다.

3. Background - 수식 깊이 이해

3.1 Reverse process (p_θ)

노이즈가 섞인 데이터에서 노이즈를 조금씩 제거하며, 그 과정을 파라미터 θ 로 학습한다.

U-Net + self-attention + positional embedding을 신경망으로 사용한다.

3.2 Forward process (q) - 학습 없음

β_t 는 0.0001 → 0.02까지 점진적으로 증가하는 상수로, **학습하지 않는다 (고정값)**. Forward process에서 q 는 학습할 게 없기 때문에 LT는 상수가 되어 무시해도 된다.

3.3 Negative Log Likelihood → ELBO

likelihood를 직접 계산하기 어려워 ****ELBO(Evidence Lower Bound)****를 활용해 하한선을 최소화하는 방향으로 학습한다.

3.4 Closed Form

기존 방식은 x_t 를 만들기 위해 노이즈를 t 번 반복해야 했지만, closed form 덕분에 **원본 x_0 에서 t 단계 x_T 로 단번에 건너뛸 수 있다**. 이것이 학습 효율을 극적으로 높인다.

3.5 Loss Function

KL Divergence로 q (가우시안 분포)와 p (가우시안 분포)가 얼마나 같은지 측정하고, **L_{t-1} 이 q 와 p 사이 거리를 줄이는 방향으로 학습한다**.

3.6 원본으로 복원

원본(x_0)과 현재 이미지(x_t)로 이전 단계(x_{t-1})의 평균과 분산을 구하는 수식이 **정답**이 되고, 이 정답과 같은 평균/분산을 모델이 생성하도록 학습시킨다.

4. Method

4.1 Forward Process (L_t)

원본 사진에 노이즈를 추가해 의도적으로 망가뜨리는 과정 (q). β_t 를 상수로 정해 **학습시키지 않음**.

4.2 Reverse Process ($L_{1:t-1}$)

노이즈에서 사진을 복구하는 과정(p). 핵심 목표는 모델이 예측한 이미지의 평균값 μ_θ 가 수학적으로 계산된 원본의 평균값 $\tilde{\mu}_t$ 와 얼마나 가까운지를 비교하는 것이다.

4.3 핵심 변환 — μ 예측 $\rightarrow \epsilon$ 예측

문제: 정답에 x_0 가 필요한데 모델은 x_t 만 본다. 해결: **x_t 를 다시 표현해 ϵ (노이즈)를 직접 예측하는 문제로 변환한다.**

이로 인해 loss가 μ 를 맞추기보다 **ϵ 를 맞추는 것으로 변환**되어, 이미지 복원 문제에서 노이즈 예측 문제로 전화된다.

4.4 Data Scaling

- 원본 이미지: $\{0, 1, \dots, 255\}$
- 모델 입력: $[-1, 1]$ 로 전처리 (Gaussian 기반 모델에 적합)
- 최종 출력: 연속 값 $\rightarrow$ 이산 픽셀 값으로 변환 (discrete decoder)

4.5 Simplified Training Objective (L_{simple})

기존 ELBO에서 복잡한 가중치를 1로 생략해 단순화:

- t 가 작을 때 (노이즈 거의 없음) $\rightarrow$ 학습 강도 낮음 (쉬운 문제)
- t 가 클 때 (노이즈 많음) $\rightarrow$ 학습 강도 높음 (어려운 문제)
- 어려운 문제에 더 집중 $\rightarrow$ 전체적인 이미지 구도가 더 선명하게 잡힘

4.6 결과 비교

[Table 1] CIFAR-10 기준:

- IS: 9.46 ± 0.11 (StyleGAN2+ADA의 9.74에 근접)
- FID: **3.17** (기존 모델들보다 우수)
- NLL: ≤ 3.75

[Table 2] Ablation:

- μ prediction (baseline): FID 13.22~23.69 $\rightarrow$ 좋지 않음

- ϵ prediction: FID 3.17 → 가장 좋음
- variance 학습: unstable, 성능 낮음

GAN vs Diffusion 비교 정리

항목	GAN	Diffusion (DDPM)
핵심 아이디어	G vs D 경쟁 (Minmax Game)	단계적 노이즈 추가/제거 (Markov Chain)
학습 방식	적대적 학습	Negative log-likelihood (ELBO) 최소화
학습 안정성	불안정 (Mode collapse, Gradient Saturation)	매우 안정적
이미지 품질	선명하고 뚜렷함	고품질, FID 3.17 달성
다양성	Mode collapse 위험	다양한 이미지 생성 가능
속도	빠름 (1회 순전파)	느림 (T=1000 스텝 필요)
확률 추정	불가 (Blackbox)	NLL로 가능
마르코프 체인	불필요	필요 (핵심 구조)
신경망	MLP (G, D 각각)	U-Net + self-attention
수학적 기반	Jensen-Shannon Divergence	ELBO, KL Divergence
수렴 조건	$P_g = P_{data}, D(x) = 1/2$	p가 q에 수렴

핵심 요약

GAN: G와 D의 경쟁을 통해 빠르고 선명한 이미지를 생성하지만, 학습 불안정성과 Mode collapse가 단점이다. 수학적으로는 JSD 최소화로 수렴이 보장된다.

Diffusion: 노이즈를 단계별로 추가/제거하는 마르코프 체인 기반으로, 학습이 안정적이고 고품질 이미지를 생성한다. 핵심 혁신은 μ 예측에서 ϵ 예측으로의 변환과 L_{simple} 이며, 이를 통해 CIFAR-10에서 FID 3.17이라는 SOTA 성능을 달성했다.