

boaz_학기 세션 과제(4)

CLIP

1. Abstract
2. Introduction
 - 2.1. 기존 모델
 - 2.2. 선행 연구
 - 2.3. CLIP 제안
3. Methods
 - 3.1. Approach
 - 3.2. **Efficient Pre-Training Method following ConVirt**
4. Experiments
 - 4.1. Choosing and Scaling a Model
 - 4.2. Zero-shot Transfer
 - 4.3. Prompt engineering and ensembling
 - 4.4. **Robustness**
 - 4.5. Comparison to Human performance
5. Conclusion
 - 5.1. Limitations
 - 5.2. Broader Impacts

SAM

1. Abstract
2. Introduction
 - 2.1. 모델 제안
3. Methods
 - 3.1. Model
 - 3.2. Resolving ambiguity
 - 3.3. Efficiency
 - 3.4. Losses and training
 - 3.5. Data engine
4. Experiments
 - 4.1. Dataset
 - 4.2. Mask properties
 - 4.3. RAI analysis
 - 4.4. Zero-shot transfer
5. Conclusion
 - 5.1. **Foundation Models**
 - 5.2. **Compositionality**

CLIP

1. Abstract

- 기존 모델 → 특정 카테고리 내에서 [이미지, 라벨] 같이 고정된 형태의 데이터를 가지고 학습
 - **고정된 형태의 데이터(특정 카테고리 내에서 간단하고 짧은 라벨만 가진 데이터)**로 모델을 학습시키면 다른 task에 유용하게 활용하지 못함 → generality 제한
- 이미지를 설명하는 상세한 텍스트를 라벨로 같이 사용해 문제 해결
- 30개의 서로 다른 벤치마크 데이터셋을 가지고 실험 → 다양한 task에서 좋은 성능을 보임
 - 추가적인 데이터셋 없이도 특정 task를 위해 추가적으로 데이터셋을 학습한 기존 모델과 비슷한 성능
 - zero-shot transfer 가능
 - 다양한 작업 수행

2. Introduction

2.1. 기존 모델

- Pre-training 방식 → Task-agnostic(특정 task에 구애받지 않는) 학습으로 모델이 대규모 데이터를 이용해 학습 가능 하도록 함
- text - to -text 방식 → task마다 다른 토큰을 사용하는 등의 추가적인 작업 없이 zero-shot transfer이 가능 (GPT-3)
- CV 분야에서는 여전히 ImageNet처럼 사람이 라벨을 붙인 데이터셋으로 pre-training
 - **How to train a general-purpose visual model using massive raw internet data, just like in NLP?**
 - **Could scalable pre-training methods which learn directly from web text result in a similar breakthrough in computer vision?**


- NLP 처럼 웹 상에서 수집된 테스트로부터 사전학습을 하는 방식을 cv에 적용 가능한가?

2.2. 선행 연구

- CNN을 사용해 이미지의 해시태그나 설명을 예측하게 하는 연구
- transformer-based 언어 모델링이나 contrastive objectives로 텍스트에서 이미지 표현을 배움
 - Learning Visual N-Grams from Web Data, Li et al.,
 - Self-training with Noisy Student improves ImageNet classification, Xie et al., 2020)
- text로부터 image representation을 학습시키는 방법론이 드문 이유
 - 표준 벤치마크에서의 성능이 기존보다 훨씬 낮음
 - 미리 정해진 클래스 내에서만 예측하는 방식으로 유연성 부족


2.3. CLIP 제안

- 웹 상에서 데이터를 얻을 수 있기에 4억에의 [이미지, 데이터] 페어를 만들어 **ConVIRT** 를 가지고 학습 → CLIP(Contrastive Language-Image Pre-training) 제안



- ConVIRT 기본 원리
 - 이미지와 그에 대응하는 텍스트 캡션을 쌍으로 묶어 서로 연관된 것들은 가깝게 연관 없는 것들은 멀게 배치하는 contrastive learning 방식 제안
- ConVIRT 한계점

- Domain limitation - 주로 의료 분야에서 활용되어 일반적인 사물이나 풍경 학습에 한계
- Data scale limitation - 수십만 건 규모의 데이터만 다룸
- ConVIRT와 CLIP 차이점
 - Train from scratch - 기존에 pre-trained 모델을 쓰는게 아닌 4억 개의 데이터를 가지고 처음부터 직접 학습
 - Use only a linear projection - 이미지 벡터와 텍스트 벡터를 공통 공간으로 보낼 때 linear layer 하나만 사용
 - Use less augmentation - 이미지를 회전하고 자르는 augmentation을 최소화
- 선행 연구 VirTEX



- 입력한 이미지로 그에 맞는 캡션을 생성하는 예측/생성 방식
- 텍스트를 직접 생성해야해 이미지의 세부적이 특징을 매우 깊게 이해해야함
- VirTEX vs Contrastive Objective
 - 캡션 생성 방식이 아닌 이미지와 텍스트 쌍을 연결하는 매칭 방식 선택
 - high training efficiency - 이미 있는 텍스트와 이미지를 대조하는 학습으로 연산이 단순하고 학습 속도가 빠름

3. Methods

3.1. Approach

- 기존 연구의 데이터셋

- MS-COCO - high quality/small
 - 자동차, 자전거, 동물과 같은 일반적인 객체는 물론 우산, 핸드백과 같은 더 구체적인 범주를 포함하여 80개의 객체 범주로 구성
- Visual Genome
- YFCC100M - Varying quality/large
 - 플리커 데이터. 유저들이 적어둔 제목, 설명GPS 좌표, 카메라 기종 등의 텍스트 정보 포함

⇒ 양질의 라벨링 데이터셋이지만 그 양이 10만개 정도로 많지 않음


- 새로운 데이터셋 생성(WIT(WebImageText))




- 약 4억개의 [image, text] 페어로 구성, 모든 데이터는 인터넷에서 수집
- 데이터 다양성을 위해 5만개의 텍스트 쿼리 사용, 하나의 쿼리에서 2만개가 넘는 페어를 갖지 않도록 함
- 쿼리로 텍스트-이미지 매칭 후 페어를 만듦

3.2. Efficient Pre-Training Method following ConVirt

- 기존 연구 - ImageNet 데이터에서 1000개의 class 분류를 위해 매우 많은 GPU 메모리 사용



- 효율적인 학습을 위해 단어 순서를 고려하지 않고 bag-of-words encoding으로 contrastive learning 진행
- 학습 방식



- 매칭되는 feature들끼리는 가까워지게 학습하는 것
1. 배치 단위 학습 진행 (N개의 [image, text] 페어)
 2. image encoder 모델에 이미지 데이터 입력, text encoder 모델에 텍스트 데이터 입력 후 각 feature 추출
 3. N개의 텍스트 벡터와 이미지 벡터 간 코사인 유사도 구함
 4. 이 유사도 값으로 cross entropy loss값을 계산해 최적화 진행
- 수도 코드

```
# image_encoder - ResNet or Vision Transformer
# text_encoder - CBOW or Text Transformer
# I[n, h, w, c] - minibatch of aligned images
# T[n, l] - minibatch of aligned texts
# W_i[d_i, d_e] - learned proj of image to embed
# W_t[d_t, d_e] - learned proj of text to embed
# t - learned temperature parameter

# extract feature representations of each modality
I_f = image_encoder(I) #[n, d_i]
T_f = text_encoder(T) #[n, d_t]

# joint multimodal embedding [n, d_e]
I_e = l2_normalize(np.dot(I_f, W_i), axis=1)
T_e = l2_normalize(np.dot(T_f, W_t), axis=1)

# scaled pairwise cosine similarities [n, n]
logits = np.dot(I_e, T_e.T) * np.exp(t)

# symmetric loss function
labels = np.arange(n)
loss_i = cross_entropy_loss(logits, labels, axis=0)
loss_t = cross_entropy_loss(logits, labels, axis=1)
loss = (loss_i + loss_t)/2
```

4. Experiments

4.1. Choosing and Scaling a Model


- 사용 모델
 - image encoder
 - ResNet-50, ResNet-101(5가지 ResNet 모델)
 - ViT
 - text encoder
 - Transformer(3가지 vision transformer)
- 효율적 학습
 - use minibatch size of 32,768
 - gradient checkpointing
 - half-precision Adam statistics
 - half-precision stochastically rounded text encoder weights

4.2. Zero-shot Transfer


- 학습 때 사용하지 않은 데이터셋에 대한 image classification task
- Visual N-Grams(image classification에서 zero-shot transfer를 처음 사용한 연구)와 비교했을때 모든 데이터셋에서 CLIP 성능 향상

	aYahoo	ImageNet	SUN
Visual N-Grams	72.4	11.5	23.0
CLIP	98.4	76.2	58.5

- zero-shot performance




- CLIP의 zero-shot prediction 성능과 ResNet50에 각 데이터셋 별로 fine-tuning 한 뒤 성능 비교
- zero-shot CLIP이 절반 이상의 경우에서 더 높은 성능을 보임
- 다만 비교적 복잡하거나 추상적인 데이터셋 task에서는 CLIP이 뒤쳐지는 모습을 보임
- 모델 비교



- 대부분 모델 성능보다 비슷하거나 좋음
- zero-shot CLIP의 data efficiency가 높음

4.3. Prompt engineering and ensembling


- Customizing prompt text to each task + ensemble of different context prompts




- “A photo of a {label}”과 같은 형식의 prompt를 default로 사용
- 80개의 다른 prompt를 사용것이 하나의 default prompt를 사용하는 것보다 3.5% 성능 향상을 보임
- 적절한 prompt engineering과 여러 classifier를 ensemble하는 방식

4.4. Robustness

- 기존모델(ImageNet으로 학습한 ResNet)
 - 특정 데이터에 과적합 → 데이터셋이 변경되면 성능이 급격히 안좋아짐
 - 모델이 학습 데이터를 다 외워 비슷한 분포의 데이터에서만 좋은 성능을 보임



- CLIP (task transfer)
 - 다른 분포의 task에서도 성능을 유지
- ImageNet 데이터셋 변형



- zero-shot CLIP이 다른 모델에 비해 높은 강건성을 보임
- 특정 데이터셋을 학습할수록 해당 데이터에 대한 성능이 증가하지만 전체적인 모델 강건성은 감소하는 trade-off 존재

4.5. Comparison to Human performance

- zero-shot CLIP과 인간의 성능을 비교한 실험
- 5명 대상으로 이미지를 분류하도록 지시
- 결과

	Accuracy	Majority Vote on Full Dataset	Accuracy on Guesses	Majority Vote Accuracy on Guesses
Zero-shot human	53.7	57.0	69.7	63.9
Zero-shot CLIP	93.5	93.5	93.5	93.5
One-shot human	75.7	80.3	78.5	81.2
Two-shot human	75.7	85.0	79.2	86.1

- 인간의 경우 zero-shot보다 one-shot일때 정확도가 크게 증가하지만 two-shot으로 늘어나면 성능 변화가 미미
- 인간은 자기가 무엇을 알고 모르는지 아는 메타 인지 능력이 있어 하나의 샘플만 주어져도 향상된 예측 가능
- zero-shot CLIP → 샘플을 추가적으로 학습할수록 성능 하락
→ 사전 지식을 활용하는 것이 인간과 아예 다름


5. Conclusion

5.1. Limitations

- performance gap
 - SOTA 대비 1000배 연산 더 필요
- Task weakness
 - 세밀한 분류 및 추상적 추론 취약
- OOD sensitivity
 - 학습 외 데이터 일반화 부족
- Data inefficiency
 - 128억장 학습 필요

5.2. Broader Impacts

- 사회적 편향 문제



- 흑인 얼굴 14% 비인간 분류 남성 16.5% 범죄 카테고리 오분류
- 여성 → 외모/가사 관련 라벨 집중, 남성 → 고위직/범죄 관련 라벨 집중
- 필터링 되지 않은 인터넷 데이터의 사회적 편향이 그대로 학습됨

SAM


1. Abstract

- 이미지 분할을 위한 task, model, dataset을 포함하는 Segment Anything project 제안
- Data collection loop(모델이 가이드를 주고 사람이 검수하는 방식을 반복해 데이터를 쌓음) 방식으로 10억 개의 데이터 규모 활용
- 사람이 프롬프트를 주면 모델이 그 의도를 파악해 zero-shot transfer 가능
- Fully supervised 기존 모델과 대비 SAM 성능이 비슷하거나 더 뛰어남


2. Introduction

2.1. 모델 제안


- NLP foundation model → prompt engineering을 통해 현재 task에 대한 유효한 텍스트 응답 구현
 - 추가학습 없이 바로 zero-shot 구현
- CV foundation model → CLIP, ALIGN처럼 학습된 텍스트 프롬프트가 새로운 시각적 개념 및 데이터 분포에 대한 zero-shot 일반화 가능
 - segmentation 데이터 부족 문제
- 목표 : image segmentation을 위한 foundation model 구축
 - 강력한 일반화를 가능하게 하는 task를 사용해 광범위한 데이터셋에서 promptable model 개발 및 사전 학습을 추구함
 - 이 모델로 prompt engineering으로 새로운 데이터 분포에 대한 다양한 하위 segmentation 문제를 해결하는 것
 - 해결해야하는 질문
 1. Zero-shot 일반화를 가능하게 하는 task는 무엇인가?
 2. 해당 모델 아키텍처는 무엇인가?
 3. 어떤 데이터가 이 task와 모델에 힘을 실어줄 수 있는가?



(a) Task: promptable segmentation



(b) Model: Segment Anything Model (SAM)



(c) Data: data engine (top) & dataset (bottom)


- task : promptable segmentation
 - 강력한 pre objective 제공
 - 넓은 범위의 하위 task가 가능한 task 정의
 - 어떤 종류의 작업이 zero-shot generalization을 가능하게 할 것인가?
 - prompt를 전경/배경 점, 대략적인 박스, 마스크, 자유 형식 텍스트 등 모든 정보가 될 수 있음
 - promptable segmentation → 프롬프트가 주어진다면 유효한 segmentation mask 반환
- model : SAM

- flexible prompting을 지원
- real-time으로 mask제공 가능한 model 필요
- data : data engine & dataset
 - 이러한 모델 학습을 위해 다양한 대규모의 data 필요하지만 없어서 Data Engine 생성

3. Methods

3.1. Model

- 모델 구성



1. 이미지 인코더

- 이미지를 압축된 특징으로 전환하는 단계
- 확장성과 강력한 사전 학습 방법을 위해 고해상도 입력을 처리하도록 조정된 MAE로 사전 학습된 ViT 구조를 사용
- 이미지당 한 번 실행 후 모델을 프롬프트 하기 전에 적용

2. 유연한 프롬프트 인코더

- 2가지 집합의 프롬프트 고려
 - Sparse(점, 박스, 텍스트)
 - Dense(마스크)
- CLIP의 텍스트 인코더를 사용해 프롬프트 타입과 자유 형식 텍스트에 대해 학습된 임베딩으로 합산된 위치 인코딩으로 점과 박스를 나타냄

3. 빠른 마스크 디코더

- 이미지 임베딩, 프롬프트 임베딩, 출력 토큰을 마스크에 효율적으로 매핑
- prompt self-attention과 cross-attention을 두 방향으로 사용

- 블록 실행 후 이미지 임베딩을 업샘플
- 각 픽셀마다 객체일 확률 계산

→ 실시간 성능에 대한 특정 trade-off가 있는 transformer 비전 모델 구축

3.2. Resolving ambiguity

- 모호한 프롬프트가 주어지면 여러 개의 유효한 마스크를 하나의 출력으로 평균
 - 사용자가 가위 손잡이에 점을 찍었을 때, 가위 전체를 원하는 건지 일부분을 원하는 건지 헷갈림
- 해결 → 단일 프롬프트에 대해 여러 출력 마스크를 예측하도록 모델 수정
 - 학습 중 마스크 순위를 매기기 위해 마스크에 대한 신뢰도 점수(IoU) 예측

3.3. Efficiency

- 모델 전체 설계는 효율성을 중시하여 이미지 임베딩은 미리 한 번만 계산
- 미리 계산된 이미지 임베딩이 주어져 프롬프트 인코더와 마스크 디코더가 50ms 내에 CPU 웹브라우저에서 실행
 - 모델의 원활한 실시간으로 상호작용하는 프롬프트 가능

3.4. Losses and training

- DETR에서 사용된 focal loss와 dice loss 선형 결합으로 마스크 예측을 supervise함
- 학습화면에 점 하나만 찍거나 박스를 치거나 여러가지 프롬프트 생성 → 무작위로 섞어서 정답맞히도록 훈련
 - 11-round interactive 설정 시뮬레이션
 - 무작위로 점 하나 찍어주면 SAM은 그점을 보고 가상 마스크 생성 → 오차확인 → 반복

3.5. Data engine

- segmentation mask가 풍부하지 않아 11억개의 마스크 데이터셋인 SA-1B를 수집할 수 있는 데이터 엔진 구축


1. Assisted-manual stage → model-assisted 주석을 사용하는 수동 단계
 - 전문 작업자가 웹 브라우저에서 직접 객체 분할 + SAM이 작업 도와줌
 - 개체에 자유롭게 레이블을 지정
 - SAM은 공개된 segmentation 데이터셋으로 새로 주석이 달린 마스크만 사용해 재학습(총 6번)
 - 모델 개선 후 마스크당 평균 주석 시간 34초 → 14초
 - 이미지 당 평균 마스크 수 20개 → 44개
 - 12만 개 이미지 → 430만개의 마스크 수집
2. Semi-automatic stage → 자동으로 예측된 마스크와 model-assisted 주석이 혼합된 반 자동 단계
 - 모델이 무엇이든 분할하는 능력을 향상시키기 위해 마스크의 다양성을 높이는 것을 목표
 - 모델이 먼저 신뢰도 높은 마스크 자동 생성 → 사람은 남은 객체만 추가 라벨링
 - 신뢰 가능한 마스크 감지를 위해 모든 첫 번째 단계 마스크에서 boundary box detector 학습
 - 18만개 이미지 → 590만개 마스크 수집(총 1020만개 마스크)
 - 새로 수집된 데이터에 대한 모델 재학습(총 5회)
 - 마스크 당 평균 주석 시간 14초 → 34초(레이블 지정이 더 어려워졌기에)
 - 이미지 당 평균 마스크 수 44개 → 72개
3. Fully automatic stage → 완전 자동 단계
 - SAM이 사람 없이 스스로 이미지 분석
 - 그리드 기법으로 모델을 유도해 각 점에 대해 유효한 객체에 해당 가능한 마스크 세트 예측
 - 모델 IoU 예측 모듈 → 신뢰가능 + 안정적인 마스크만 식별해 선택함
 - 안정적인 마스크 선택 후 NMS로 중복 필터링
 - 마스크 품질 향상을 위해 확대 이미지 crop 처리
 - 데이터셋의 모든 1100만개 이미지에 완전 자동 마스크 생성 후 총 11억개의 고품질 마스크 생성

4. Experiments


4.1. Dataset

- SA-1B 데이터셋 → 1100만개의 다양한 고해상도 라이선스 + 11억개의 고품질 segmentation mask로 구성
 - 마스크 99.1%는 자동으로 생성
- 마스크 품질 측정을 위해 랜덤하게 선택된 이미지와 주석 전문가들이 개선한 마스크 비교
 - 원래 마스크 vs 개선된 마스크 IoU 계산
 - 94% 마스크가 90% 이상 IoU, 97%의 마스크가 75% 이상의 IoU를 보임

4.2. Mask properties




- SA-1B 물체 중심의 공간적 분포를 다른 segmentation 데이터셋과 비교
- 다른 모델에 비해 고르게 분산



- 데이터셋들의 크기 비교
- SA-1B는 이미지 당 마스크 개수가 높으며 중소형 크기의 마스크를 더 많이 포함

4.3. RAI analysis



- SA-1B의 지리적 분포 → 공정성과 편향 문제 분석
- 유럽, 아시아/오세아니아, 고중간 소득 국가 비율 높음
- 아프리카와 저소득 국가는 데이터가 적지만 SA-1B의 경우 최소 2800만개로 기존 데이터셋보다 10배이상 많은 수준

	# countries	SA-1B		% images		
		#imgs	#masks	SA-1B	COCO	O.I.
Africa	54	300k	28M	2.8%	3.0%	1.7%
Asia & Oceania	70	3.9M	423M	36.2%	11.4%	14.3%
Europe	47	5.4M	540M	49.8%	34.2%	36.2%
Latin America & Carib.	42	380k	36M	3.5%	3.1%	5.0%
North America	4	830k	80M	7.7%	48.3%	42.8%
high income countries	81	5.8M	598M	54.0%	89.1%	87.5%
middle income countries	108	4.9M	499M	45.0%	10.5%	12.0%
low income countries	28	100k	9.4M	0.9%	0.4%	0.5%


- 지리적 및 소득 표현 비교

	mIoU at			mIoU at	
	1 point	3 points		1 point	3 points
<i>perceived gender presentation</i>			<i>perceived skin tone</i>		
feminine	54.4 ± 1.7	90.4 ± 0.6	1	52.9 ± 2.2	91.0 ± 0.9
masculine	55.7 ± 1.7	90.1 ± 0.6	2	51.5 ± 1.4	91.1 ± 0.5
<i>perceived age group</i>			3	52.2 ± 1.9	91.4 ± 0.7
older	62.9 ± 6.7	92.6 ± 1.3	4	51.5 ± 2.7	91.7 ± 1.0
middle	54.5 ± 1.3	90.2 ± 0.5	5	52.4 ± 4.2	92.5 ± 1.4
young	54.2 ± 2.2	91.2 ± 0.7	6	56.7 ± 6.3	91.2 ± 2.4


- 성별, 나이, 피부색에 따른 segmentation 성능
- 성별 간 성능 차이 거의 없음

- 노년층에서 성능이 가장 좋았음
- 피부톤 차이로 인해 큰 성능 차이 없음

4.4. Zero-shot transfer



- SAM의 zero-shot transfer 능력 평가를 위한 23개의 다양한 데이터셋 샘플
- SAM이 학습 시 보지 못한 데이터셋&도메인에서 다양한 시각 과제를 수행할 수 있는지 실험



- Zero-Shot Single Point Valid Mask Evaluation
 - point 하나만 정보로 주었을 때 object의 mask를 얼마나 잘 생성해내는지
- 23개 데이터셋에 대해 mIoU 측정 후 기존 SOTA인 RITM과 결과 비교
 - 16개 데이터셋에서 SAM이 더 좋은 성능을 보임



- Zero-Shot Edge Detection
- object들의 edge를 검출

method	year	ODS	OIS	AP	R50
HED [108]	2015	.788	.808	.840	.923
EDETR [79]	2022	.840	.858	.896	.930
<i>zero-shot transfer methods:</i>					
Sobel filter	1968	.539	-	-	-
Canny [13]	1986	.600	.640	.580	-
Felz-Hutt [35]	2004	.610	.640	.560	-
SAM	2023	.768	.786	.794	.928


- BSDS500에서 edge detection에 대한 zero-shot transfer 성능을 비교
- 학습 없이도 합리적 엣지 맵 생성

		mask AR@1000					
method	all	small	med.	large	freq.	com.	rare
ViTDet-H [62]	63.0	51.7	80.8	87.0	63.1	63.3	58.3
<i>zero-shot transfer methods:</i>							
SAM – single out.	54.9	42.8	76.7	74.4	54.7	59.8	62.0
SAM	59.3	45.5	81.6	86.9	59.1	63.9	65.8

- Zero-shot instance segmentation
 - 객체가 있을 법한 영역을 예측

method	COCO [66]				LVIS v1 [44]			
	AP	AP ^S	AP ^M	AP ^L	AP	AP ^S	AP ^M	AP ^L
ViTDet-H [62]	51.0	32.0	54.3	68.9	46.6	35.0	58.0	66.3
<i>zero-shot transfer methods (segmentation module only):</i>								
SAM	46.5	30.8	51.0	61.7	44.7	32.5	57.6	65.5

- Zero-shot text-to-mask



- SAM은 간단하고 미묘한 텍스트 프롬프트에 대해 동작 가능하며 정확한 예측에 실패하면 추가적인 점 프롬프트로 예측에 도움을 줌

5. Conclusion

5.1. Foundation Models

- SAM은 대규모 다양한 데이터로 학습되어 여러 하위 segmentation 과제에 적응 가능
- 다만 CV 전체의 Foundation Model X
- 백본(ViT)에 Self-supervised (MAE) 사용했지만 성능 대부분은 대규모 지도학습에서 나옴
 - 주석 확장이 가능한 환경이라면, 지도학습이 효과적인 해법

5.2. Compositionality

- SAM은 다양한 프롬프트에 대해 항상 유효한 mask를 출력 → 다른 시스템과 쉽게 결합 가능

5.3. Limitations

- 세밀한 구조 감지 한계, 작은 분리 영역 잘못 생성 가능
- 고화질 경계는 전용 고정밀 방법(zoom-in)보다 떨어짐포인트를 많이 줄수록 전용 interactive segmentation 모델이 더 우수
- 무거운 백본(ViT-H) 사용 시 실시간 전체 처리 어려움Text-to-mask는 아직 실험적이고 안정적이지 않음