

8주차 과제: GPT-1 & DeepSeek 요약

GPT-1

Generative Pre-Training + Supervised Fine-Tuning 의 2단계 학습 방식
unlabeled 텍스트로 먼저 언어 모델을 많이 학습시킨 뒤, 적은 labeled 데이터로 각 task에 fine-tuning

Introduction

등장 배경 (RNN → LSTM → Seq2Seq → Transformer)

- RNN: 순차 데이터를 시간 흐름대로 처리하는 최초의 신경망. 기울기 소실 문제로 긴 문맥 학습이 어려움.
- LSTM: 게이트 구조 도입으로 RNN의 기울기 소실 문제를 완화. 긴 의존성을 더 안정적으로 학습 가능하지만 실제로는 long-range 의존성 학습에 한계, 구조적으로 순차적이라 표현력 제한.
- Seq2Seq: Encoder-Decoder 구조로 가변 길이 문제 해결. 초기엔 정보 압축 한계 존재.
- Transformer: RNN 없이 Self-Attention만으로 문맥을 병렬 처리. 긴 문맥 이해와 대규모 학습이 가능해지며 BERT·GPT 같은 LLM의 기반이 됨.
 - Encoder 블록: Multi-Head Self-Attention + FFN + Residual Connection + LayerNorm
 - Decoder 블록: Masked Self-Attention
 - Self-Attention: Q와 K의 유사도로 중요도 계산, 그 가중치로 V를 합산

문제 의식

- 지도학습 의존성이 너무 큼 → 라벨 데이터는 비싸고 도메인 확장에 취약
- 기존 방식의 한계: 좋은 표현을 위한 목적함수에 합의가 없고, 학습한 표현을 downstream task로 옮기는 방법도 표준화되지 않음

Related Work

- Semi-supervised learning for NLP: 초창기엔 라벨 없는 데이터로 통계적 특징 추출
→ 이후 word2vec, GloVe 같은 word embedding으로 발전. 하지만 이런 접근은 단어 수준(word-level) 정보만 옮김.
- Unsupervised pre-training: 지도학습 전에 비지도 목표로 초기 파라미터를 찾는 것 (준지도 학습의 특수 케이스). 사전학습은 성능보다 일반화를 향상시킴.
- LSTM 기반의 한계 → Transformer 선택: LSTM은 사전학습을 해도 넓은 언어 구조를 충분히 잡기 어렵고 병렬 학습 불가. Transformer는 Self-attention으로 모든 토큰이 직접 연결되어 긴 거리 의존성 완화 및 병렬 학습 가능 → 더 강한 전이 성능 기대.
- Auxiliary training objectives: 메인 태스크 학습 중 보조 LM loss를 함께 사용하면 성능 향상 ($\text{Loss} = L_{\text{task}} + \lambda L_{\text{aux}}$). GPT-1도 이 방식을 fine-tuning에 적용.

Framework

Unsupervised Pre-training

- 라벨 없는 토큰 시퀀스로 다음 단어 확률 최대화: $L_1(U) = \sum \log P(u_i \mid u_{i-k}, \dots, u_{i-1}; \Theta)$
- 입력 임베딩: $h_0 = U W_e + W_p$ (단어 의미 + 위치 정보)
- Transformer 블록 n번 통과 후 softmax로 토큰 분포 출력

Supervised Fine-tuning

- 사전학습된 Transformer에 입력 토큰을 넣고 마지막 레이어의 마지막 토큰 hidden state(h_{l^m})를 추출 → 새 선형층 W_v 를 붙여 softmax로 클래스 확률 출력
- 최종 loss: $L_3(C) = L_2(C) + \lambda L_1(C)$ (지도 분류 손실 + 언어모델 손실)
- LM loss 유지 이유: 과적합 방지(일반화 개선) + 수렴 속도 향상

Task별 입력 변환 (모델 구조 변경 없이 입력 포맷만 조정)

- Textual Entailment: $[p \ \$ \ h]$ 형태로 두 문장 이어붙임
- Similarity: 두 순서($[s_1 s_2], [s_2 s_1]$) 모두 처리 후 벡터 합산
 $s_2], [s_2 s_2], [s_2$
- QA/Commonsense Reasoning: $[z \ \$ \ q \ \$ \ a_k]$ 형태로 후보마다 시퀀스 생성 후 softmax

핵심 제안

- 목표: 조금만 바뀌도 많은 태스크로 잘 옮겨지는 범용 표현
- 2-stage 학습: 비지도 사전학습(대규모 텍스트로 Language Modeling) → 지도 미세 조정(태스크 맞춤 헤드만 추가, 최소 변경)
- 모델 선택: Transformer Decoder-only → LM에 자연스럽게 맞고 긴 문맥 처리, 구조 변경 없이 fine-tuning 가능

Architecture

- Transformer **Decoder**만 사용
- 활성화 함수: ReLU → **GELU**
- 위치 임베딩 방식: sinusoidal → learnable **positional embedding**
- 사전학습 데이터: **BooksCorpus** 책 데이터셋 사용 - long context 학습에 유리

Experiment

4가지 downstream task에서 fine-tuning 진행

Task	결과
Natural Language Inference	대부분 SOTA, 작은 데이터셋(RTE)에선 약함
Question Answering	모든 데이터셋 SOTA (긴 맥락 처리 강점)
Semantic Similarity	3개 중 2개 SOTA
Classification	SOTA

Conclusion

- **레이어를 많이 가져올수록** fine-tuning 성능 향상 → pre-training의 각 레이어가 실질적으로 도움이 된다는 증거 (pre-training 없을 시 성능 14.8% 감소)
- **LM을 오래 학습할수록** zero-shot 성능도 꾸준히 상승 → 모든 downstream task를 포괄하는 전반적인 NLP 능력 형성
- **Transformer가 LSTM보다 훨씬 빠르게** 성능이 오름 → pre-training에 더 적합한 구조

한계 및 Future Work: GPT-2, 3 ...

GPT-1의 한계: 모델 크기 작음(117M), 데이터 제한적, 모든 task마다 새 레이블 데이터 필요.

GPT-1 (fine-tuning) → **GPT-2** (zero-shot) → **GPT-3** (few-shot / in-context learning) → ChatGPT, Claude, Gemini 등 LLM 시대

DeepSeek

DeepSeek-R1: Incentivizing Reasoning Capability in LLMs via Reinforcement Learning

Introduction

SFT(지도 미세조정) 없이 순수 강화학습(RL)만으로 LLM의 추론 능력을 끌어낼 수 있는가를 탐구한 논문. DeepSeek-R1-Zero(순수 RL)와 DeepSeek-R1(Cold Start + 다단계 파이프라인) 두 모델을 제안하며, 최종적으로 OpenAI-o1-1217 수준의 추론 성능을 달성. 모델 및 6개의 증류(distilled) 소형 모델을 전부 오픈소스로 공개.

Introduction

등장 배경

- LLM의 post-training이 점점 중요해지고 있음. 추론 능력, 사회적 가치 정렬, 사용자 선호 반영을 pre-training 대비 훨씬 적은 자원으로 달성 가능.
- OpenAI o1이 Chain-of-Thought(CoT) 길이를 늘리는 방식(inference-time scaling)으로 추론 성능을 크게 끌어올림.
- 하지만 이를 재현하거나 능가하는 오픈 연구는 없었음. PRM(process reward model), MCTS, beam search 등 다양한 시도들이 있었지만 o1 수준에는 미치지 못함.

문제 의식

- 기존 RL 기반 연구들은 대부분 SFT 데이터에 크게 의존함 → 레이블 데이터 수집에 시간과 비용이 많이 듦.

- SFT 없이 순수 RL만으로 추론 능력을 끌어낼 수 있는가? → 아직 검증된 오픈 연구 없음.
- 사람이 정의한 추론 패턴으로 모델을 제약하면 오히려 새로운 추론 능력의 발현을 막을 수 있음.

핵심 제안

- DeepSeek-V3-Base를 기반 모델로, GRPO(Group Relative Policy Optimization)를 RL 프레임워크로 사용.
- 두 가지 모델 제안: (1) SFT 없이 순수 RL만 적용한 **DeepSeek-R1-Zero**, (2) 소량의 Cold Start 데이터 + 다단계 훈련 파이프라인을 적용한 **DeepSeek-R1**.
- 대형 모델의 추론 패턴을 소형 모델로 증류(distillation)하는 방법도 탐구.

Approach

DeepSeek-R1-Zero: 순수 RL

RL 알고리즘 - GRPO (Group Relative Policy Optimization)

- 기존 PPO는 policy model과 동일한 크기의 critic model이 필요 → 비용이 큼.
- GRPO는 critic 없이 그룹 내 출력들의 상대적 점수로 baseline을 추정 → 훈련 비용 절감.
- 같은 질문에 대해 G개의 출력을 샘플링하고, 각 출력의 reward를 그룹 평균·표준편차로 정규화하여 $advantage(A_i)$ 를 계산.
- KL divergence 페널티로 reference model로부터의 이탈을 제어.

Reward Modeling (규칙 기반, 신경망 reward model 미사용)

- Accuracy reward: 수학 문제는 최종 답의 정오 판별 (박스 형식 요구), 코딩 문제는 컴파일러로 테스트케이스 통과 여부 판별.
- Format reward: `<think>...</think>` 태그 안에 reasoning process를 작성하도록 강제.
- Neural reward model은 대규모 RL 과정에서 reward hacking 위험이 있어 사용 안 함.

Training Template

- `<think> reasoning </think> <answer> answer </answer>` 형태로 출력 구조를 강제.
- 내용적 편향(반드시 반성적으로 사고할 것 등)은 의도적으로 배제 → 모델의 자연스러운 진화 관찰.

DeepSeek-R1-Zero의 성과 및 Self-evolution

- AIME 2024 pass@1: 15.6% → 71.0% (RL 학습만으로), majority voting 시 86.7%로 OpenAI-o1-0912 수준 달성.
- RL 학습이 진행될수록 thinking token 길이가 자연스럽게 늘어남 → 더 깊은 사고를 스스로 학습.
- 외부 지시 없이 reflection(자기 점검), 대안적 접근 탐색 등의 고급 추론 행동이 **자발적으로 창발(emergent)**.
- **"Aha Moment"**: 특정 학습 단계에서 모델이 스스로 문제를 재검토하고 접근법을 전환하는 행동이 출현 → RL이 추론 능력을 자발적으로 만들어낸다는 증거.

DeepSeek-R1-Zero의 한계

- 가독성이 낮음 (poor readability).
- 언어 혼용(language mixing): CoT가 영어와 다른 언어가 섞여 나옴.
- 이를 해결하기 위해 DeepSeek-R1 도입.

DeepSeek-R1: RL with Cold Start (4단계 파이프라인)

1단계 - Cold Start SFT

- DeepSeek-V3-Base를 수천 개의 고품질 long-CoT 예시로 fine-tuning.
- 사람 친화적인 대화체 사고 과정을 학습시켜 RL의 초기 안정성 확보.
- R1-Zero와 달리 초기에 구조화된 읽기 쉬운 reasoning을 출력할 수 있게 됨.

2단계 - Reasoning-oriented RL

- Cold Start로 fine-tuning된 모델에 R1-Zero와 동일한 대규모 RL 적용.
- 수학, 코딩, 논리, 과학 문제 중심으로 추론 능력 강화.

- 언어 혼용 문제를 완화하기 위해 **language consistency reward** 추가 (CoT 내 목표 언어 비율로 계산).

3단계 - Rejection Sampling + SFT

- RL checkpoint에서 rejection sampling으로 고품질 reasoning 데이터를 추출.
- 여기에 writing, factual QA, self-cognition 등 non-reasoning 데이터(약 20만 개)도 혼합.
- 총 약 80만 개의 데이터로 DeepSeek-V3-Base를 2 epoch 동안 재학습 → 범용 능력도 함께 확보.

4단계 - RL for All Scenarios

- 추론 + 일반 태스크 전반에 걸쳐 2차 RL 적용.
- 사람의 선호(helpfulness, harmlessness)에 맞도록 정렬 → 최종 DeepSeek-R1 완성.

Distillation: 소형 모델에 추론 능력 이식

- DeepSeek-R1이 생성한 약 80만 개의 추론 데이터로 Qwen2.5, Llama3 기반 소형 모델들을 fine-tuning.
- 소형 모델에 직접 RL을 적용하는 것보다 대형 모델에서 증류하는 것이 성능이 더 우수 → 대형 모델이 발견한 추론 패턴이 소형 모델에게 매우 중요.
- 1.5B, 7B, 8B, 14B, 32B, 70B 6종 전부 오픈소스 공개.

Experiment

모델	AIME 2024 (pass@1)	MATH-500	GPQA Diamond	Codeforces
OpenAI-o1-mini	63.6%	90.0%	60.0%	1820
OpenAI-o1-0912	74.4%	94.8%	77.3%	1843
DeepSeek-R1-Zero	71.0%	95.9%	73.3%	1444
DeepSeek-R1	79.8%	97.3%	71.5%	2029

- 추론: AIME 2024에서 OpenAI-o1-1217을 소폭 상회. MATH-500에서 97.3%로 동급 최고 수준.
- 코딩: Codeforces Elo 2029로 인간 참가자 96.3%를 능가.
- 지식: MMLU 90.8%, MMLU-Pro 84.0%, GPQA Diamond 71.5%. o1-1217보다는 소폭 낮지만 다른 closed-source 모델 상회.
- 범용: AlpacaEval 2.0 87.6%, ArenaHard 92.3% → 추론 외 일반 태스크에서도 강력한 성능.
- 증류 소형 모델: R1-Distill-Qwen-7B가 QwQ-32B-Preview를 능가. R1-Distill-Qwen-32B는 o1-mini와 유사한 수준.

Discussion

Distillation vs. RL

- 소형 모델(Qwen-32B)에 대해 대규모 RL을 직접 적용하는 것과 R1에서 증류하는 것을 비교 → 증류가 훨씬 우수.
- 소형 모델의 RL은 막대한 컴퓨팅이 필요하고도 증류 모델에 미치지 못함.
- 즉, 대형 모델이 발견한 추론 패턴을 증류로 전달하는 것이 핵심.

Unsuccessful Attempts (실패한 시도들)

- **Process Reward Model (PRM)**: 중간 추론 단계에 reward를 주는 방식. reward hacking이 발생하고, 각 단계를 자동으로 평가하기 어려워 실용적이지 않음.
- **Monte Carlo Tree Search (MCTS)**: 토큰/문장 단위 탐색 시도. 추론 문제에서 탐색 공간이 너무 방대하고, 각 단계의 value를 정확히 추정하기 어려워 효과적이지 않음.

Conclusion

- SFT 없이 순수 RL만으로도 LLM의 추론 능력이 자발적으로 창발할 수 있음을 처음으로 오픈 연구로 입증.
- Cold Start + 다단계 파이프라인으로 가독성·언어 일관성 문제를 해결하며 OpenAI-o1 수준의 성능 달성.
- 대형 모델의 추론 패턴을 소형 모델에 증류하는 것이 소형 모델에 직접 RL을 적용하는 것보다 효과적.

- DeepSeek-R1, R1-Zero, 6종의 증류 모델 전부 MIT 라이선스로 오픈소스 공개 → 연구 커뮤니티에 크게 기여.

한계 및 Future Work

한계: 언어 혼용 문제가 완전히 해결되지 않음 / 일반 대화(open-domain chat)에서 SFT 기반 모델 대비 성능이 약함 / 소프트웨어 엔지니어링 등 장시간 평가가 필요한 태스크에서는 RL 적용이 아직 제한적 / 추론 능력이 언어 전반으로 충분히 전이되지 않을 수 있음.

	DeepSeek-R1-Zero	DeepSeek-R1
기본 모델	DeepSeek-V3-Base	DeepSeek-V3-Base
SFT	X	O (Cold Start + Rejection Sampling)
RL	O (순수 RL, GRPO)	O (2단계 RL)
추론 창발	자발적 (Aha Moment)	구조화·안정화
가독성	낮음 (언어 혼용)	높음
성능 (AIME 2024)	71.0%	79.8%