

< U-Net 과제 >

비교 항목	2015 U-Net	현재 U-Net	핵심 변화
Encoder	Training from Scratch (초기화 학습)	Transfer Learning (ResNet, Swin)	데이터 부족 해결 및 수렴 속도 향상
Blocks	Simple Conv Block (단순 반복)	Residual / Dense Block	층을 깊게 쌓아도 학습이 잘 됨
Context	Local Context (국소 정보)	Global Context (Attention, ViT)	전역적 문맥 파악 및 인식 범위 확장
Feature Fusion	Simple Concatenation (단순 결합)	Attention Gate / Multi-scale	노이즈 억제 및 객체 경계 정밀화
Stability	No Batch Normalization	Batch / Layer Normalization	학습 안정성 확보 및 속도 비약적 상승
Training	Supervised (지도 학습)	Self-supervised (MAE) + Focal/Dice Loss	레이블 비용 절감 및 클래스 불균형 해결

1. Encoder

2015 년 U-Net 은 CNN 구조를 초기화 상태에서부터 학습시켜야 했기에 데이터 효율성이 낮았다. 반면 최신 U-Net 은 ResNet, Swin Transformer 등 대규모 데이터셋을 통해 검증된 모델을 인코더로 활용한다. 이를 통해 최신 U-Net 은 높은 특징 추출 성능과 빠른 속도를 가지게 되었다.

2. Block

2015 년 U-Net 은 단순한 Convolution 계층을 반복했다.

하지만 최신 U-Net 은 Residual Block 이나 Dense Block 을 도입하여 네트워크 깊이를 늘렸다. 이를 통해 기울기 소실 문제를 방지하고, 더 깊고 복잡한 패턴을 안정적으로 학습할 수 있게 되었다.

3. Context

2015 년 UNet 은 CNN 기반 구조를 활용하여 커널이 확인하는 Local Context 에만 집중하여 이미지 전체의 흐름을 놓치는 경우가 많았다.

하지만 최신 U-Net 은 Vision Transformer(ViT)나 Attention Mechanism 을 결합하여 픽셀 간의 장거리 의존성을 파악하고, Global Context 를 이해함으로써 큰 객체나 복잡한 배경에서도 타겟을 잘 인식한다.

4. Feature Fusion (Skip Connection)

2015 년 U-Net 은 특징을 Decoder 로 무조건 넘겨주던 단순 결합 방식을 사용했다.

최신 U-Net 은 Attention Gate 나 Multi-scale Fusion 방식으로 진화했습니다. 이는 Decoder 가 불필요한 배경 노이즈는 억제하고 타겟 객체의 중요한 정보만 선별적으로 받아들이게 하여, 특히 모호한 경계선(Boundary)을 정밀하게 복원하는 데 기여합니다.

5. Stability (Normalization)

초기 U-Net 과 다르게 최신 U-Net 은 Batch Normalization(BN) 또는 Layer Normalization 을 적용한다. 정규화 과정에서는 각 층의 입력 분포를 일정하게 유지해 학습의 불안정성을 제거하고, 이를 통해 학습률이 높아졌고, 학습 속도가 빨라졌다.

6. Training

2015 U-Net 은 정답 레이블에만 의존하던 지도 학습의 한계가 있었다.

최신 U-Net 은 MAE(Masked Autoencoder)와 같은 자기지도 학습을 통해 레이블 없는 데이터에서도 유의미한 특징을 학습한다.

또한, Focal Loss 나 Dice Loss 를 도입하여 배경이 객체보다 압도적으로 많은 클래스 불균형 문제를 구조적으로 해결할 수 있다,