

WEEK 11(CLIP, SAM)

26기 분석 성유민

CLIP

<개요>

NLP의 Bert, GPT2처럼 웹의 방대한 데이터를 가지고 CV를 학습시키는 거대모델을 개발하고자 함

<Problem>

기존 모델인

ConVIRT: Medical specific하다는 특징과 복잡한 구조로 인해서 스케일을 늘리는데 제한이 있었음 -> linear projection, augmentation 감소 등으로 구조를 간단하게 변화시킴

Virtex: Transformer 기반으로 완벽한 문장을 생성해내야 하기 때문에, 정답을 맞추기 어려움

<Framework>

-4억개의 양질의 image/text paired 데이터셋을 새로 구축함

-텍스트 인코더, 이미지 인코더에 각각 쌍을 벡터로 변환한뒤, 짝이 맞는 벡터쌍의 거리를 최소화하고 나머지 쌍의 거리를 최대화하는 모델링

-text를 생성하는 방식에서, 쌍들중 가장 그럴싸한 정답을 고르는 문제로 수정

<Experiment>

-prompt engineering: 웹 텍스트는 거의다 문장 형태였기 때문에 단어에 대한 추론능력이 떨어졌음. -> a photo of {label}의 프롬프트를 씌워 성능 향상

-ensembling: 임베딩 스페이스에서 80개의 프롬프트를 앙상블하여 general한 추론능력 향상

- 결과적으로 zero shot 성능이 뛰어난 모델이 생성됨.
- 오류패턴이 인간과 비슷하게 나타남
- 웹 데이터를 이용하는 만큼 사회적으로 민감한 테스트는 조정이 필요함

SAM

<개요>

Zero shot 일반화를 가능하게 하는 Image segmentation을 위한 foundation model 구축

<Problem>

CLIP, ALIGN 등에서 제로샷 학습이 가능해졌지만 segmentation에서는 아직 어려웠음

<Framework>

-점, 박스, 마스크, 텍스트 등 유연한 프롬프트를 제공하고자 함

-**image encoder**: MAE로 학습된 ViT구조 사용

-**prompt encoder**: 점/박스/텍스트 등 모든 프롬프트를 같은 벡터공간으로 변환

-**mask decoder**: 이미지 인코더, 프롬프트 인코더를 각각 넣어 valid한 mask 출력.

Self attention으로 프롬프트끼리 이해한 뒤 ,

cross attention으로 prompt, image 관계 이해

<Experiment>

Zero shot transfer experiment: 16개의 데이터셋에서 기존 SOTA인 RITM보다 대부분 높은 성능을 보임

다양한 프롬프트에 항상 유효한 mask를 출력한다는 장점이 있지만 세밀한 구조 감지는 약함, 무거운 백본은 아직 실시간 처리가 어렵다는 단점이 있음.