

WEEK 12(TabPFN, TabNet)

26기 분석 성유민

TabPFN

<개요>

ICN(In-Context-Learning)을 활용해 table dataset을 효과적으로 합성예측하는 트랜스포머 기반 모델

<Problem>

표 형식데이터의 다양성은 텍스트 및 이미지와는 다르게 dataset마다 동일한 값이 다른 의미가 되어 고유성을 찾기 어려움. 더 작고 독립적으로 분석할 필요가 있음.

또한 다양한 척도와 유형이 혼재되어있으며 이상치, missing data도 존재하여 기존에는 트리 기반 비심층 학습 모델이 주로 활용됨.

<Framework>

-ICL로 다양한 분포와 복잡한 알고리즘을 근사하여 closed form이 존재하지 않는 경우 더 넓은 범위의 알고리즘을 학습함.

데이터 생성

-다양한 합성 데이터셋을 생성하여 적합한 알고리즘 동작을 설계한 뒤, 인코딩하여 훈련

사전 학습

-추론 시점에 training, test data을 한번에 순방향 전파로 예측 수행

-입력 특징과 비마스킹 샘플을 컨텍스트로 삼아 마스킹된 목표 예측

실제 예측

-학습 샘플을 컨텍스트로 제공해 임의의 미지 데이터셋 레이블 베이지안 예측

<Experiment>

- 선형,비선형에 관계 없이 데이터 구조에 따라 함수를 유연하게 모델링
- 확률분포 전체를 예측하기 때문에 불확실성을 함께 예측함
- TabPFN을 앙상블해서 성능을 더 끌어올릴 수 있음을 암시
- 분류, 회귀에서 모두 좋은 성능을 보이고 이상치 탐지에도 탁월함

TabNET

<개요>

Raw Tabular Data를 Gradient Descent기반 최적화하여 유연한 end-to-end학습을 가능하게 함.

Sequential Processing

데이터를 한 번에 처리하는 것이 아닌 stepwise하게 처리

Instance-wise selection

모든 데이터에 동일 기준이 아닌 객체마다 피처를 다르게 선택

Soft Feature selection

역전파를 통해 학습 가능한 마스크 사용

<Problem>

정형 데이터는 feature간의 독립성, 변수 중요도의 편차 등 제한적인 특징을 가짐

<Framework>

Step by step flow: 이전단계의 정보를 바탕으로 마스크 생성,처리

Components: Feature transformer, attentive transformer, mask, split이 하나의 step

Feature masking: Sparsemax Mask에 유효한 피처만 통과시켜 학습 용량 낭비X

<Experiment>

-피처별 중요도가 비슷한 경우, 중요한 피처가 인스턴스에 의존하는 경우 모두 좋은 성능을 보임.

-하이퍼 파라미터 탐색 없이도 이에 능가하는 성능을 보이며, 불균형 데이터 처리,정렬, 순위학습에도 과적합 없이 비선형적인 처리.