

Week5, U-Net

26 기 분석 성유민

1. Padding

2015: 패딩을 주지 않아 Convolution 을 거칠 때마다 이미지 크기가 줄어들었고 receptive field 를 키우기 위해 feature map 의 공간 해상도가 점점 감소했다.

현재: Zero padding 등을 사용하여 입력 이미지와 Segmentation Map 의 해상도가 1:1 로 대응되도록 할 수 있다. 또한 overlap-tile 과 Mirroring 기법의 도입으로 경계처리를 해서 손실을 줄일 수 있다.

2. 블록 구조: Plain Conv -> Residual Connection

2015: 단순히 Convolution 레이어를 일렬로 쌓았기 때문에 층이 깊어지면 학습이 안 되거나 성능이 떨어지는 문제가 있었다.

현재: 각 블록 안에 Residual Connection (Skip Connection)을 추가하여 값을 그대로 전달해주기 때문에 기울기 소실 문제를 해결하여 네트워크를 깊게 쌓아도 좋은 성능을 유지할 수 있다.

3. 인코더: CNN 기반 -> Transformer Encoder 결합

2015 년: CNN 기반이라 Receptive Field 가 제한적이고 이미지 구석에 있는 픽셀 간의 관계를 파악하기 어렵습니다.

현재: 인코더에 Vit 를 결합하여 Self Attention 을 통해 이미지 전체의 Global Context 정보를 학습할 수 있다.

4. Multi-scale Feature Fusion

2015 년: 인코더의 같은 Level 에 있는 특징 맵만 가져와서 붙이는 Concatenation 방식으로 작동했다. 패딩을 안줬기 때문에 copy&crop 방식으로 크기를 잘라야했다.

현재: 서로 다른 깊이의 특징 맵들을 모두 가져와 섞는 Full-scale Skip Connection 방식을 이용하기 때문에 다양한 크기의 객체를 모두 잘 잡아낸다. 특히 아주 작은 객체나 경계선이 모호한 부분을 분할할 때 유용하다.

5. 학습 환경의 변화: Batch Size 1 & Normalization

2015 년: 일반적인 Batch Normalization 을 사용하려면 배치 사이즈가 커야 유의미했다.

현재: 배치 사이즈를 1 로 줄여도 학습이 안정적으로 되도록 **Instance Normalization** 이나 Group Normalization 을 주로 사용하여 안정적 학습이 가능하다.