

WEEK 8(RAG, LoRA)

26기 분석 성유민

RAG

<개요>

외부 문서 데이터베이스에서 관련 정보를 검색한 뒤 LLM과 결합하여 답변을 생성하는 언어모델

<Problem>

기존에는 메모리 확장, 수정이 어렵고 모든 지식을 파라미터화하기 어려웠음

<Framework>

-hybrid memory 구조

사전 학습 seq2seq모델(BART)의 파라미터 안에 지식을 저장하는 방식인 모수적 메모리+ 외부 데이터베이스(Wikipedia)로부터 필요한 지식을 검색하는 비모수적 메모리

Retriever(DDR):쿼리에 대해 텍스트 구절에 대한 top-k로 자른 분포를 반환함

-쿼리 문장, 문서 문장을 각각 독립적 인코더에 입력하여 임베딩 벡터 생성 후, 두 벡터 간 내적으로 유사도를 계산하는 Bi-encoder구조

-학습방식: Trivia QA, Natural Question의 답변을 포함하는 문서를 positive sample로 학습하여 검색기가 관련 문서를 상위 K개 안에 포함시키도록 훈련

Generator(BART):이전 토큰, 원본 및 검색된 구절의 컨텍스트를 기반으로 현재 토큰 생성

-BART:인코더-디코더 구조로 쿼리 x 와 검색된 문서 z 를 단순연결할 수 있음

<Experiment>

Open-domain QA, Abstractive QA, Jeopardy Question generation, Fact Verification의 4가지 항목으로 평가.

Retrieval, Generation이 모두 가능하며 단순한 구조임에도 대부분 SOTA 달성

LoRA

<개요>

모델 적응 과정에서 weight 변화가 low-rank 구조를 가지기 때문에 파라미터의 변화를 행렬로 계산하여 표현

<Problem>

-Pretrained model은 fine tuning 과정에서 모델의 모든 파라미터를 업데이트 해야 하기 때문에 비용이 큼.

-기존 해결 방식인 adapter layer를 추가하는 prefix tuning 방식은 효율과 성능 사이의 trade off문제가 있음.

<Framework>

기존의 $W=d*k$ 였다면 LoRA에서는 $B=d*r$, $A=r*k$ 의 작은 행렬로 weight update를 표현

<Experiment>

-Natural Language Understanding, Natural Language Generation에서 평가 진행

-Shared parameter 구조로 빠른 task switching이 가능함.

-rank8, rank64모델의 subspace가 많이 겹치고 있기에 **Low rank가 실제로 작동함을** 확인