

보아즈 과제

1. TabNet: Attentive Interpretable Tabular Learning

1) Abstract (문제 정의)

TabNet은 tabular 데이터에 특화된 딥러닝 모델을 제안한다. 기존에는 XGBoost, LightGBM과 같은 트리 기반 모델이 tabular 데이터에서 높은 성능을 보였지만, 딥러닝은 적합한 구조가 부족해 성능이 제한적이었다.

이 논문은 다음을 해결하고자 한다:

- 딥러닝 기반 tabular 모델의 성능 부족
- 해석 가능성 부족 문제
- feature selection의 비효율성

핵심 접근은 **attention 기반 feature selection**을 통해 중요한 feature만 선택적으로 사용하는 것이다. 또한 self-supervised pretraining을 통해 unlabeled 데이터 활용까지 가능하게 한다

2) Introduction (동기 및 문제점)

tabular 데이터는 현실 세계에서 가장 많이 사용되는 데이터 형태이지만, 딥러닝에서는 성과가 제한적이었다.

그 이유는 다음과 같다:

- feature 간 관계가 단순하지 않음
- 중요 feature 선택이 핵심인데 MLP는 이를 잘 수행하지 못함
- 트리 모델은 feature selection을 잘하지만 representation 학습이 부족함

따라서 목표는 다음과 같다:

- 트리 모델의 feature selection 능력
- 딥러닝의 representation 학습 능력

을 동시에 갖는 모델 설계

3) Method (접근 방법 및 구조)

핵심 아이디어

각 decision step마다 중요한 feature를 선택하여 처리하는 구조

전체 구조

TabNet은 여러 개의 decision step으로 구성된다:

- 각 step에서 feature 선택
 - 선택된 feature를 처리
 - 결과를 누적하여 최종 output 생성
-

Feature Selection

각 step마다 mask를 생성하여 feature를 선택:

- sparsemax 사용 → sparse한 선택
- 대부분 feature는 0, 일부만 활성화

이때 특징은:

- instance마다 다른 feature 선택 가능 (instance-wise selection)
-

Sequential Attention

이전 step에서 사용된 feature는 이후 step에서 덜 사용되도록 조정:

- prior scale을 통해 feature reuse 조절
-

Feature Transformer

선택된 feature를 처리하는 모듈:

- FC + BN + GLU 구조
 - 일부 layer는 shared, 일부는 step-specific
-

Output Aggregation

각 step의 결과를 누적:

- 모든 step의 정보를 합쳐 최종 prediction 생성
-

Interpretability

feature selection mask 자체가 설명 가능성 제공:

- local interpretability: 개별 샘플 기준 중요 feature
 - global interpretability: 전체 feature 중요도
-

Self-Supervised Learning

일부 feature를 masking하고 나머지로 복원:

- representation 학습 가능
 - labeled 데이터 부족한 상황에서 성능 개선
-

4) Experiments (결과)

- synthetic 데이터에서 instance-wise feature selection 성능 우수
- real-world 데이터에서 트리 모델 대비 경쟁력 있는 성능

예:

- Forest Cover Type dataset에서 기존 모델보다 높은 정확도 기록
-

5) 핵심 정리

- feature selection을 모델 내부에서 수행
 - sparse attention으로 중요한 feature만 사용
 - interpretability 확보
 - tabular 데이터에서 딥러닝 가능성 확장
-

2. TabFPN: Tabular Data Modeling with Feature Pyramid Networks

1) Abstract (문제 정의)

TabFPN은 tabular 데이터를 더 효과적으로 표현하기 위해 **multi-scale** 구조를 도입한 모델이다.

기존 문제:

- tabular feature는 서로 다른 중요도와 scale을 가짐
- 기존 모델은 이를 단일 레벨에서 처리

해결 방법:

- Feature Pyramid Network(FPN) 구조를 tabular 데이터에 적용
 - 다양한 레벨의 feature representation을 동시에 학습
-

2) Introduction (동기 및 문제점)

기존 tabular 모델의 한계:

- feature interaction이 충분히 반영되지 않음
- 다양한 scale의 feature를 동일하게 처리
- MLP 구조는 표현력이 제한적

이미지 분야에서는 FPN을 통해 multi-scale 정보를 잘 활용하고 있기 때문에, 이를 tabular에도 적용하려는 접근이다.

3) Method (접근 방법 및 구조)

핵심 아이디어

feature를 단일 벡터가 아니라 계층적 구조로 확장하여 학습

전체 구조

세 단계로 구성:

1. Feature embedding
 2. Multi-scale feature 생성
 3. Pyramid 구조로 결합
-

Feature Embedding

- categorical → embedding
 - numerical → projection 또는 그대로 사용
-

Multi-scale Representation

feature를 여러 레벨로 변환:

- low-level: 원래 feature
 - mid-level: 일부 조합된 feature
 - high-level: 복잡한 interaction
-

Feature Pyramid 구조

FPN 구조 적용:

- top-down pathway
- lateral connection

즉,

- high-level 정보를 lower-level로 전달
 - 모든 레벨 정보를 통합
-

Feature Interaction

multi-level representation을 통해

- 단순한 feature 조합이 아니라
 - 다양한 수준의 interaction 학습 가능
-

4) Experiments (결과)

- 기존 MLP 대비 성능 향상
- 일부 데이터셋에서 tree-based 모델과 경쟁 가능

핵심은:

- multi-scale 구조가 실제로 성능 개선에 기여
-

5) 핵심 정리

- tabular 데이터를 계층적으로 표현
 - multi-scale feature interaction 학습
 - FPN 구조를 tabular에 적용
-

