

Segment Anything

1) 연구 배경과 문제의식

기존 이미지 분할(segmentation) 모델은 보통 특정 데이터셋, 특정 태스크에 맞춰 학습된다. 그래서 새로운 도메인이나 새로운 분할 과제로 일반화하기 어렵다. 이 논문은 NLP의 foundation model처럼, 프롬프트만 바꿔 여러 분할 문제에 대응할 수 있는 범용 분할 모델을 만들겠다는 목표를 잡는다. 이를 위해 논문은 태스크, 모델, 데이터를 한꺼번에 설계한다.

2) 핵심 아이디어

이 논문의 핵심은 "promptable segmentation"이다.

즉, 모델에게 "무엇을 분할할지"를 프롬프트로 주면, 그에 맞는 유효한 마스크를 출력하게 만드는 것이다. 프롬프트는 점(point), 박스(box), 마스크(mask), 텍스트(text) 등 다양한 형태가 될 수 있다. 중요한 점은 프롬프트가 모호해도, 모델은 적어도 그에 해당하는 타당한 객체 하나의 마스크를 내야 한다는 것이다. 이 설정 덕분에 하나의 모델을 여러 다운스트림 분할 작업에 재사용할 수 있다.

3) 모델 구조

SAM은 크게 세 부분으로 구성된다.

Image Encoder: 고해상도 이미지를 임베딩으로 변환한다. MAE로 사전학습된 ViT를 사용한다.

Prompt Encoder: 점, 박스, 텍스트, 마스크 같은 프롬프트를 임베딩한다.

Mask Decoder: 이미지 임베딩과 프롬프트 임베딩을 결합해 최종 마스크를 예측한다.

이 구조의 장점은 이미지 인코더를 한 번만 돌리고, 이후엔 같은 이미지 임베딩에 여러 프롬프트를 빠르게 질의할 수 있다는 점이다. 논문은 브라우저 환경의 CPU에서도 프롬프트 인코더와 마스크 디코더가 약 50ms 수준으로 동작한다고 설명한다. 즉, 실시간 인터랙션을 염두에 둔 구조다.

또 하나 중요한 점은 모호성 처리다. 점 하나가 “사람 전체”를 뜻하는지 “옷”을 뜻하는지 애매할 수 있는데, SAM은 한 프롬프트에 대해 여러 개의 마스크 후보를 내고 confidence score까지 예측한다. 논문은 보통 whole / part / subpart 수준의 중첩 구조를 다루기 위해 3개 출력 마스크가 충분하다고 본다.

4) 데이터 수집 방식과 SA-1B

이 논문의 진짜 강점은 모델만이 아니라 데이터 엔진(data engine)까지 설계했다는 점이다. 분할 마스크는 웹에서 자연스럽게 대량 수집되지 않기 때문에, SAM을 이용해 다시 SAM 학습용 데이터를 모으는 구조를 만들었다. 단계는 세 가지다.

Assisted-manual: 사람이 클릭하며 마스크를 만들고 SAM이 보조

Semi-automatic: 일부 객체는 자동 생성, 나머지는 사람이 보완

Fully automatic: 정규 격자 점들을 프롬프트로 넣어 자동으로 대량 마스크 생성

최종적으로 구축된 SA-1B는 1.1B masks, 11M images 규모다. 논문은 이것이 기존 주요 segmentation 데이터셋보다 압도적으로 크며, 평균적으로 이미지당 약 100개 수준의 마스크를 가진다고 설명한다. 또한 자동 생성된 마스크의 품질도 높아, 표본 검증에서 다수의 마스크가 사람 보정 결과와 높은 IoU를 보였다고 주장한다.

5) 실험과 결과

논문은 SAM을 23개 segmentation datasets에 대해 평가했다. 핵심 실험은 “한 개의 foreground point만으로 유효한 마스크를 생성할 수 있는가”와, 프롬프트 엔지니어링을 통해 전혀 다른 다운스트림 작업으로 전이할 수 있는가이다.

특히 다음 같은 작업을 zero-shot으로 다룬다.

edge detection

object proposal generation

instance segmentation

text-to-mask의 초기 형태

즉, SAM은 “분할 모델 하나”라기보다 다양한 시각 과제의 공통 분할 인터페이스로 제시된다.

6) 의의

이 논문의 기여는 세 가지로 정리된다.

첫째, 분할을 foundation model 관점으로 재정의했다.

둘째, 범용 프롬프트 입력이 가능한 SAM 아키텍처를 만들었다.

셋째, 이를 뒷받침할 초대형 segmentation dataset SA-1B를 구축했다.

7) 한계

논문도 완전한 범용성을 주장하진 않는다. “many tasks”에는 강하지만 모든 segmentation 문제를 완전히 해결하는 건 아니다. 또한 자동 생성 데이터의 편향, 특정 도메인에서의 한계, 시스템에 포함되었을 때 생길 수 있는 bias 가능성도 남아 있다. RAI 분석에서는 전반적으로 사람 그룹 간 성능 차이가 크지 않다고 보고하지만, 일부 세부 항목에서는 추가 검토 여지를 인정한다.

CLIP

1) 연구 배경과 문제의식

기존 컴퓨터 비전 모델은 보통 ImageNet 같은 라벨 데이터셋 위에서 고정된 클래스 집합을 예측하도록 학습된다. 문제는 이런 방식이 새로운 개념에 약하다는 점이다. 새로운 태스크가 생기면 보통 다시 라벨링하고 다시 학습해야 한다.

2) 핵심 아이디어

CLIP의 핵심은 단순하다.

이미지와 그에 대응하는 텍스트를 같은 임베딩 공간에 매핑하고, 맞는 이미지-텍스트 쌍은 가깝게, 틀린 쌍은 멀게 학습한다. 즉, 정답 클래스 ID를 맞추는 대신 이미지와 문장의 대응 관계 자체를 학습한다.

이 방식의 장점은 테스트 시 별도 classifier head를 새로 학습하지 않아도 된다는 점이다. 클래스 이름이나 설명 문장을 텍스트 인코더에 넣어 임베딩한 뒤, 입력 이미지와 가장 가까운 텍스트를 고르면 된다. 그래서 zero-shot classification이 가능해진다. 예를 들어 클래스가 dog, cat, car라면 "a photo of a dog", "a photo of a cat" 같은 문장을 만들어 비교하면 된다.

3) 데이터와 학습 방식

논문은 인터넷에서 수집한 4억 개의 image-text pair를 사용한다. 기존 공개 데이터셋으로는 자연어 supervision의 잠재력을 충분히 보기 어렵다고 판단해서, 별도로 대규모 데이터셋 WIT(WebImageText)를 구축했다. 텍스트 쿼리 50만 개를 활용해 다양한 시각 개념을 폭넓게 포괄하려고 했다.

학습 목표는 batch 안의 N개 이미지와 N개 텍스트에 대해, 실제 짝인 쌍을 맞추는 것이다. 즉 $N \times N$ 가능한 조합 중 정답 pair를 맞추는 contrastive learning이다. 논문은 이전의 caption generation 방식보다 이 방식이 훨씬 효율적이라고 보고한다. 텍스트를 정확히 생성하는 방식은 너무 어렵고 비효율적인데, "어떤 텍스트가 어떤 이미지와 맞는가"만 맞

히는 contrastive objective가 더 낫다는 것이다. 실제로 zero-shot ImageNet 성능 관점에서 bag-of-words prediction보다 더 효율적이었고, transformer LM 기반 caption prediction보다도 학습 효율이 높았다고 제시한다.

4) 모델 구조

CLIP은 구조 자체는 복잡하지 않다.

Image Encoder: ResNet 계열 또는 Vision Transformer

Text Encoder: Transformer

두 인코더 출력은 각각 선형 투영 후 정규화되어 공통 임베딩 공간으로 들어간다.

학습은 이미지-텍스트 cosine similarity를 기반으로 한 대칭적 cross-entropy loss로 진행한다.

중요한 건 구조의 화려함보다 학습 프레임 자체다. 즉, 텍스트를 classifier weight 생성기로 사용해 동적으로 분류기를 만든다는 점이 본질이다.

5) 실험과 결과

CLIP은 30개가 넘는 비전 데이터셋에서 zero-shot transfer를 평가했다. OCR, action recognition, geo-localization, fine-grained classification 등 폭넓은 태스크를 포함한다.

대표적으로 논문은 zero-shot ImageNet에서 76.2% top-1 accuracy를 보고하며, 이는 원래 ResNet-50이 ImageNet 128만 장 라벨 데이터로 학습한 정확도에 맞먹는 수준이라고 주장한다. 즉, ImageNet의 라벨을 전혀 사용하지 않고도 강한 분류 성능을 달성했다는 점이 핵심이다.

또한 CLIP은 단순 zero-shot 성능만이 아니라, 기존 ImageNet 중심 supervised 모델보다 distribution shift에 더 robust한 경향을 보였다고 분석한다. 논문은 zero-shot CLIP이 자연 분포 이동 상황에서 기존 모델들보다 높은 effective robustness를 보였다고 설명한다.

6) Prompt engineering의 중요성

CLIP은 그냥 클래스 이름만 넣는 것보다,

예를 들어 "a photo of a {label}." 같은 템플릿을 쓰는 것이 더 낫다고 보고한다. 더 나아가 데이터셋 특성에 맞게 템플릿을 바꾸고, 여러 템플릿을 ensemble하면 성능이 더 오른다. 논문은 이런 prompt engineering + ensembling이 ImageNet 정확도를 눈에 띄게 끌어올린다고 설명한다. 즉, CLIP은 모델 하나로 끝나는 게 아니라 텍스트 프롬프트 설계 자체가 성능 요소가 된다.

7) 의의

CLIP의 진짜 의미는 "이미지 분류를 자연어 인터페이스로 바꿨다"는 데 있다.

기존 분류 모델은 고정된 class head를 학습하지만, CLIP은 텍스트 설명으로 새로운 클래스를 즉석에서 정의할 수 있다. 이게 이후 vision-language 모델, 멀티모달 foundation model, text-guided vision 시스템 전반에 큰 영향을 줬다. 실제로 SAM 논문도 서론에서 CLIP 같은 vision-language foundation model 계열을 중요한 전례로 언급한다.

8) 한계

CLIP은 강력하지만 한계도 분명하다.

few-shot 학습을 직접 최적화한 모델은 아니다.

복잡하거나 추상적인 시각 과제에서는 약하다.

인터넷 이미지-텍스트 데이터를 쓰기 때문에 사회적 편향을 학습할 수 있다.

진짜 zero-shot이라기보다, 개발 과정에서 평가셋에 반복적으로 노출된 한계도 논문에서 스스로 인정한다.

즉, CLIP은 범용성의 방향은 제시했지만, 모든 시각 문제를 완전히 해결한 모델은 아니다.