

TabNet: Attentive Interpretable Tabular Learning

1) 연구 배경

이 논문은 표형 데이터(tabular data)에서는 여전히 XGBoost, LightGBM 같은 트리 기반 모델이 강세인 이유를 짚고, 기존 DNN 구조가 표형 데이터의 특성에 잘 맞지 않는다는 문제의식에서 출발한다. 저자들은 표형 데이터용으로 해석 가능성과 성능을 동시에 노리는 새로운 딥러닝 구조로 TabNet을 제안한다. TabNet은 raw tabular data를 거의 전처리 없이 다루고, 각 결정 단계마다 중요한 feature만 선택해서 처리하도록 설계되었다.

2) 핵심 아이디어

TabNet의 핵심은 sequential attention 기반의 instance-wise feature selection이다. 즉, 모든 feature를 한 번에 똑같이 처리하는 대신, 각 decision step에서 현재 샘플에 중요한 feature만 골라서 본다. 이 선택은 샘플마다 달라질 수 있고, 그래서 global feature selection보다 더 유연하다. 저자들은 이런 구조가 학습 용량을 중요한 변수에 집중하게 만들어 성능과 해석 가능성을 함께 높인다고 주장한다. 또한 이 구조는 단일 모델 안에서 feature selection과 prediction을 동시에 수행한다는 점이 특징이다.

3) 모델 구조

TabNet은 여러 개의 decision step으로 구성된다. 각 step에서는 먼저 attentive transformer가 sparse mask를 만들어 어떤 feature를 볼지 정하고, 이후 feature transformer가 선택된 feature를 비선형적으로 가공한다. 이 과정이 반복되며 step별 출력이 누적되어 최종 예측을 만든다. 마스크 생성에는 sparsemax가 사용되어 희소한 선택을 유도하고, feature transformer는 shared layer와 step-dependent layer를 함께 가져가도록 설계되었다. 또 GLU, batch normalization, residual-style normalization을 써서 안정성과 표현력을 높였다. 논문 그림 기준으로 encoder는 "feature transformer + attentive transformer + mask" 구조이며, decoder는 self-supervised pretraining용 복원 모듈로 따로 제시된다.

4) 해석 가능성

TabNet의 큰 장점 중 하나는 해석 가능성이다. 각 decision step에서 어떤 feature가 선택됐는지 마스크 자체를 통해 볼 수 있고, 여러 step의 마스크를 합쳐 aggregate feature importance도 계산할 수 있다. 즉, 로컬 수준에서는 특정 샘플 예측에 어떤 feature가 작용했는지 볼 수 있고, 글로벌 수준에서는 모델 전체가 어떤 feature에 의존하는지 파악할 수 있다. 이 점은 일반적인 MLP보다 훨씬 직접적이다.

5) 자기지도 사전학습

이 논문은 표형 데이터에서도 masked feature prediction 기반 self-supervised learning이 효과적일 수 있음을 보인다. 일부 feature column을 가리고 나머지 feature로 이를 복원하도록 encoder-decoder를 학습한 뒤, supervised task에 fine-tuning하는 방식이다. 논문은 실제 표형 데이터의 컬럼들이 서로 의존성을 갖기 때문에 이런 사전학습이 표현 학습에 도움이 된다고 설명한다.

6) 실험 결과

논문은 synthetic dataset과 real-world dataset 모두에서 TabNet을 평가했다. Synthetic task에서는 instance-wise salient feature가 중요한 상황에서 기존 방법보다 우수하거나 비슷한 성능을 보였고, compact parameterization도 장점으로 제시했다. Real-world 결과에서도 강한 성능을 보였는데, 예를 들어 Forest Cover Type에서는 TabNet이 96.99% 정확도로 XGBoost, LightGBM, AutoML Tables보다 높았고, Poker Hand에서는 99.2% 정확도로 다른 ML/DL 기반 방법들을 크게 앞섰다. Sarcos 회귀에서도 중대형 모델에서 매우 낮은 MSE를 기록했다.

7) 논문의 의의

이 논문의 의의는 세 가지다. 첫째, 표형 데이터에 특화된 딥러닝 구조를 제안했다는 점이다. 둘째, 성능뿐 아니라 선택 마스크 기반의 해석 가능성을 구조 자체에 포함시켰다는 점이다. 셋째, 표형 데이터에서도 self-supervised pretraining이 의미 있다는 방향을 제시했다는 점이다. 즉, TabNet은 “표형 데이터에서는 트리만 강하다”는 흐름에 대해 딥러닝도 설계만 잘하면 경쟁력이 있다는 사례를 보여준 논문이라고 볼 수 있다.

8) 한계 및 비판적으로 볼 점

다만 TabNet은 feature selection과 step-wise reasoning이라는 명확한 구조적 장점이 있지만, 이후 연구 흐름 전체를 보면 모든 tabular benchmark에서 항상 트리 계열을 압도하는 표준 해법이 되지는 못했다. 즉, 이 논문은 매우 중요한 구조적 제안이지만, 이후 분야 전체는 “표형 데이터에는 여전히 트리 계열이 강한 경우가 많다”는 방향도 함께 보여주었다. 그래서 TabNet은 해석 가능한 딥 tabular model의 대표작으로 보는 게 가장 정확하다. 이 부분은 논문 자체의 기여를 깎는 게 아니라, 후속 연구들과 함께 위치를 잡아야 한다는 뜻이다.

Accurate predictions on small data with a tabular foundation model

1) 연구 배경

이 논문은 표형 데이터에서 딥러닝이 오랫동안 트리 기반 모델보다 약세였던 문제를 다시 정면으로 다룬다. 특히 현실의 많은 표형 데이터셋이 크지 않다는 점에 주목하며, 작은 데이터 환경에서 강력하게 동작하는 tabular foundation model을 만들고자 한다. 저자들은 기존 gradient-boosted decision tree가 20년 가까이 지배적이었지만, 표형 데이터의 다양성과 dataset 간 이질성 때문에 일반적인 딥러닝이 잘 작동하지 않았다고 본다. 이 문제에 대한 해법으로 TabPFN을 제시한다.

2) 핵심 아이디어

TabPFN의 핵심은 in-context learning(ICL)을 표형 데이터 학습에 본격적으로 적용한 것이다. 일반적인 지도학습처럼 특정 데이터셋 하나에 대해 파라미터를 업데이트하는 방식이 아니라, 모델을 수많은 synthetic tabular datasets 위에서 미리 학습시킨 뒤, 실제 추론 시에는 학습 데이터와 테스트 데이터를 한 번에 입력으로 넣어 한 번의 forward pass로 예측을 수행한다. 쉽게 말해, "학습 알고리즘 자체를 미리 학습한 모델"이라고 볼 수 있다.

3) 모델의 이론적 관점

논문은 TabPFN을 단순한 트릭으로 설명하지 않고, Prior-Data Fitted Network(PFN)라는 틀 안에서 설명한다. 이는 synthetic prior로부터 생성된 데이터 분포에 대해 posterior predictive를 근사하는 방식으로 이해된다. 즉, TabPFN은 "많은 인공 데이터셋에서 어떤 예측 규칙이 유효한지"를 학습하고, 실제 데이터가 들어오면 그에 맞는 Bayesian-style prediction을 빠르게 근사하는 구조다.

4) 아키텍처

TabPFN은 표형 데이터를 위해 transformer를 그대로 쓰지 않고, 2차원 표 구조에 맞게 바꾼 구조를 사용한다. 각 셀에 별도 representation을 두고, 한 번은 같은 행의 다른 feature들에 attention하고, 다음에는 같은 열의 다른 sample들에 attention하는 two-way attention을 사용한다. 이 구조 덕분에 sample 순서와 feature 순서에 대해 invariant하고, 더 큰 테이블에도 효율적으로 일반화할 수 있다. 또한 train-state caching을 통해 fit-predict 반복 계산을 줄여 추론 속도를 크게 높였다. 논문은 10,000개 학습 샘플과 10개 feature 기준으로 CPU에서 약 300배, feature가 더 많을 때는 더 큰 speedup이 가능하다고 보고한다.

5) synthetic prior 설계

TabPFN의 성능은 synthetic data generation 품질에 크게 의존한다. 논문은 structural causal model(SCM)을 이용해 다양한 tabular dataset을 생성한다. 데이터셋 크기, feature 수, graph complexity 같은 상위 하이퍼파라미터를 먼저 샘플링하고, 이후 neural network, tree, discretization, noise, warping 등을 포함한 causal graph를 통해 feature와 target을 만든다. missing values, categorical features, nonlinear distortion, quantization 같은 현실적 요소도 synthetic prior에 포함해, 실제 표형 데이터에서 만날 문제를 미리 학습하도록 설계했다. 논문은 모델 학습당 약 1억 개의 synthetic dataset을 생성했다고 설명한다.

6) 정성적 결과

논문은 toy regression과 double-slit density prediction 같은 예시를 통해 TabPFN의 특성을 보여준다. TabPFN은 단순 선형 함수뿐 아니라 비매끄러운 step function이나 잡음이 있는 함수도 다룰 수 있었고, 특히 기존 회귀 모델과 달리 출력 분포 자체를 예측할 수 있다는 점을 강조한다. double-slit 예시에서는 multi-modal distribution까지 한 번의 forward pass로 예측했으며, CatBoost 기반 quantile reconstruction보다 더 나은 질적 결과를 보였다고 보고한다.

7) 정량적 결과

정량 평가에서는 AutoML Benchmark와 OpenML-CTR23을 포함한 분류 29개, 회귀 28개 데이터셋을 사용했고, 조건은 최대 10,000 samples, 500 features, 10 classes였다. 여기서 TabPFN은 random forest, XGBoost, CatBoost, LightGBM, 선형모델, SVM, MLP와 비교되었다. 논문에 따르면 분류에서는 default TabPFN이 평균 2.8초 만에 4시간 튜닝한 강한 baseline ensemble보다도 앞섰고, 회귀에서도 4.8초 수준에서 매우 강한 성능을 보였다. 특히 CatBoost 대비 normalized ROC AUC와 normalized RMSE에서 일관된 우위를 보였으며, 4시간 튜닝 대비 분류에서 5,140배, 회귀에서 3,000배 speedup을 주장한다.

8) 강건성 및 확장

논문은 TabPFN이 uninformative features, outliers, missing values, categorical features 등 다양한 데이터 특성에 대해 비교적 강건하다고 보고한다. 또 AutoGluon 같은 tuned ensemble 과도 비교했는데, TabPFN(PHE) 라는 post hoc ensembling 버전까지 포함하면 성능이 더 올라간다고 설명한다. 다만 논문도 명확히 말하듯, 이런 결과가 TabPFN이 10,000 samples와 500 features를 크게 넘는 환경에서도 그대로 잘 스케일한다는 뜻은 아니다. 오히려 저자들은 사용 범위를 꽤 분명하게 한정한다.

9) foundation model 능력

이 논문이 특히 중요한 이유는 TabPFN을 단순 분류기/회귀기로만 제시하지 않았다는 점이다. 논문은 density estimation, synthetic data generation, reusable embedding, fine-tuning, SHAP 기반 해석까지 보여준다. 즉, TabPFN은 단순히 “작은 표형 데이터에서 잘 맞는 모델”이 아니라, 표형 데이터용 foundation model로서 여러 다운스트림 가능성을 보여준 것이다. 예를 들어 German Credit Dataset에서는 density estimation과 data generation을 시연했고, mfeat-factors에서는 embedding의 분리 성질을 보였으며, 관련된 sine-curve task에서는 fine-tuning의 가능성도 보여주었다.

10) 논문의 의의

이 논문의 가장 큰 의의는 small tabular data에서 “학습 알고리즘 자체를 사전학습한 foundation model”이 전통적 ML을 능가할 수 있다는 점을 강하게 입증한 데 있다. 이전 tabular DL 연구들은 대개 특정 데이터셋에서 학습하는 일반 모델을 더 잘 만들려는 방향이었다면, TabPFN은 아예 문제 설정을 바꿨다. 즉, “tabular data를 위한 거대한 사전학습 알고리즘”이라는 발상 자체가 핵심 기여다.

11) 한계

논문 스스로도 사용 범위를 분명히 한다. TabPFN은 up to 10,000 samples, 500 features 정도의 small-to-medium tabular data에서 특히 강하며, 더 큰 데이터셋이나 highly non-smooth regression에서는 CatBoost, XGBoost, AutoGluon 같은 방법이 더 나을 수 있다고 적고 있다. 즉, 모든 tabular setting의 만능 해법이라기보다는, 특정 크기 범위의 small data에서 매우 강한 foundation model로 이해하는 게 맞다.