

Transformer, BERT

Transformer

초기 모델의 한계

Attention의 등장

Transformer

BERT

Input Sequence & Embedding

Pre-training


Transformer

초기 모델의 한계

- 자연어 처리의 핵심 : 언어와 단어의 순서를 파악하는 것
 - N-gram : 단어의 순서와 빈도에만 기반해 예측하여 희소 문제 발생
 - NNLM : 의미가 비슷한 단어를 임베딩할 수 있으나 가변 길이 문장에는 대응하기 어려움
 - RNN & LSTM/GRU : 장기 의존성 문제, 정보 전달의 한계
 - Seq2Seq : 인코더가 모든 정보를 context vector에 압축해 병목 현상 발생


Attention의 등장

- 매 시점마다 과거 token을 돌아보며 새로운 context vector를 생성하고, Softmax 함수를 통해 Attention Distribution을 진행함




- Attention Distribution → 어떤 token에 더 집중할지 결정함

Transformer




- 층을 여러개 쌓아서 지속적으로 업데이트하는 과정을 거침




- Positional Encoding

- RNN과 달리 모든 token을 순차정보 없이 병렬로 입력받기에 단어의 위치 정보를 알려주는 별도의 encoding 과정을 추가




- Encoder

- Self-Attention : 현재 층에서 단어 간 점수를 즉시 계산함 이때 값이 너무 커져 학습이 불안정해지는 것을 막기 위해 루트로 나누어 안정성을 확보함
- Multi-Head Attention : 서로 다른 가중치 행렬을 활용해 언어를 여러 관점에서 병렬로 분석하며 풍부하게 문맥을 파악함




- Decoder
 - Masking : 미래의 단어를 미리 보고 예측하는 치팅을 방지하기 위해 과거 token만 참고하도록 가중치를 0으로 만듦
 - Position-wise FFN : 각 위치 벡터에 동일한 비선형 함수를 적용해 표현력을 높임
 - Attention norm : 층이 깊어질수록 기울기 소실 문제를 막고 residual을 통해 학습 안정화 유도, layer normalization으로 값의 분포를 안정화

BERT



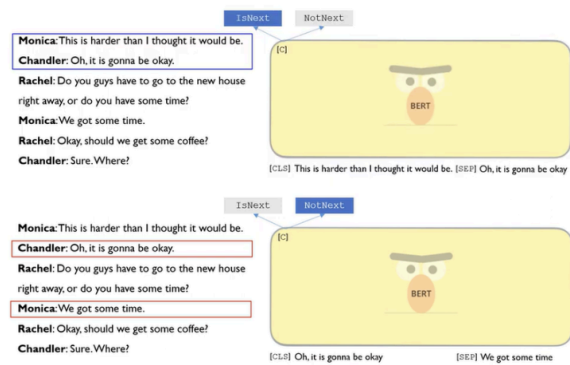

- 기존 모델들이 단방향으로만 문맥을 파악하는 문제를 해결하기 위해 Transformer의 인코더 구조만을 사용해 양방향 문맥을 이해하도록 설계된 모델

Input Sequence & Embedding



- BERT가 처리할 수 있는 형태로 변환
- Wordpiece Tokenization
 - 단어를 더 작은 단위로 쪼개 효율적으로 관리
- Special Token 추가
 - 문장의 시작, 경계 등을 표현하는 특수 토큰([CLS] 등)을 추가
- token/segment/position embedding
 - 토큰 사전/몇번째 sequence인지/토큰 위치 정보를 모두 결합

Pre-training



- MLM(문장 이해)
 - 일부 token을 가리고 좌우 양방향 문맥을 통해 원래 단어를 예측하며 이해력을 쌓음
- NSP(문장 연속)
 - 두 문장이 이어지는 관계인지 예측하며 문장 간의 흐름을 학습함